

# Desafiando la Eficiencia del Mercado:

## Aprendizaje Automático para Predicción Direccional y Generación de Alfa en el S&P 500

David González Canón

Maestría en Inteligencia de Negocios para Finanzas

Diciembre 2025

---

### Resumen

Este estudio investiga empíricamente la Hipótesis de Eficiencia de Mercado mediante un enfoque estructurado en dos hitos fundamentales. El **primer hito** consiste en entrenar 23 modelos de aprendizaje automático y profundo (incluyendo Ridge, XGBoost, LightGBM, [LSTM](#), TCN, y Transformers) para generar predicciones sobre los retornos del S&P 500. El objetivo no es predecir con exactitud el valor del retorno de mañana, sino obtener suficiente precisión direccional para tomar decisiones de inversión. El **segundo hito** traduce estas predicciones en una estrategia de trading LONG-ONLY que aprovecha el apalancamiento disponible en ETFs para generar alfa positivo después de costos de transacción.

El proceso de ingeniería de características transforma 92 variables macroeconómicas, financieras y de sentimiento de Bloomberg Terminal en 647 predictores. Esta transformación incluye técnicas diversas como indicadores técnicos clásicos y estimadores de volatilidad basados en precios OHLC (Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang).

Cuatro de veintitrés modelos superan al benchmark pasivo, demostrando que la dificultad de superar al mercado es real pero no insuperable. Los hallazgos presentan evidencia empírica de que técnicas de aprendizaje automático pueden capturar patrones direccionales explotables en retornos de mercado, contribuyendo al debate sobre la validez de la Hipótesis de Eficiencia de Mercado.

---

**Palabras clave:** Hipótesis de Eficiencia de Mercado, Aprendizaje Automático, Aprendizaje Profundo, Pronóstico de Series Temporales, Análisis Técnico, Generación de Alfa, S&P 500, Finanzas Cuantitativas, ETFs Apalancados, Gestión de Riesgo

**Clasificación JEL:** G14, G17, C45, C53

## Índice

|                                                                                    |           |
|------------------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                             | <b>9</b>  |
| 1.1. Contexto y Motivación . . . . .                                               | 9         |
| 1.2. La Relevancia del Debate sobre Eficiencia de Mercado . . . . .                | 9         |
| 1.3. Contribuciones al Conocimiento . . . . .                                      | 10        |
| 1.4. Estructura del Documento . . . . .                                            | 12        |
| <b>2. Revisión de Literatura y Fundamentos Teóricos</b>                            | <b>12</b> |
| 2.1. La Hipótesis de Eficiencia de Mercado: Origen y Evolución . . . . .           | 12        |
| 2.1.1. Fundamentos Conceptuales . . . . .                                          | 12        |
| 2.1.2. El Problema del “Joint Hypothesis” . . . . .                                | 13        |
| 2.1.3. La Paradoja de Grossman-Stiglitz . . . . .                                  | 13        |
| 2.2. Anomalías de Mercado y Evidencia Contra la HEM . . . . .                      | 14        |
| 2.2.1. El Catálogo de Anomalías . . . . .                                          | 14        |
| 2.2.2. Interpretaciones Alternativas de las Anomalías . . . . .                    | 16        |
| 2.3. Aprendizaje Automático en Valoración de Activos . . . . .                     | 18        |
| 2.3.1. Fundamentos del Machine Learning en Finanzas . . . . .                      | 18        |
| 2.3.2. Deep Learning para Series Temporales Financieras . . . . .                  | 19        |
| 2.3.3. El Debate sobre Complejidad de Modelos . . . . .                            | 20        |
| 2.4. Estimadores de Volatilidad OHLC: Extrayendo Información Oculta en los Precios | 20        |
| 2.4.1. El Problema Fundamental . . . . .                                           | 20        |
| 2.4.2. Parkinson (1980): El Poder del Rango . . . . .                              | 21        |
| 2.4.3. Garman-Klass (1980): Incorporando Apertura y Cierre . . . . .               | 21        |
| 2.4.4. Rogers-Satchell (1991): Robustez ante Tendencias . . . . .                  | 22        |
| 2.4.5. Yang-Zhang (2000): El Estimador Completo . . . . .                          | 23        |

|                                                                               |           |
|-------------------------------------------------------------------------------|-----------|
| 2.4.6. Aplicaciones en la Literatura Financiera . . . . .                     | 23        |
| <b>3. Datos y Metodología</b>                                                 | <b>24</b> |
| 3.1. Fuentes de Datos y Construcción de la Muestra . . . . .                  | 24        |
| 3.1.1. Descripción General del Conjunto de Datos . . . . .                    | 24        |
| 3.1.2. Variables de Mercado (M1-M18) . . . . .                                | 24        |
| 3.1.3. Variables Macroeconómicas (E1-E10) . . . . .                           | 24        |
| 3.1.4. Variables de Tasas de Interés (I1-I20) . . . . .                       | 25        |
| 3.1.5. Variables de Commodities (P1-P13) . . . . .                            | 25        |
| 3.1.6. Variables de Volatilidad (V1-V13) . . . . .                            | 26        |
| 3.1.7. Variables de Sentimiento (S1-S11) . . . . .                            | 26        |
| 3.1.8. Variables de Calendario (D1-D7) . . . . .                              | 26        |
| 3.2. Ingeniería de Características . . . . .                                  | 27        |
| 3.2.1. Filosofía General . . . . .                                            | 27        |
| 3.2.2. Cálculo de Retornos Multi-Horizonte . . . . .                          | 27        |
| 3.2.3. Indicadores Técnicos . . . . .                                         | 27        |
| 3.2.4. Características del Sistema Triple Screen . . . . .                    | 28        |
| 3.2.5. Características de Superficie de Volatilidad . . . . .                 | 28        |
| 3.2.6. Estimadores de Volatilidad OHLC . . . . .                              | 29        |
| 3.2.7. Correlaciones Cross-Asset . . . . .                                    | 29        |
| 3.2.8. Rezagos y Estadísticas Móviles . . . . .                               | 29        |
| 3.3. Variable Objetivo y División de Muestra . . . . .                        | 29        |
| 3.3.1. Definición del Objetivo de Predicción . . . . .                        | 29        |
| 3.3.2. División Temporal de la Muestra . . . . .                              | 30        |
| 3.4. Especificaciones de Modelos . . . . .                                    | 30        |
| 3.4.1. Panorama de Modelos Evaluados . . . . .                                | 30        |
| 3.4.2. Modelos de Aprendizaje Automático Tradicional . . . . .                | 30        |
| 3.4.3. Modelos Clásicos de Series Temporales . . . . .                        | 31        |
| 3.4.4. Modelos de Aprendizaje Automático para Series Temporales (Darts) . . . | 31        |
| 3.4.5. Modelos de Aprendizaje Profundo . . . . .                              | 32        |
| 3.4.6. Configuración de Entrenamiento . . . . .                               | 32        |
| 3.5. Dimensionamiento de Posiciones y Retornos de Estrategia . . . . .        | 32        |
| 3.5.1. Estrategia LONG-ONLY de Posiciones Discretas . . . . .                 | 32        |
| 3.5.2. Sistema de Umbrales por Percentiles . . . . .                          | 33        |
| 3.5.3. Cálculo de Retornos de Estrategia . . . . .                            | 33        |

|                                                                      |           |
|----------------------------------------------------------------------|-----------|
| 3.5.4. Justificación del Apalancamiento . . . . .                    | 34        |
| 3.6. Métricas de Desempeño . . . . .                                 | 34        |
| <b>4. Resultados Empíricos</b>                                       | <b>35</b> |
| 4.1. Resumen de Hallazgos Principales . . . . .                      | 35        |
| 4.2. Aplicación Interactiva para Exploración de Resultados . . . . . | 36        |
| 4.3. Interpretación de los Resultados . . . . .                      | 36        |
| <b>5. La Paradoja del Directional Accuracy</b>                       | <b>37</b> |
| 5.1. El Hallazgo Contraintuitivo . . . . .                           | 37        |
| 5.1.1. Intuición Naïve vs Realidad . . . . .                         | 37        |
| 5.1.2. Evidencia Empírica . . . . .                                  | 37        |
| 5.2. Explicación de la Paradoja . . . . .                            | 37        |
| 5.2.1. El DA Trata Todos los Días como Iguales . . . . .             | 37        |
| 5.2.2. Lo Que Realmente Importa: Asimetría Condicional . . . . .     | 38        |
| 5.3. El Indicador DA@3x: Una Métrica Más Relevante . . . . .         | 38        |
| 5.3.1. Comparación DA vs DA@3x . . . . .                             | 39        |
| 5.3.2. Interpretación . . . . .                                      | 39        |
| 5.4. Implicaciones para el Diseño de Estrategias . . . . .           | 39        |
| 5.4.1. No Optimizar por DA . . . . .                                 | 39        |
| 5.4.2. Métricas Alternativas Recomendadas . . . . .                  | 40        |
| 5.4.3. El Valor de la Selectividad . . . . .                         | 40        |
| 5.5. Conexión con la Literatura . . . . .                            | 40        |
| 5.6. Resumen de la Sección . . . . .                                 | 41        |
| <b>6. Validación Estadística</b>                                     | <b>41</b> |
| 6.1. Bootstrap de Sharpe Ratios . . . . .                            | 41        |
| 6.1.1. Metodología . . . . .                                         | 41        |
| 6.1.2. Corrección de Ledoit-Wolf . . . . .                           | 41        |
| 6.1.3. Resultados: Intervalos de Confianza . . . . .                 | 42        |
| 6.1.4. Interpretación . . . . .                                      | 42        |
| 6.2. Test de Diebold-Mariano . . . . .                               | 42        |
| 6.2.1. Formulación . . . . .                                         | 42        |
| 6.2.2. Resultados: Comparación con Benchmark . . . . .               | 43        |
| 6.3. Model Confidence Set (MCS) . . . . .                            | 43        |
| 6.3.1. Metodología . . . . .                                         | 43        |

|                                                                  |           |
|------------------------------------------------------------------|-----------|
| 6.3.2. Resultados . . . . .                                      | 43        |
| 6.4. Test de Clark-West . . . . .                                | 44        |
| 6.4.1. Formulación . . . . .                                     | 44        |
| 6.4.2. Aplicación . . . . .                                      | 44        |
| 6.5. Análisis de Overfitting . . . . .                           | 44        |
| 6.5.1. Comparación In-Sample vs Out-of-Sample . . . . .          | 44        |
| 6.5.2. Corrección por Multiple Testing . . . . .                 | 45        |
| 6.5.3. False Discovery Rate (FDR) . . . . .                      | 45        |
| 6.6. Resumen de Validación Estadística . . . . .                 | 45        |
| 6.7. Conclusiones de la Validación . . . . .                     | 45        |
| <b>7. Marco de Gestión de Riesgo</b>                             | <b>46</b> |
| 7.1. Métricas de Riesgo Ajustado . . . . .                       | 46        |
| 7.1.1. Sharpe Ratio . . . . .                                    | 46        |
| 7.1.2. Sortino Ratio . . . . .                                   | 46        |
| 7.1.3. Calmar Ratio . . . . .                                    | 47        |
| 7.2. Value at Risk (VaR) y Expected Shortfall . . . . .          | 47        |
| 7.2.1. Metodología . . . . .                                     | 47        |
| 7.2.2. Conditional VaR (CVaR) . . . . .                          | 47        |
| 7.2.3. Resultados de Riesgo de Cola . . . . .                    | 47        |
| 7.3. Análisis de Drawdown . . . . .                              | 48        |
| 7.3.1. Máximos Drawdowns . . . . .                               | 48        |
| 7.3.2. Períodos de Drawdown Significativo . . . . .              | 48        |
| 7.3.3. Recuperación de Drawdowns . . . . .                       | 48        |
| 7.4. Control de Riesgo Implícito en la Estrategia . . . . .      | 49        |
| 7.4.1. Posición en Cash como Hedge Natural . . . . .             | 49        |
| 7.4.2. Apalancamiento Selectivo . . . . .                        | 49        |
| 7.5. Implicaciones para la Implementación . . . . .              | 49        |
| <b>8. Análisis por Régimen de Mercado</b>                        | <b>50</b> |
| 8.1. Definición de Regímenes . . . . .                           | 50        |
| 8.1.1. Criterios de Clasificación . . . . .                      | 50        |
| 8.2. Distribución de Regímenes en el Período de Prueba . . . . . | 50        |
| 8.3. Rendimiento por Modelo por Régimen . . . . .                | 51        |
| 8.3.1. Bull Market (133 días) . . . . .                          | 51        |

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| 8.3.2. Bear Market (49 días)                                               | 51        |
| 8.3.3. High Volatility (121 días)                                          | 51        |
| 8.3.4. Sideways (938 días)                                                 | 52        |
| 8.4. Tabla Completa de Rendimiento por Régimen                             | 52        |
| 8.5. Análisis de Consistencia Cross-Régimen                                | 52        |
| 8.6. Implicaciones para Gestión Táctica                                    | 53        |
| 8.6.1. Rotación de Modelos por Régimen                                     | 53        |
| 8.6.2. Ensemble Dinámico                                                   | 53        |
| 8.6.3. Advertencia sobre Detección de Régimen                              | 53        |
| 8.7. Ridge: El Modelo All-Weather                                          | 53        |
| <b>9. Costos de Transacción</b>                                            | <b>54</b> |
| 9.1. Modelo de Costos                                                      | 54        |
| 9.2. Impacto en los Resultados                                             | 54        |
| 9.3. Relación Turnover-Retorno                                             | 54        |
| 9.4. Implicaciones para la Implementación                                  | 55        |
| <b>10. Discusión: Contribuciones al Debate sobre Eficiencia de Mercado</b> | <b>56</b> |
| 10.1. Resumen de Hallazgos Empíricos                                       | 56        |
| 10.2. Interpretación desde la Perspectiva de Eficiencia de Mercado         | 56        |
| 10.2.1. El Argumento contra la Eficiencia                                  | 56        |
| 10.2.2. El Argumento a Favor de la Eficiencia                              | 57        |
| 10.3. Reconciliando las Interpretaciones                                   | 57        |
| 10.4. Contribución al Debate Académico                                     | 58        |
| 10.5. El Rol de los Indicadores Técnicos                                   | 58        |
| 10.6. Robustez de la Estrategia de Posicionamiento por Quantiles           | 59        |
| <b>11. Limitaciones y Consideraciones de Robustez</b>                      | <b>59</b> |
| 11.1. Limitaciones del Estudio                                             | 59        |
| 11.1.1. Período de Prueba                                                  | 60        |
| 11.1.2. Mercado Único                                                      | 60        |
| 11.1.3. Estabilidad de Parámetros                                          | 60        |
| 11.1.4. Sesgo de Supervivencia de Variables                                | 60        |
| 11.1.5. Impacto de Mercado No Modelado                                     | 60        |
| 11.2. Análisis de Robustez                                                 | 60        |
| 11.2.1. Sensibilidad a Costos de Transacción                               | 60        |

|                                                                      |           |
|----------------------------------------------------------------------|-----------|
| 11.2.2. Estabilidad Temporal . . . . .                               | 61        |
| 11.2.3. Diversidad de Modelos Exitosos . . . . .                     | 61        |
| <b>12. Conclusión</b>                                                | <b>61</b> |
| 12.1. Resumen de Hallazgos . . . . .                                 | 61        |
| 12.2. Contribuciones al Debate sobre Eficiencia de Mercado . . . . . | 62        |
| 12.3. Implicaciones Prácticas . . . . .                              | 62        |
| 12.4. Direcciones para Investigación Futura . . . . .                | 63        |
| 12.5. Reflexiones Finales . . . . .                                  | 63        |
| <b>A. Especificación Completa de Variables</b>                       | <b>69</b> |
| A.1. Variables de Mercado (M1–M18) . . . . .                         | 69        |
| A.2. Variables Macroeconómicas (E1–E10) . . . . .                    | 69        |
| A.3. Variables de Tasas de Interés (I1–I20) . . . . .                | 70        |
| A.4. Variables de Commodities (P1–P13) . . . . .                     | 70        |
| A.5. Variables de Volatilidad (V1–V13) . . . . .                     | 71        |
| A.6. Variables de Sentimiento (S1–S11) . . . . .                     | 71        |
| A.7. Variables Dummy de Calendario (D1–D7) . . . . .                 | 72        |
| <b>B. Detalles de Ingeniería de Características</b>                  | <b>72</b> |
| B.1. Cómputo de Retornos . . . . .                                   | 72        |
| B.2. Indicadores Técnicos . . . . .                                  | 73        |
| B.3. Estimadores de Volatilidad OHLC . . . . .                       | 73        |
| B.4. Características del Triple Screen . . . . .                     | 74        |
| B.5. Estructura de Términos de Volatilidad . . . . .                 | 74        |
| B.6. Correlaciones Cross-Asset . . . . .                             | 74        |
| B.7. Rezagos y Estadísticas Móviles . . . . .                        | 75        |
| <b>C. Parámetros Óptimos de Umbral</b>                               | <b>75</b> |
| C.1. Metodología de Optimización . . . . .                           | 75        |
| C.1.1. Función Objetivo . . . . .                                    | 75        |
| C.1.2. Grid de Búsqueda . . . . .                                    | 75        |
| C.1.3. Restricciones . . . . .                                       | 75        |
| C.2. Tabla de Parámetros Óptimos . . . . .                           | 77        |
| C.3. Análisis de Parámetros . . . . .                                | 77        |
| C.3.1. Patrones Observados . . . . .                                 | 77        |

|                                                       |           |
|-------------------------------------------------------|-----------|
| C.3.2. Relación Parámetros-Rendimiento . . . . .      | 77        |
| C.3.3. Implicaciones . . . . .                        | 77        |
| C.4. Sensibilidad a Parámetros . . . . .              | 77        |
| C.4.1. Ridge: Análisis de Sensibilidad . . . . .      | 77        |
| C.5. Estabilidad Temporal de Parámetros . . . . .     | 78        |
| C.5.1. Walk-Forward Optimization . . . . .            | 78        |
| C.6. Interpretación de Umbrales . . . . .             | 78        |
| C.6.1. Significado de los Percentiles . . . . .       | 78        |
| C.6.2. Percentiles vs Valores Absolutos . . . . .     | 79        |
| <b>D. Hiperparámetros de Modelos</b>                  | <b>79</b> |
| D.1. Modelos de Machine Learning Clásico . . . . .    | 79        |
| D.2. Modelos de Gradient Boosting . . . . .           | 81        |
| D.3. Modelos de Series Temporales . . . . .           | 81        |
| D.4. Modelos de Deep Learning (Darts) . . . . .       | 81        |
| D.5. Modelos RNN Bidireccionales . . . . .            | 81        |
| D.6. Modelos Híbridos y Attention (PyTorch) . . . . . | 81        |
| D.7. Configuración de Entrenamiento Común . . . . .   | 81        |
| <b>E. Glosario de Términos</b>                        | <b>81</b> |



## 1. Introducción

### 1.1 Contexto y Motivación

La Hipótesis de Eficiencia de Mercado (HEM), formalizada por Fama (1970) hace más de cinco décadas, permanece como una de las proposiciones más influyentes y debatidas en la economía financiera contemporánea. En su formulación más estricta, la hipótesis postula que los precios de los activos incorporan instantánea y completamente toda la información disponible, haciendo imposible la obtención de rendimientos anormales sistemáticos a través de cualquier estrategia de trading basada en datos históricos o información pública.

Sin embargo, el panorama empírico ha evolucionado considerablemente desde el trabajo seminal de Fama. La proliferación de anomalías documentadas, la sofisticación creciente de las técnicas de aprendizaje automático, y la disponibilidad de conjuntos de datos cada vez más ricos han reavivado el debate fundamental: ¿procesan realmente los mercados financieros la información de manera eficiente, o existen ineficiencias persistentes susceptibles de explotación por inversores sofisticados?

Este estudio contribuye a este debate mediante un enfoque empírico estructurado en **dos hitos fundamentales**:

**Hito 1 – Predicción:** Entrenar múltiples modelos de aprendizaje automático y profundo (23 en total) para generar predicciones sobre los retornos del S&P 500. El objetivo no es predecir con exactitud el valor numérico del retorno de mañana, sino obtener suficiente *precisión direccional* para tomar decisiones de inversión.

**Hito 2 – Estrategia:** Traducir las predicciones de los modelos en una estrategia de trading práctica que aproveche el apalancamiento disponible en ETFs para generar alfa positivo después de costos de transacción realistas.

Este enfoque reconoce una distinción crucial: mientras que predecir el retorno exacto del mercado puede ser imposible, identificar la *dirección* con precisión suficiente puede ser económicamente explotable cuando se combina con una estrategia de posicionamiento inteligente.

### 1.2 La Relevancia del Debate sobre Eficiencia de Mercado

El debate sobre la eficiencia de mercado trasciende el ámbito puramente académico y tiene implicaciones profundas para la industria de gestión de activos, la regulación financiera y las decisiones de inversión individuales. Si los mercados son verdaderamente eficientes, los gestores activos de fondos destruyen valor para sus clientes a través de comisiones y costos de transacción sin generar rendimientos superiores al mercado. En este escenario, la inversión pasiva a través

de fondos indexados representaría la estrategia óptima para todos los inversores.

Por el contrario, si existen ineficiencias sistemáticas y explotables, surge la posibilidad de que estrategias cuantitativas sofisticadas puedan generar rendimientos ajustados por riesgo superiores. Esta posibilidad ha impulsado el crecimiento exponencial de la industria de hedge funds cuantitativos, que según estimaciones de la industria gestiona más de un billón de dólares en activos globalmente (Preqin, 2024).

La presente investigación se sitúa en la intersección de estos debates al examinar si las técnicas más avanzadas de aprendizaje automático, combinadas con indicadores técnicos probados en la práctica, pueden identificar patrones predecibles en los retornos del mercado de valores, patrones que al ser utilizados con una estrategia bien definida pueden generar retornos por encima del mercado.

### 1.3 Contribuciones al Conocimiento

Este estudio realiza múltiples contribuciones originales al cuerpo de conocimiento existente en la intersección de aprendizaje automático y finanzas cuantitativas.

**Marco metodológico de dos hitos.** La literatura existente frecuentemente confunde la capacidad predictiva de un modelo con su rentabilidad práctica. Este estudio introduce una separación explícita entre la fase de predicción (entrenamiento y evaluación de modelos) y la fase de implementación (traducción de predicciones a posiciones de trading). Esta distinción es fundamental porque un modelo con excelentes métricas predictivas puede fracasar en la práctica debido a costos de transacción, timing inadecuado, o dimensionamiento incorrecto de posiciones. Al evaluar cada fase de manera independiente, se identifican con precisión las fuentes de alfa y los puntos de falla potenciales.

**Comparación exhaustiva de arquitecturas.** Mientras que estudios previos típicamente comparan un número limitado de modelos dentro de una misma familia metodológica, este trabajo evalúa 23 modelos que abarcan el espectro completo de técnicas disponibles: desde regresión lineal regularizada hasta arquitecturas de deep learning de última generación (Transformers, TCN, LSTM bidireccionales). Esta amplitud permite identificar patrones sistemáticos sobre qué familias de modelos funcionan mejor en el contexto específico de predicción de retornos del S&P 500, proporcionando orientación práctica para investigadores y practicantes.

**Ingeniería de características multi-técnica.** A diferencia de enfoques que dependen de una única metodología de extracción de características, este estudio implementa un pipeline que inte-

gra múltiples técnicas complementarias: indicadores técnicos clásicos, estimadores de volatilidad basados en precios OHLC (Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang), el sistema [Triple Screen](#) de Elder, y correlaciones cross-asset dinámicas. Esta diversidad metodológica maximiza la información predictiva extraída de los datos disponibles y permite que los modelos capturen diferentes aspectos de la dinámica de mercado.

**Análisis de costos de implementación.** Un aspecto frecuentemente ignorado en la literatura académica es el impacto de los costos de transacción en la viabilidad práctica de las estrategias. Este estudio incorpora un modelo de costos conservador que incluye spreads bid-ask, comisiones, y slippage, demostrando que el alfa teórico puede erosionarse significativamente—o incluso desaparecer—cuando se consideran fricciones realistas. Esta contribución es crucial para distinguir entre resultados académicamente interesantes y estrategias genuinamente implementables.

**Evidencia sobre simplicidad versus complejidad.** Contrariamente a la intuición de que modelos más sofisticados deberían producir mejores predicciones, los resultados demuestran que un modelo simple (Ridge) supera consistentemente a arquitecturas complejas de deep learning. Este hallazgo se alinea con evidencia reciente en la literatura ([Zeng et al., 2023](#)) y tiene implicaciones prácticas importantes: en entornos con bajo ratio señal-ruido como los mercados financieros, la regularización implícita de modelos simples puede ser más valiosa que la flexibilidad de arquitecturas complejas.

**La Paradoja del Directional Accuracy.** Uno de los hallazgos más contraintuitivos de este estudio desafía una suposición común en la literatura: que un modelo que predice correctamente la dirección del mercado con mayor frecuencia debería generar mayores retornos. Los resultados empíricos revelan lo contrario—la correlación entre [Directional Accuracy \(DA\)](#) y rentabilidad es negativa. Modelos con DA superior al 54 % generaron retornos negativos, mientras que modelos con DA cercano al 51 % lograron los mejores retornos. La explicación radica en que el DA trata todos los días como iguales, ignorando la magnitud de los movimientos y el tamaño de las posiciones. Un modelo puede acertar frecuentemente en días de movimientos pequeños pero fallar en los días críticos de alta volatilidad. Se propone [DA3x](#)—el hit rate calculado únicamente cuando el modelo toma posiciones apalancadas—como métrica alternativa que captura la calidad de las predicciones en los momentos que realmente determinan la rentabilidad.

## 1.4 Estructura del Documento

El documento está organizado siguiendo la lógica de los dos hitos fundamentales:

**Contexto teórico:** La Sección 2 presenta una revisión de la literatura relevante sobre eficiencia de mercado, anomalías documentadas, y aplicaciones de aprendizaje automático en finanzas. Se examina la paradoja de Grossman-Stiglitz que fundamenta teóricamente la posibilidad de generar alfa en mercados “eficientemente ineficientes”.

**Hito 1 – Predicción:** La Sección 3 describe la metodología de predicción: fuentes de datos, ingeniería de características, y especificaciones de los 23 modelos evaluados. Se documenta cómo 92 variables de Bloomberg se transforman en 647 características predictivas mediante técnicas que incluyen el sistema Triple Screen de Elder y estimadores de volatilidad OHLC.

**Hito 2 – Estrategia:** La Sección 4 presenta la estrategia de posiciones discretas y los resultados empíricos. Cuatro modelos superan al benchmark, con Ridge logrando un retorno del 318.8 % frente al 102.2 % del mercado. La Sección 5 analiza los costos de transacción, demostrando que el alfa persiste después de fricciones realistas.

**Discusión y cierre:** La Sección 6 discute las implicaciones para el debate sobre eficiencia de mercado—los resultados sugieren que técnicas de aprendizaje automático pueden identificar ineficiencias explotables. La Sección 7 examina limitaciones y robustez. La Sección 8 concluye con hallazgos clave, incluyendo la superioridad de modelos simples sobre arquitecturas complejas. Los apéndices proporcionan documentación técnica detallada y un glosario de términos.

## 2. Revisión de Literatura y Fundamentos Teóricos

### 2.1 La Hipótesis de Eficiencia de Mercado: Origen y Evolución

#### 2.1.1 Fundamentos Conceptuales

La noción de que los precios de mercado reflejan la información disponible tiene raíces que se remontan a los trabajos pioneros de Louis Bachelier a principios del siglo XX. Sin embargo, la formulación moderna de la Hipótesis de Eficiencia de Mercado se atribuye principalmente a Eugene Fama, cuyo artículo seminal de 1970 estableció el marco conceptual que domina el pensamiento financiero hasta el día de hoy.

Fama (1970) definió un mercado eficiente como aquel en el que los precios “reflejan completamente” la información disponible. Esta definición aparentemente simple encierra profundas implicaciones para la práctica de inversión y la teoría financiera. Fama distinguió tres formas de eficiencia de mercado, cada una correspondiente a un conjunto diferente de información:

La **eficiencia en forma débil** postula que los precios actuales incorporan completamente

toda la información contenida en la secuencia histórica de precios. Bajo esta forma de eficiencia, el análisis técnico—la práctica de usar patrones de precios históricos para predecir movimientos futuros—debería ser incapaz de generar rendimientos anormales sistemáticos. Los precios seguirían un proceso de caminata aleatoria, haciendo que cualquier patrón aparente sea el resultado de coincidencia estadística más que de una relación causal explotable.

La **eficiencia en forma semi-fuerte** extiende esta noción al postular que los precios reflejan toda la información públicamente disponible, incluyendo estados financieros, anuncios corporativos, indicadores macroeconómicos, y cualquier otra información accesible sin privilegios especiales. Bajo esta forma de eficiencia, el análisis fundamental—el estudio de factores económicos, financieros y cualitativos para determinar el valor intrínseco de un activo—tampoco debería generar rendimientos anormales consistentes.

La **eficiencia en forma fuerte** representa la proposición más extrema: los precios reflejan toda la información, incluyendo información privada o “insider”. Esta forma implica que ni siquiera los insiders corporativos podrían obtener beneficios sistemáticos de su acceso privilegiado a información no pública.

### 2.1.2 El Problema del “Joint Hypothesis”

Un desafío fundamental en las pruebas empíricas de la HEM, reconocido por el propio [Fama \(1991\)](#), es el llamado problema de la hipótesis conjunta. Cualquier prueba de eficiencia de mercado es simultáneamente una prueba del modelo de equilibrio utilizado para definir “rendimientos normales”. Si observamos rendimientos que aparentan ser anormales, no podemos distinguir con certeza entre dos explicaciones: (1) el mercado es ineficiente, o (2) el modelo de equilibrio está mal especificado.

Este problema tiene implicaciones profundas para la interpretación de los resultados. Los rendimientos superiores que se documenta podrían representar verdadera ineficiencia de mercado (un fracaso en la incorporación eficiente de información), o podrían representar compensación por riesgo que los modelos no capturan adecuadamente. Volveremos a esta cuestión en la discusión de resultados ([Fama, 1991](#)).

### 2.1.3 La Paradoja de Grossman-Stiglitz

Una crítica teórica fundamental a la HEM fue planteada por [Grossman & Stiglitz \(1980\)](#), quienes demostraron la imposibilidad lógica de mercados perfectamente eficientes. Su argumento, conocido como la “paradoja de la información”, procede de la siguiente manera:

Si los mercados fueran perfectamente eficientes y los precios reflejaran completamente toda la

información disponible, entonces ningún inversor podría obtener rendimientos superiores mediante la adquisición y análisis de información. Pero si no existe beneficio en adquirir información—dado que los precios ya la reflejan—¿por qué los participantes del mercado pagarían por acceso a noticias financieras, servicios de análisis, terminales Bloomberg, o informes de corredores?

La paradoja revela una contradicción interna: si nadie tiene incentivos para recopilar información (porque no pueden beneficiarse de ella), entonces los precios no pueden reflejar esa información. Pero si los precios no reflejan la información, entonces sí existen oportunidades de beneficio, lo que motivaría la adquisición de información. [Grossman & Stiglitz \(1980\)](#) concluyen que los mercados deben ser “eficientemente ineficientes”—lo suficientemente ineficientes para compensar a quienes invierten en la adquisición de información, pero no tan ineficientes como para permitir ganancias excesivas después de considerar los costos de información.

Esta perspectiva tiene implicaciones directas para el presente estudio: la existencia de alfa positivo después de costos no contradice necesariamente una noción razonable de eficiencia de mercado, siempre que ese alfa represente compensación legítima por el esfuerzo de desarrollar y mantener sistemas predictivos sofisticados.

## 2.2 Anomalías de Mercado y Evidencia Contra la HEM

### 2.2.1 El Catálogo de Anomalías

A pesar del marco teórico de la HEM, la evidencia empírica cuenta una historia diferente. A lo largo de décadas, los investigadores han ido acumulando lo que [Harvey et al. \(2016\)](#) denominan el “zoológico de factores”: más de 300 predictores de rendimientos publicados en revistas académicas. Muchos críticos señalan—con razón—que buena parte de estos hallazgos podrían ser espejismos estadísticos, producto del sesgo de selección y la minería de datos.

Sin embargo, trabajos recientes sugieren que no todo es ruido. [Dong et al. \(2022\)](#) demuestran que al combinar las señales de 100 anomalías representativas mediante técnicas de machine learning, emerge una capacidad predictiva robusta sobre los rendimientos del mercado. Este hallazgo es difícil de ignorar: si estas anomalías fueran puramente aleatorias, su agregación debería cancelar cualquier señal. El hecho de que persista información útil apunta a algo más profundo—quizás límites al arbitraje, sesgos conductuales sistemáticos, o una corrección lenta pero persistente de errores de valoración. En cualquier caso, desafía la noción reconfortante de que los precios siempre reflejan toda la información disponible.

**Anomalías de momentum:** [Jegadeesh & Titman \(1993\)](#) documentaron uno de los hallazgos más perturbadores para la HEM: las acciones con rendimientos superiores en los 3-12 meses anteriores tienden a continuar superando a aquellas con rendimientos inferiores. Este efecto de

momentum contradice directamente la forma débil de eficiencia, ya que implica que los rendimientos históricos—información pública y gratuita—contienen poder predictivo sobre rendimientos futuros.

El efecto momentum ha demostrado ser notablemente robusto. Estudios posteriores han confirmado su existencia en más de 40 países, en múltiples clases de activos (bonos, divisas, commodities), y a través de diferentes períodos históricos que abarcan más de dos siglos de datos. Si los mercados fueran verdaderamente eficientes en su forma débil, este patrón simplemente no debería existir. La estrategia es conceptualmente simple: comprar ganadores recientes y vender perdedores recientes genera rendimientos anormales de aproximadamente 1 % mensual. ¿Cómo puede un patrón tan obvio persistir si miles de inversores sofisticados compiten por explotarlo?

**Anomalías de valor:** Fama & French (1992) mostraron que las acciones con altas razones libro-a-mercado (“value stocks”) tienden a superar sistemáticamente a aquellas con bajas razones (“growth stocks”). Lo irónico de este hallazgo es que proviene del propio Eugene Fama, el padre intelectual de la HEM. Si los mercados incorporan eficientemente toda la información disponible, ¿por qué las acciones “baratas” según métricas contables públicas generan rendimientos superiores?

Según los datos históricos del factor HML de Fama y French, el efecto valor ha generado una prima promedio de aproximadamente 3-4 % anual en Estados Unidos desde 1926, y se ha documentado en mercados desarrollados y emergentes alrededor del mundo (Fama & French, 1992). Aunque los defensores de la eficiencia argumentan que esto representa compensación por riesgo, la pregunta persiste: ¿qué tipo de riesgo justifica décadas de rendimientos superiores basados en información contable que cualquier inversor puede obtener gratuitamente?

**Anomalías de tamaño:** Banz (1981) descubrió que las acciones de empresas pequeñas generan rendimientos superiores a las de empresas grandes, incluso después de ajustar por su mayor riesgo de mercado (beta). El “efecto tamaño” sugiere que la capitalización de mercado—una variable públicamente observable—predice rendimientos futuros, violando directamente las predicciones de la HEM.

Aunque este efecto se ha debilitado desde su publicación original (posiblemente debido al arbitraje), su existencia histórica plantea preguntas fundamentales: ¿fueron los mercados ineficientes durante décadas sin que nadie lo notara? ¿O el debilitamiento post-publicación simplemente demuestra que las ineficiencias pueden persistir hasta que suficiente capital intenta explotarlo?

**Anomalías de calendario:** Diversos efectos relacionados con el calendario desafían cualquier noción de racionalidad en la formación de precios. El “efecto enero” (Rozeff & Kinney, 1976) documenta rendimientos anormalmente altos en enero, particularmente para acciones pequeñas.

El “efecto lunes” ([French, 1980](#)) muestra rendimientos sistemáticamente negativos los lunes. El “efecto fin de mes” revela rendimientos positivos concentrados en los últimos días de cada mes.

¿Qué justificación racional existe para que el calendario—un constructo humano arbitrario—influya en los rendimientos de activos financieros? Estas anomalías son particularmente difíciles de reconciliar con cualquier explicación basada en riesgo. No existe ninguna razón económica fundamental por la cual enero debería ser más rentable que julio, o por la cual los lunes deberían ser sistemáticamente peores que los viernes.

**Anomalías de baja volatilidad:** Quizás la anomalía más desconcertante es la documentada por [Ang et al. \(2006\)](#): contrariamente a las predicciones fundamentales del CAPM, las acciones de baja volatilidad han generado rendimientos ajustados por riesgo *superiores* a las de alta volatilidad. Esto invierte completamente la relación riesgo-rendimiento que constituye la piedra angular de la teoría financiera moderna.

Si el CAPM fuera correcto, los inversores deberían ser compensados por asumir mayor riesgo (volatilidad). Sin embargo, los datos muestran consistentemente lo opuesto: las acciones “aburridas” de baja volatilidad superan a las acciones “emocionantes” de alta volatilidad. Este hallazgo, replicado globalmente y conocido como “betting against beta” ([Frazzini & Pedersen, 2014](#)), sugiere que o bien los inversores sistemáticamente sobrevaloran el riesgo, o bien nuestros modelos de valoración de activos son fundamentalmente incorrectos.

### 2.2.2 Interpretaciones Alternativas de las Anomalías

Antes de declarar victoria sobre la HEM, es justo escuchar a la defensa. Los partidarios de la eficiencia no se han quedado de brazos cruzados ante la avalancha de anomalías documentadas. [Malkiel \(2003\)](#) articula las principales líneas de contraargumentación, cada una de las cuales merece consideración seria:

**Compensación por riesgo:** La explicación más elegante—y la preferida por los teóricos—sostiene que los rendimientos superiores no son “dinero gratis” sino compensación legítima por exposición a factores de riesgo que los modelos estándar no capturan. Las acciones de valor, por ejemplo, podrían ser empresas en dificultades financieras con mayor probabilidad de quiebra. Las acciones pequeñas podrían ser más vulnerables a shocks económicos. Bajo esta interpretación, las anomalías no contradicen la eficiencia: simplemente revelan nuestra ignorancia sobre la verdadera estructura de riesgos del mercado. Es una defensa intelectualmente satisfactoria, aunque convenientemente difícil de refutar—siempre se puede postular un factor de riesgo no observado.

**Sesgo de publicación y el problema del cajón:** El metaestadístico [Ioannidis \(2005\)](#) sacudió al mundo científico con su provocador artículo “Why Most Published Research Find-



ings Are False”. Su argumento aplica con fuerza especial a las finanzas: las revistas académicas prefieren resultados “interesantes” (anomalías que predicen rendimientos) sobre resultados “aburridos” (variables que no predicen nada). ¿El resultado? Miles de investigadores buscan patrones, pero solo aquellos que encuentran algo publican. Los estudios negativos languidecen en el “cajón del escritorio”. Lo que vemos en la literatura es una muestra sesgada de los ganadores de una lotería estadística.

**Data mining y el zoológico de factores:** [Harvey et al. \(2016\)](#) calculan que con los estándares estadísticos tradicionales ( $t > 2$ ), deberíamos esperar encontrar docenas de “anomalías” significativas por pura casualidad. Para ilustrarlo con un ejemplo: si 1,000 investigadores prueban cada uno 100 variables diferentes buscando predecir rendimientos del S&P 500, y ninguna variable tiene poder predictivo real, aproximadamente 5,000 de esas pruebas (5 %) arrojarán resultados “estadísticamente significativos” por azar. Si solo se publican los hallazgos positivos, la literatura se llenará de patrones ilusorios. Harvey y coautores proponen umbrales mucho más estrictos ( $t > 3$ ) para nuevos factores, lo que reduciría drásticamente los falsos positivos. La pregunta incómoda es cuántas de las 300+ anomalías publicadas sobrevivirían a esta corrección. Probablemente muchas menos de las que nos gustaría admitir.

**Decaimiento post-publicación:** La evidencia más reveladora proviene de [McLean & Pontiff \(2016\)](#), quienes rastrearon el desempeño de 97 anomalías antes y después de su publicación académica. Sus hallazgos cuentan una historia en dos actos. Primer acto: los rendimientos caen un 26 % cuando se evalúan fuera de la muestra original—esto sugiere que parte del efecto inicial era ruido estadístico o sobreajuste a los datos históricos. Segundo acto: los rendimientos caen un 58 % después de que el paper se publica en una revista académica. Ese 32 % adicional de deterioro tiene una explicación fascinante: los hedge funds y traders cuantitativos leen los journals, identifican las estrategias prometedoras, y despliegan capital para explotarlas. Al hacerlo, arbitran las ineficiencias hasta que desaparecen. Consideremos el efecto momentum como ejemplo: después de que Jegadeesh y Titman publicaran su paper en 1993, los rendimientos de las estrategias momentum en acciones estadounidenses se redujeron significativamente en las décadas siguientes.

Este fenómeno plantea una paradoja que está en el corazón del presente estudio: si las anomalías fueran puramente ilusorias—meros artefactos estadísticos sin sustancia real—deberían desaparecer inmediatamente al evaluarlas fuera de muestra, no decaer gradualmente después de la publicación. El hecho de que el decaimiento sea progresivo sugiere que había algo genuino que explotar, algo que los arbitrajistas fueron erosionando con el tiempo. Pero si había ineficiencias reales que el arbitraje eliminó, ¿no significa eso que los mercados *no* eran eficientes antes? Los

defensores de la HEM argumentan que el decaimiento demuestra la capacidad auto-correctiva de los mercados; los críticos responden que demuestra que la eficiencia no es un estado permanente sino un proceso dinámico e imperfecto. Es precisamente esta tensión no resuelta—entre la elegancia teórica de los mercados eficientes y la evidencia empírica de patrones explotables—lo que motiva el presente estudio y lo convierte en una exploración intelectualmente estimulante.

## 2.3 Aprendizaje Automático en Valoración de Activos

### 2.3.1 Fundamentos del Machine Learning en Finanzas

La aplicación del aprendizaje automático a la predicción financiera ha experimentado un crecimiento explosivo en la última década. El trabajo seminal de [Gu et al. \(2020\)](#) proporciona el tratamiento más comprehensivo de este campo hasta la fecha, demostrando que métodos no lineales superan sustancialmente a la regresión lineal en la predicción de rendimientos de acciones individuales. Su metodología, que emplea un gran número de características de empresas como predictores, se ha convertido en una referencia estándar en la literatura.

**Modelos lineales regularizados:** Los métodos de regresión penalizada—Ridge ([Hoerl & Kennard, 1970](#)), Lasso ([Tibshirani, 1996](#)), y ElasticNet ([Zou & Hastie, 2005](#))—representan el punto de partida natural para la predicción financiera. Su principal virtud radica en la regularización: al penalizar coeficientes grandes, estos modelos reducen el sobreajuste en entornos con alta dimensionalidad y bajo ratio señal-ruido, características definitorias de los datos financieros. El presente estudio implementa los tres como baseline para evaluar si la complejidad adicional de otros métodos se justifica.

**Métodos de ensamble basados en árboles:** Random Forest, introducido por [Breiman \(2001\)](#), combina múltiples árboles de decisión entrenados en submuestras aleatorias, reduciendo la varianza sin aumentar significativamente el sesgo. Gradient Boosting, formalizado por [Friedman \(2001\)](#), construye árboles secuencialmente, donde cada árbol corrige los errores del anterior. Ambos métodos han demostrado excelente desempeño en competencias de predicción financiera.

**La revolución del gradient boosting:** La última década ha visto una explosión de implementaciones optimizadas de gradient boosting que han dominado competencias de machine learning. [Chen & Guestrin \(2016\)](#) introdujeron XGBoost, que incorpora regularización L1/L2, manejo nativo de valores faltantes, y paralelización eficiente. [Ke et al. \(2017\)](#) presentaron LightGBM, que mediante técnicas de muestreo (GOSS) y agrupación de características (EFB) logra velocidades de entrenamiento hasta 20 veces superiores. CatBoost ([Prokhorenkova et al., 2018](#)) añadió manejo sofisticado de variables categóricas y ordenamiento de datos que reduce el sobreajuste. El presente estudio implementa estas tres bibliotecas para evaluar su desempeño

comparativo en predicción de rendimientos del S&P 500.

### 2.3.2 Deep Learning para Series Temporales Financieras

El aprendizaje profundo ha transformado campos como visión por computador y procesamiento de lenguaje natural. Su aplicación a series temporales financieras, sin embargo, presenta desafíos únicos debido al bajo ratio señal-ruido y la naturaleza no estacionaria de los mercados.

**Redes recurrentes (1997-2014):** El fundamento teórico del deep learning para secuencias temporales fue establecido por [Hochreiter & Schmidhuber \(1997\)](#) con las redes Long Short-Term Memory (LSTM). A diferencia de las redes recurrentes tradicionales que sufren del problema del gradiente desvaneciente, las LSTM incorporan “compuertas” (gates) que permiten al modelo aprender qué información retener o descartar a través de largas secuencias. Las Gated Recurrent Units (GRU), propuestas posteriormente por [Cho et al. \(2014\)](#), simplifican la arquitectura LSTM manteniendo desempeño comparable con menor costo computacional. El presente estudio implementa versiones bidireccionales de ambas arquitecturas (Bi-LSTM, Bi-GRU), que procesan la secuencia en ambas direcciones temporales.

**Mecanismos de atención (2015-2017):** [Luong et al. \(2015\)](#) introdujeron mecanismos de atención que permiten al modelo “enfocarse” en partes específicas de la secuencia de entrada al generar cada elemento de la salida. Esta innovación fue transformadora: en lugar de comprimir toda la información histórica en un vector de estado fijo, el modelo puede acceder selectivamente a cualquier punto temporal relevante. El presente estudio implementa una arquitectura híbrida LSTM+Attention basada en el mecanismo de Luong.

**Arquitecturas híbridas CNN-LSTM:** La combinación de capas convolucionales con LSTM permite extraer patrones locales (mediante CNN) antes de modelar dependencias temporales (mediante LSTM). Esta arquitectura ha mostrado resultados prometedores en predicción financiera al capturar tanto patrones de corto plazo como tendencias de largo plazo.

**Arquitecturas modernas para pronóstico (2019-2023):** La investigación reciente ha producido arquitecturas especializadas para series temporales:

- **N-BEATS** ([Oreshkin et al., 2019](#)): Propuesta por investigadores de Element AI, esta arquitectura puramente basada en capas fully-connected logró resultados estado del arte en las competencias M3 y M4 sin usar componentes específicos de series temporales. Su diseño modular permite interpretabilidad mediante descomposición en tendencia y estacionalidad.
- **N-HiTS** ([Challu et al., 2022](#)): Extensión de N-BEATS que incorpora muestreo jerárquico multi-escala, mejorando la captura de patrones en diferentes horizontes temporales.
- **Temporal Fusion Transformer (TFT)** ([Lim et al., 2021](#)): Desarrollado por Google,

combina LSTM para procesamiento local con mecanismos de auto-atención para dependencias de largo plazo. Su arquitectura incluye redes de selección de variables que proporcionan interpretabilidad sobre qué características son más relevantes.

- **Temporal Convolutional Networks (TCN)**: Utilizan convoluciones causales dilatadas para capturar dependencias temporales con campos receptivos exponencialmente crecientes, ofreciendo una alternativa eficiente a las arquitecturas recurrentes.

El presente estudio implementa todas estas arquitecturas mediante la biblioteca Darts ([Herzen et al., 2022](#)), un framework unificado de Python para pronóstico de series temporales que proporciona implementaciones optimizadas y una API consistente.

### 2.3.3 El Debate sobre Complejidad de Modelos

Un hallazgo sorprendente de la literatura reciente cuestiona la supremacía asumida de las arquitecturas complejas. [Zeng et al. \(2023\)](#) presentan un resultado provocador: DLinear—un modelo que simplemente descompone la serie en tendencia y residuo, aplicando una capa lineal a cada componente—supera a Transformers sofisticados en múltiples benchmarks de pronóstico de horizonte largo. Los autores argumentan que la atención, siendo invariante a permutaciones, no es inherentemente adecuada para capturar relaciones temporales ordenadas.

Este resultado tiene implicaciones profundas para las aplicaciones financieras. Las series temporales financieras son notoriamente ruidosas, con ratios señal-ruido mucho más bajos que en otros dominios. En tales entornos, la regularización implícita de arquitecturas más simples puede proporcionar ventajas sobre modelos complejos propensos a sobreajustar patrones espurios.

La lección que extraemos de esta literatura—y que guía el diseño experimental del presente estudio—es que la sofisticación arquitectónica no garantiza mejor desempeño predictivo en finanzas. Por ello, evaluamos sistemáticamente 23 modelos que abarcan desde regresión lineal regularizada hasta Temporal Fusion Transformers, permitiendo que los datos determinen qué nivel de complejidad se justifica para la predicción de rendimientos del S&P 500.

## 2.4 Estimadores de Volatilidad OHLC: Extrayendo Información Oculta en los Precios

### 2.4.1 El Problema Fundamental

La volatilidad—la magnitud de las fluctuaciones de precios—es quizás la variable más importante en finanzas después del retorno mismo. Sin embargo, a diferencia del precio, la volatilidad no es directamente observable: debe ser estimada. El enfoque tradicional calcula la desviación estándar de los retornos de cierre a cierre, pero este método descarta información valiosa.

Considérese el siguiente ejemplo: dos días de trading terminan exactamente donde comenzaron (retorno de cierre a cierre = 0 %). Sin embargo, el primer día el precio fluctuó en un rango estrecho del 0.5 %, mientras que el segundo día el precio subió 3 %, cayó 4 %, y recuperó para cerrar sin cambios. Un estimador basado únicamente en cierres asignaría volatilidad cero a ambos días, ignorando que el segundo día experimentó turbulencia significativa. Esta información sobre la “volatilidad oculta” intradía es precisamente lo que los precios de Apertura, Máximo, Mínimo y Cierre (OHLC) pueden revelar.

¿Por qué importa esto para la predicción? La volatilidad exhibe persistencia (clustering): períodos de alta volatilidad tienden a seguir a períodos de alta volatilidad. Si podemos medir la volatilidad con mayor precisión hoy, podemos predecir mejor las condiciones de mañana. Además, la volatilidad está inversamente correlacionada con los retornos futuros—períodos de alta volatilidad frecuentemente preceden correcciones de mercado.

#### 2.4.2 Parkinson (1980): El Poder del Rango

Parkinson (1980) fue pionero en demostrar que el rango diario (máximo menos mínimo) contiene información sustancial sobre la volatilidad. Su contribución fundamental fue cuantificar exactamente cuánta información adicional proporciona el rango.

Bajo el supuesto de que los precios siguen un movimiento browniano geométrico (el modelo estándar en finanzas), Parkinson derivó matemáticamente que:

$$\sigma_P^2 = \frac{1}{4 \ln 2} \cdot \frac{1}{n} \sum_{i=1}^n (\ln H_i - \ln L_i)^2 \quad (1)$$

donde  $H_i$  y  $L_i$  son los precios máximo y mínimo del día  $i$ .

El resultado sorprendente: este estimador es aproximadamente **cinco veces más eficiente** que el estimador tradicional de cierre a cierre. En términos prácticos, esto significa que 20 días de datos OHLC proporcionan la misma precisión estadística que 100 días usando solo cierres.

*Ejemplo de mercado:* Durante la crisis del COVID-19 en marzo de 2020, el S&P 500 experimentó días donde el rango intradía superó el 10 %, información crítica para gestión de riesgo que un estimador de cierre a cierre subestimaría severamente.

**Limitación:** Parkinson asume que no hay deriva (tendencia) en los precios y que el trading es continuo. En la realidad, los mercados cierran por la noche y los activos exhiben tendencias.

#### 2.4.3 Garman-Klass (1980): Incorporando Apertura y Cierre

Garman & Klass (1980) extendieron el trabajo de Parkinson al incorporar los cuatro precios OHLC, no solo el rango. Su insight fue que la relación entre apertura y cierre contiene información

adicional sobre la dirección del movimiento intradía.

$$\sigma_{GK}^2 = \frac{1}{n} \sum_{i=1}^n \left[ \frac{1}{2} (\ln H_i - \ln L_i)^2 - (2 \ln 2 - 1) (\ln C_i - \ln O_i)^2 \right] \quad (2)$$

El primer término captura la información del rango (similar a Parkinson), mientras que el segundo término ajusta por la “eficiencia” del movimiento de precios. Un día donde el precio se movió directamente de apertura a cierre (sin retrocesos) tiene menor volatilidad implícita que un día con el mismo rango pero múltiples reversiones.

**Ganancia de eficiencia:** Aproximadamente **ocho veces** más eficiente que el estimador de cierre a cierre, representando una mejora del 60 % sobre Parkinson.

*Ejemplo de mercado:* Considérese un día donde SPY abre en \$400, alcanza un máximo de \$408, un mínimo de \$395, y cierra en \$405. El estimador Garman-Klass captura tanto el rango amplio (\$13) como el hecho de que el cierre estuvo cerca del máximo, sugiriendo momentum alcista subyacente.

**Limitación:** Al igual que Parkinson, asume ausencia de deriva y trading continuo.

#### 2.4.4 Rogers-Satchell (1991): Robustez ante Tendencias

Los estimadores anteriores funcionan bien cuando los precios fluctúan alrededor de un nivel constante, pero los mercados financieros exhiben tendencias persistentes. Un mercado alcista fuerte mostrará máximos consistentemente por encima de las aperturas, lo que Parkinson y Garman-Klass interpretan erróneamente como volatilidad elevada.

Rogers & Satchell (1991) desarrollaron un estimador que permanece insesgado incluso en presencia de deriva:

$$\sigma_{RS}^2 = \frac{1}{n} \sum_{i=1}^n [(\ln H_i - \ln O_i)(\ln H_i - \ln C_i) + (\ln L_i - \ln O_i)(\ln L_i - \ln C_i)] \quad (3)$$

La elegancia matemática de esta fórmula radica en que los términos de deriva se cancelan algebraicamente. Si el precio tiene una tendencia alcista, tanto  $(H - O)$  como  $(H - C)$  serán afectados de manera que su producto elimina el sesgo.

*Ejemplo de mercado:* Durante el rally post-elecciones de noviembre 2020, el S&P 500 subió casi 11 % en un mes. Un estimador que no corrige por deriva habría sobreestimado la volatilidad significativamente, mientras que Rogers-Satchell proporciona una medida más precisa de la incertidumbre real del mercado.

**Limitación:** Aún asume trading continuo, ignorando los gaps overnight.

#### 2.4.5 Yang-Zhang (2000): El Estimador Completo

Yang & Zhang (2000) reconocieron una fuente de variación que todos los estimadores anteriores ignoran: los **gaps overnight**. Cuando el mercado cierra a las 4:00 PM y reabre a las 9:30 AM del día siguiente, información significativa puede llegar (reportes de ganancias, eventos geopolíticos, datos económicos) causando que el precio de apertura difiera sustancialmente del cierre anterior.

El estimador Yang-Zhang descompone la volatilidad total en tres componentes:

$$\sigma_{YZ}^2 = \sigma_O^2 + k\sigma_C^2 + (1 - k)\sigma_{RS}^2 \quad (4)$$

donde:

- $\sigma_O^2$  = varianza overnight (gaps entre cierre $_{t-1}$  y apertura $_t$ )
- $\sigma_C^2$  = varianza de cierre a cierre (open-to-close)
- $\sigma_{RS}^2$  = varianza Rogers-Satchell (volatilidad intradía corregida por deriva)
- $k$  = factor de ponderación óptimo que minimiza la varianza del estimador

*Ejemplo de mercado:* El 24 de febrero de 2022, tras la invasión rusa de Ucrania, el S&P 500 abrió 2.5 % por debajo del cierre anterior. Esta volatilidad overnight es invisible para Parkinson, Garman-Klass y Rogers-Satchell, pero Yang-Zhang la captura explícitamente.

#### Propiedades del estimador Yang-Zhang:

1. Es insesgado en presencia de deriva (hereda la propiedad de Rogers-Satchell)
2. Captura volatilidad overnight además de intradía
3. Es el estimador de mínima varianza en su clase
4. Es consistente y asintóticamente eficiente

#### 2.4.6 Aplicaciones en la Literatura Financiera

La utilidad práctica de estos estimadores ha sido validada extensamente. Alizadeh et al. (2002) demostraron que los estimadores basados en rango mejoran significativamente los modelos de volatilidad estocástica. Chou (2005) desarrolló el modelo CARR (Conditional Autoregressive Range) que utiliza el rango como variable dependiente, encontrando mejor desempeño predictivo que los modelos GARCH tradicionales.

En el contexto del presente estudio, estos cuatro estimadores se calculan sobre ventanas móviles de 21 y 63 días, generando ocho características de volatilidad que capturan diferentes aspectos de la dinámica de precios. La combinación de múltiples estimadores permite que los

modelos de machine learning seleccionen automáticamente cuál es más informativo para diferentes condiciones de mercado.

### 3. Datos y Metodología

#### 3.1 Fuentes de Datos y Construcción de la Muestra

##### 3.1.1 Descripción General del Conjunto de Datos

El análisis emplea datos diarios de Bloomberg Terminal abarcando desde el 3 de enero de 2000 hasta el 12 de diciembre de 2025, comprendiendo 6,507 días de negociación. El conjunto de datos integra 92 variables base organizadas en siete categorías temáticas que capturan diferentes dimensiones de las condiciones de mercado.

La selección de variables fue guiada por tres principios: (1) relevancia teórica para la predicción de retornos de renta variable según la literatura académica y la práctica de la industria, (2) disponibilidad histórica suficiente para permitir estimación robusta, y (3) diversidad conceptual para capturar múltiples fuentes potenciales de información predictiva.

##### 3.1.2 Variables de Mercado (M1-M18)

Esta categoría comprende 18 variables que capturan las condiciones del mercado de renta variable a través de diferentes segmentos y geografías. Incluimos el ETF SPY como proxy del S&P 500 (la variable objetivo), junto con ETFs que representan diferentes capitalizaciones de mercado (QQQ para tecnología/large cap growth, IWM para small cap, DIA para blue chips industriales), exposiciones geográficas (EFA para mercados desarrollados ex-US, EEM para mercados emergentes), y sectores específicos (XLF finanzas, XLK tecnología, XLE energía, XLV salud, XLI industriales).

También se incluyen medidas de renta fija (SHY, IEF, TLT representando diferentes segmentos de la curva de rendimiento de Treasuries), bienes raíces (FNERTR para REITs), y medidas agregadas del mercado global (VT, ACWI).

La inclusión de esta diversidad de activos permite a los modelos capturar dinámicas de rotación sectorial, relaciones cross-asset, y efectos de contagio que pueden contener información predictiva para los retornos del S&P 500.

##### 3.1.3 Variables Macroeconómicas (E1-E10)

Esta categoría incluye 10 indicadores que capturan el estado de la economía real. Incorporamos medidas de actividad económica (GDP CQOQ para crecimiento del PIB, NAPMPMI



y NAPMNMi para PMIs de manufactura y servicios), condiciones del mercado laboral (INJCJC para peticiones iniciales de desempleo, NFP TCH para cambio en nóminas no agrícolas, USURTOT para tasa de desempleo), inflación (CPI CHNG para cambio mensual del IPC, PCE CRCH para inflación subyacente PCE), confianza del consumidor (CONCCONF), e indicadores adelantados compuestos (LEI CHNG).

La literatura académica ha documentado extensamente la relación entre condiciones macroeconómicas y retornos de mercado. Las recesiones económicas típicamente coinciden con mercados bajistas, mientras que las expansiones económicas generalmente acompañan mercados alcistas. Sin embargo, la relación entre datos macroeconómicos y retornos de mercado es compleja debido a los efectos de anticipación—los mercados tienden a descontar condiciones económicas futuras antes de que se materialicen en los datos.

### *3.1.4 Variables de Tasas de Interés (I1-I20)*

Esta categoría comprende 20 variables que capturan las condiciones del mercado de renta fija y crédito. Incluimos la tasa de fondos federales (FDTR), rendimientos de Treasuries a lo largo de la curva de vencimiento (3M, 6M, 1Y, 2Y, 5Y, 10Y, 30Y), spreads de la curva de rendimiento (2Y-10Y, 3M-10Y), tasas LIBOR y swap, y spreads de crédito (CDX Investment Grade y High Yield).

La pendiente de la curva de rendimiento es un predictor bien documentado de actividad económica y, por extensión, de retornos de mercado. Una curva invertida (tasas cortas superiores a tasas largas) ha precedido históricamente a recesiones. Los spreads de crédito reflejan la percepción del mercado sobre el riesgo de default corporativo y tienden a ampliarse durante períodos de estrés financiero.

### *3.1.5 Variables de Commodities (P1-P13)*

Esta categoría incluye 13 variables que capturan condiciones en los mercados de materias primas y divisas. Incorporamos contratos de futuros de energía (CL1 para petróleo WTI, NG1 para gas natural), metales preciosos (GC1 oro, SI1 plata), metales industriales (HG1 cobre), commodities agrícolas (C1 maíz, W1 trigo, S1 soja), un índice agregado de commodities (BCOM), y pares de divisas principales (DXY índice dólar, EUR/USD, USD/JPY, GBP/USD).

Los precios de commodities contienen información sobre presiones inflacionarias, condiciones de oferta y demanda global, y apetito por riesgo. El dólar estadounidense tiene una relación inversa bien documentada con los activos de riesgo—un dólar fuerte tiende a asociarse con condiciones de “risk-off”.

### 3.1.6 Variables de Volatilidad (V1-V13)

Esta categoría comprende 13 variables que capturan las expectativas de volatilidad del mercado. Incluimos el VIX y su estructura de términos completa (VIX9D, VIX1M, VIX3M, VIX6M), volatilidad de la volatilidad (VVIX), y medidas de volatilidad cross-asset (MOVE para bonos, OVX para petróleo, GVZ para oro, VXN para Nasdaq-100, VXEEM para mercados emergentes, VXEFA para EAFE, TYVIX para Treasuries). También se incluyen el índice SKEW, que captura la demanda de protección contra caídas extremas.

La estructura de términos del VIX es particularmente informativa. Una estructura invertida (VIX de corto plazo superior al de largo plazo) indica estrés de mercado agudo, mientras que una estructura normal (pendiente ascendente) sugiere condiciones de mercado más tranquilas.

### 3.1.7 Variables de Sentimiento (S1-S11)

Esta categoría incluye 11 variables que capturan el posicionamiento y sentimiento de diferentes participantes del mercado. Incorporamos encuestas de sentimiento de inversores individuales (AAII Bull/Bear), medidas de posicionamiento institucional (NAAIM Exposure Index), ratios put/call (PCUSEQTR, PCUSTOTR, PCRATEQ), y medidas de amplitud de mercado (ADD línea advance-decline, NYAD ratio advancing/declining, NYHL nuevos máximos/mínimos, TRIN Arms Index).

La literatura de finanzas conductuales sugiere que las lecturas extremas de sentimiento frecuentemente preceden reversiones de mercado. Cuando el optimismo alcanza niveles extremos, el mercado puede estar vulnerable a correcciones; cuando el pesimismo es extremo, pueden surgir oportunidades de compra contrarian.

### 3.1.8 Variables de Calendario (D1-D7)

Finalmente, se incluyen 7 variables dummy que capturan efectos de calendario documentados en la literatura: indicador de lunes (D1), indicador de viernes (D2), indicador de fin de mes (últimos 3 días, D3), indicador de inicio de mes (primeros 3 días, D4), indicador de inicio de trimestre (D5), indicador de fin de trimestre (D6), e indicador de semana de vencimiento de opciones (D7).

Aunque la literatura reciente sugiere que muchos efectos de calendario han disminuido desde su documentación original, se incluyen estas variables para permitir que los modelos determinen su relevancia contemporánea.

## 3.2 Ingeniería de Características

### 3.2.1 Filosofía General

Las variables en bruto raramente sirven como predictores efectivos en su forma original. Siguiendo prácticas establecidas en finanzas cuantitativas (Gu et al., 2020), se transforman las 92 variables base en 647 características a través de un pipeline sistemático de ingeniería de características. Este proceso busca extraer información predictiva que puede estar latente en las variables originales, capturar dinámicas temporales y relaciones cross-seccionales, y normalizar las características para facilitar el aprendizaje del modelo.

### 3.2.2 Cálculo de Retornos Multi-Horizonte

La primera categoría de transformación involucra el cálculo de retornos logarítmicos sobre múltiples horizontes temporales:

$$r_{t,h} = \ln(P_t/P_{t-h}) \times 100 \quad (5)$$

donde  $P_t$  es el precio en el tiempo  $t$  y  $h \in \{1, 5, 21, 63, 126, 252\}$  días de negociación. Estos horizontes corresponden aproximadamente a: diario (1), semanal (5), mensual (21), trimestral (63), semestral (126), y anual (252).

Este enfoque multi-horizonte permite a los modelos identificar señales que pueden ser invisibles en cualquier frecuencia única. Por ejemplo, el momentum a 12 meses puede tener poder predictivo diferente al momentum a 1 mes.

### 3.2.3 Indicadores Técnicos

La segunda categoría comprende indicadores técnicos calculados sobre los datos del mercado de renta variable:

**RSI (Relative Strength Index):** Indicador de momentum de 14 períodos que oscila entre 0 y 100:

$$RSI = 100 - \frac{100}{1 + RS} \quad (6)$$

donde  $RS = \frac{\text{Ganancia Promedio}}{\text{Pérdida Promedio}}$  sobre los últimos 14 períodos.

**MACD:** Indicador de seguimiento de tendencia y momentum:

$$MACD = EMA_{12} - EMA_{26} \quad (7)$$

$$\text{Signal} = EMA_9(MACD) \quad (8)$$

$$\text{Histogram} = MACD - \text{Signal} \quad (9)$$

**Bandas de Bollinger:** Medida de volatilidad relativa:

$$\%B = \frac{P - BB_{inferior}}{BB_{superior} - BB_{inferior}} \quad (10)$$

donde las bandas se calculan como  $\pm 2$  desviaciones estándar de una media móvil de 20 períodos.

**ATR (Average True Range):** Medida de volatilidad basada en rangos diarios:

$$TR = \max(H - L, |H - C_{prev}|, |L - C_{prev}|) \quad (11)$$

$$ATR = EMA_{14}(TR) \quad (12)$$

### 3.2.4 Características del Sistema Triple Screen

La tercera categoría implementa el sistema Triple Screen de Elder como características cuantitativas:

**Indicadores Semanales:** MACD calculado sobre datos agregados a 5 días para capturar la tendencia estratégica. Incluimos el valor del MACD, la línea de señal, el histograma, y la pendiente del histograma.

**Indicadores Diarios:** Force Index (períodos de 2 y 13 días) y Elder Ray (Bull Power y Bear Power) calculados sobre datos diarios para identificar puntos de entrada tácticos.

**Sistema Impulso:** Clasificación de cada barra como verde (alcista), rojo (bajista), o azul (neutral) según las reglas descritas en la Sección 2.4.

**Señales Combinadas:** Variables binarias que indican setup de compra (tendencia semanal alcista + osciladores diarios sobrevendidos), setup de venta (tendencia semanal bajista + osciladores diarios sobrecomprados), y señal final Triple Screen.

### 3.2.5 Características de Superficie de Volatilidad

La cuarta categoría construye características de la estructura de términos del VIX:

**Pendiente de estructura de términos:** Diferencias entre puntos de la curva (VIX - VIX3M, VIX3M - VIX6M) capturando expectativas sobre la evolución de la volatilidad.

**Z-scores de VIX:** VIX relativo a su distribución histórica de 21 y 63 días, identificando si los niveles actuales son inusualmente altos o bajos.

**Indicadores de régimen:** Variables binarias para  $VIX > 20$  (volatilidad elevada) y  $VIX > 30$  (volatilidad extrema).

**Cambios porcentuales:** Variaciones del VIX sobre horizontes de 1, 5, y 21 días.

### 3.2.6 Estimadores de Volatilidad OHLC

La quinta categoría implementa los estimadores de volatilidad descritos en la Sección 2.5:

Calculamos los estimadores de Parkinson, Garman-Klass, Rogers-Satchell, y Yang-Zhang sobre ventanas móviles de 21 y 63 días. Adicionalmente, construimos características de microestructura incluyendo:

**Rango intradía:**  $(H - L)/C$  como porcentaje del precio.

**Localización del cierre:**  $(C - L)/(H - L)$  indicando dónde cerró el precio dentro del rango del día.

**Gap overnight:**  $|O_t - C_{t-1}|/C_{t-1}$  capturando la magnitud de la información overnight.

**Cuerpo de vela:**  $|C - O|/(H - L)$  relación entre el movimiento apertura-cierre y el rango total.

### 3.2.7 Correlaciones Cross-Asset

La sexta categoría crea características de correlación entre clases de activos, calculando correlaciones móviles de 21 días entre:

- Renta variable - Renta fija (SPY-TLT)
- Renta variable - Oro (SPY-GLD)
- Renta variable - Petróleo (SPY-CL1)
- Dólar - Renta variable (DXY-SPY)

Las correlaciones variables en el tiempo contienen información sobre regímenes de mercado y apetito por riesgo. Durante periodos de “risk-off”, las correlaciones entre activos de riesgo típicamente aumentan mientras que las correlaciones con activos refugio como bonos y oro se vuelven más negativas.

### 3.2.8 Rezagos y Estadísticas Móviles

Finalmente, se incluyen valores rezagados (1, 2, 3, 5, y 7 días) de variables clave y estadísticas móviles (media y desviación estándar sobre ventanas de 5, 10, 21, y 63 días) para capturar dinámicas autorregresivas y características distribucionales locales.

## 3.3 Variable Objetivo y División de Muestra

### 3.3.1 Definición del Objetivo de Predicción

El objetivo de predicción es el retorno en exceso a un día del S&P 500 sobre la tasa libre de riesgo:

$$y_t = r_{t+1}^{SPY} - r_{t+1}^f \quad (13)$$

donde  $r_{t+1}^{SPY}$  denota el retorno del S&P 500 realizado en el día  $t + 1$  y  $r_{t+1}^f$  es la tasa libre de riesgo correspondiente (tasa de fondos federales dividida por 252).

La formulación en términos de retornos en exceso es estándar en la literatura de valoración de activos y tiene la interpretación económica de medir el rendimiento sobre lo que podría obtenerse invirtiendo en un activo libre de riesgo.

### 3.3.2 División Temporal de la Muestra

Para asegurar una evaluación rigurosa fuera de muestra, se emplea una división temporal sin aleatorización. El conjunto de entrenamiento comprende el primer 80 % de las observaciones (5,205 días de negociación desde enero 2000 hasta principios de octubre 2020), mientras que el conjunto de prueba contiene el 20 % restante (1,302 días de negociación desde octubre 2020 hasta diciembre 2025).

Esta división asegura que todo el entrenamiento de modelos y selección de hiperparámetros ocurre exclusivamente sobre datos que preceden temporalmente al período de evaluación, eliminando el sesgo de look-ahead que invalida muchos estudios de backtesting.

Es importante notar que el período de prueba incluye condiciones de mercado diversas: la recuperación post-COVID de 2020-2021, el mercado alcista de 2023-2024, y varios episodios de corrección. Esta diversidad proporciona una evaluación más robusta que períodos de prueba dominados por una sola condición de mercado.

## 3.4 Especificaciones de Modelos

### 3.4.1 Panorama de Modelos Evaluados

Evalúamos 21 modelos abarcando cuatro categorías metodológicas, proporcionando una comparación comprehensiva de enfoques tradicionales y modernos.

### 3.4.2 Modelos de Aprendizaje Automático Tradicional

Esta categoría incluye métodos lineales regularizados y métodos de ensamble basados en árboles:

**Ridge Regression:** Regresión lineal con penalización L2 ( $\alpha ||w||_2^2$ ), que shrinkea los coeficientes hacia cero sin eliminarlos completamente. Hiperparámetro  $\alpha$  seleccionado mediante validación cruzada temporal.

**Lasso Regression:** Regresión lineal con penalización L1 ( $\alpha||w||_1$ ), que puede eliminar características completamente al shrinkear algunos coeficientes a exactamente cero. Proporciona selección de características implícita.

**ElasticNet:** Combinación de penalizaciones L1 y L2, controlada por el parámetro de mezcla  $l_1\_ratio$ . Combina las propiedades de Ridge y Lasso.

**Random Forest:** Ensamble de árboles de decisión entrenados sobre subconjuntos aleatorios de datos y características. Captura relaciones no lineales e interacciones entre variables sin especificación explícita.

**Gradient Boosting:** Construcción secuencial de árboles donde cada árbol corrige los errores de los anteriores. Típicamente logra mayor precisión que Random Forest pero es más susceptible a sobreajuste.

**XGBoost:** Implementación optimizada de gradient boosting con regularización incorporada y manejo eficiente de valores faltantes.

**LightGBM:** Implementación alternativa de gradient boosting con crecimiento de árbol leaf-wise (vs. level-wise en XGBoost) y técnicas de muestreo para mayor velocidad.

### 3.4.3 Modelos Clásicos de Series Temporales

**AutoARIMA:** Selección automática de especificación ARIMA óptima (p,d,q) basada en criterios de información (AIC/BIC). Captura estructura autorregresiva y de media móvil.

**Exponential Smoothing:** Familia de métodos que asignan pesos exponencialmente decrecientes a observaciones pasadas. Incluye variantes con y sin componentes de tendencia y estacionalidad.

**Prophet:** Modelo desarrollado por Meta (Taylor & Letham, 2018) que descompone series temporales en tendencia, estacionalidad, y efectos de días festivos. Diseñado para ser robusto a datos faltantes y cambios de tendencia, con especial énfasis en interpretabilidad.

### 3.4.4 Modelos de Aprendizaje Automático para Series Temporales (Darts)

Implementaciones optimizadas para contextos de series temporales con manejo apropiado de dependencias temporales:

**DARTS\_LightGBM, DARTS\_XGBoost, DARTS\_RandomForest:** Versiones de los métodos basados en árboles integrados en el framework Darts con ingeniería de características temporal automática.

### 3.4.5 Modelos de Aprendizaje Profundo

**DLinear:** Arquitectura simple propuesta por [Zeng et al. \(2023\)](#) que descompone la serie temporal en componentes de tendencia y residuo, aplicando transformaciones lineales separadas a cada componente. A pesar de su simplicidad, ha demostrado superar arquitecturas más complejas en benchmarks de pronóstico.

**NLinear:** Variante de DLinear que normaliza la entrada restando el último valor de la secuencia antes de la predicción, ayudando a manejar distributional shift.

**N-BEATS:** Arquitectura basada en bloques que aprende bases de expansión para tendencia y estacionalidad. Diseñada específicamente para pronóstico de series temporales.

**N-HiTS:** Extensión de N-BEATS propuesta por [Challu et al. \(2023\)](#) que incorpora muestreo jerárquico para capturar patrones a múltiples escalas temporales con mayor eficiencia computacional.

**TCN (Temporal Convolutional Network):** Red convolucional con dilataciones causales ([Bai et al., 2018](#)) que captura dependencias de largo alcance manteniendo la causalidad temporal. Supera a arquitecturas recurrentes en múltiples benchmarks de secuencias.

**TFT (Temporal Fusion Transformer):** Arquitectura de atención diseñada por [Lim et al. \(2021\)](#) para series temporales con múltiples covariables. Incorpora mecanismos de selección de variables y atención temporal interpretable.

**TiDE:** Modelo basado en codificador-decodificador con capas densas para pronóstico de largo horizonte.

**TSMixer:** Arquitectura basada en MLP que mezcla información a través de la dimensión temporal y de características.

### 3.4.6 Configuración de Entrenamiento

Para los modelos de aprendizaje profundo, se emplea una configuración consistente: longitud de secuencia de entrada de 30 días, entrenamiento por 50 épocas con early stopping basado en pérdida de validación, y covariables extraídas de el conjunto de 647 características. La selección de hiperparámetros para modelos tradicionales emplea validación cruzada temporal con 5 folds.

## 3.5 Dimensionamiento de Posiciones y Retornos de Estrategia

### 3.5.1 Estrategia LONG-ONLY de Posiciones Discretas

A diferencia de enfoques académicos que emplean posiciones continuas o permiten ventas en corto, se implementa una estrategia LONG-ONLY de posiciones discretas que refleja instrumentos



realmente disponibles en el mercado y reconoce las limitaciones prácticas de las posiciones cortas en índices bursátiles. La estrategia utiliza tres niveles de exposición:

- **UPRO (ProShares UltraPro S&P500):** Exposición 3x larga al S&P 500
- **SPY (SPDR S&P 500 ETF):** Exposición 1x larga al S&P 500
- **Efectivo:** Posición neutral, gana la tasa libre de riesgo

La decisión de excluir posiciones cortas tiene fundamentos tanto teóricos como empíricos. Primero, la prima de renta variable históricamente positiva implica que las posiciones cortas sistemáticas en índices enfrentan un viento en contra estructural. Segundo, los costos de préstamo de valores y el riesgo de “short squeeze” introducen fricciones asimétricas que reducen la viabilidad práctica de estrategias cortas. Tercero, [Frazzini & Pedersen \(2014\)](#) demuestran que el apalancamiento aplicado a la prima de renta variable puede generar rendimientos ajustados por riesgo superiores cuando se gestiona apropiadamente, sugiriendo que la exposición variable al lado largo captura mejor las oportunidades de mercado.

### 3.5.2 Sistema de Umbrales por Percentiles

Convertimos las predicciones continuas del modelo a posiciones discretas mediante un sistema de umbrales basado en percentiles de la distribución histórica de predicciones:

$$\text{posición}_t = \begin{cases} +3 & \text{si } \hat{y}_t > Q_{q_{3x}} \\ +1 & \text{si } Q_{q_{1x}} < \hat{y}_t \leq Q_{q_{3x}} \\ 0 & \text{si } \hat{y}_t \leq Q_{q_{1x}} \end{cases} \quad (14)$$

donde  $Q_q$  denota el percentil  $q$  de las predicciones sobre una ventana móvil de 63 días de negociación (aproximadamente un trimestre). Los parámetros  $(q_{3x}, q_{1x})$  son optimizados independientemente para cada modelo mediante grid search sobre el conjunto de entrenamiento, típicamente explorando valores en el rango  $[5, 50]$  para  $q_{1x}$  y  $[10, 60]$  para  $q_{3x}$ .

Este sistema de umbrales tiene varias propiedades deseables: (1) diferentes modelos pueden optimizar sus propios umbrales reconociendo que las distribuciones de predicciones varían según la metodología, (2) el uso de percentiles móviles proporciona adaptación automática a cambios en el régimen de mercado, y (3) la estructura jerárquica (efectivo  $\rightarrow$  1x  $\rightarrow$  3x) permite calibrar el nivel de agresividad de la estrategia.

### 3.5.3 Cálculo de Retornos de Estrategia

Los retornos de la estrategia se calculan como:

$$r_t^{estrategia} = r_t^f + \text{posición}_t \times (r_t^{SPY} - r_t^f) - \text{costos}_t \quad (15)$$

Esta formulación anida los siguientes casos:

- Posición = +3: replica aproximadamente el retorno de UPRO (3x largo)
- Posición = +1: replica el retorno de SPY (1x largo)
- Posición = 0: gana la tasa libre de riesgo (efectivo)

Los costos de transacción se aplican únicamente cuando hay cambio de posición, reflejando los spreads bid-ask de los instrumentos: 0.05 % para UPRO y 0.02 % para SPY.

### 3.5.4 Justificación del Apalancamiento

El uso de apalancamiento 3x puede parecer agresivo desde una perspectiva de gestión de riesgo tradicional. Sin embargo, varios argumentos respaldan esta elección:

**Prima de renta variable persistente:** La evidencia histórica muestra que la prima de renta variable—el exceso de retorno de las acciones sobre activos libres de riesgo—ha sido consistentemente positiva en horizontes largos. [Mehra & Prescott \(1985\)](#) documentaron esta “puzzle” que persiste hasta hoy.

**Criterio de Kelly:** La teoría de crecimiento óptimo de capital, formalizada por [Kelly \(1956\)](#) y extendida a mercados financieros por [Thorp \(2006\)](#), sugiere que el apalancamiento óptimo para maximizar el crecimiento logarítmico del capital es  $f^* = \mu/\sigma^2$ , donde  $\mu$  es el retorno esperado y  $\sigma^2$  la varianza. Para la prima de renta variable histórica del S&P 500 ( 7 % anual) y volatilidad ( 15 %), el apalancamiento óptimo de Kelly es aproximadamente 3x.

**Control de drawdown:** El riesgo del apalancamiento se mitiga mediante el sistema de control dinámico de drawdown, descrito en la siguiente sección, que reduce automáticamente la exposición cuando las pérdidas acumuladas alcanzan umbrales predeterminados.

## 3.6 Métricas de Desempeño

Evaluamos las estrategias usando métricas estándar en la industria de hedge funds:

**Retorno Acumulado:** Retorno total sobre el período de prueba, calculado como  $\prod_t (1 + r_t) - 1$ .

**Ratio de Sharpe:** Retorno ajustado por riesgo anualizado:

$$\text{Sharpe} = \frac{\bar{r} - r_f}{\sigma_r} \times \sqrt{252} \quad (16)$$

**Drawdown Máximo:** La mayor caída de pico a valle durante el período de evaluación:

$$\text{MaxDD} = \min_t \left( \frac{V_t}{\max_{s \leq t} V_s} - 1 \right) \quad (17)$$

**Ratio de Calmar:** Retorno anualizado dividido por drawdown máximo, midiendo el retorno por unidad de riesgo de cola.

**Ratio de Sortino:** Similar al Sharpe pero usando solo desviación negativa en el denominador:

$$\text{Sortino} = \frac{\bar{r} - r_f}{\sigma_{down}} \times \sqrt{252} \quad (18)$$

**Precisión Direccional:** Porcentaje de días donde la dirección predicha coincide con la dirección realizada.

**Turnover:** Cambio promedio diario de posición, indicando la actividad de trading requerida.

## 4. Resultados Empíricos

### 4.1 Resumen de Hallazgos Principales

Los 23 modelos entrenados fueron evaluados durante el período de prueba (octubre 2020 – diciembre 2025, 1,301 días de trading) utilizando la estrategia LONG-ONLY de posiciones discretas. Los hallazgos principales son:

- **4 de 23 modelos superan al benchmark:** Ridge (318.8 %), GradientBoosting (267.5 %), CNN\_LSTM (207.1 %), y BiGRU (127.7 %) superan el retorno del SPY buy-and-hold (102.2 %).
- **El modelo Ridge logra el mejor desempeño:** Con un ratio de Sharpe de 0.93 y un alfa de 216 puntos porcentuales sobre el benchmark, demuestra que modelos simples pueden superar arquitecturas complejas.
- **La diversidad metodológica valida la robustez:** Los modelos exitosos incluyen regularización lineal (Ridge), gradient boosting (GradientBoosting), y deep learning híbrido (CNN\_LSTM, BiGRU), sugiriendo que la señal predictiva puede capturarse por enfoques distintos.
- **El enfoque conservador genera alfa:** El modelo Ridge permanece en efectivo el 62 % del tiempo, tomando posición apalancada solo en momentos de alta convicción, lo que reduce drawdowns mientras captura tendencias alcistas.

## 4.2 Aplicación Interactiva para Exploración de Resultados

### Exploración Detallada de Resultados

Para facilitar la comprensión profunda del proceso de backtesting y los resultados obtenidos, se ha desarrollado una **aplicación web interactiva** desplegada en Amazon Web Services (AWS). Esta herramienta permite explorar en detalle:

- Curvas de equity y drawdown para cada uno de los 23 modelos
- Distribución de posiciones día a día
- Métricas detalladas de desempeño (Sharpe, Sortino, Calmar, etc.)
- Comparación lado a lado entre modelos
- Registro de cada trade ejecutado durante el período de prueba
- Análisis de regímenes de mercado

**Acceso:** <http://3.20.234.106>

*La aplicación está alojada en una instancia EC2 de AWS y proporciona visualizaciones interactivas de todo el proceso de backtesting, permitiendo al lector profundizar en los resultados más allá de lo presentado en este documento.*

## 4.3 Interpretación de los Resultados

Los resultados empíricos revelan tres patrones fundamentales:

**1. La dificultad de superar al mercado es real:** Solo 4 de 23 modelos logran superar al benchmark SPY en retorno total. Esto es consistente con la literatura sobre eficiencia de mercado y valida la premisa de que generar alfa sistemático es inherentemente difícil.

**2. La direccionalidad es más importante que la precisión:** Los modelos exitosos no predicen valores exactos de retorno, sino que capturan la dirección del mercado con suficiente precisión para informar decisiones de posicionamiento apalancado.

**3. El enfoque conservador genera valor:** El modelo Ridge, que permanece en efectivo el 62 % del tiempo, demuestra que la preservación de capital durante períodos de incertidumbre es tan importante como la captura de tendencias alcistas.

*Para análisis detallados de curvas de equity, distribución de posiciones, métricas por modelo, y registro de trades, se invita al lector a explorar la aplicación interactiva en:*

<http://3.20.234.106>

## 5. La Paradoja del Directional Accuracy

Un hallazgo contraintuitivo de este estudio es que el Directional Accuracy (DA)—la métrica más comúnmente utilizada para evaluar modelos de predicción de dirección de mercado—no es un predictor confiable de rentabilidad en estrategias de trading.

### 5.1 El Hallazgo Contraintuitivo

#### 5.1.1 Intuición Naïve vs Realidad

La intuición convencional sugiere que un modelo que predice correctamente la dirección del mercado con mayor frecuencia debería generar mayores retornos. Sin embargo, nuestros resultados empíricos contradicen esta suposición:

$$\rho(\text{DA}, \text{Return}) = -0,14 \quad (19)$$

La correlación entre Directional Accuracy y retorno total es **ligeramente negativa**, indicando que modelos con mayor DA no necesariamente generan mejores retornos.

#### 5.1.2 Evidencia Empírica

Cuadro 1: Paradoja DA vs Retorno: Casos Ilustrativos

| Modelo               | DA General | Retorno Total | Categoría                 |
|----------------------|------------|---------------|---------------------------|
| GARCH                | 54.3 %     | -6.2 %        | Alto DA, Retorno Negativo |
| Theta                | 54.6 %     | -19.2 %       | Alto DA, Retorno Negativo |
| ExponentialSmoothing | 53.8 %     | -4.6 %        | Alto DA, Retorno Negativo |
| Ridge                | 52.7 %     | +318.8 %      | DA Medio, Mejor Retorno   |
| CNN_LSTM             | 50.8 %     | +207.1 %      | DA Bajo, Alto Retorno     |
| GradientBoosting     | 51.2 %     | +267.5 %      | DA Medio, Alto Retorno    |

*Nota: DA calculado como porcentaje de días donde la predicción de dirección coincide con el movimiento realizado del mercado.*

## 5.2 Explicación de la Paradoja

### 5.2.1 El DA Trata Todos los Días como Iguales

El Directional Accuracy asigna el mismo peso a cada predicción, independientemente de:

- La magnitud del movimiento del mercado
- La posición que tomó el modelo




Figura 1: La Paradoja del Directional Accuracy. Panel izquierdo: Scatter plot de DA vs Retorno Total mostrando correlación negativa ( $\rho = -0,14$ ). Panel derecho: Comparación de DA General vs DA@3x (hit rate en posiciones apalancadas) para modelos seleccionados. Los retornos se indican sobre cada par de barras.

- El momento del ciclo de mercado

### Ejemplo ilustrativo:

D\`ia 1: Mercado +0.1% | Modelo predice correctamente | +

D\`ia 2: Mercado +0.1% | Modelo predice correctamente | +

D\`ia 3: Mercado -3.0% | Modelo falla | -

DA = 66.7% (2/3 aciertos)

Pero P&L = NEGATIVO (la p\`erdida del d\`ia 3 supera las ganancias)

### 5.2.2 Lo Que Realmente Importa: Asimetría Condicional

La rentabilidad de una estrategia de trading depende de tres factores que el DA no captura:

1. **Cuándo aciertas:** Acertar en días de movimientos grandes importa más que acertar en días tranquilos.
2. **Cuánto apuestas:** El tamaño de la posición cuando aciertas vs cuando fallas determina el P&L.
3. **Asimetría ganancia/pérdida:** El ratio entre ganancia promedio y pérdida promedio (Profit Factor).

### 5.3 El Indicador DA@3x: Una Métrica Más Relevante

Proponemos el indicador **DA@3x** (Directional Accuracy en posiciones apalancadas) como una métrica más predictiva de rentabilidad:

$$DA@3x = \frac{\sum_{t: \text{pos}_t=3} \mathbf{1}[r_t^{mkt} > 0]}{\sum_t \mathbf{1}[\text{pos}_t = 3]} \quad (20)$$

donde  $\mathbf{1}[\cdot]$  es la función indicadora.

### 5.3.1 Comparación DA vs DA@3x

Cuadro 2: DA General vs DA@3x: El Predictor de Rentabilidad

| Modelo           | DA General | DA@3x  | % Tiempo 3x | Retorno  |
|------------------|------------|--------|-------------|----------|
| Ridge            | 52.7 %     | 58.3 % | 29.5 %      | +318.8 % |
| GradientBoosting | 51.2 %     | 56.8 % | 84.6 %      | +267.5 % |
| CNN_LSTM         | 50.8 %     | 55.8 % | 33.2 %      | +207.1 % |
| BiGRU            | 52.1 %     | 54.9 % | 28.7 %      | +127.7 % |
| GARCH            | 54.3 %     | 55.2 % | 25.8 %      | -6.2 %   |
| Theta            | 54.6 %     | 52.1 % | 15.3 %      | -19.2 %  |

*Nota: DA@3x = hit rate cuando el modelo está en posición 3x (UPRO). % Tiempo 3x indica qué fracción del período el modelo estuvo en posición apalancada.*

### 5.3.2 Interpretación

Los modelos rentables se distinguen por:

1. **Mayor DA@3x que DA general:** Ridge tiene 52.7 % DA general pero 58.3 % DA@3x—acierta más cuando apuesta fuerte.
2. **Selectividad en el apalancamiento:** Ridge solo usa posición 3x el 29.5 % del tiempo, reservándola para señales de alta confianza.
3. **Protección en incertidumbre:** Cuando no tiene confianza, permanece en cash (62 % del tiempo para Ridge).

En contraste, los modelos con alto DA general pero bajo DA@3x (como Theta con 54.6 % vs 52.1 %) tienden a “acertar en los días que no importan”.

## 5.4 Implicaciones para el Diseño de Estrategias

### 5.4.1 No Optimizar por DA

Este hallazgo tiene implicaciones importantes para el diseño de estrategias de trading:

**Implicación Clave**

Optimizar un modelo para maximizar Directional Accuracy puede ser contraproducente. En su lugar, se debe optimizar por métricas que capturen la asimetría entre ganancias y pérdidas condicionales al tamaño de la posición.

*5.4.2 Métricas Alternativas Recomendadas*

En lugar de DA, recomendamos evaluar modelos de trading usando:

1. **Sharpe Ratio:** Captura el trade-off riesgo-retorno
2. **Profit Factor:** Ratio entre ganancia promedio y pérdida promedio por trade
3. **DA@3x:** Hit rate en posiciones de alta convicción
4. **Retorno Neto:** La métrica final que realmente importa

*5.4.3 El Valor de la Selectividad*

El éxito del modelo Ridge ilustra el valor de la selectividad:

- **No predice mejor en general:** DA = 52.7%, apenas sobre el azar
- **Sabe cuándo apostar fuerte:** DA@3x = 58.3 %, significativamente mejor
- **Sabe cuándo no apostar:** 62 % del tiempo en cash
- **Resultado:** +318.8 % de retorno, el mejor de todos los modelos

**5.5 Conexión con la Literatura**

Este hallazgo es consistente con la literatura sobre trading y gestión de portafolios:

**López de Prado (2018)** argumenta que las métricas tradicionales de evaluación de modelos predictivos (como  $R^2$  o accuracy) son inadecuadas para evaluar estrategias de trading, donde lo que importa es la rentabilidad ajustada por riesgo.

**La paradoja de Grossman-Stiglitz (Grossman & Stiglitz, 1980)** sugiere que en mercados eficientes, la capacidad predictiva marginal (como un DA ligeramente superior al 50 %) puede ser suficiente para generar alfa si se combina con una estrategia de posicionamiento inteligente.

**El criterio de Kelly (Kelly, 1956)** formaliza la idea de que el tamaño óptimo de la apuesta depende no solo de la probabilidad de ganar, sino también de las magnitudes de ganancia y pérdida—exactamente lo que el DA no captura.



## 5.6 Resumen de la Sección

### Resumen: La Paradoja del DA

1. El Directional Accuracy (DA) no es un predictor confiable de rentabilidad ( $\rho = -0,14$ )
2. Modelos con  $DA > 54\%$  generaron retornos negativos
3. Modelos con  $DA \approx 51\text{-}52\%$  generaron los mejores retornos
4. El indicador  $DA@3x$  (hit rate en posiciones apalancadas) es más predictivo
5. Los modelos rentables se caracterizan por **selectividad**, no por **frecuencia** de aciertos
6. Implicación: Optimizar por DA puede ser contraproducente para estrategias de trading

## 6. Validación Estadística

La evaluación del rendimiento de estrategias de trading requiere rigor estadístico más allá de simples comparaciones de retornos. Esta sección presenta los tests estadísticos aplicados para validar la significancia de los resultados.

### 6.1 Bootstrap de Sharpe Ratios

#### 6.1.1 Metodología

El Sharpe Ratio estándar no provee información sobre la precisión de la estimación. Utilizamos bootstrap no paramétrico (Efron, 1979) para construir intervalos de confianza:

1. Generar  $B = 10,000$  muestras bootstrap con reemplazo de los retornos diarios
2. Calcular el Sharpe Ratio para cada muestra bootstrap:  $\hat{S}_b$ ,  $b = 1, \dots, B$
3. Construir el intervalo de confianza al 95 % usando percentiles:  $[\hat{S}_{0,025}, \hat{S}_{0,975}]$

#### 6.1.2 Corrección de Ledoit-Wolf

Aplicamos la corrección de Ledoit & Wolf (2008) para muestras finitas y autocorrelación en los retornos:

$$SE(\hat{S}) = \sqrt{\frac{1 + \frac{\hat{S}^2}{2} \cdot (1 + \hat{\rho}_1)}{T \cdot (1 - \hat{\rho}_1)}} \quad (21)$$

donde  $\hat{\rho}_1$  es la autocorrelación de primer orden de los retornos y  $T$  el número de observaciones.

### 6.1.3 Resultados: Intervalos de Confianza

Cuadro 3: Intervalos de Confianza del Sharpe Ratio (Bootstrap 95 %)

| Modelo           | Sharpe | IC 95 % Inf | IC 95 % Sup | P(S>0) | P(S>SPY) |
|------------------|--------|-------------|-------------|--------|----------|
| Ridge            | 0.932  | 0.612       | 1.248       | 99.8 % | 58.2 %   |
| CNN_LSTM         | 0.744  | 0.428       | 1.056       | 99.1 % | 42.6 %   |
| BiGRU            | 0.680  | 0.374       | 0.982       | 98.4 % | 36.1 %   |
| GradientBoosting | 0.589  | 0.214       | 0.960       | 96.8 % | 28.3 %   |
| N-BEATS          | 0.511  | 0.198       | 0.820       | 94.7 % | 18.9 %   |
| SPY (B&H)        | 0.882  | 0.584       | 1.176       | 99.6 % | —        |

= probabilidad de Sharpe positivo.  $P(S>SPY)$  = probabilidad de superar el Sharpe del benchmark. IC calculados con 10,000 iteraciones bootstrap.

### 6.1.4 Interpretación

Los intervalos de confianza revelan que:

- **Ridge**: Con 99.8 % de probabilidad, tiene Sharpe positivo. Sin embargo, solo 58.2 % de probabilidad de superar al benchmark SPY.
- **CNN-LSTM**: Sharpe positivo con 99.1 % de confianza, pero solo 42.6 % de superar SPY.
- **Solapamiento significativo**: Los intervalos de confianza de los mejores modelos se solapan sustancialmente con el del benchmark, indicando que la superioridad no es estadísticamente conclusiva.

## 6.2 Test de Diebold-Mariano

### 6.2.1 Formulación

El test de [Diebold & Mariano \(1995\)](#) evalúa si la diferencia en error de predicción entre dos modelos es estadísticamente significativa:

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \quad (22)$$

donde  $d_t = L(e_{1,t}) - L(e_{2,t})$  es la diferencia en pérdida entre los dos modelos en el tiempo  $t$ , y  $\hat{V}(\bar{d})$  es un estimador consistente de la varianza de  $\bar{d}$  que considera autocorrelación.

Bajo la hipótesis nula de igual capacidad predictiva,  $DM \xrightarrow{d} N(0, 1)$ .

### 6.2.2 Resultados: Comparación con Benchmark

Cuadro 4: Test de Diebold-Mariano vs Modelo Naive (Retorno = 0)

| Modelo           | Estadístico DM | p-valor | Significativo (5 %) |
|------------------|----------------|---------|---------------------|
| Ridge            | 2.847          | 0.0044  | Sí                  |
| GradientBoosting | 1.923          | 0.0545  | No                  |
| CNN_LSTM         | 2.412          | 0.0159  | Sí                  |
| BiGRU            | 2.156          | 0.0311  | Sí                  |
| RandomForest     | 1.284          | 0.1992  | No                  |

*indica que el modelo supera al benchmark naive. Corrección Newey-West con 5 rezagos para autocorrelación.*

## 6.3 Model Confidence Set (MCS)

### 6.3.1 Metodología

El Model Confidence Set de [Hansen et al. \(2011\)](#) identifica el conjunto de modelos que contiene al mejor modelo verdadero con una probabilidad dada:

1. Comenzar con el conjunto completo de modelos  $\mathcal{M}_0$
2. Testear la hipótesis de igual capacidad predictiva (EPA) sobre  $\mathcal{M}_0$
3. Si EPA se rechaza, eliminar el peor modelo
4. Repetir hasta que EPA no se rechace

El MCS final  $\hat{\mathcal{M}}_\alpha^*$  contiene todos los modelos que no pueden ser descartados como inferiores al nivel  $\alpha$ .

### 6.3.2 Resultados

Al nivel de confianza del 90 %, el Model Confidence Set contiene:

$$\hat{\mathcal{M}}_{0,10}^* = \{\text{Ridge}, \text{CNN-LSTM}, \text{BiGRU}, \text{GradientBoosting}\} \quad (23)$$

Esto indica que estos cuatro modelos no pueden distinguirse estadísticamente como superiores entre sí, pero sí son estadísticamente superiores al resto.

## 6.4 Test de Clark-West

### 6.4.1 Formulación

El test de [Clark & West \(2007\)](#) es apropiado para comparar modelos anidados (nested models):

$$CW_t = (e_{1,t}^2 - e_{2,t}^2) + (e_{1,t} - e_{2,t})^2 \quad (24)$$

donde el término de ajuste  $(e_{1,t} - e_{2,t})^2$  corrige el sesgo que surge cuando el modelo restringido es verdadero.

### 6.4.2 Aplicación

Comparamos cada modelo contra el modelo naive (predicción = promedio histórico):

Cuadro 5: Test de Clark-West vs Modelo de Media Histórica

| Modelo           | CW Stat | p-valor (1-cola) | Conclusión    |
|------------------|---------|------------------|---------------|
| Ridge            | 2.31    | 0.010            | Rechaza $H_0$ |
| CNN_LSTM         | 1.89    | 0.029            | Rechaza $H_0$ |
| BiGRU            | 1.67    | 0.047            | Rechaza $H_0$ |
| GradientBoosting | 1.52    | 0.064            | Marginal      |

*Nota:  $H_0$ : el modelo extendido no tiene capacidad predictiva superior al modelo restringido. Test de una cola dado que la hipótesis alternativa es unidireccional.*

## 6.5 Análisis de Overfitting

### 6.5.1 Comparación In-Sample vs Out-of-Sample

Una señal de overfitting es una degradación significativa del rendimiento entre el período de entrenamiento y prueba:

Cuadro 6: Degradación del Sharpe Ratio: Entrenamiento vs Prueba

| Modelo       | Sharpe Train | Sharpe Test | Degradación |
|--------------|--------------|-------------|-------------|
| Ridge        | 1.12         | 0.93        | -17 %       |
| CNN_LSTM     | 0.98         | 0.74        | -24 %       |
| RandomForest | 1.45         | 0.39        | -73 %       |
| XGBoost      | 1.89         | 0.16        | -92 %       |

*Nota: Degradación = (Sharpe Test - Sharpe Train) / Sharpe Train. Mayor degradación sugiere mayor overfitting.*

Los resultados revelan:

- **Ridge:** Mínima degradación (-17 %), sugiriendo buen ajuste de regularización.

- **RandomForest y XGBoost:** Degradación severa (73-92 %), indicando overfitting significativo a pesar de validación cruzada.

### 6.5.2 Corrección por Multiple Testing

Con 23 modelos evaluados, el riesgo de falsos positivos por comparaciones múltiples es sustancial. Aplicamos la corrección de Bonferroni:

$$\alpha_{\text{Bonferroni}} = \frac{\alpha}{m} = \frac{0,05}{23} \approx 0,0022 \quad (25)$$

Bajo este criterio estricto, solo Ridge mantiene significancia estadística (p-valor DM = 0.0044).

### 6.5.3 False Discovery Rate (FDR)

Alternativamente, el procedimiento de [Benjamini & Hochberg \(1995\)](#) controla la proporción esperada de falsos positivos entre los rechazos:

1. Ordenar los p-valores:  $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$
2. Encontrar el mayor  $k$  tal que  $p_{(k)} \leq \frac{k}{m} \cdot q$
3. Rechazar  $H_0$  para los  $k$  menores p-valores

Con  $q = 0,10$  (FDR del 10 %), identificamos 4 modelos significativos: Ridge, CNN-LSTM, BiGRU, y AutoARIMA.

## 6.6 Resumen de Validación Estadística

Cuadro 7: Resumen de Tests Estadísticos por Modelo

| Modelo           | P(S>0) | DM Test | CW Test | MCS | FDR |
|------------------|--------|---------|---------|-----|-----|
| Ridge            | 99.8 % | ✓       | ✓       | ✓   | ✓   |
| CNN_LSTM         | 99.1 % | ✓       | ✓       | ✓   | ✓   |
| BiGRU            | 98.4 % | ✓       | ✓       | ✓   | ✓   |
| GradientBoosting | 96.8 % | –       | –       | ✓   | –   |

✓ = pasa el test al nivel de significancia estándar (5 % o 10 % según el test). – = no pasa.

## 6.7 Conclusiones de la Validación

La validación estadística proporciona evidencia mixta:

1. **Evidencia positiva:** Ridge, CNN-LSTM y BiGRU demuestran capacidad predictiva estadísticamente significativa bajo múltiples tests.

2. **Cautela necesaria:** Los intervalos de confianza del Sharpe Ratio se solapan sustancialmente con el benchmark, sugiriendo que la superioridad no es robusta.
3. **Overfitting parcial:** Modelos ensemble (RandomForest, XGBoost) muestran degradación severa entre entrenamiento y prueba.
4. **Modelos regularizados:** Ridge y redes con dropout (CNN-LSTM, BiGRU) mantienen mejor generalización.

Estos hallazgos son consistentes con la literatura que sugiere que modelos más simples y regularizados tienden a generalizar mejor en predicción financiera (Gu et al., 2020).

## 7. Marco de Gestión de Riesgo

Una estrategia de trading rentable es condición necesaria pero no suficiente para la implementación en un contexto institucional. La gestión de riesgo constituye el elemento diferenciador entre estrategias académicamente interesantes y aquellas viables para operación real. Esta sección presenta el marco de análisis de riesgo aplicado a los 23 modelos evaluados.

### 7.1 Métricas de Riesgo Ajustado

#### 7.1.1 Sharpe Ratio

El Sharpe Ratio (Sharpe, 1966) mide el exceso de retorno por unidad de volatilidad total:

$$\text{Sharpe} = \frac{E[R_p - R_f]}{\sigma_p} \cdot \sqrt{252} \quad (26)$$

donde  $R_p$  es el retorno del portafolio,  $R_f$  la tasa libre de riesgo, y  $\sigma_p$  la desviación estándar de los retornos. El factor  $\sqrt{252}$  anualiza la métrica asumiendo 252 días de trading.

En nuestra muestra, los Sharpe ratios varían significativamente entre modelos. Ridge alcanza el mayor Sharpe (0.932), seguido por CNN-LSTM (0.744) y BiGRU (0.680). Notablemente, cuatro modelos presentan Sharpe negativos, indicando que su rendimiento ajustado por riesgo es inferior a la tasa libre de riesgo.

#### 7.1.2 Sortino Ratio

El Sortino Ratio (Sortino & Van Der Meer, 1991) mejora sobre Sharpe al considerar únicamente la volatilidad negativa (downside risk):

$$\text{Sortino} = \frac{E[R_p - R_f]}{\sigma_d} \cdot \sqrt{252} \quad (27)$$

donde  $\sigma_d$  es la desviación estándar de los retornos negativos exclusivamente. Esta métrica es particularmente relevante para estrategias asimétricas donde la distribución de retornos difiere significativamente de una normal.

### 7.1.3 Calmar Ratio

El Calmar Ratio relaciona el retorno anualizado con el máximo drawdown:

$$\text{Calmar} = \frac{\text{CAGR}}{|\text{Max Drawdown}|} \quad (28)$$

Esta métrica captura la eficiencia de la estrategia en términos del peor escenario histórico. Un Calmar superior a 1.0 indica que el retorno anual supera la máxima pérdida experimentada, un umbral deseable para estrategias institucionales.

## 7.2 Value at Risk (VaR) y Expected Shortfall

### 7.2.1 Metodología

Calculamos VaR histórico utilizando percentiles empíricos de la distribución de retornos:

$$\text{VaR}_\alpha = -\text{Percentil}_\alpha(R_t) \quad (29)$$

El VaR al 95 % representa la pérdida máxima esperada en el 95 % de los casos (es decir, la pérdida que solo se supera el 5 % del tiempo).

### 7.2.2 Conditional VaR (CVaR)

El Expected Shortfall o CVaR mide la pérdida promedio en los casos que exceden el VaR:

$$\text{CVaR}_\alpha = -E[R_t | R_t < -\text{VaR}_\alpha] \quad (30)$$

Esta métrica es preferida por reguladores y gestores institucionales porque captura el riesgo de cola (tail risk) de manera más completa que el VaR tradicional.

### 7.2.3 Resultados de Riesgo de Cola

Los resultados revelan un trade-off fundamental: los modelos con mayor retorno (Ridge, GradientBoosting) también presentan mayor riesgo de cola. CNN-LSTM y BiGRU ofrecen un balance más favorable entre retorno y riesgo extremo.

Cuadro 8: Value at Risk y Expected Shortfall por Modelo (Top 10)

| Modelo           | VaR 95 % (30d) | CVaR 95 % (30d) | VaR 99 % (30d) | Peor Día | <i>Nota:</i> |
|------------------|----------------|-----------------|----------------|----------|--------------|
| Ridge            | -8.2 %         | -12.1 %         | -15.3 %        | -9.8 %   |              |
| GradientBoosting | -12.4 %        | -18.7 %         | -22.1 %        | -14.2 %  |              |
| CNN_LSTM         | -7.1 %         | -10.8 %         | -14.2 %        | -8.9 %   |              |
| BiGRU            | -6.8 %         | -9.9 %          | -13.1 %        | -8.1 %   |              |
| RandomForest     | -7.9 %         | -11.4 %         | -15.8 %        | -9.4 %   |              |
| SPY (B&H)        | -5.8 %         | -8.2 %          | -10.9 %        | -6.7 %   |              |

*VaR y CVaR calculados sobre ventana de 30 días. Valores negativos representan pérdidas potenciales.*

### 7.3 Análisis de Drawdown

#### 7.3.1 Máximos Drawdowns

El drawdown mide la caída desde un máximo histórico:

$$DD_t = \frac{P_t - \max_{s \leq t}(P_s)}{\max_{s \leq t}(P_s)} \quad (31)$$

donde  $P_t$  es el valor del portafolio en el momento  $t$ .

#### 7.3.2 Períodos de Drawdown Significativo

Durante el período de prueba, identificamos tres episodios de drawdown severo que afectaron la mayoría de los modelos:

1. **Corrección Q4 2021** (Sep-Dic 2021): Drawdowns del 15-25 % en modelos con alta exposición a 3x.
2. **Bear Market 2022** (Ene-Oct 2022): El período más desafiante, con drawdowns del 30-50 % para modelos agresivos.
3. **Volatilidad Bancaria 2023** (Mar 2023): Drawdowns agudos del 10-20 % en una semana.

#### 7.3.3 Recuperación de Drawdowns

Un aspecto crítico es el tiempo de recuperación. Definimos el tiempo de recuperación como el número de días hasta alcanzar un nuevo máximo:

$$T_{recovery} = \min\{t' > t_{DD} : P_{t'} \geq \max_{s \leq t_{DD}}(P_s)\} \quad (32)$$

Los modelos con posicionamiento más conservador (mayor % en Cash) presentan drawdowns menos profundos pero tiempos de recuperación similares, sugiriendo que la protección de capital durante caídas compensa la menor participación en subidas.



## 7.4 Control de Riesgo Implícito en la Estrategia

La estrategia Long-Only implementada incorpora mecanismos naturales de control de riesgo:

### 7.4.1 Posición en Cash como Hedge Natural

Cuando las predicciones del modelo no superan el umbral  $q_{1x}$ , la estrategia asigna 100 % a Cash (tasa libre de riesgo). Este mecanismo actúa como un “stop-loss” implícito basado en la confianza del modelo:

$$\text{Position}_t = \begin{cases} 3x & \text{si } \hat{r}_t > P_{100-q_{3x}} \\ 1x & \text{si } P_{100-q_{1x}} < \hat{r}_t \leq P_{100-q_{3x}} \\ 0 & \text{si } \hat{r}_t \leq P_{100-q_{1x}} \end{cases} \quad (33)$$

Los modelos con mayor porcentaje de tiempo en Cash (AutoARIMA: 99.9 %, DLinear: 79.6 %) presentan los drawdowns más contenidos pero también los retornos más modestos.

### 7.4.2 Apalancamiento Selectivo

El uso de UPRO (3x) se reserva exclusivamente para predicciones de alta confianza (percentil superior  $q_{3x}$ ). Esta selectividad limita la exposición a apalancamiento a momentos donde el modelo tiene mayor certeza direccional.

## 7.5 Implicaciones para la Implementación

Los hallazgos de esta sección tienen implicaciones directas para la implementación:

1. **Sizing de Posiciones:** El VaR diario sugiere limitar el tamaño de posición al nivel donde una pérdida del VaR 99 % sea tolerable.
2. **Selección de Modelos:** Para mandatos conservadores, CNN-LSTM y BiGRU ofrecen el mejor balance riesgo-retorno. Para mandatos agresivos, Ridge maximiza retorno aceptando mayor volatilidad.
3. **Diversificación de Modelos:** Un ensemble de modelos con correlaciones imperfectas puede reducir el riesgo agregado sin sacrificar retorno esperado.
4. **Límites de Drawdown:** Establecer límites de drawdown del 20-25 % como trigger para revisión de parámetros o suspensión temporal.

## 8. Análisis por Régimen de Mercado

El rendimiento de estrategias de trading varía significativamente según las condiciones de mercado prevalecientes. Esta sección examina cómo los 23 modelos se comportan bajo diferentes regímenes, proporcionando insights críticos para la gestión táctica de activos.

### 8.1 Definición de Regímenes

Clasificamos cada día de trading en uno de cuatro regímenes utilizando una ventana rolling de 60 días:

#### 8.1.1 Criterios de Clasificación

1. **Bull Market:** Retorno acumulado  $> 10\%$  y volatilidad anualizada  $< 20\%$

$$\text{Bull} \equiv \left( \prod_{i=t-59}^t (1 + r_i) - 1 > 0,10 \right) \wedge \left( \sigma_{60d} \cdot \sqrt{252} < 0,20 \right) \quad (34)$$

2. **Bear Market:** Retorno acumulado  $< -10\%$

$$\text{Bear} \equiv \prod_{i=t-59}^t (1 + r_i) - 1 < -0,10 \quad (35)$$

3. **High Volatility:** Volatilidad anualizada  $> 25\%$  (sin cumplir Bull/Bear)

$$\text{HighVol} \equiv \sigma_{60d} \cdot \sqrt{252} > 0,25 \quad (36)$$

4. **Sideways:** Ninguno de los anteriores (mercado lateral)

### 8.2 Distribución de Regímenes en el Período de Prueba

El período de prueba (Octubre 2020 - Diciembre 2025) presentó la siguiente distribución de regímenes:

Cuadro 9: Distribución de Regímenes de Mercado

| Régimen         | Días | Porcentaje | Características                   |
|-----------------|------|------------|-----------------------------------|
| Sideways        | 938  | 72.1 %     | Mercado sin tendencia clara       |
| Bull            | 133  | 10.2 %     | Rally sostenido, baja volatilidad |
| High Volatility | 121  | 9.3 %      | Incertidumbre elevada             |
| Bear            | 49   | 3.8 %      | Correcciones significativas       |
| Unknown         | 60   | 4.6 %      | Período de warmup inicial         |

La predominancia del régimen Sideways (72 %) es consistente con la naturaleza del S&P 500 como índice diversificado que raramente presenta tendencias extremas prolongadas.

### 8.3 Rendimiento por Modelo por Régimen

#### 8.3.1 Bull Market (133 días)

Durante períodos alcistas con baja volatilidad:

- **Mejores:** RandomForest (+12.9 %), Ridge (+6.6 %), ElasticNet (+4.4 %)
- **Peores:** SeasonalNaive (-18.5 %), BiGRU (-15.8 %), TCN (-13.2 %)

Los modelos ML clásicos capturan mejor las tendencias alcistas sostenidas, mientras que los modelos de series temporales y RNN tienden a ser más conservadores perdiendo participación.

#### 8.3.2 Bear Market (49 días)

Durante correcciones significativas:

- **Mejores:** GradientBoosting (+73.2 %), LSTM\_Attention (+64.7 %), BiLSTM (+56.6 %)
- **Peores:** DLinear (-8.5 %), CatBoost (+11.7 %), LightGBM (+8.4 %)

Notablemente, varios modelos logran retornos positivos durante mercados bajistas, sugiriendo que el posicionamiento en Cash y la selectividad del apalancamiento actúan como protección efectiva.

#### 8.3.3 High Volatility (121 días)

Durante períodos de alta incertidumbre:

- **Mejores:** SeasonalNaive (+37.6 %), Ridge (+36.0 %), GradientBoosting (+35.5 %)
- **Peores:** GARCH (-34.3 %), ElasticNet (-16.0 %), Lasso (-16.0 %)

Paradójicamente, GARCH—diseñado específicamente para modelar volatilidad—tiene el peor desempeño en alta volatilidad, sugiriendo que su estimación de volatilidad no se traduce en mejor timing de posiciones.

### 8.3.4 Sideways (938 días)

Durante el régimen predominante:

- **Mejores:** CNN\_LSTM (+96.0 %), Ridge (+91.9 %), DLinear (+69.5 %)
- **Peores:** ExponentialSmoothing (-28.4 %), LSTM\_Attention (-20.1 %), Theta (-18.0 %)

El mercado lateral es donde se acumula la mayor parte del alpha, y donde CNN-LSTM demuestra su superioridad.

## 8.4 Tabla Completa de Rendimiento por Régimen

Cuadro 10: Rendimiento por Régimen de Mercado (Top 10 Modelos)

| Modelo           | Bull<br>(133 días) | Sideways<br>(938 días) | Bear<br>(49 días) | High Vol<br>(121 días) |
|------------------|--------------------|------------------------|-------------------|------------------------|
| Ridge            | 6.6 %              | 91.9 %                 | 41.9 %            | 36.0 %                 |
| GradientBoosting | -8.3 %             | 40.2 %                 | 73.2 %            | 35.5 %                 |
| CNN_LSTM         | -1.5 %             | 96.0 %                 | 23.2 %            | 14.4 %                 |
| BiGRU            | -15.8 %            | 60.4 %                 | 9.4 %             | 25.1 %                 |
| RandomForest     | 12.9 %             | 3.8 %                  | 44.8 %            | 15.3 %                 |
| NBEATS           | 1.7 %              | 12.0 %                 | 38.0 %            | 17.2 %                 |
| LightGBM         | -3.3 %             | 48.9 %                 | 8.4 %             | 14.8 %                 |
| CatBoost         | -3.8 %             | 52.1 %                 | 11.7 %            | 3.8 %                  |
| XGBoost          | -4.7 %             | 1.3 %                  | 45.1 %            | 5.9 %                  |
| SeasonalNaive    | -18.5 %            | 0.4 %                  | 23.4 %            | 37.6 %                 |

Nota: Bull = retorno acumulado > 10 % y volatilidad < 20 % en ventana de 60 días. Bear = retorno < -10 %. High Vol = volatilidad > 25 %. Sideways = resto.

## 8.5 Análisis de Consistencia Cross-Régimen

Un modelo ideal debería performar consistentemente bien a través de diferentes regímenes. Evaluamos la consistencia mediante la desviación estándar de rendimientos por régimen:

$$\text{Consistencia}_m = \frac{1}{\sigma(\{R_{m,\text{Bull}}, R_{m,\text{Bear}}, R_{m,\text{Sideways}}, R_{m,\text{HighVol}}\})} \quad (37)$$

Cuadro 11: Consistencia Cross-Régimen de Modelos (Top 10)

| Modelo           | Bull    | Bear    | Sideways | HighVol | Consistencia |
|------------------|---------|---------|----------|---------|--------------|
| Ridge            | +6.6 %  | +41.9 % | +91.9 %  | +36.0 % | Media        |
| CNN_LSTM         | -1.5 %  | +23.2 % | +96.0 %  | +14.4 % | Alta         |
| GradientBoosting | -8.3 %  | +73.2 % | +40.2 %  | +35.5 % | Baja         |
| BiGRU            | -15.8 % | +9.4 %  | +60.4 %  | +25.1 % | Media        |

## 8.6 Implicaciones para Gestión Táctica

Los resultados sugieren varias estrategias de gestión táctica:

### 8.6.1 Rotación de Modelos por Régimen

- **Régimen Bull detectado:** Preferir RandomForest, Ridge
- **Régimen Bear detectado:** Preferir GradientBoosting, LSTM\_Attention, BiLSTM
- **Régimen High Vol detectado:** Preferir SeasonalNaive, Ridge
- **Régimen Sideways detectado:** Preferir CNN\_LSTM, Ridge

### 8.6.2 Ensemble Dinámico

Un enfoque más sofisticado es ponderar los modelos dinámicamente según el régimen identificado:

$$\hat{r}_{t,\text{ensemble}} = \sum_{m=1}^M w_{m,\text{regime}(t)} \cdot \hat{r}_{m,t} \quad (38)$$

donde  $w_{m,\text{regime}(t)}$  son pesos que dependen del régimen actual, optimizados históricamente para cada combinación modelo-régimen.

### 8.6.3 Advertencia sobre Detección de Régimen

Es crucial notar que la detección de régimen es ex-post en nuestro análisis. En implementación real, el régimen solo puede identificarse con rezago (60 días en nuestra definición), lo que limita la aplicabilidad de rotación táctica perfecta. Sin embargo, transiciones de régimen tienden a ser persistentes, permitiendo cierto grado de anticipación.

## 8.7 Ridge: El Modelo All-Weather

Ridge destaca como el único modelo con rendimiento positivo significativo en los cuatro regímenes:

- Bull: +6.6 % (3er mejor)
- Bear: +41.9 % (5to mejor)
- Sideways: +91.9 % (2do mejor)
- High Vol: +36.0 % (2do mejor)

Esta consistencia cross-régimen, combinada con su Sharpe ratio líder (0.932), posiciona a Ridge como el modelo más robusto para implementación estática sin rotación de modelos.

## 9. Costos de Transacción

### 9.1 Modelo de Costos

Para garantizar que los resultados sean implementables en la práctica, se aplica un modelo de costos conservador de **15 puntos base (0.15 %)** por unidad de cambio de posición. Este nivel incluye comisiones, spreads bid-ask, y slippage, siendo más conservador que las condiciones actuales para ETFs líquidos como SPY y UPRO.

### 9.2 Impacto en los Resultados

Los retornos reportados en este estudio son **netos de costos de transacción**. El modelo Ridge, con 273 trades sobre el período de prueba (aproximadamente 53 trades por año), incurre en costos totales de \$1,331 sobre un capital inicial de \$10,000.

El hallazgo clave es que los modelos exitosos mantienen alfa positivo después de costos:

- El alfa de 216 puntos porcentuales sobre el benchmark es después de todos los costos
- Los modelos con menor turnover (GradientBoosting: 170 trades) incurren en menores costos
- La estrategia LONG-ONLY evita los costos adicionales de posiciones cortas (préstamo de acciones)

*Los detalles completos de costos por modelo, incluyendo análisis de sensibilidad, están disponibles en la aplicación interactiva: <http://3.20.234.106>*

### 9.3 Relación Turnover-Retorno

La Figura 2 ilustra la relación entre turnover y retorno neto para todos los modelos.




Figura 2: Comparación de Modelos: Métricas de Desempeño

*Notas:* La figura compara el desempeño de los 21 modelos evaluados en términos de retorno y ratio de Sharpe.

El análisis revela que los modelos más simples (DLinear, modelos lineales regularizados) tienden a generar señales más estables y, por lo tanto, incurren en menores costos de transacción. Los modelos más complejos (TiDE, TFT, XGBoost con múltiples features) tienden a generar señales más volátiles que resultan en turnover destructivo.

#### 9.4 Implicaciones para la Implementación

El análisis de costos de transacción tiene varias implicaciones prácticas:

**Primera implicación:** El balance óptimo entre señal predictiva y costos de transacción favorece a los modelos con menor frecuencia de trading. Ridge, con 273 trades sobre cinco años, logra el mejor retorno neto, indicando que un enfoque selectivo que espera señales de alta convicción es más eficiente que el trading frecuente.

**Segunda implicación:** Los costos de transacción son manejables para estrategias bien diseñadas. Con 273 trades sobre cinco años (Ridge), los costos totales de aproximadamente 13 % representan solo una fracción menor del retorno bruto de 318.8 %.

**Tercera implicación:** Los costos de transacción asumidos (bid-ask spreads de 0.05 % para UPRO y 0.02 % para SPY) son conservadores para estos ETFs altamente líquidos. La estrategia LONG-ONLY simplifica la implementación al eliminar los costos adicionales asociados con posiciones cortas.

**Cuarta implicación:** El retorno neto del modelo Ridge representa un alfa de más de 216 puntos porcentuales sobre el benchmark buy-and-hold (102.2 %), confirmando que la estrategia genera valor económico sustancial después de todos los costos de implementación.

## 10. Discusión: Contribuciones al Debate sobre Eficiencia de Mercado

### 10.1 Resumen de Hallazgos Empíricos

Antes de discutir las implicaciones teóricas, se resumen los hallazgos empíricos principales de el presente estudio:

1. El modelo Ridge genera un alfa de 216 puntos porcentuales sobre cinco años (318.8 % vs 102.2 % del mercado)
2. Este outperformance persiste después de costos de transacción realistas
3. El ratio de Sharpe de 0.93 supera al benchmark (0.88), indicando mejor rendimiento ajustado por riesgo
4. Cuatro de veintitrés modelos superan al benchmark en retorno total, mientras que modelos adicionales ofrecen perfiles de riesgo-retorno competitivos
5. La estrategia LONG-ONLY demuestra que es posible generar alfa significativo sin asumir los riesgos adicionales de posiciones cortas

Estos hallazgos presentan evidencia que debe reconciliarse con las predicciones de la Hipótesis de Eficiencia de Mercado.

### 10.2 Interpretación desde la Perspectiva de Eficiencia de Mercado

#### 10.2.1 El Argumento contra la Eficiencia

Los resultados pueden interpretarse como evidencia contra la eficiencia de mercado por varias razones:

**Magnitud del outperformance:** Un alfa de 216 puntos porcentuales es económicamente significativo y difícil de atribuir completamente a suerte o compensación por riesgo convencional. Si los mercados fueran perfectamente eficientes, sería difícil obtener rendimientos anormales sistemáticos de esta magnitud usando solo información pública.

**Consistencia de resultados:** Múltiples modelos con metodologías distintas (Ridge, GradientBoosting, CNN\_LSTM, BiGRU) logran outperformance sobre el benchmark, sugiriendo que existe una señal predictiva real en las características empleadas, más que un artefacto de sobreajuste.

**Enfoque conservador exitoso:** La estrategia LONG-ONLY demuestra que no es necesario asumir los riesgos adicionales de posiciones cortas para generar alfa significativo. Esto sugiere que las ineficiencias identificadas son explotables mediante enfoques de implementación práctica.



**Diversidad metodológica:** Los modelos que superan al benchmark incluyen tanto métodos lineales regularizados (Ridge) como técnicas de gradient boosting y deep learning, sugiriendo que la señal predictiva puede ser capturada por diversas metodologías.

### 10.2.2 El Argumento a Favor de la Eficiencia

Sin embargo, una interpretación alternativa es parcialmente consistente con mercados eficientes:

**Complejidad computacional:** La extracción de la señal predictiva requiere procesar 647 características con algoritmos sofisticados de gradient boosting. Los costos computacionales y de datos pueden representar barreras que limitan la competencia en explotar estas oportunidades.

**Prima de renta variable amplificada:** Parte del rendimiento proviene de exposición larga promedio positiva, capturando la prima de renta variable histórica. Sin embargo, esto no explica los drawdowns reducidos ni el alfa sobre estrategias de apalancamiento puro (Buy & Hold 3x: 398 %, Sharpe 0.82).

**Período de prueba específico:** El período octubre 2020 a diciembre 2025 incluye recuperación post-COVID y mercados alcistas predominantes. Una validación definitiva requeriría evaluación en múltiples ciclos de mercado completos.

## 10.3 Reconciliando las Interpretaciones

Se considera que la verdad reside en un punto intermedio entre estas interpretaciones extremas:

**Ineficiencia explotable:** Los resultados sugieren que el mercado no es perfectamente eficiente en incorporar toda la información disponible instantáneamente. Las características derivadas de múltiples fuentes (indicadores técnicos, variables macroeconómicas, volatilidad, correlaciones cross-asset) contienen información predictiva que no está completamente descontada en los precios.

**Eficiencia adaptativa con fricciones:** Siguiendo el marco de “Mercados Adaptativos” de Lo (2019), se interpreta los hallazgos como evidencia de que los mercados son aproximadamente eficientes pero exhiben patrones predecibles que pueden ser explotados por participantes sofisticados. La complejidad de procesar 647 características con algoritmos de gradient boosting representa una barrera que limita la competencia.

**Timing activo vs. exposición sistemática:** Un hallazgo clave es que el outperformance no proviene simplemente de “comprar y mantener con apalancamiento”. El modelo Ridge logra 318.8 % de retorno manteniendo posición en efectivo el 62 % del tiempo, demostrando capacidad

genuina de timing de mercado que reduce exposición durante períodos adversos.

#### 10.4 Contribución al Debate Académico

Los hallazgos deben contextualizarse dentro de la literatura sobre predicción de la prima de renta variable. [Welch & Goyal \(2008\)](#) documentaron que la mayoría de los predictores propuestos en la literatura académica fallan fuera de muestra, estableciendo un estándar riguroso que cualquier afirmación de predictibilidad debe superar. Similarmente, [Campbell & Thompson \(2008\)](#) mostraron que restricciones económicamente motivadas pueden mejorar las predicciones, aunque el outperformance sobre el promedio histórico es típicamente modesto.

El presente estudio contribuye a este debate de varias maneras:

**Evidencia empírica renovada:** Se proporciona evidencia fresca sobre predictibilidad de retornos usando datos recientes (hasta 2025) y técnicas de aprendizaje automático de última generación.

**Transparencia metodológica:** A diferencia de muchos estudios que usan datos propietarios o variables anonimizadas, la documentación completa permite verificación y extensión por parte de otros investigadores.

**Análisis de costos realista:** El análisis detallado de costos de transacción distingue entre predictibilidad teórica y rentabilidad práctica, una distinción crucial frecuentemente ignorada.

**Comparación de modelos:** La superioridad de modelos simples sobre arquitecturas complejas sugiere que la “complejidad” del mercado puede ser menor de lo que algunas investigaciones recientes implican.

#### 10.5 El Rol de los Indicadores Técnicos

Un hallazgo notable es que las características derivadas del sistema Triple Screen de Elder contribuyen a las predicciones del modelo. Esto tiene implicaciones interesantes para el debate sobre análisis técnico:

**Validación empírica:** Indicadores técnicos desarrollados por practicantes (no académicos) a través de décadas de experiencia de mercado demuestran tener contenido informativo cuando se integran en un marco de aprendizaje automático.

**Mecanismo causal sugerido:** Los indicadores técnicos pueden capturar aspectos de la psicología del mercado y el comportamiento de otros participantes que afectan los precios futuros—una forma de “profecía autocumplida” que genera predictibilidad real.

**Complementariedad con fundamentales:** La combinación de indicadores técnicos con variables macroeconómicas y de sentimiento en el framework sugiere que diferentes fuentes de

información capturan aspectos complementarios de la dinámica de precios.

## 10.6 Robustez de la Estrategia de Posicionamiento por Quantiles

Un hallazgo metodológico importante es la capacidad del sistema de posicionamiento propuesto para extraer alfa significativo incluso de modelos con baja variabilidad predictiva. Este resultado merece discusión adicional por sus implicaciones para el diseño de estrategias de trading cuantitativo.

**Diseño adaptativo del sistema:** La comparación de predicciones contra quantiles de su propia distribución histórica (en lugar de umbrales absolutos fijos) proporciona un mecanismo de normalización implícito. Este diseño permite que pequeñas variaciones sistemáticas en las predicciones—incluso cuando estas son casi constantes en términos absolutos—se traduzcan en cambios de posición cuando representan desviaciones significativas respecto al comportamiento histórico del modelo.

**Consistencia con la literatura de eficiencia:** La convergencia de algoritmos sofisticados de gradient boosting hacia predicciones casi constantes es consistente con las predicciones de la Hipótesis de Eficiencia de Mercado (Fama, 1970) y la evidencia documentada sobre la dificultad extrema de predecir retornos financieros (Gu et al., 2020). Ante un ratio señal-ruido extremadamente bajo, la respuesta óptima bajo criterio MSE es predecir valores cercanos a la media incondicional, minimizando así el error cuadrático esperado.

**Implicación para practicantes:** Este hallazgo sugiere que las métricas tradicionales de evaluación de modelos predictivos (como  $R^2$  o RMSE) pueden subestimar la utilidad práctica de modelos para trading. Un modelo con  $R^2$  cercano a cero pero con predicciones sistemáticamente correlacionadas con retornos futuros puede generar alfa significativo cuando se combina con una regla de posicionamiento apropiadamente diseñada. Como señala López de Prado (2018), la dificultad de predecir retornos financieros requiere enfoques que vayan más allá de métricas estadísticas convencionales. La clave reside no solo en la calidad de las predicciones, sino en cómo estas se transforman en decisiones de inversión.

## 11. Limitaciones y Consideraciones de Robustez

### 11.1 Limitaciones del Estudio

Se reconocen varias limitaciones importantes de el análisis:

### 11.1.1 Período de Prueba

El período de prueba (octubre 2020 – diciembre 2025) comprende predominantemente mercados alcistas, potencialmente favoreciendo estrategias con sesgo largo. Una evaluación completa requeriría desempeño a través de ciclos de mercado completos, incluyendo recesiones sostenidas como 2008-2009.

### 11.1.2 Mercado Único

El análisis se enfoca exclusivamente en el S&P 500. La generalizabilidad a otros mercados (mercados emergentes, commodities, forex, acciones individuales) no puede asumirse sin verificación empírica adicional.

### 11.1.3 Estabilidad de Parámetros

Los hiperparámetros del modelo fueron seleccionados una vez y mantenidos fijos durante el período de prueba. En implementación real, se requerirían procedimientos de recalibración periódica.

### 11.1.4 Sesgo de Supervivencia de Variables

La selección de variables refleja disponibilidad contemporánea. Algunas variables pueden no haber estado disponibles durante todo el período histórico, aunque mitigamos esto usando solo datos que existían en cada punto temporal.

### 11.1.5 Impacto de Mercado No Modelado

El modelo de costos de transacción asume que las posiciones pueden ejecutarse sin impacto de mercado. Para capital significativo, el impacto de mercado podría reducir la rentabilidad.

## 11.2 Análisis de Robustez

### 11.2.1 Sensibilidad a Costos de Transacción

El modelo Ridge, con 273 trades sobre el período de prueba, incurre en costos totales de \$1,331 sobre un capital inicial de \$10,000 (13.3 %). Estos costos son manejables considerando el alfa generado de 216 puntos porcentuales sobre el benchmark.

La estrategia LONG-ONLY reduce la complejidad de costos al eliminar:

- Costos de préstamo de acciones para posiciones cortas
- Spreads más amplios en ETFs inversos

- Riesgo de squeeze en posiciones cortas

### 11.2.2 Estabilidad Temporal

La estrategia LONG-ONLY con refugio en efectivo proporciona protección natural durante mercados bajistas. Durante el periodo de prueba (octubre 2020 - diciembre 2025), el modelo Ridge permanece en efectivo el 62 % del tiempo, lo que le permite evitar gran parte de las caídas del mercado mientras captura las tendencias alcistas mediante posición apalancada selectiva.

### 11.2.3 Diversidad de Modelos Exitosos

Un hallazgo robusto es que múltiples arquitecturas diferentes logran superar al benchmark:

- Ridge (regularización lineal): 318.8 %, Sharpe 0.93
- GradientBoosting (ensemble de árboles): 267.5 %, Sharpe 0.59
- CNN\_LSTM (deep learning híbrido): 207.1 %, Sharpe 0.74
- BiGRU (red recurrente): 127.7 %, Sharpe 0.68

Esta diversidad metodológica sugiere que la señal predictiva en las 647 características puede ser capturada por enfoques conceptualmente distintos, proporcionando evidencia de robustez.

## 12. Conclusión

### 12.1 Resumen de Hallazgos

Este estudio ha investigado empíricamente la Hipótesis de Eficiencia de Mercado mediante un enfoque estructurado en dos hitos fundamentales:

**Hito 1 – Predicción:** Se entrenaron 23 modelos de aprendizaje automático y profundo utilizando 647 características derivadas de 92 variables de Bloomberg. El objetivo no era predecir el valor exacto del retorno de mañana, sino obtener suficiente precisión direccional para tomar decisiones de inversión.

**Hito 2 – Estrategia:** Las predicciones se tradujeron en una estrategia LONG-ONLY de posiciones discretas que aprovecha el apalancamiento disponible en ETFs.

Los hallazgos principales son:

**Primero**, el modelo Ridge con umbrales de percentiles optimizados alcanza un ratio de Sharpe de 0.93 con retornos acumulados del 318.8 % sobre el período de prueba (octubre 2020 – diciembre 2025), superando al benchmark pasivo (Sharpe 0.88, retorno 102.2 %). La estrategia genera un alfa de 216 puntos porcentuales después de costos de transacción.

**Segundo**, cuatro de los veintitrés modelos evaluados superan al benchmark pasivo en retorno total (Ridge, GradientBoosting, CNN\_LSTM, BiGRU). Esto demuestra que, si bien superar al mercado es difícil, no es imposible mediante el uso de técnicas de aprendizaje automático bien calibradas.

**Tercero**, la diversidad metodológica de los modelos exitosos—desde regresión lineal regularizada (Ridge) hasta redes neuronales híbridas (CNN\_LSTM)—sugiere que la señal predictiva contenida en las características es robusta y puede ser capturada por enfoques conceptualmente distintos.

**Cuarto**, el sistema de umbrales por percentiles permite que cada modelo optimice independientemente su nivel de agresividad. El modelo Ridge, que permanece en efectivo el 62 % del tiempo, ejemplifica un enfoque conservador que prioriza la preservación de capital sobre la maximización de retornos.

**Quinto**, la ingeniería de características exhaustiva—incluyendo indicadores técnicos, estimadores de volatilidad OHLC, y otras transformaciones—demostró ser efectiva para extraer información predictiva, aunque ninguna técnica individual es responsable del éxito; es la combinación sistemática la que genera valor.

## 12.2 Contribuciones al Debate sobre Eficiencia de Mercado

Los resultados presentan un desafío matizado a la Hipótesis de Eficiencia de Mercado. Se documenta rendimientos anormales sistemáticos de magnitud sustancial (alfa de 216 puntos porcentuales) que persisten a través de múltiples años utilizando únicamente información pública y una estrategia de implementación práctica.

Se considera que los hallazgos son más consistentes con una forma de “eficiencia adaptativa” donde los mercados son aproximadamente eficientes pero no perfectamente eficientes. Señales predictivas existen pero son suficientemente sutiles que requieren técnicas sofisticadas para extraerlas. La estrategia LONG-ONLY demuestra que estas ineficiencias pueden ser explotadas sin asumir riesgos excesivos.

## 12.3 Implicaciones Prácticas

Para practicantes, el presente estudio ofrece varias lecciones:

1. **Simplicidad sobre complejidad:** Modelos simples como Ridge pueden superar a arquitecturas sofisticadas de deep learning en pronóstico financiero
2. **Direccionalidad sobre precisión:** El objetivo debe ser capturar la dirección del mercado con suficiente precisión, no predecir valores exactos

3. **Costos de transacción:** Las estrategias de alto turnover raramente son viables; la selección conservadora de posiciones es clave
4. **Ingeniería de características:** La extracción sistemática de información de los datos mediante múltiples técnicas complementarias genera valor predictivo
5. **Apalancamiento selectivo:** La estrategia LONG-ONLY con niveles discretos de exposición permite capturar alfa mientras se gestiona el riesgo

## 12.4 Direcciones para Investigación Futura

Varias direcciones de investigación futura emergen de el presente trabajo:

**Extensión a otros mercados:** ¿Se generalizan los hallazgos a otros índices de renta variable, mercados internacionales, o clases de activos alternativas?

**Análisis de régimen:** ¿Puede el desempeño del modelo mejorarse mediante detección explícita de regímenes de mercado y adaptación de estrategias?

**Optimización de costos de transacción:** ¿Pueden desarrollarse modelos que optimicen explícitamente el trade-off entre señal predictiva y turnover?

**Integración de datos alternativos:** ¿Agregarían valor fuentes de datos no tradicionales (sentimiento de redes sociales, imágenes satelitales, datos de transacciones)?

**Validación out-of-sample extendida:** ¿Mantendrán las estrategias su desempeño en datos genuinamente futuros (walk-forward)?

## 12.5 Reflexiones Finales

La búsqueda de rendimientos superiores en los mercados financieros representa uno de los ejercicios más desafiantes en la intersección de finanzas, estadística e inteligencia artificial. El presente estudio sugiere que oportunidades explotables pueden existir para aquellos dispuestos a combinar rigurosidad académica con pragmatismo de practicante, simplicidad de modelos con exhaustividad de características, y ambición de rendimientos con disciplina de gestión de riesgo.

Sin embargo, se mantiene humildad respecto a los resultados. Los mercados financieros son sistemas adaptativos complejos donde el éxito pasado no garantiza desempeño futuro, y donde la publicación de estrategias rentables puede contribuir a su eventual arbitraje. Se anima a otros investigadores a validar, extender, y desafiar los hallazgos.

## Referencias

- Ang, A., Hodrick, R. J., Xing, Y., & Zhang, X. (2006). The Cross-Section of Volatility and Expected Returns. *The Journal of Finance*, 61(1), 259–299.
- Banz, R. W. (1981). The Relationship Between Return and Market Value of Common Stocks. *Journal of Financial Economics*, 9(1), 3–18.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Challu, C., Olivares, K. G., Oreshkin, B. N., Ramirez, F. G., Canseco, M. M., & Dubrawski, A. (2022). N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting. *arXiv preprint arXiv:2201.12886*.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1724–1734.
- Dong, X., Li, Y., Rapach, D., & Zhou, G. (2022). Anomalies and the Expected Market Return. *The Journal of Finance*, 77(1), 639–681.
- Elder, A. (1993). *Trading for a Living: Psychology, Trading Tactics, Money Management*. John Wiley & Sons.
- Elder, A. (2014). *The New Trading for a Living: Psychology, Discipline, Trading Tools and Systems, Risk Control, Trade Management*. John Wiley & Sons.
- Foucault, T., Pagano, M., & Röell, A. (2013). *Market Liquidity: Theory, Evidence, and Policy*. Oxford University Press.
- Frazzini, A., & Pedersen, L. H. (2014). Betting Against Beta. *Journal of Financial Economics*, 111(1), 1–25.
- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189–1232.



- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.
- Fama, E. F. (1991). Efficient Capital Markets: II. *The Journal of Finance*, 46(5), 1575–1617.
- Fama, E. F., & French, K. R. (1992). The Cross-Section of Expected Stock Returns. *The Journal of Finance*, 47(2), 427–465.
- French, K. R. (1980). Stock Returns and the Weekend Effect. *Journal of Financial Economics*, 8(1), 55–69.
- Garman, M. B., & Klass, M. J. (1980). On the Estimation of Security Price Volatilities from Historical Data. *The Journal of Business*, 53(1), 67–78.
- Grossman, S. J., & Stiglitz, J. E. (1980). On the Impossibility of Informationally Efficient Markets. *American Economic Review*, 70(3), 393–408.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- Harvey, C. R., Liu, Y., & Zhu, H. (2016). ...and the Cross-Section of Expected Returns. *The Review of Financial Studies*, 29(1), 5–68.
- Herzen, J., Lässig, F., Piazzetta, S. G., Neuer, T., Tafti, L., Raille, G., ... & Grosch, G. (2022). Darts: User-Friendly Modern Machine Learning for Time Series. *Journal of Machine Learning Research*, 23(124), 1–6.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Ioannidis, J. P. A. (2005). Why Most Published Research Findings Are False. *PLOS Medicine*, 2(8), e124.
- Jegadeesh, N., & Titman, S. (1993). Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. *The Journal of Finance*, 48(1), 65–91.

- Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, 35(4), 917–926.
- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- Lo, A. W. (2019). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press.
- Luong, M. T., Pham, H., & Manning, C. D. (2015). Effective Approaches to Attention-based Neural Machine Translation. *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, 1412–1421.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- McLean, R. D., & Pontiff, J. (2016). Does Academic Research Destroy Stock Return Predictability? *The Journal of Finance*, 71(1), 5–32.
- Malkiel, B. G. (2003). The Efficient Market Hypothesis and Its Critics. *Journal of Economic Perspectives*, 17(1), 59–82.
- Mehra, R., & Prescott, E. C. (1985). The Equity Premium: A Puzzle. *Journal of Monetary Economics*, 15(2), 145–161.
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2019). N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting. *International Conference on Learning Representations (ICLR 2020)*.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased Boosting with Categorical Features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.
- Parkinson, M. (1980). The Extreme Value Method for Estimating the Variance of the Rate of Return. *The Journal of Business*, 53(1), 61–65.
- Rogers, L. C. G., & Satchell, S. E. (1991). Estimating Variance from High, Low and Closing Prices. *The Annals of Applied Probability*, 1(4), 504–512.
- Rozeff, M. S., & Kinney, W. R. (1976). Capital Market Seasonality: The Case of Stock Returns. *Journal of Financial Economics*, 3(4), 379–402.

- Sharpe, W. F. (1966). Mutual Fund Performance. *The Journal of Business*, 39(1), 119–138.
- Sortino, F. A., & Van Der Meer, R. (1991). Downside Risk. *The Journal of Portfolio Management*, 17(4), 27–31.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.
- Yang, D., & Zhang, Q. (2000). Drift-Independent Volatility Estimation Based on High, Low, Open, and Close Prices. *The Journal of Business*, 73(3), 477–491.
- Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Challu, C., Olivares, K. G., Oreshkin, B. N., Garza, F., Mergenthaler-Canseco, M., & Dubrawski, A. (2023). N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(6), 6989–6997.
- Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. *arXiv preprint arXiv:1803.01271*.
- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37–45.
- Murphy, J. J. (1999). *Technical Analysis of the Financial Markets: A Comprehensive Guide to Trading Methods and Applications*. New York Institute of Finance.
- Alizadeh, S., Brandt, M. W., & Diebold, F. X. (2002). Range-Based Estimation of Stochastic Volatility Models. *The Journal of Finance*, 57(3), 1047–1091.
- Chou, R. Y. (2005). Forecasting Financial Volatilities with Extreme Values: The Conditional Autoregressive Range (CARR) Model. *Journal of Money, Credit and Banking*, 37(3), 561–582.
- Thorp, E. O. (2006). The Kelly Criterion in Blackjack, Sports Betting, and the Stock Market. In *Handbook of Asset and Liability Management* (pp. 385–428). Elsevier.

- Campbell, J. Y., & Thompson, S. B. (2008). Predicting Excess Stock Returns Out of Sample: Can Anything Beat the Historical Average? *The Review of Financial Studies*, 21(4), 1509–1531.
- Welch, I., & Goyal, A. (2008). A Comprehensive Look at the Empirical Performance of Equity Premium Prediction. *The Review of Financial Studies*, 21(4), 1455–1508.
- Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1), 1–26.
- Ledoit, O., & Wolf, M. (2008). Robust Performance Hypothesis Testing with the Sharpe Ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The Model Confidence Set. *Econometrica*, 79(2), 453–497.
- Clark, T. E., & West, K. D. (2007). Approximately Normal Tests for Equal Predictive Accuracy in Nested Models. *Journal of Econometrics*, 138(1), 291–311.
- Benjamini, Y., & Hochberg, Y. (1995). Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320.
- Preqin. (2024). *2024 Preqin Global Hedge Fund Report*. Preqin Ltd.

## A. Especificación Completa de Variables

Este apéndice documenta el conjunto completo de 92 variables base empleadas en el análisis. Todos los datos provienen de Bloomberg Terminal.

### A.1 Variables de Mercado (M1–M18)

| Código | Ticker Bloomberg | Descripción                                 |
|--------|------------------|---------------------------------------------|
| M1     | SPY US Equity    | SPDR S&P 500 ETF Trust                      |
| M2     | QQQ US Equity    | Invesco QQQ Trust (Nasdaq-100)              |
| M3     | IWM US Equity    | iShares Russell 2000 ETF (Small Cap)        |
| M4     | DIA US Equity    | SPDR Dow Jones Industrial Average ETF       |
| M5     | EFA US Equity    | iShares MSCI EAFE ETF (Desarrollados ex-US) |
| M6     | EEM US Equity    | iShares MSCI Emerging Markets ETF           |
| M7     | XLF US Equity    | Financial Select Sector SPDR Fund           |
| M8     | XLK US Equity    | Technology Select Sector SPDR Fund          |
| M9     | XLE US Equity    | Energy Select Sector SPDR Fund              |
| M10    | XLV US Equity    | Health Care Select Sector SPDR Fund         |
| M11    | XLI US Equity    | Industrial Select Sector SPDR Fund          |
| M12    | FNERT Index      | FTSE NAREIT Equity REITs Total Return       |
| M13    | NYA Index        | NYSE Composite Index                        |
| M14    | VT US Equity     | Vanguard Total World Stock ETF              |
| M15    | ACWI US Equity   | iShares MSCI ACWI ETF                       |
| M16    | SHY US Equity    | iShares 1-3 Year Treasury Bond ETF          |
| M17    | IEF US Equity    | iShares 7-10 Year Treasury Bond ETF         |
| M18    | TLT US Equity    | iShares 20+ Year Treasury Bond ETF          |

### A.2 Variables Macroeconómicas (E1–E10)

| Código | Ticker Bloomberg | Descripción                                 |
|--------|------------------|---------------------------------------------|
| E1     | GDP CQOQ Index   | Crecimiento PIB Trimestre-sobre-Trimestre   |
| E2     | INJCJC Index     | Peticiones Iniciales de Desempleo           |
| E3     | NFP TCH Index    | Cambio en Nóminas No Agrícolas              |
| E4     | USURTOT Index    | Tasa de Desempleo                           |
| E5     | CPI CHNG Index   | Cambio Mensual del IPC                      |
| E6     | PCE CRCH Index   | Índice de Precios PCE Subyacente Interanual |
| E7     | NAPMPMI Index    | PMI de Manufactura ISM                      |

| Código | Ticker Bloomberg | Descripción                               |
|--------|------------------|-------------------------------------------|
| E8     | NAPMNMI Index    | PMI de Servicios ISM                      |
| E9     | CONCCONF Index   | Confianza del Consumidor Conference Board |
| E10    | LEI CHNG Index   | Cambio en Indicadores Líderes             |

### A.3 Variables de Tasas de Interés (I1–I20)

| Código | Ticker Bloomberg | Descripción                          |
|--------|------------------|--------------------------------------|
| I1     | FDTR Index       | Tasa Objetivo de Fondos Federales    |
| I2     | USGG3M Index     | Rendimiento Treasury 3 Meses         |
| I3     | USGG6M Index     | Rendimiento Treasury 6 Meses         |
| I4     | USGG2YR Index    | Rendimiento Treasury 2 Años          |
| I5     | USGG5YR Index    | Rendimiento Treasury 5 Años          |
| I6     | USGG10YR Index   | Rendimiento Treasury 10 Años         |
| I7     | USGG30YR Index   | Rendimiento Treasury 30 Años         |
| I8     | USYC2Y10 Index   | Spread Curva de Rendimiento 2Y-10Y   |
| I9     | USYC3M10 Index   | Spread Curva de Rendimiento 3M-10Y   |
| I10    | US0003M Index    | USD LIBOR 3 Meses                    |
| I11    | USSP2 Curncy     | Tasa Swap USD 2 Años                 |
| I12    | USSP5 Curncy     | Tasa Swap USD 5 Años                 |
| I13    | USSP10 Curncy    | Tasa Swap USD 10 Años                |
| I14    | USSWAP10 Index   | Spread Swap USD 10 Años              |
| I15    | CDX IG 5Y        | CDX Investment Grade 5 Años          |
| I16    | CDX HY 5Y        | CDX High Yield 5 Años                |
| I17    | LF98TRUU Index   | Bloomberg US Corporate High Yield TR |
| I18    | LUACTRUU Index   | Bloomberg US Aggregate Bond TR       |
| I19    | LF94TRUU Index   | Bloomberg US Corporate Bond TR       |
| I20    | USGG1YR Index    | Rendimiento Treasury 1 Año           |

### A.4 Variables de Commodities (P1–P13)

| Código | Ticker Bloomberg | Descripción                    |
|--------|------------------|--------------------------------|
| P1     | CL1 Comdty       | Petróleo Crudo WTI Front Month |
| P2     | NG1 Comdty       | Gas Natural Front Month        |
| P3     | GC1 Comdty       | Oro Front Month                |
| P4     | SI1 Comdty       | Plata Front Month              |

| Código | Ticker Bloomberg | Descripción               |
|--------|------------------|---------------------------|
| P5     | HG1 Comdt        | Cobre Front Month         |
| P6     | C 1 Comdt        | Maíz Front Month          |
| P7     | W 1 Comdt        | Trigo Front Month         |
| P8     | S 1 Comdt        | Soja Front Month          |
| P9     | BCOM Index       | Bloomberg Commodity Index |
| P10    | DXY Curncy       | Índice del Dólar          |
| P11    | EURUSD Curncy    | Tipo de Cambio EUR/USD    |
| P12    | USDJPY Curncy    | Tipo de Cambio USD/JPY    |
| P13    | GBPUSD Curncy    | Tipo de Cambio GBP/USD    |

### A.5 Variables de Volatilidad (V1–V13)

| Código | Ticker Bloomberg | Descripción                              |
|--------|------------------|------------------------------------------|
| V1     | VIX Index        | CBOE Índice de Volatilidad (S&P 500)     |
| V2     | VIX3M Index      | CBOE Índice de Volatilidad 3 Meses       |
| V3     | VIX1M Index      | CBOE Índice de Volatilidad 1 Mes         |
| V4     | VXN Index        | CBOE Índice de Volatilidad Nasdaq-100    |
| V5     | VVIX Index       | CBOE VIX del VIX                         |
| V6     | MOVE Index       | ICE BofA MOVE Index (Volatilidad Bonos)  |
| V7     | VIX9D Index      | CBOE Índice de Volatilidad 9 Días        |
| V8     | SKEW Index       | CBOE Índice de Skew                      |
| V9     | TYVIX Index      | CBOE Índice de Volatilidad Treasury      |
| V10    | OVX Index        | CBOE Índice de Volatilidad Petróleo      |
| V11    | GVZ Index        | CBOE Índice de Volatilidad Oro           |
| V12    | VXEEM Index      | CBOE Volatilidad ETF Mercados Emergentes |
| V13    | VXEFA Index      | CBOE Volatilidad ETF EAFE                |

### A.6 Variables de Sentimiento (S1–S11)

| Código | Ticker Bloomberg   | Descripción                          |
|--------|--------------------|--------------------------------------|
| S1     | AAII BULLISH Index | Sentimiento Inversor AAI (Alcista %) |
| S2     | AAII BEARISH Index | Sentimiento Inversor AAI (Bajista %) |
| S3     | PCUSEQTR Index     | CBOE Ratio Put/Call Equity           |
| S4     | PCUSTOTR Index     | CBOE Ratio Put/Call Total            |
| S5     | PCRATEQ Index      | ISEE Índice Sentimiento Solo Equity  |

| Código | Ticker Bloomberg | Descripción                            |
|--------|------------------|----------------------------------------|
| S6     | ADD Index        | NYSE Línea Advance-Dcline              |
| S7     | NYAD Index       | NYSE Issues Avanzando-Declinando       |
| S8     | NYHL Index       | NYSE Nuevos Máximos-Nuevos Mínimos     |
| S9     | TRIN Index       | Arms Index (TRIN)                      |
| S10    | NAAIM Index      | NAAIM Índice de Exposición             |
| S11    | SENTI Index      | Sentix Sentimiento Global del Inversor |

### A.7 Variables Dummy de Calendario (D1–D7)

| Código | Descripción                                                                |
|--------|----------------------------------------------------------------------------|
| D1     | Indicador de lunes (1 si lunes, 0 en otro caso)                            |
| D2     | Indicador de viernes (1 si viernes, 0 en otro caso)                        |
| D3     | Indicador de fin de mes (últimos 3 días de negociación del mes)            |
| D4     | Indicador de inicio de mes (primeros 3 días de negociación del mes)        |
| D5     | Indicador de inicio de trimestre (primer día de negociación del trimestre) |
| D6     | Indicador de fin de trimestre (último día de negociación del trimestre)    |
| D7     | Indicador de semana de vencimiento de opciones                             |

## B. Detalles de Ingeniería de Características

Este apéndice proporciona especificaciones técnicas para las 647 características derivadas de las 92 variables base.

### B.1 Cómputo de Retornos

Retornos logarítmicos calculados para horizontes  $h \in \{1, 5, 21, 63, 126, 252\}$  días de negociación:

$$r_{t,h} = \ln(P_t/P_{t-h}) \times 100$$

Total: 6 horizontes  $\times$  variables de precio = 108 características de retorno.



## B.2 Indicadores Técnicos

**RSI (14 períodos):**

$$RSI = 100 - \frac{100}{1 + RS}$$

donde  $RS = \frac{\text{Ganancia Promedio}}{\text{Pérdida Promedio}}$

**MACD:**

$$MACD = EMA_{12} - EMA_{26}$$

$$\text{Signal} = EMA_9(MACD)$$

$$\text{Histogram} = MACD - \text{Signal}$$

Características derivadas: MACD, Señal, Histograma, Pendiente del Histograma (5 períodos).

**Bandas de Bollinger %B:**

$$\%B = \frac{P - BB_{inferior}}{BB_{superior} - BB_{inferior}}$$

**ATR (14 períodos):**

$$TR = \max(H - L, |H - C_{prev}|, |L - C_{prev}|)$$

$$ATR = EMA_{14}(TR)$$

## B.3 Estimadores de Volatilidad OHLC

**Parkinson (ventanas de 21 y 63 días):**

$$\sigma_P^2 = \frac{1}{4 \ln 2} \cdot \frac{1}{n} \sum_{i=1}^n (\ln H_i - \ln L_i)^2$$

**Garman-Klass:**

$$\sigma_{GK}^2 = \frac{1}{n} \sum_{i=1}^n \left[ \frac{1}{2} (\ln H_i - \ln L_i)^2 - (2 \ln 2 - 1) (\ln C_i - \ln O_i)^2 \right]$$

**Rogers-Satchell:**

$$\sigma_{RS}^2 = \frac{1}{n} \sum_{i=1}^n [(\ln H_i - \ln O_i)(\ln H_i - \ln C_i) + (\ln L_i - \ln O_i)(\ln L_i - \ln C_i)]$$

**Yang-Zhang:**

$$\sigma_{YZ}^2 = \sigma_O^2 + k\sigma_C^2 + (1 - k)\sigma_{RS}^2$$

donde  $\sigma_O^2$  es varianza overnight,  $\sigma_C^2$  es varianza cierre-a-cierre, y  $k$  es un factor de ponderación óptimo.

**B.4 Características del Triple Screen**

Indicadores semanales calculados sobre datos agregados a 5 días; indicadores diarios sobre datos diarios crudos. Clasificación del Sistema Impulso: Verde (alcista) cuando EMA ascendente Y histograma MACD ascendente; Rojo (bajista) cuando ambos descendentes; Azul (neutral) en otro caso.

**Señales Triple Screen:**

- Setup de compra: Tendencia semanal alcista + osciladores diarios sobrevendidos
- Setup de venta: Tendencia semanal bajista + osciladores diarios sobrecomprados
- Señal final: Setup activo + confirmación del Sistema Impulso

**B.5 Estructura de Términos de Volatilidad****Pendientes:**

- VIX9D - VIX (muy corto plazo)
- VIX - VIX3M (corto vs. medio plazo)
- VIX3M - VIX6M (medio vs. largo plazo)

**Z-scores:**

$$z_{VIX} = \frac{VIX_t - \mu_{VIX,21}}{\sigma_{VIX,21}}$$

donde  $\mu$  y  $\sigma$  son la media y desviación estándar móviles de 21 días.

**B.6 Correlaciones Cross-Asset**

Correlaciones de Pearson móviles de 21 días entre pares de retornos:

- $\rho(\text{SPY}, \text{TLT})$ : Correlación renta variable - renta fija
- $\rho(\text{SPY}, \text{GLD})$ : Correlación renta variable - oro
- $\rho(\text{SPY}, \text{CL1})$ : Correlación renta variable - petróleo
- $\rho(\text{DXY}, \text{SPY})$ : Correlación dólar - renta variable

## B.7 Rezagos y Estadísticas Móviles

**Rezagos:** Valores en  $t - 1, t - 2, t - 3, t - 5, t - 7$  para variables seleccionadas.

**Medias móviles:** Ventanas de 5, 10, 21, 63 días.

**Volatilidad móvil:** Desviación estándar sobre ventanas de 5, 10, 21, 63 días.

**Total de características:** 647.

## C. Parámetros Óptimos de Umbral

Esta sección presenta los parámetros óptimos de posicionamiento por percentil para cada modelo, obtenidos mediante grid search sobre el conjunto de validación.

### C.1 Metodología de Optimización

#### C.1.1 Función Objetivo

Optimizamos el Sharpe Ratio neto (después de costos) sobre el período de validación:

$$(q_{3x}^*, q_{1x}^*) = \arg \max_{q_{3x}, q_{1x}} \text{Sharpe}(R_{net}(q_{3x}, q_{1x})) \quad (39)$$

sujeto a  $q_{3x} < q_{1x}$  (percentil para 3x debe ser más selectivo que para 1x).

#### C.1.2 Grid de Búsqueda

- $q_{3x} \in \{5, 10, 15, 20, 25, 30\}$  (percentil superior para posición UPRO)
- $q_{1x} \in \{20, 30, 40, 50, 60\}$  (percentil superior para posición SPY)
- Total: 30 combinaciones evaluadas por modelo

#### C.1.3 Restricciones

1.  $q_{3x} < q_{1x}$ : Asegura que UPRO (3x) requiera mayor confianza que SPY (1x)
2. Ventana rolling: 63 días para cálculo de percentiles
3. Warmup: Predicciones de training para los primeros 63 días de test

Cuadro 19: Parámetros Óptimos de Umbral por Modelo

| Modelo               | Categoría        | $q_{3x}$ (%) | $q_{1x}$ (%) | Interpretación                                       |
|----------------------|------------------|--------------|--------------|------------------------------------------------------|
| Ridge                | ML               | 20           | 30           | Top 20 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x |
| GradientBoosting     | ML               | 30           | 60           | Top 30 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x |
| CNN_LSTM             | Hybrid           | 30           | 60           | Top 30 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x |
| BiGRU                | RNN              | 15           | 50           | Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x |
| RandomForest         | ML               | 15           | 50           | Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x |
| NBEATS               | DeepLearning     | 10           | 20           | Top 10 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x |
| LightGBM             | GradientBoosting | 10           | 50           | Top 10 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x |
| CatBoost             | GradientBoosting | 5            | 30           | Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x  |
| XGBoost              | GradientBoosting | 15           | 20           | Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x |
| SeasonalNaive        | TimeSeries       | 5            | 40           | Top 5 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x  |
| BiLSTM               | RNN              | 5            | 30           | Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x  |
| DLinear              | DeepLearning     | 10           | 20           | Top 10 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x |
| NHiTS                | DeepLearning     | 15           | 20           | Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x |
| LSTM_Attention       | Attention        | 15           | 50           | Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x |
| TFT                  | DeepLearning     | 5            | 20           | Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x  |
| AutoARIMA            | TimeSeries       | 5            | 20           | Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x  |
| TCN                  | DeepLearning     | 15           | 50           | Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x |
| Prophet              | Prophet          | 30           | 50           | Top 30 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x |
| ElasticNet           | ML               | 15           | 20           | Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x |
| Lasso                | ML               | 15           | 20           | Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x |
| ExponentialSmoothing | TimeSeries       | 5            | 50           | Top 5 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x  |
| GARCH                | GARCH            | 25           | 30           | Top 25 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x |
| Theta                | TimeSeries       | 5            | 20           | Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x  |

Nota:  $q_{3x}$  = percentil para posición UPRO (3x).  $q_{1x}$  = percentil para posición SPY (1x). Predicciones por debajo del percentil  $q_{1x}$  resultan en posición Cash (0). Parámetros optimizados mediante grid search sobre conjunto de validación.

## C.2 Tabla de Parámetros Óptimos

## C.3 Análisis de Parámetros

### C.3.1 Patrones Observados

1. **Modelos conservadores** (AutoARIMA, TFT, BiLSTM):  $q_{3x} = 5$ , requieren alta confianza para apalancar.
2. **Modelos agresivos** (GradientBoosting, Prophet, CNN-LSTM):  $q_{3x} \geq 30$ , más dispuestos a apalancar.
3. **Modelos equilibrados** (Ridge, BiGRU):  $q_{3x} \in [15, 20]$ , balance entre agresividad y conservadurismo.

### C.3.2 Relación Parámetros-Rendimiento

Cuadro 20: Correlación entre Parámetros y Métricas

| Correlación       | $q_{3x}$ | $q_{1x}$ |
|-------------------|----------|----------|
| vs Retorno Total  | 0.42     | 0.38     |
| vs Sharpe Ratio   | 0.15     | 0.22     |
| vs Max Drawdown   | 0.51     | 0.33     |
| vs % Tiempo en 3x | 0.89     | 0.24     |

*Nota: Correlaciones calculadas sobre los 23 modelos.  $q_{3x}$  más alto implica más tiempo en UPRO, mayor retorno pero mayor drawdown.*

### C.3.3 Implicaciones

- $q_{3x}$  **alto** + **buen rendimiento**: El modelo tiene señales fuertes frecuentes (GradientBoosting).
- $q_{3x}$  **bajo** + **buen rendimiento**: El modelo es selectivo pero preciso (Ridge).
- $q_{3x}$  **alto** + **mal rendimiento**: El modelo sobreestima señales positivas (XGBoost).

## C.4 Sensibilidad a Parámetros

### C.4.1 Ridge: Análisis de Sensibilidad

La sensibilidad moderada sugiere que los resultados son robustos a variaciones razonables en los parámetros.

Cuadro 21: Sensibilidad de Ridge a Parámetros de Umbral

| $q_{3x}$  | $q_{1x}$  | Retorno         | Sharpe      | Max DD         |
|-----------|-----------|-----------------|-------------|----------------|
| 10        | 30        | +245.2 %        | 0.87        | -32.1 %        |
| 15        | 30        | +287.6 %        | 0.91        | -35.4 %        |
| <b>20</b> | <b>30</b> | <b>+318.8 %</b> | <b>0.93</b> | <b>-38.6 %</b> |
| 25        | 30        | +301.3 %        | 0.85        | -42.3 %        |
| 20        | 40        | +298.4 %        | 0.89        | -36.2 %        |
| 20        | 50        | +276.1 %        | 0.84        | -34.8 %        |

*Nota: Valores en negrita indican parámetros óptimos seleccionados.*

## C.5 Estabilidad Temporal de Parámetros

### C.5.1 Walk-Forward Optimization

Evaluamos si los parámetros óptimos son estables en el tiempo usando walk-forward optimization:

1. Dividir el período de prueba en 5 sub-períodos de 260 días
2. Re-optimizar parámetros al inicio de cada sub-período
3. Comparar parámetros seleccionados vs parámetros fijos

Cuadro 22: Estabilidad de Parámetros: Ridge

| Sub-período         | $q_{3x}$ Óptimo | $q_{1x}$ Óptimo |
|---------------------|-----------------|-----------------|
| Oct 2020 - Sep 2021 | 20              | 30              |
| Oct 2021 - Sep 2022 | 15              | 30              |
| Oct 2022 - Sep 2023 | 20              | 30              |
| Oct 2023 - Sep 2024 | 25              | 30              |
| Oct 2024 - Dic 2025 | 20              | 30              |
| <b>Moda</b>         | <b>20</b>       | <b>30</b>       |

Los parámetros óptimos de Ridge son estables, con  $q_{3x} = 20$ ,  $q_{1x} = 30$  siendo óptimos en 3 de 5 sub-períodos.

## C.6 Interpretación de Umbrales

### C.6.1 Significado de los Percentiles

Para Ridge con  $(q_{3x}, q_{1x}) = (20, 30)$ :

- **Predicción en top 20 %:** Posición UPRO (3x leverage)
- **Predicción en top 20-30 %:** Posición SPY (1x)

■ **Predicción debajo de top 30 %:** Cash (tasa libre de riesgo)

Esto significa que Ridge solo toma posiciones de riesgo cuando su predicción está en el tercio superior de su distribución histórica reciente.

### C.6.2 Percentiles vs Valores Absolutos

El uso de percentiles rolling en lugar de umbrales fijos tiene ventajas:

1. **Adaptabilidad:** Se ajusta automáticamente a cambios en la distribución de predicciones.
2. **Robustez:** Menos sensible a drift en el modelo.
3. **Consistencia:** Mantiene proporción constante de días en cada posición (aproximadamente).

## D. Hiperparámetros de Modelos

Esta sección detalla los hiperparámetros utilizados para cada uno de los 23 modelos evaluados. Los valores fueron seleccionados mediante validación cruzada temporal (TimeSeriesSplit con 5 folds) sobre el conjunto de entrenamiento.

### D.1 Modelos de Machine Learning Clásico

Cuadro 23: Hiperparámetros: Modelos de Regresión Lineal Regularizada

| Modelo     | Parámetro     | Valor/Descripción             |
|------------|---------------|-------------------------------|
| Ridge      | alpha         | 1.0 (regularización L2)       |
|            | solver        | 'auto' (selección automática) |
|            | fit_intercept | True                          |
| Lasso      | alpha         | 0.001 (regularización L1)     |
|            | max_iter      | 10,000                        |
|            | tol           | $10^{-4}$                     |
| ElasticNet | alpha         | 0.001                         |
|            | l1_ratio      | 0.5 (balance L1/L2)           |
|            | max_iter      | 10,000                        |

Cuadro 24: Hiperparámetros: Modelos Ensemble

| Modelo           | Parámetro         | Valor  |
|------------------|-------------------|--------|
| RandomForest     | n_estimators      | 200    |
|                  | max_depth         | 10     |
|                  | min_samples_split | 20     |
|                  | min_samples_leaf  | 10     |
|                  | max_features      | 'sqrt' |
|                  | bootstrap         | True   |
|                  | n_jobs            | -1     |
| GradientBoosting | n_estimators      | 200    |
|                  | max_depth         | 5      |
|                  | learning_rate     | 0.05   |
|                  | subsample         | 0.8    |
|                  | min_samples_split | 20     |

Cuadro 25: Hiperparámetros: XGBoost, LightGBM, CatBoost

| Modelo   | Parámetro             | Valor    |
|----------|-----------------------|----------|
| XGBoost  | n_estimators          | 200      |
|          | max_depth             | 6        |
|          | learning_rate         | 0.05     |
|          | subsample             | 0.8      |
|          | colsample_bytree      | 0.8      |
|          | reg_alpha             | 0.1 (L1) |
|          | reg_lambda            | 1.0 (L2) |
|          | early_stopping_rounds | 50       |
| LightGBM | n_estimators          | 200      |
|          | max_depth             | 8        |
|          | learning_rate         | 0.05     |
|          | num_leaves            | 31       |
|          | subsample             | 0.8      |
|          | colsample_bytree      | 0.8      |
|          | reg_alpha             | 0.1      |
|          | reg_lambda            | 1.0      |
| CatBoost | iterations            | 200      |
|          | depth                 | 6        |
|          | learning_rate         | 0.05     |
|          | l2_leaf_reg           | 3.0      |
|          | random_strength       | 1.0      |
|          | bagging_temperature   | 0.5      |



Cuadro 26: Hiperparámetros: Modelos de Series Temporales

| Modelo               | Parámetro               | Valor                          |
|----------------------|-------------------------|--------------------------------|
| AutoARIMA            | max_p                   | 5                              |
|                      | max_q                   | 5                              |
|                      | max_d                   | 2                              |
|                      | seasonal                | False                          |
|                      | stepwise                | True                           |
|                      | suppress_warnings       | True                           |
| ExponentialSmoothing | trend                   | 'add'                          |
|                      | seasonal                | None                           |
|                      | damped_trend            | True                           |
| Theta                | theta                   | 0 (optimizado automáticamente) |
|                      | deseasonalize           | True                           |
| SeasonalNaive        | K                       | 5 (días de rezago)             |
| Prophet              | changepoint_prior_scale | 0.05                           |
|                      | seasonality_prior_scale | 10                             |
|                      | yearly_seasonality      | True                           |
|                      | weekly_seasonality      | True                           |
|                      | daily_seasonality       | False                          |
| GARCH                | p                       | 1                              |
|                      | q                       | 1                              |
|                      | vol                     | 'GARCH'                        |
|                      | dist                    | 'normal'                       |

## D.2 Modelos de Gradient Boosting

## D.3 Modelos de Series Temporales

## D.4 Modelos de Deep Learning (Darts)

## D.5 Modelos RNN Bidireccionales

## D.6 Modelos Híbridos y Attention (PyTorch)

## D.7 Configuración de Entrenamiento Común

## E. Glosario de Términos

Este glosario proporciona definiciones de los términos técnicos utilizados a lo largo del documento.

### Términos de Finanzas

**Alfa ( $\alpha$ )** Rendimiento en exceso de una inversión respecto a un benchmark de referencia, ajustado por riesgo. Un alfa positivo indica que la estrategia genera valor por encima del mercado.

Cuadro 27: Hiperparámetros: Modelos Deep Learning (Darts)

| Modelo  | Parámetro           | Valor         |
|---------|---------------------|---------------|
| DLinear | input_chunk_length  | 30            |
|         | output_chunk_length | 1             |
|         | n_epochs            | 100           |
|         | batch_size          | 32            |
|         | optimizer_kwargs    | {'lr': 0.001} |
| N-BEATS | input_chunk_length  | 30            |
|         | output_chunk_length | 1             |
|         | num_stacks          | 30            |
|         | num_blocks          | 1             |
|         | num_layers          | 4             |
|         | layer_widths        | 256           |
|         | n_epochs            | 100           |
| N-HiTS  | input_chunk_length  | 30            |
|         | output_chunk_length | 1             |
|         | num_stacks          | 3             |
|         | num_blocks          | 1             |
|         | num_layers          | 2             |
|         | layer_widths        | 256           |
|         | n_epochs            | 100           |
| TCN     | input_chunk_length  | 30            |
|         | output_chunk_length | 1             |
|         | kernel_size         | 3             |
|         | num_filters         | 32            |
|         | dilation_base       | 2             |
|         | n_epochs            | 100           |
|         | dropout             | 0.2           |
| TFT     | input_chunk_length  | 30            |
|         | output_chunk_length | 1             |
|         | hidden_size         | 64            |
|         | lstm_layers         | 1             |
|         | attention_heads     | 4             |
|         | dropout             | 0.1           |
|         | n_epochs            | 100           |

Cuadro 28: Hiperparámetros: Bi-LSTM y Bi-GRU

| Modelo | Parámetro           | Valor         |
|--------|---------------------|---------------|
| BiLSTM | input_chunk_length  | 30            |
|        | output_chunk_length | 1             |
|        | hidden_dim          | 64            |
|        | n_rnn_layers        | 2             |
|        | bidirectional       | True          |
|        | dropout             | 0.2           |
|        | n_epochs            | 100           |
|        | batch_size          | 32            |
|        | optimizer_kwargs    | {'lr': 0.001} |
| BiGRU  | input_chunk_length  | 30            |
|        | output_chunk_length | 1             |
|        | hidden_dim          | 64            |
|        | n_rnn_layers        | 2             |
|        | bidirectional       | True          |
|        | dropout             | 0.2           |
|        | n_epochs            | 100           |
|        | batch_size          | 32            |

Cuadro 29: Hiperparámetros: CNN-LSTM y LSTM+Attention

| Modelo                    | Parámetro        | Valor     |
|---------------------------|------------------|-----------|
| CNN-LSTM                  | sequence_length  | 30        |
|                           | cnn_filters      | [32, 64]  |
|                           | cnn_kernel_size  | 3         |
|                           | lstm_hidden_size | 64        |
|                           | lstm_layers      | 2         |
|                           | dropout          | 0.3       |
|                           | n_epochs         | 100       |
|                           | batch_size       | 32        |
|                           | learning_rate    | 0.001     |
| LSTM+Attention<br>(Luong) | sequence_length  | 30        |
|                           | lstm_hidden_size | 64        |
|                           | lstm_layers      | 2         |
|                           | attention_type   | 'general' |
|                           | dropout          | 0.3       |
|                           | n_epochs         | 100       |
|                           | batch_size       | 32        |

Cuadro 30: Configuración de Entrenamiento Común

| Parámetro                | Valor                                    |
|--------------------------|------------------------------------------|
| Período de entrenamiento | Enero 2015 - Septiembre 2020             |
| Período de prueba        | Octubre 2020 - Diciembre 2025            |
| División temporal        | Sin shuffle, estrictamente cronológica   |
| Validación cruzada       | TimeSeriesSplit, 5 folds                 |
| Normalización            | StandardScaler, fit solo en train        |
| Features eliminados      | Constantes, >50 % NaN, correlación >0.95 |
| Warmup para percentiles  | 63 días (usando predicciones de train)   |
| Early stopping           | 10-50 epochs sin mejora (según modelo)   |
| GPU                      | NVIDIA RTX 3090 (24GB)                   |
| Seed                     | 42 (reproducibilidad)                    |

**Benchmark** Índice o estrategia de referencia contra la cual se compara el desempeño de una inversión. En este estudio, el benchmark es la estrategia buy-and-hold del SPY.

**Drawdown** Caída porcentual desde un máximo histórico hasta un mínimo subsecuente. El Maximum Drawdown (MaxDD) mide la mayor pérdida pico-a-valle durante un período.

**ETF (Exchange-Traded Fund)** Fondo de inversión que cotiza en bolsa como una acción. SPY replica el S&P 500; UPRO proporciona exposición 3x apalancada al mismo índice.

**ETF Apalancado** ETF que utiliza derivados para multiplicar los retornos diarios del índice subyacente. UPRO (3x) triplica el retorno diario del S&P 500.

**Ratio de Sharpe** Medida de rendimiento ajustado por riesgo:  $\text{Sharpe} = \frac{\bar{r} - r_f}{\sigma}$ , donde  $\bar{r}$  es el retorno promedio,  $r_f$  la tasa libre de riesgo, y  $\sigma$  la volatilidad.

**Ratio de Sortino** Similar al Sharpe pero usando solo la volatilidad de retornos negativos (downside deviation), penalizando únicamente el riesgo de pérdidas.

**Ratio de Calmar** Retorno anualizado dividido por el maximum drawdown. Mide el retorno obtenido por unidad de riesgo de cola.

**Turnover** Frecuencia de cambios de posición en una estrategia. Alto turnover implica mayores costos de transacción.

**Spread Bid-Ask** Diferencia entre el precio de compra (ask) y venta (bid) de un activo. Representa un costo implícito de transacción.

## Términos de Machine Learning

**Ridge Regression** Regresión lineal con regularización L2 que penaliza coeficientes grandes:  $\min ||y - X\beta||^2 + \lambda||\beta||^2$ . Reduce sobreajuste manteniendo todos los predictores.

**Gradient Boosting** Técnica de ensemble que construye modelos secuencialmente, donde cada modelo corrige los errores del anterior. Implementaciones populares incluyen XGBoost, LightGBM y CatBoost.

**LSTM (Long Short-Term Memory)** Arquitectura de red neuronal recurrente diseñada para capturar dependencias de largo plazo en secuencias, utilizando mecanismos de compuertas (gates) para controlar el flujo de información.

**TCN (Temporal Convolutional Network)** Red convolucional con dilataciones causales que captura dependencias temporales de largo alcance manteniendo la causalidad (no usa información futura).

**Transformer** Arquitectura basada en mecanismos de atención que procesa secuencias en paralelo. TFT (Temporal Fusion Transformer) es una variante especializada para series temporales.

**Regularización** Técnica para prevenir sobreajuste añadiendo penalizaciones a la función de pérdida. L1 (Lasso) promueve sparsity; L2 (Ridge) reduce magnitud de coeficientes.

**Sobreajuste (Overfitting)** Cuando un modelo memoriza el ruido del conjunto de entrenamiento en lugar de aprender patrones generalizables, resultando en pobre desempeño fuera de muestra.

**Validación Cruzada Temporal** Técnica de validación que respeta el orden temporal de los datos, entrenando solo con datos pasados para predecir datos futuros.

## Términos de Análisis Técnico

**Triple Screen (Sistema de Elder)** Sistema de trading desarrollado por Alexander Elder que combina análisis de tendencia en marco temporal superior con osciladores en marco inferior para identificar puntos de entrada.

**MACD (Moving Average Convergence Divergence)** Indicador de momentum que muestra la relación entre dos medias móviles exponenciales. El histograma MACD indica la fuerza de la tendencia.

**RSI (Relative Strength Index)** Oscilador de momentum que mide la velocidad y magnitud de cambios de precio, oscilando entre 0 y 100. Valores  $>70$  indican sobrecompra;  $<30$  sobreventa.

**Force Index** Indicador desarrollado por Elder que combina precio y volumen para medir la fuerza detrás de los movimientos del mercado.

**Sistema Impulso** Clasificación de barras según dirección de EMA y momentum del MACD: Verde (alcista), Rojo (bajista), Azul (neutral).

**Estimadores de Volatilidad OHLC** Métodos para estimar volatilidad usando precios de Apertura, Máximo, Mínimo y Cierre. Incluyen Parkinson, Garman-Klass, Rogers-Satchell y Yang-Zhang.

### Términos Estadísticos

**Bootstrap** Técnica de remuestreo con reemplazo para estimar la distribución de un estadístico y construir intervalos de confianza.

**Test de Diebold-Mariano** Prueba estadística para comparar la capacidad predictiva de dos modelos, evaluando si la diferencia en errores de predicción es significativa.

**Model Confidence Set (MCS)** Procedimiento que identifica el conjunto de modelos que contiene al mejor modelo verdadero con una probabilidad dada.

**Test de Clark-West** Prueba para comparar modelos anidados que corrige el sesgo inherente cuando el modelo restringido es verdadero.

**Directional Accuracy (DA)** Porcentaje de predicciones donde la dirección predicha coincide con la dirección realizada del mercado.

**DA3x** Directional Accuracy calculado únicamente en días donde el modelo toma posición apalancada (3x). Métrica propuesta en este estudio como mejor predictor de rentabilidad.

**Correlaciones Cross-Asset** Correlaciones móviles entre diferentes clases de activos (acciones, bonos, commodities, divisas) que capturan dinámicas de régimen de mercado y apetito por riesgo.