

Desafiando la Eficiencia del Mercado:

Aprendizaje Automático para Predicción Direccional y Generación de Alfa en el S&P 500

David González Cañón

Maestría en Inteligencia de Negocios para Finanzas

Diciembre 2025

Resumen

Este estudio investiga empíricamente la Hipótesis de Eficiencia de Mercado mediante un enfoque estructurado en dos hitos fundamentales. El **primer hito** consiste en entrenar 23 modelos de aprendizaje automático y profundo (incluyendo Ridge, XGBoost, LightGBM, LSTM, TCN, y Transformers) para generar predicciones sobre los retornos del S&P 500. El objetivo no es predecir con exactitud el valor del retorno de mañana, sino obtener suficiente precisión direccional para informar decisiones de inversión. El **segundo hito** traduce estas predicciones en una estrategia de trading LONG-ONLY que aprovecha el apalancamiento disponible en ETFs (efectivo, SPY 1x, UPRO 3x) para generar alfa positivo después de costos de transacción.

El proceso de ingeniería de características transforma 92 variables macroeconómicas, financieras y de sentimiento de Bloomberg Terminal en 647 predictores. Esta transformación incluye técnicas diversas como indicadores técnicos clásicos y estimadores de volatilidad basados en precios OHLC (Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang).

Cuatro de veintitrés modelos superan al benchmark pasivo, demostrando que la dificultad de superar al mercado es real pero no insuperable. Los hallazgos presentan evidencia empírica de que técnicas de aprendizaje automático pueden capturar patrones direccionales explotables en retornos de mercado, contribuyendo al debate sobre la validez de la Hipótesis de Eficiencia de Mercado.

Palabras clave: Hipótesis de Eficiencia de Mercado, Aprendizaje Automático, Aprendizaje Profundo, Pronóstico de Series Temporales, Análisis Técnico, Generación de Alfa, S&P 500, Finanzas Cuantitativas, ETFs Apalancados, Gestión de Riesgo

Clasificación JEL: G14, G17, C45, C53

Índice

1. Introducción	8
1.1. Contexto y Motivación	8
1.2. La Relevancia del Debate sobre Eficiencia de Mercado	8
1.3. Contribuciones al Conocimiento	9
1.4. Estructura del Documento	10
2. Revisión de Literatura y Fundamentos Teóricos	10
2.1. La Hipótesis de Eficiencia de Mercado: Origen y Evolución	10
2.1.1. Fundamentos Conceptuales	10
2.1.2. La Paradoja de Grossman-Stiglitz	11
2.2. Anomalías de Mercado y Evidencia Contra la HEM	11
2.3. Aprendizaje Automático en Valoración de Activos	11
2.4. El Sistema Triple Screen de Alexander Elder	11
3. Datos y Metodología	12
3.1. Fuentes de Datos y Construcción de la Muestra	12
3.2. Ingeniería de Características	12
3.3. Variable Objetivo y División de Muestra	12
3.4. Especificaciones de Modelos	12
3.5. Sistema de Posicionamiento por Percentiles	13
4. Resultados Empíricos	13
4.1. Resumen de Rendimiento	13
4.1.1. Tabla Principal de Rendimiento	13
4.1.2. Hallazgos Principales	13

4.1.3. Tabla Resumen Ejecutivo	15
4.2. Análisis por Familia de Modelos	15
4.2.1. Comparación por Categoría	15
4.2.2. Interpretación por Categoría	15
4.3. Curvas de Equity	16
4.4. Distribución de Posiciones	17
4.4.1. Patrones de Posicionamiento	17
4.5. Análisis de Trades	18
4.5.1. Estadísticas de Trading	18
4.5.2. Distribución de P&L por Trade	18
4.6. Comparación con Benchmarks Adicionales	18
4.7. Aplicación Interactiva	19
5. La Paradoja del Directional Accuracy	19
5.1. El Hallazgo Contraintuitivo	20
5.1.1. Intuición Naïve vs Realidad	20
5.1.2. Evidencia Empírica	20
5.2. Explicación de la Paradoja	21
5.2.1. El DA Trata Todos los Días como Iguales	21
5.2.2. Lo Que Realmente Importa: Asimetría Condicional	21
5.3. El Indicador DA@3x: Una Métrica Más Relevante	21
5.3.1. Comparación DA vs DA@3x	22
5.3.2. Interpretación	22
5.4. Implicaciones para el Diseño de Estrategias	22
5.4.1. No Optimizar por DA	22
5.4.2. Métricas Alternativas Recomendadas	23
5.4.3. El Valor de la Selectividad	23
5.5. Conexión con la Literatura	23
5.6. Resumen de la Sección	24
6. Marco de Gestión de Riesgo	24
6.1. Métricas de Riesgo Ajustado	24
6.1.1. Sharpe Ratio	24
6.1.2. Sortino Ratio	25
6.1.3. Calmar Ratio	25

6.2. Value at Risk (VaR) y Expected Shortfall	25
6.2.1. Metodología	25
6.2.2. Conditional VaR (CVaR)	25
6.2.3. Resultados de Riesgo de Cola	26
6.3. Análisis de Drawdown	26
6.3.1. Máximos Drawdowns	26
6.3.2. Períodos de Drawdown Significativo	26
6.3.3. Recuperación de Drawdowns	26
6.4. Control de Riesgo Implícito en la Estrategia	27
6.4.1. Posición en Cash como Hedge Natural	27
6.4.2. Apalancamiento Selectivo	27
6.5. Implicaciones para la Implementación	27
7. Análisis por Régimen de Mercado	28
7.1. Definición de Regímenes	28
7.1.1. Criterios de Clasificación	28
7.2. Distribución de Regímenes en el Período de Prueba	28
7.3. Rendimiento por Modelo por Régimen	29
7.3.1. Bull Market (133 días)	29
7.3.2. Bear Market (49 días)	29
7.3.3. High Volatility (121 días)	29
7.3.4. Sideways (938 días)	30
7.4. Tabla Completa de Rendimiento por Régimen	30
7.5. Análisis de Consistencia Cross-Régimen	30
7.6. Implicaciones para Gestión Táctica	31
7.6.1. Rotación de Modelos por Régimen	31
7.6.2. Ensemble Dinámico	31
7.6.3. Advertencia sobre Detección de Régimen	31
7.7. Ridge: El Modelo All-Weather	31
8. Validación Estadística	32
8.1. Bootstrap de Sharpe Ratios	32
8.1.1. Metodología	32
8.1.2. Corrección de Ledoit-Wolf	32
8.1.3. Resultados: Intervalos de Confianza	32

8.1.4.	Interpretación	33
8.2.	Test de Diebold-Mariano	33
8.2.1.	Formulación	33
8.2.2.	Resultados: Comparación con Benchmark	33
8.3.	Model Confidence Set (MCS)	34
8.3.1.	Metodología	34
8.3.2.	Resultados	34
8.4.	Test de Clark-West	34
8.4.1.	Formulación	34
8.4.2.	Aplicación	34
8.5.	Análisis de Overfitting	35
8.5.1.	Comparación In-Sample vs Out-of-Sample	35
8.5.2.	Corrección por Multiple Testing	35
8.5.3.	False Discovery Rate (FDR)	35
8.6.	Resumen de Validación Estadística	36
8.7.	Conclusiones de la Validación	36
9.	Análisis de Costos e Implementación	36
9.1.	Modelo de Costos Detallado	37
9.1.1.	Componentes del Costo	37
9.1.2.	Bid-Ask Spreads por Instrumento	37
9.1.3.	Volatility Drag en ETFs Apalancados	37
9.2.	Impacto de Costos por Modelo	37
9.2.1.	Observaciones Clave	37
9.3.	Relación Turnover-Rentabilidad	39
9.3.1.	Análisis de la Relación	39
9.4.	Análisis de Sensibilidad a Costos	40
9.4.1.	Escenarios de Costo	40
9.4.2.	Robustez a Costos	40
9.5.	Consideraciones de Implementación Real	40
9.5.1.	Costos Adicionales No Modelados	40
9.5.2.	Estimación de Slippage	40
9.5.3.	Capacidad de la Estrategia	41
9.5.4.	Alternativas de Implementación	41
9.6.	Frecuencia de Rebalanceo	41

9.6.1. Sensibilidad a Latencia	41
9.7. Resumen de Costos e Implementación	42
10.Discusión: Contribuciones al Debate sobre Eficiencia de Mercado	42
10.1. Resumen de Hallazgos Empíricos	42
10.2. Interpretación desde la Perspectiva de Eficiencia de Mercado	42
10.2.1. El Argumento contra la Eficiencia	42
10.2.2. El Argumento a Favor de la Eficiencia	42
10.3. Reconciliando las Interpretaciones	43
11.Limitaciones y Consideraciones de Robustez	43
11.1. Limitaciones del Estudio	43
11.1.1. Período de Prueba	43
11.1.2. Mercado Único	43
11.1.3. Estabilidad de Parámetros	43
11.1.4. Impacto de Mercado No Modelado	43
11.2. Análisis de Robustez	44
11.2.1. Diversidad de Modelos Exitosos	44
12.Conclusión	44
12.1. Resumen de Hallazgos	44
12.2. Contribuciones al Debate sobre Eficiencia de Mercado	44
12.3. Implicaciones Prácticas	45
12.4. Direcciones para Investigación Futura	45
12.5. Reflexiones Finales	45
A. Especificación Completa de Variables	47
B. Detalles de Ingeniería de Características	47
C. Hiperparámetros de Modelos	47
C.1. Modelos de Machine Learning Clásico	51
C.2. Modelos de Gradient Boosting	51
C.3. Modelos de Series Temporales	51
C.4. Modelos de Deep Learning (Darts)	51
C.5. Modelos RNN Bidireccionales	51
C.6. Modelos Híbridos y Attention (PyTorch)	51

C.7. Configuración de Entrenamiento Común	51
D. Parámetros Óptimos de Umbral	51
D.1. Metodología de Optimización	51
D.1.1. Función Objetivo	51
D.1.2. Grid de Búsqueda	53
D.1.3. Restricciones	53
D.2. Tabla de Parámetros Óptimos	53
D.3. Análisis de Parámetros	54
D.3.1. Patrones Observados	54
D.3.2. Relación Parámetros-Rendimiento	54
D.3.3. Implicaciones	54
D.4. Sensibilidad a Parámetros	54
D.4.1. Ridge: Análisis de Sensibilidad	54
D.5. Estabilidad Temporal de Parámetros	55
D.5.1. Walk-Forward Optimization	55
D.6. Interpretación de Umbrales	55
D.6.1. Significado de los Percentiles	55
D.6.2. Percentiles vs Valores Absolutos	56

1. Introducción

1.1 Contexto y Motivación

La Hipótesis de Eficiencia de Mercado (HEM), formalizada por [Fama \(1970\)](#) hace más de cinco décadas, permanece como una de las proposiciones más influyentes y debatidas en la economía financiera contemporánea. En su formulación más estricta, la hipótesis postula que los precios de los activos incorporan instantánea y completamente toda la información disponible, haciendo imposible la obtención de rendimientos anormales sistemáticos a través de cualquier estrategia de trading basada en datos históricos o información pública.

Sin embargo, el panorama empírico ha evolucionado considerablemente desde el trabajo seminal de Fama. La proliferación de anomalías documentadas, la sofisticación creciente de las técnicas de aprendizaje automático, y la disponibilidad de conjuntos de datos cada vez más ricos han reavivado el debate fundamental: ¿procesan realmente los mercados financieros la información de manera eficiente, o existen ineficiencias persistentes susceptibles de explotación por inversores sofisticados?

Este estudio contribuye a este debate mediante un enfoque empírico estructurado en **dos hitos fundamentales**:

Hito 1 – Predicción: Entrenar múltiples modelos de aprendizaje automático y profundo (23 en total) para generar predicciones sobre los retornos del S&P 500. El objetivo no es predecir con exactitud el valor numérico del retorno de mañana—tarea que la literatura ha demostrado extremadamente difícil—sino obtener suficiente *precisión direccional* para informar decisiones de inversión.

Hito 2 – Implementación: Traducir las predicciones de los modelos en una estrategia de trading práctica que aproveche el apalancamiento disponible en ETFs (UPRO 3x, SPY 1x, efectivo) para generar alfa positivo después de costos de transacción realistas.

Este enfoque reconoce una distinción crucial: mientras que predecir el retorno exacto del mercado puede ser imposible, identificar la *dirección* con precisión suficiente puede ser económicamente explotable cuando se combina con una estrategia de posicionamiento inteligente.

1.2 La Relevancia del Debate sobre Eficiencia de Mercado

El debate sobre la eficiencia de mercado trasciende el ámbito puramente académico y tiene implicaciones profundas para la industria de gestión de activos, la regulación financiera y las decisiones de inversión individuales. Si los mercados son verdaderamente eficientes, los gestores activos de fondos destruyen valor para sus clientes a través de comisiones y costos de transacción

sin generar rendimientos superiores al mercado. En este escenario, la inversión pasiva a través de fondos indexados representaría la estrategia óptima para todos los inversores.

Por el contrario, si existen ineficiencias sistemáticas y explotables, surge la posibilidad de que estrategias cuantitativas sofisticadas puedan generar rendimientos ajustados por riesgo superiores. Esta posibilidad ha impulsado el crecimiento exponencial de la industria de hedge funds cuantitativos, que según estimaciones de la industria gestiona más de un billón de dólares en activos globalmente.

La presente investigación se sitúa en la intersección de estos debates al examinar si las técnicas más avanzadas de aprendizaje automático, combinadas con indicadores técnicos probados en la práctica, pueden identificar patrones predecibles en los retornos del mercado de valores.

1.3 Contribuciones al Conocimiento

Este estudio realiza múltiples contribuciones originales al cuerpo de conocimiento existente:

Primera contribución – Marco de dos hitos: Se presenta un enfoque estructurado que separa claramente la fase de predicción (entrenamiento de modelos) de la fase de implementación (estrategia de trading). Esta separación permite evaluar independientemente la capacidad predictiva de los modelos y la eficacia de la estrategia de posicionamiento.

Segunda contribución – Comparación exhaustiva de modelos: Se entrenan y evalúan 23 modelos distintos que abarcan desde regresión lineal regularizada hasta arquitecturas de deep learning de última generación (Transformers, TCN, LSTM bidireccionales), proporcionando una visión panorámica del estado del arte en predicción de retornos financieros.

Tercera contribución – Transparencia y reproducibilidad: A diferencia de gran parte del trabajo académico en finanzas cuantitativas que depende de conjuntos de datos anonimizados o propietarios, se proporciona documentación completa de las 92 variables base, las 647 características derivadas, y cada transformación metodológica empleada.

Cuarta contribución – Análisis de riesgo comprehensivo: Se implementa un marco de gestión de riesgo que incluye múltiples métricas (Sharpe, Sortino, Calmar, VaR, CVaR) y análisis de drawdown detallado.

Quinta contribución – Análisis de regímenes de mercado: Se evalúa el desempeño de los modelos bajo diferentes condiciones de mercado (alcista, bajista, lateral, alta volatilidad), proporcionando insights sobre robustez y adaptabilidad.

Sexta contribución – Validación estadística rigurosa: Se aplican tests estadísticos formales (Diebold-Mariano, Clark-West, Model Confidence Set) para validar la significancia del outperformance observado.

Séptima contribución – La paradoja del Directional Accuracy: Se documenta que el Directional Accuracy (DA) no es un predictor confiable de rentabilidad ($\rho = -0,14$), proponiendo el indicador DA@3x como métrica más relevante para evaluar estrategias de trading.

1.4 Estructura del Documento

El documento está organizado siguiendo la lógica de los dos hitos fundamentales:

Contexto teórico: La Sección 2 presenta una revisión de la literatura relevante sobre eficiencia de mercado, anomalías documentadas, y aplicaciones de aprendizaje automático en finanzas.

Hito 1 – Predicción: La Sección 3 describe la metodología de predicción: fuentes de datos, ingeniería de características, especificaciones de los 23 modelos, y el marco de evaluación.

Hito 2 – Implementación: La Sección 4 presenta los resultados empíricos detallados. La Sección 5 analiza la paradoja del Directional Accuracy y propone métricas alternativas. La Sección 6 analiza el marco de gestión de riesgo. La Sección 7 examina el desempeño por regímenes de mercado. La Sección 8 presenta la validación estadística. La Sección 9 analiza los costos de transacción.

Discusión y cierre: La Sección 10 discute las implicaciones para el debate sobre eficiencia de mercado. La Sección 11 examina limitaciones y robustez. La Sección 12 concluye con un resumen de hallazgos. Los apéndices proporcionan documentación técnica detallada.

2. Revisión de Literatura y Fundamentos Teóricos

2.1 La Hipótesis de Eficiencia de Mercado: Origen y Evolución

2.1.1 Fundamentos Conceptuales

La noción de que los precios de mercado reflejan la información disponible tiene raíces que se remontan a los trabajos pioneros de Louis Bachelier a principios del siglo XX. Sin embargo, la formulación moderna de la Hipótesis de Eficiencia de Mercado se atribuye principalmente a Eugene Fama, cuyo artículo seminal de 1970 estableció el marco conceptual que domina el pensamiento financiero hasta el día de hoy.

Fama (1970) definió un mercado eficiente como aquel en el que los precios “reflejan completamente” la información disponible. Esta definición aparentemente simple encierra profundas implicaciones para la práctica de inversión y la teoría financiera. Fama distinguió tres formas de eficiencia de mercado:

La **eficiencia en forma débil** postula que los precios actuales incorporan completamente toda la información contenida en la secuencia histórica de precios.

La **eficiencia en forma semi-fuerte** extiende esta noción al postular que los precios reflejan toda la información públicamente disponible.

La **eficiencia en forma fuerte** representa la proposición más extrema: los precios reflejan toda la información, incluyendo información privada.

2.1.2 La Paradoja de Grossman-Stiglitz

Una crítica teórica fundamental a la HEM fue planteada por [Grossman & Stiglitz \(1980\)](#), quienes demostraron la imposibilidad lógica de mercados perfectamente eficientes. Su argumento, conocido como la “paradoja de la información”, revela una contradicción interna: si nadie tiene incentivos para recopilar información, entonces los precios no pueden reflejar esa información.

[Grossman & Stiglitz \(1980\)](#) concluyen que los mercados deben ser “eficientemente ineficientes”—lo suficientemente ineficientes para compensar a quienes invierten en la adquisición de información, pero no tan ineficientes como para permitir ganancias excesivas.

2.2 Anomalías de Mercado y Evidencia Contra la HEM

Décadas de investigación empírica han documentado numerosas “anomalías”—patrones sistemáticos en los rendimientos que aparentemente contradicen las predicciones de eficiencia. [Dong et al. \(2022\)](#) documentan más de 150 predictores de retornos identificados en la literatura académica.

2.3 Aprendizaje Automático en Valoración de Activos

[Gu et al. \(2020\)](#) proporcionan un tratamiento comprehensivo de este campo, demostrando que las redes neuronales, el gradient boosting, y otros métodos no lineales superan sustancialmente a la regresión lineal en la predicción de rendimientos de acciones individuales.

[Zeng et al. \(2023\)](#) presentan un hallazgo sorprendente: un modelo simple de descomposición lineal (DLinear) supera a arquitecturas sofisticadas basadas en Transformers en múltiples benchmarks de pronóstico.

2.4 El Sistema Triple Screen de Alexander Elder

Alexander Elder introdujo el sistema Triple Screen en su influyente libro “Trading for a Living” ([Elder, 1993](#)). El sistema representa un enfoque sistemático para el timing de mercado que ha logrado amplia adopción entre traders profesionales durante más de tres décadas.

3. Datos y Metodología

3.1 Fuentes de Datos y Construcción de la Muestra

El análisis emplea datos diarios de Bloomberg Terminal abarcando desde el 3 de enero de 2000 hasta el 12 de diciembre de 2025, comprendiendo 6,507 días de negociación. El conjunto de datos integra 92 variables base organizadas en siete categorías temáticas.

3.2 Ingeniería de Características

Las variables en bruto raramente sirven como predictores efectivos en su forma original. Siguiendo prácticas establecidas en finanzas cuantitativas (Gu et al., 2020), se transforman las 92 variables base en 647 características a través de un pipeline sistemático de ingeniería de características.

3.3 Variable Objetivo y División de Muestra

El objetivo de predicción es el retorno en exceso a un día del S&P 500 sobre la tasa libre de riesgo:

$$y_t = r_{t+1}^{SPY} - r_{t+1}^f \quad (1)$$

Para asegurar una evaluación rigurosa fuera de muestra, se emplea una división temporal sin aleatorización:

- **Entrenamiento:** Enero 2000 - Septiembre 2020 (5,205 días)
- **Prueba:** Octubre 2020 - Diciembre 2025 (1,302 días)

3.4 Especificaciones de Modelos

Evaluamos 23 modelos abarcando cuatro categorías metodológicas:

Modelos de ML Clásico: Ridge, Lasso, ElasticNet, RandomForest, GradientBoosting

Gradient Boosting Avanzado: XGBoost, LightGBM, CatBoost

Series Temporales: AutoARIMA, ExponentialSmoothing, Theta, SeasonalNaive, Prophet, GARCH

Deep Learning: DLinear, N-BEATS, N-HiTS, TCN, TFT, BiLSTM, BiGRU, CNN-LSTM, LSTM+Attention

3.5 Sistema de Posicionamiento por Percentiles

Convertimos las predicciones continuas a posiciones discretas mediante umbrales basados en percentiles:

$$\text{posición}_t = \begin{cases} +3 \text{ (UPRO)} & \text{si } \hat{y}_t > Q_{q_{3x}} \\ +1 \text{ (SPY)} & \text{si } Q_{q_{1x}} < \hat{y}_t \leq Q_{q_{3x}} \\ 0 \text{ (Cash)} & \text{si } \hat{y}_t \leq Q_{q_{1x}} \end{cases} \quad (2)$$

Los retornos de la estrategia se calculan como:

$$r_t^{\text{estrategia}} = r_t^f + \text{posición}_t \times (r_t^{\text{SPY}} - r_t^f) - \text{costos}_t \quad (3)$$

4. Resultados Empíricos

Esta sección presenta los resultados del backtesting de los 23 modelos durante el período de prueba (Octubre 2020 - Diciembre 2025, 1,301 días de trading).

4.1 Resumen de Rendimiento

4.1.1 Tabla Principal de Rendimiento

La Tabla 1 presenta las métricas de rendimiento completas para los 23 modelos evaluados.

4.1.2 Hallazgos Principales

1. **4 de 23 modelos superan al benchmark SPY:** Ridge (+318.8 %), GradientBoosting (+267.5 %), CNN-LSTM (+207.1 %), y BiGRU (+127.7 %) vs SPY (+102.2 %).
2. **El modelo simple supera a los complejos:** Ridge, un modelo de regresión lineal regularizada, obtiene el mejor rendimiento absoluto, superando a arquitecturas deep learning más sofisticadas.
3. **Variabilidad significativa:** Los retornos totales varían desde +318.8 % (Ridge) hasta -19.2 % (Theta), un rango de 338 puntos porcentuales.
4. **Sharpe Ratios positivos predominan:** 19 de 23 modelos logran Sharpe positivo, indicando que la mayoría genera alpha aunque no todos superen al benchmark.

Cuadro 1: Rendimiento de los 23 Modelos en el Período de Prueba (Oct 2020 - Dic 2025)

Rank	Modelo	Categoría	Ret. Total	Ret. Anual	Sharpe	Sortino	Calmar	M
1	Ridge	ML	318.8 %	32.0 %	0.932	0.811	0.828	
2	GradientBoosting	ML	267.5 %	28.7 %	0.589	0.774	0.582	
3	CNN_LSTM	Hybrid	207.1 %	24.3 %	0.744	0.773	0.876	
4	BiGRU	RNN	127.7 %	17.3 %	0.680	0.670	0.629	
5	RandomForest	ML	97.9 %	14.1 %	0.385	0.395	0.439	
6	NBEATS	DeepLearning	93.5 %	13.6 %	0.511	0.419	0.517	
7	LightGBM	GradientBoosting	85.2 %	12.7 %	0.381	0.327	0.331	
8	CatBoost	GradientBoosting	71.5 %	11.0 %	0.467	0.438	0.466	
9	XGBoost	GradientBoosting	71.3 %	11.0 %	0.161	0.213	0.166	
10	SeasonalNaive	TimeSeries	57.8 %	9.2 %	0.220	0.268	0.281	
11	BiLSTM	RNN	56.3 %	9.0 %	0.280	0.327	0.376	
12	DLinear	DeepLearning	41.4 %	6.9 %	0.265	0.218	0.301	
13	NHiTS	DeepLearning	38.6 %	6.5 %	0.167	0.126	0.212	
14	LSTM_Attention	Attention	31.5 %	5.5 %	0.067	0.057	0.122	
15	TFT	DeepLearning	28.4 %	5.0 %	0.123	0.092	0.174	
16	AutoARIMA	TimeSeries	20.1 %	3.6 %	0.516	–	–	
17	TCN	DeepLearning	19.1 %	3.4 %	0.008	0.008	0.072	
18	Prophet	Prophet	16.6 %	3.0 %	-0.009	-0.008	0.059	
19	ElasticNet	ML	9.0 %	1.7 %	-0.060	-0.049	0.029	
20	Lasso	ML	3.3 %	0.6 %	-0.100	-0.081	0.011	
21	ExponentialSmoothing	TimeSeries	-4.6 %	-0.9 %	-0.181	-0.189	-0.019	
22	GARCH	GARCH	-6.2 %	-1.2 %	-0.201	-0.168	-0.024	
23	Theta	TimeSeries	-19.2 %	-4.0 %	-0.272	-0.297	-0.068	
–	SPY (B&H)	Benchmark	102.2 %	–	0.882	–	–	

Nota: Los modelos en negrita superan al benchmark SPY Buy & Hold. Retorno total calculado como producto de $(1+r)$ - 1 sobre el período completo. Sharpe ratio anualizado con tasa libre de riesgo promedio del período.

Cuadro 2: Resumen Ejecutivo: Top 5 Modelos vs Benchmark

Modelo	Ret. Total	Sharpe	Max DD	Capital Final	α vs SPY
Ridge	318.8 %	0.932	-38.6 %	\$41,876	216.5 %
GradientBoosting	267.5 %	0.589	-49.3 %	\$36,748	165.2 %
CNN_LSTM	207.1 %	0.744	-27.7 %	\$30,711	104.9 %
BiGRU	127.7 %	0.680	-27.5 %	\$22,767	25.4 %
RandomForest	97.9 %	0.385	-32.2 %	\$19,791	-4.3 %
SPY (B&H)	102.2 %	0.882	-25.4 %	\$20,224	–

Nota: Período de prueba: 2020-10-07 a 2025-12-10 (1301 días). Capital inicial: \$10,000. α = exceso de retorno sobre SPY Buy & Hold.

4.1.3 Tabla Resumen Ejecutivo

4.2 Análisis por Familia de Modelos

4.2.1 Comparación por Categoría

Cuadro 3: Rendimiento Promedio por Categoría de Modelo

Categoría	N	Ret. Prom.	Mejor Ret.	Sharpe Prom.	DD Prom.	Mejor Modelo
Hybrid	1	207.1 %	207.1 %	0.744	-27.7 %	CNN_LSTM
ML	5	139.3 %	318.8 %	0.349	-47.3 %	Ridge
RNN	2	92.0 %	127.7 %	0.480	-25.8 %	BiGRU
GradientBoosting	3	76.0 %	85.2 %	0.337	-42.7 %	LightGBM
DeepLearning	5	44.2 %	93.5 %	0.215	-31.3 %	NBEATS
Attention	1	31.5 %	31.5 %	0.067	-44.8 %	LSTM_Attention
Prophet	1	16.6 %	16.6 %	-0.009	-51.4 %	Prophet
TimeSeries	4	13.5 %	57.8 %	0.071	-35.3 %	SeasonalNaive
GARCH	1	-6.2 %	-6.2 %	-0.201	-50.4 %	GARCH

Nota: N = número de modelos en la categoría. ML = Machine Learning clásico, GradientBoosting = XGBoost/LightGBM/CatBoost, DeepLearning = redes Darts, RNN = Bi-LSTM/Bi-GRU, Time-Series = ARIMA/ETS/Theta.

4.2.2 Interpretación por Categoría

Machine Learning Clásico (ML):

- Mejor rendimiento promedio (+94.5 %)
- Ridge lidera la categoría y el ranking general
- Lasso y ElasticNet subperforman significativamente (regularización L1 demasiado agresiva)

Gradient Boosting:

- Rendimiento mixto: GradientBoosting excelente (+267.5 %), pero XGBoost/LightGBM/CatBoost moderados
- XGBoost muestra el peor Calmar ratio (0.17) debido a drawdown del 66 %

Deep Learning (Darts):

- Rendimiento inferior al esperado (+44.2 % promedio)
- N-BEATS el mejor de la categoría (+93.5 %), resto subperforma
- TCN y TFT decepcionan pese a su complejidad arquitectural

RNN Bidireccionales:

- Rendimiento sólido: BiGRU (+127.7 %) supera a BiLSTM (+56.3 %)
- Arquitectura GRU más eficiente que LSTM para esta aplicación

Híbridos/Attention:

- CNN-LSTM destaca (+207.1 %), demostrando valor de combinar CNN para features locales con LSTM para dependencias temporales
- LSTM+Attention underperforma (+31.5 %), sugiriendo que attention puro no es suficiente

Series Temporales Clásicas:

- Rendimiento pobre en general
- AutoARIMA conservador (+20.1 %) pero con drawdown mínimo
- Theta y ExponentialSmoothing con retornos negativos


4.3 Curvas de Equity

Figura 1: Curvas de Equity: Top 5 Modelos vs SPY Buy & Hold. Período: Oct 2020 - Dic 2025. Capital inicial: \$10,000. Líneas verticales indican principales períodos de drawdown del mercado.

Las curvas de equity revelan:

- **Ridge**: Crecimiento más consistente, menor volatilidad visual
- **GradientBoosting**: Mayor pendiente en subidas pero drawdowns más pronunciados
- **CNN-LSTM**: Rendimiento estable con protección en caídas
- **Todos superan SPY** a partir de Q2 2022, tras el bear market

4.4 Distribución de Posiciones

Cuadro 4: Distribución de Posiciones por Modelo (Estrategia Long-Only)

Modelo	UPRO (3x)	SPY (1x)	Cash (0)	Total Long	N° Trades
Ridge	29.5 %	8.5 %	62.0 %	38.0 %	273
GradientBoosting	84.6 %	1.5 %	13.9 %	86.1 %	170
CNN_LSTM	27.3 %	30.6 %	42.1 %	57.9 %	250
BiGRU	21.1 %	29.4 %	49.4 %	50.6 %	331
RandomForest	20.9 %	26.2 %	52.9 %	47.1 %	366
NBEATS	13.9 %	9.8 %	76.2 %	23.8 %	378
LightGBM	12.8 %	35.0 %	52.2 %	47.8 %	475
CatBoost	7.5 %	20.5 %	71.9 %	28.1 %	455
XGBoost	97.2 %	0.0 %	2.8 %	97.2 %	20
SeasonalNaive	20.1 %	40.0 %	40.0 %	60.0 %	1041
BiLSTM	7.1 %	23.1 %	69.9 %	30.1 %	466
DLinear	10.2 %	10.1 %	79.6 %	20.4 %	397
NHiTS	14.5 %	4.9 %	80.6 %	19.4 %	393
LSTM_Attention	22.1 %	25.4 %	52.6 %	47.4 %	117
TFT	5.6 %	13.6 %	80.8 %	19.2 %	452
AutoARIMA	0.0 %	0.1 %	99.9 %	0.1 %	2
TCN	15.2 %	33.1 %	51.7 %	48.3 %	678
Prophet	28.2 %	20.9 %	50.9 %	49.1 %	449
ElasticNet	16.1 %	4.8 %	79.0 %	21.0 %	350
Lasso	16.2 %	4.8 %	79.0 %	21.0 %	348
ExponentialSmoothing	19.1 %	40.1 %	40.7 %	59.3 %	1014
GARCH	24.9 %	4.5 %	70.6 %	29.4 %	458
Theta	32.3 %	1.8 %	65.9 %	34.1 %	860

Nota: Porcentajes representan la proporción de días en cada posición. UPRO = 3x apalancado largo, SPY = 1x largo, Cash = tasa libre de riesgo. Número de trades = cambios de posición.

4.4.1 Patrones de Posicionamiento

- **Modelos agresivos**: XGBoost (97.2 % en UPRO 3x), GradientBoosting (84.6 %)
- **Modelos conservadores**: AutoARIMA (99.9 % Cash), DLinear (79.6 % Cash)
- **Balance óptimo**: Ridge (29.5 % UPRO, 8.5 % SPY, 62.0 % Cash)

El análisis sugiere que el éxito de Ridge proviene de ser selectivo: solo toma posiciones apalancadas cuando la señal es fuerte, permaneciendo en cash el 62 % del tiempo.

4.5 Análisis de Trades

4.5.1 Estadísticas de Trading

Cuadro 5: Estadísticas de Trading por Modelo (Top 10)

Modelo	N Trades	Win Rate	Avg Win	Avg Loss	Profit Factor	Avg Dur.
Ridge	273	76.5 %	+2.8 %	-1.9 %	1.47	4.8d
GradientBoosting	170	53.9 %	+5.2 %	-3.1 %	1.68	7.6d
CNN_LSTM	250	68.6 %	+2.4 %	-1.6 %	1.50	5.2d
BiGRU	331	70.1 %	+1.8 %	-1.4 %	1.29	3.9d
RandomForest	366	71.7 %	+1.6 %	-1.2 %	1.33	3.6d

Nota: Win Rate calculado sobre trades con posición $\neq 0$. Profit Factor = Avg Win / |Avg Loss|.

4.5.2 Distribución de P&L por Trade




Figura 2: Distribución de P&L por Trade: Modelo Ridge. Histograma de retornos por trade. Verde = trades ganadores, Rojo = trades perdedores. Línea vertical en 0 %.

La distribución revela:

- Asimetría positiva: cola derecha más larga que izquierda
- Concentración de trades ganadores pequeños (+1-3 %)
- Límite natural de pérdidas por posicionamiento conservador

4.6 Comparación con Benchmarks Adicionales

Comparado con benchmarks alternativos:

Cuadro 6: Top 5 Modelos vs Múltiples Benchmarks

Estrategia	Ret. Total	Sharpe	Max DD	Calmar	<i>Nota: UPRO B&H asume</i>
Ridge	+318.8 %	0.93	-38.6 %	0.83	
GradientBoosting	+267.5 %	0.59	-49.3 %	0.58	
CNN_LSTM	+207.1 %	0.74	-27.7 %	0.88	
BiGRU	+127.7 %	0.68	-27.5 %	0.63	
SPY Buy & Hold	+102.2 %	0.88	-25.4 %	0.56	
UPRO Buy & Hold	+245.1 %	0.52	-62.8 %	0.39	
60/40 Portfolio	+58.7 %	0.72	-18.2 %	0.45	

compra y retención del ETF 3x durante todo el período. 60/40 = 60 % SPY + 40 % BND (bonds) con rebalanceo mensual.

- **vs UPRO B&H:** Ridge supera en retorno (+318 % vs +245 %) con mucho menor draw-down (-38 % vs -63 %)
- **vs 60/40:** Todos los top modelos superan ampliamente al portafolio conservador

4.7 Aplicación Interactiva

Para facilitar la exploración detallada de los resultados, hemos desarrollado una aplicación web interactiva disponible en:

[https://github.com/\[repositorio\]/app](https://github.com/[repositorio]/app)

La aplicación permite:

- Visualizar curvas de equity dinámicas
- Analizar trades individuales
- Comparar múltiples modelos simultáneamente
- Explorar rendimiento por régimen de mercado
- Ajustar parámetros de costo para sensibilidad

5. La Paradoja del Directional Accuracy

Un hallazgo contraintuitivo de este estudio es que el Directional Accuracy (DA)—la métrica más comúnmente utilizada para evaluar modelos de predicción de dirección de mercado—no es un predictor confiable de rentabilidad en estrategias de trading.

5.1 El Hallazgo Contraintuitivo

5.1.1 Intuición Naïve vs Realidad

La intuición convencional sugiere que un modelo que predice correctamente la dirección del mercado con mayor frecuencia debería generar mayores retornos. Sin embargo, nuestros resultados empíricos contradicen esta suposición:

$$\rho(\text{DA}, \text{Return}) = -0,14 \quad (4)$$

La correlación entre Directional Accuracy y retorno total es **ligeramente negativa**, indicando que modelos con mayor DA no necesariamente generan mejores retornos.

5.1.2 Evidencia Empírica

Cuadro 7: Paradoja DA vs Retorno: Casos Ilustrativos

Modelo	DA General	Retorno Total	Categoría
GARCH	54.3 %	-6.2 %	Alto DA, Retorno Negativo
Theta	54.6 %	-19.2 %	Alto DA, Retorno Negativo
ExponentialSmoothing	53.8 %	-4.6 %	Alto DA, Retorno Negativo
Ridge	52.7 %	+318.8 %	DA Medio, Mejor Retorno
CNN_LSTM	50.8 %	+207.1 %	DA Bajo, Alto Retorno
GradientBoosting	51.2 %	+267.5 %	DA Medio, Alto Retorno

Nota: DA calculado como porcentaje de días donde la predicción de dirección coincide con el movimiento realizado del mercado.




Figura 3: La Paradoja del Directional Accuracy. Panel izquierdo: Scatter plot de DA vs Retorno Total mostrando correlación negativa ($\rho = -0,14$). Panel derecho: Comparación de DA General vs DA@3x (hit rate en posiciones apalancadas) para modelos seleccionados. Los retornos se indican sobre cada par de barras.

5.2 Explicación de la Paradoja

5.2.1 El DA Trata Todos los Días como Iguales

El Directional Accuracy asigna el mismo peso a cada predicción, independientemente de:

- La magnitud del movimiento del mercado
- La posición que tomó el modelo
- El momento del ciclo de mercado

Ejemplo ilustrativo:

Día 1: Mercado +0.1% | Modelo predice correctamente | +

Día 2: Mercado +0.1% | Modelo predice correctamente | +

Día 3: Mercado -3.0% | Modelo falla | -

DA = 66.7% (2/3 aciertos)

Pero P&L = NEGATIVO (la pérdida del día 3 supera las ganancias)

5.2.2 Lo Que Realmente Importa: Asimetría Condicional

La rentabilidad de una estrategia de trading depende de tres factores que el DA no captura:

1. **Cuándo aciertas:** Acertar en días de movimientos grandes importa más que acertar en días tranquilos.
2. **Cuánto apuestas:** El tamaño de la posición cuando aciertas vs cuando fallas determina el P&L.
3. **Asimetría ganancia/pérdida:** El ratio entre ganancia promedio y pérdida promedio (Profit Factor).

5.3 El Indicador DA@3x: Una Métrica Más Relevante

Proponemos el indicador **DA@3x** (Directional Accuracy en posiciones apalancadas) como una métrica más predictiva de rentabilidad:

$$DA@3x = \frac{\sum_{t: pos_t=3} \mathbf{1}[r_t^{mkt} > 0]}{\sum_t \mathbf{1}[pos_t = 3]} \quad (5)$$

donde $\mathbf{1}[\cdot]$ es la función indicadora.

5.3.1 Comparación DA vs DA@3x

Cuadro 8: DA General vs DA@3x: El Predictor de Rentabilidad

Modelo	DA General	DA@3x	% Tiempo 3x	Retorno
Ridge	52.7 %	58.3 %	29.5 %	+318.8 %
GradientBoosting	51.2 %	56.8 %	84.6 %	+267.5 %
CNN_LSTM	50.8 %	55.8 %	33.2 %	+207.1 %
BiGRU	52.1 %	54.9 %	28.7 %	+127.7 %
GARCH	54.3 %	55.2 %	25.8 %	-6.2 %
Theta	54.6 %	52.1 %	15.3 %	-19.2 %

Nota: DA@3x = hit rate cuando el modelo está en posición 3x (UPRO). % Tiempo 3x indica qué fracción del período el modelo estuvo en posición apalancada.

5.3.2 Interpretación

Los modelos rentables se distinguen por:

1. **Mayor DA@3x que DA general:** Ridge tiene 52.7 % DA general pero 58.3 % DA@3x—acierta más cuando apuesta fuerte.
2. **Selectividad en el apalancamiento:** Ridge solo usa posición 3x el 29.5 % del tiempo, reservándola para señales de alta confianza.
3. **Protección en incertidumbre:** Cuando no tiene confianza, permanece en cash (62 % del tiempo para Ridge).

En contraste, los modelos con alto DA general pero bajo DA@3x (como Theta con 54.6 % vs 52.1 %) tienden a “acertar en los días que no importan”.

5.4 Implicaciones para el Diseño de Estrategias

5.4.1 No Optimizar por DA

Este hallazgo tiene implicaciones importantes para el diseño de estrategias de trading:

Implicación Clave

Optimizar un modelo para maximizar Directional Accuracy puede ser contraproducente. En su lugar, se debe optimizar por métricas que capturen la asimetría entre ganancias y pérdidas condicionales al tamaño de la posición.

5.4.2 Métricas Alternativas Recomendadas

En lugar de DA, recomendamos evaluar modelos de trading usando:

1. **Sharpe Ratio**: Captura el trade-off riesgo-retorno
2. **Profit Factor**: Ratio entre ganancia promedio y pérdida promedio por trade
3. **DA@3x**: Hit rate en posiciones de alta convicción
4. **Retorno Neto**: La métrica final que realmente importa

5.4.3 El Valor de la Selectividad

El éxito del modelo Ridge ilustra el valor de la selectividad:

- **No predice mejor en general**: DA = 52.7 %, apenas sobre el azar
- **Sabe cuándo apostar fuerte**: DA@3x = 58.3 %, significativamente mejor
- **Sabe cuándo no apostar**: 62 % del tiempo en cash
- **Resultado**: +318.8 % de retorno, el mejor de todos los modelos

5.5 Conexión con la Literatura

Este hallazgo es consistente con la literatura sobre trading y gestión de portafolios:

López de Prado (2018) argumenta que las métricas tradicionales de evaluación de modelos predictivos (como R^2 o accuracy) son inadecuadas para evaluar estrategias de trading, donde lo que importa es la rentabilidad ajustada por riesgo.

La paradoja de Grossman-Stiglitz (Grossman & Stiglitz, 1980) sugiere que en mercados eficientes, la capacidad predictiva marginal (como un DA ligeramente superior al 50 %) puede ser suficiente para generar alfa si se combina con una estrategia de posicionamiento inteligente.

El criterio de Kelly (?) formaliza la idea de que el tamaño óptimo de la apuesta depende no solo de la probabilidad de ganar, sino también de las magnitudes de ganancia y pérdida—exactamente lo que el DA no captura.

5.6 Resumen de la Sección

Resumen: La Paradoja del DA

1. El Directional Accuracy (DA) no es un predictor confiable de rentabilidad ($\rho = -0,14$)
2. Modelos con DA > 54 % generaron retornos negativos
3. Modelos con DA $\approx$ 51-52 % generaron los mejores retornos
4. El indicador DA@3x (hit rate en posiciones apalancadas) es más predictivo
5. Los modelos rentables se caracterizan por **selectividad**, no por **frecuencia** de aciertos
6. Implicación: Optimizar por DA puede ser contraproducente para estrategias de trading

6. Marco de Gestión de Riesgo

Una estrategia de trading rentable es condición necesaria pero no suficiente para la implementación en un contexto institucional. La gestión de riesgo constituye el elemento diferenciador entre estrategias académicamente interesantes y aquellas viables para operación real. Esta sección presenta el marco de análisis de riesgo aplicado a los 23 modelos evaluados.

6.1 Métricas de Riesgo Ajustado

6.1.1 Sharpe Ratio

El Sharpe Ratio (?) mide el exceso de retorno por unidad de volatilidad total:

$$\text{Sharpe} = \frac{E[R_p - R_f]}{\sigma_p} \cdot \sqrt{252} \quad (6)$$

donde R_p es el retorno del portafolio, R_f la tasa libre de riesgo, y σ_p la desviación estándar de los retornos. El factor $\sqrt{252}$ anualiza la métrica asumiendo 252 días de trading.

En nuestra muestra, los Sharpe ratios varían significativamente entre modelos. Ridge alcanza el mayor Sharpe (0.932), seguido por CNN-LSTM (0.744) y BiGRU (0.680). Notablemente, cuatro modelos presentan Sharpe negativos, indicando que su rendimiento ajustado por riesgo es inferior a la tasa libre de riesgo.

6.1.2 Sortino Ratio

El Sortino Ratio (?) mejora sobre Sharpe al considerar únicamente la volatilidad negativa (downside risk):

$$\text{Sortino} = \frac{E[R_p - R_f]}{\sigma_d} \cdot \sqrt{252} \quad (7)$$

donde σ_d es la desviación estándar de los retornos negativos exclusivamente. Esta métrica es particularmente relevante para estrategias asimétricas donde la distribución de retornos difiere significativamente de una normal.

6.1.3 Calmar Ratio

El Calmar Ratio relaciona el retorno anualizado con el máximo drawdown:

$$\text{Calmar} = \frac{\text{CAGR}}{|\text{Max Drawdown}|} \quad (8)$$

Esta métrica captura la eficiencia de la estrategia en términos del peor escenario histórico. Un Calmar superior a 1.0 indica que el retorno anual supera la máxima pérdida experimentada, un umbral deseable para estrategias institucionales.

6.2 Value at Risk (VaR) y Expected Shortfall

6.2.1 Metodología

Calculamos VaR histórico utilizando percentiles empíricos de la distribución de retornos:

$$\text{VaR}_\alpha = -\text{Percentil}_\alpha(R_t) \quad (9)$$

El VaR al 95 % representa la pérdida máxima esperada en el 95 % de los casos (es decir, la pérdida que solo se supera el 5 % del tiempo).

6.2.2 Conditional VaR (CVaR)

El Expected Shortfall o CVaR mide la pérdida promedio en los casos que exceden el VaR:

$$\text{CVaR}_\alpha = -E[R_t | R_t < -\text{VaR}_\alpha] \quad (10)$$

Esta métrica es preferida por reguladores y gestores institucionales porque captura el riesgo de cola (tail risk) de manera más completa que el VaR tradicional.

6.2.3 Resultados de Riesgo de Cola

Cuadro 9: Value at Risk y Expected Shortfall por Modelo (Top 10)

Modelo	VaR 95 % (30d)	CVaR 95 % (30d)	VaR 99 % (30d)	Peor Día	<i>Nota:</i>
Ridge	-8.2 %	-12.1 %	-15.3 %	-9.8 %	
GradientBoosting	-12.4 %	-18.7 %	-22.1 %	-14.2 %	
CNN_LSTM	-7.1 %	-10.8 %	-14.2 %	-8.9 %	
BiGRU	-6.8 %	-9.9 %	-13.1 %	-8.1 %	
RandomForest	-7.9 %	-11.4 %	-15.8 %	-9.4 %	
SPY (B&H)	-5.8 %	-8.2 %	-10.9 %	-6.7 %	

VaR y CVaR calculados sobre ventana de 30 días. Valores negativos representan pérdidas potenciales.

Los resultados revelan un trade-off fundamental: los modelos con mayor retorno (Ridge, GradientBoosting) también presentan mayor riesgo de cola. CNN-LSTM y BiGRU ofrecen un balance más favorable entre retorno y riesgo extremo.

6.3 Análisis de Drawdown

6.3.1 Máximos Drawdowns

El drawdown mide la caída desde un máximo histórico:

$$DD_t = \frac{P_t - \max_{s \leq t}(P_s)}{\max_{s \leq t}(P_s)} \quad (11)$$

donde P_t es el valor del portafolio en el momento t .

6.3.2 Períodos de Drawdown Significativo

Durante el período de prueba, identificamos tres episodios de drawdown severo que afectaron la mayoría de los modelos:

1. **Corrección Q4 2021** (Sep-Dic 2021): Drawdowns del 15-25 % en modelos con alta exposición a 3x.
2. **Bear Market 2022** (Ene-Oct 2022): El período más desafiante, con drawdowns del 30-50 % para modelos agresivos.
3. **Volatilidad Bancaria 2023** (Mar 2023): Drawdowns agudos del 10-20 % en una semana.

6.3.3 Recuperación de Drawdowns

Un aspecto crítico es el tiempo de recuperación. Definimos el tiempo de recuperación como el número de días hasta alcanzar un nuevo máximo:

$$T_{recovery} = \min\{t' > t_{DD} : P_{t'} \geq \max_{s \leq t_{DD}} (P_s)\} \quad (12)$$

Los modelos con posicionamiento más conservador (mayor % en Cash) presentan drawdowns menos profundos pero tiempos de recuperación similares, sugiriendo que la protección de capital durante caídas compensa la menor participación en subidas.

6.4 Control de Riesgo Implícito en la Estrategia

La estrategia Long-Only implementada incorpora mecanismos naturales de control de riesgo:

6.4.1 Posición en Cash como Hedge Natural

Cuando las predicciones del modelo no superan el umbral q_{1x} , la estrategia asigna 100 % a Cash (tasa libre de riesgo). Este mecanismo actúa como un “stop-loss” implícito basado en la confianza del modelo:

$$\text{Position}_t = \begin{cases} 3x & \text{si } \hat{r}_t > P_{100-q_{3x}} \\ 1x & \text{si } P_{100-q_{1x}} < \hat{r}_t \leq P_{100-q_{3x}} \\ 0 & \text{si } \hat{r}_t \leq P_{100-q_{1x}} \end{cases} \quad (13)$$

Los modelos con mayor porcentaje de tiempo en Cash (AutoARIMA: 99.9 %, DLinear: 79.6 %) presentan los drawdowns más contenidos pero también los retornos más modestos.

6.4.2 Apalancamiento Selectivo

El uso de UPRO (3x) se reserva exclusivamente para predicciones de alta confianza (percentil superior q_{3x}). Esta selectividad limita la exposición a apalancamiento a momentos donde el modelo tiene mayor certeza direccional.

6.5 Implicaciones para la Implementación

Los hallazgos de esta sección tienen implicaciones directas para la implementación:

1. **Sizing de Posiciones:** El VaR diario sugiere limitar el tamaño de posición al nivel donde una pérdida del VaR 99 % sea tolerable.
2. **Selección de Modelos:** Para mandatos conservadores, CNN-LSTM y BiGRU ofrecen el mejor balance riesgo-retorno. Para mandatos agresivos, Ridge maximiza retorno aceptando mayor volatilidad.

3. **Diversificación de Modelos:** Un ensemble de modelos con correlaciones imperfectas puede reducir el riesgo agregado sin sacrificar retorno esperado.
4. **Límites de Drawdown:** Establecer límites de drawdown del 20-25 % como trigger para revisión de parámetros o suspensión temporal.

7. Análisis por Régimen de Mercado

El rendimiento de estrategias de trading varía significativamente según las condiciones de mercado prevalecientes. Esta sección examina cómo los 23 modelos se comportan bajo diferentes regímenes, proporcionando insights críticos para la gestión táctica de activos.

7.1 Definición de Regímenes

Clasificamos cada día de trading en uno de cuatro regímenes utilizando una ventana rolling de 60 días:

7.1.1 Criterios de Clasificación

1. **Bull Market:** Retorno acumulado $> 10\%$ y volatilidad anualizada $< 20\%$

$$\text{Bull} \equiv \left(\prod_{i=t-59}^t (1 + r_i) - 1 > 0,10 \right) \wedge \left(\sigma_{60d} \cdot \sqrt{252} < 0,20 \right) \quad (14)$$

2. **Bear Market:** Retorno acumulado $< -10\%$

$$\text{Bear} \equiv \prod_{i=t-59}^t (1 + r_i) - 1 < -0,10 \quad (15)$$

3. **High Volatility:** Volatilidad anualizada $> 25\%$ (sin cumplir Bull/Bear)

$$\text{HighVol} \equiv \sigma_{60d} \cdot \sqrt{252} > 0,25 \quad (16)$$

4. **Sideways:** Ninguno de los anteriores (mercado lateral)

7.2 Distribución de Regímenes en el Período de Prueba

El período de prueba (Octubre 2020 - Diciembre 2025) presentó la siguiente distribución de regímenes:

La predominancia del régimen Sideways (72 %) es consistente con la naturaleza del S&P 500 como índice diversificado que raramente presenta tendencias extremas prolongadas.

Cuadro 10: Distribución de Regímenes de Mercado

Régimen	Días	Porcentaje	Características
Sideways	938	72.1 %	Mercado sin tendencia clara
Bull	133	10.2 %	Rally sostenido, baja volatilidad
High Volatility	121	9.3 %	Incertidumbre elevada
Bear	49	3.8 %	Correcciones significativas
Unknown	60	4.6 %	Período de warmup inicial

7.3 Rendimiento por Modelo por Régimen

7.3.1 Bull Market (133 días)

Durante períodos alcistas con baja volatilidad:

- **Mejores:** RandomForest (+12.9 %), Ridge (+6.6 %), ElasticNet (+4.4 %)
- **Peores:** SeasonalNaive (-18.5 %), BiGRU (-15.8 %), TCN (-13.2 %)

Los modelos ML clásicos capturan mejor las tendencias alcistas sostenidas, mientras que los modelos de series temporales y RNN tienden a ser más conservadores perdiendo participación.

7.3.2 Bear Market (49 días)

Durante correcciones significativas:

- **Mejores:** GradientBoosting (+73.2 %), LSTM_Attention (+64.7 %), BiLSTM (+56.6 %)
- **Peores:** DLinear (-8.5 %), CatBoost (+11.7 %), LightGBM (+8.4 %)

Notablemente, varios modelos logran retornos positivos durante mercados bajistas, sugiriendo que el posicionamiento en Cash y la selectividad del apalancamiento actúan como protección efectiva.

7.3.3 High Volatility (121 días)

Durante períodos de alta incertidumbre:

- **Mejores:** SeasonalNaive (+37.6 %), Ridge (+36.0 %), GradientBoosting (+35.5 %)
- **Peores:** GARCH (-34.3 %), ElasticNet (-16.0 %), Lasso (-16.0 %)

Paradójicamente, GARCH—diseñado específicamente para modelar volatilidad—tiene el peor desempeño en alta volatilidad, sugiriendo que su estimación de volatilidad no se traduce en mejor timing de posiciones.

7.3.4 Sideways (938 días)

Durante el régimen predominante:

- **Mejores:** CNN_LSTM (+96.0 %), Ridge (+91.9 %), DLinear (+69.5 %)
- **Peores:** ExponentialSmoothing (-28.4 %), LSTM_Attention (-20.1 %), Theta (-18.0 %)

El mercado lateral es donde se acumula la mayor parte del alpha, y donde CNN-LSTM demuestra su superioridad.

7.4 Tabla Completa de Rendimiento por Régimen

Cuadro 11: Rendimiento por Régimen de Mercado (Top 10 Modelos)

Modelo	Bull (133 días)	Sideways (938 días)	Bear (49 días)	High Vol (121 días)
Ridge	6.6 %	91.9 %	41.9 %	36.0 %
GradientBoosting	-8.3 %	40.2 %	73.2 %	35.5 %
CNN_LSTM	-1.5 %	96.0 %	23.2 %	14.4 %
BiGRU	-15.8 %	60.4 %	9.4 %	25.1 %
RandomForest	12.9 %	3.8 %	44.8 %	15.3 %
NBEATS	1.7 %	12.0 %	38.0 %	17.2 %
LightGBM	-3.3 %	48.9 %	8.4 %	14.8 %
CatBoost	-3.8 %	52.1 %	11.7 %	3.8 %
XGBoost	-4.7 %	1.3 %	45.1 %	5.9 %
SeasonalNaive	-18.5 %	0.4 %	23.4 %	37.6 %

Nota: Bull = retorno acumulado > 10 % y volatilidad < 20 % en ventana de 60 días. Bear = retorno < -10 %. High Vol = volatilidad > 25 %. Sideways = resto.

7.5 Análisis de Consistencia Cross-Régimen

Un modelo ideal debería performar consistentemente bien a través de diferentes regímenes. Evaluamos la consistencia mediante la desviación estándar de rendimientos por régimen:

$$\text{Consistencia}_m = \frac{1}{\sigma(\{R_{m,\text{Bull}}, R_{m,\text{Bear}}, R_{m,\text{Sideways}}, R_{m,\text{HighVol}}\})} \quad (17)$$

Cuadro 12: Consistencia Cross-Régimen de Modelos (Top 10)

Modelo	Bull	Bear	Sideways	HighVol	Consistencia
Ridge	+6.6 %	+41.9 %	+91.9 %	+36.0 %	Media
CNN_LSTM	-1.5 %	+23.2 %	+96.0 %	+14.4 %	Alta
GradientBoosting	-8.3 %	+73.2 %	+40.2 %	+35.5 %	Baja
BiGRU	-15.8 %	+9.4 %	+60.4 %	+25.1 %	Media

7.6 Implicaciones para Gestión Táctica

Los resultados sugieren varias estrategias de gestión táctica:

7.6.1 Rotación de Modelos por Régimen

- **Régimen Bull detectado:** Preferir RandomForest, Ridge
- **Régimen Bear detectado:** Preferir GradientBoosting, LSTM_Attention, BiLSTM
- **Régimen High Vol detectado:** Preferir SeasonalNaive, Ridge
- **Régimen Sideways detectado:** Preferir CNN_LSTM, Ridge

7.6.2 Ensemble Dinámico

Un enfoque más sofisticado es ponderar los modelos dinámicamente según el régimen identificado:

$$\hat{r}_{t,\text{ensemble}} = \sum_{m=1}^M w_{m,\text{regime}(t)} \cdot \hat{r}_{m,t} \quad (18)$$

donde $w_{m,\text{regime}(t)}$ son pesos que dependen del régimen actual, optimizados históricamente para cada combinación modelo-régimen.

7.6.3 Advertencia sobre Detección de Régimen

Es crucial notar que la detección de régimen es ex-post en nuestro análisis. En implementación real, el régimen solo puede identificarse con rezago (60 días en nuestra definición), lo que limita la aplicabilidad de rotación táctica perfecta. Sin embargo, transiciones de régimen tienden a ser persistentes, permitiendo cierto grado de anticipación.

7.7 Ridge: El Modelo All-Weather

Ridge destaca como el único modelo con rendimiento positivo significativo en los cuatro regímenes:

- Bull: +6.6 % (3er mejor)
- Bear: +41.9 % (5to mejor)
- Sideways: +91.9 % (2do mejor)
- High Vol: +36.0 % (2do mejor)

Esta consistencia cross-régimen, combinada con su Sharpe ratio líder (0.932), posiciona a Ridge como el modelo más robusto para implementación estática sin rotación de modelos.

8. Validación Estadística

La evaluación del rendimiento de estrategias de trading requiere rigor estadístico más allá de simples comparaciones de retornos. Esta sección presenta los tests estadísticos aplicados para validar la significancia de los resultados.

8.1 Bootstrap de Sharpe Ratios

8.1.1 Metodología

El Sharpe Ratio estándar no provee información sobre la precisión de la estimación. Utilizamos bootstrap no paramétrico (?) para construir intervalos de confianza:

1. Generar $B = 10,000$ muestras bootstrap con reemplazo de los retornos diarios
2. Calcular el Sharpe Ratio para cada muestra bootstrap: $\hat{S}_b$, $b = 1, \dots, B$
3. Construir el intervalo de confianza al 95 % usando percentiles: $[\hat{S}_{0,025}, \hat{S}_{0,975}]$

8.1.2 Corrección de Ledoit-Wolf

Aplicamos la corrección de ? para muestras finitas y autocorrelación en los retornos:

$$SE(\hat{S}) = \sqrt{\frac{1 + \frac{\hat{S}^2}{2} \cdot (1 + \hat{\rho}_1)}{T \cdot (1 - \hat{\rho}_1)}} \quad (19)$$

donde $\hat{\rho}_1$ es la autocorrelación de primer orden de los retornos y T el número de observaciones.

8.1.3 Resultados: Intervalos de Confianza

Cuadro 13: Intervalos de Confianza del Sharpe Ratio (Bootstrap 95 %)

Modelo	Sharpe	IC 95 % Inf	IC 95 % Sup	P(S>0)	P(S>SPY)
Ridge	0.932	0.612	1.248	99.8 %	58.2 %
CNN_LSTM	0.744	0.428	1.056	99.1 %	42.6 %
BiGRU	0.680	0.374	0.982	98.4 %	36.1 %
GradientBoosting	0.589	0.214	0.960	96.8 %	28.3 %
N-BEATS	0.511	0.198	0.820	94.7 %	18.9 %
SPY (B&H)	0.882	0.584	1.176	99.6 %	—

= probabilidad de Sharpe positivo. $P(S>SPY)$ = probabilidad de superar el Sharpe del benchmark. IC calculados con 10,000 iteraciones bootstrap.

8.1.4 Interpretación

Los intervalos de confianza revelan que:

- **Ridge**: Con 99.8 % de probabilidad, tiene Sharpe positivo. Sin embargo, solo 58.2 % de probabilidad de superar al benchmark SPY.
- **CNN-LSTM**: Sharpe positivo con 99.1 % de confianza, pero solo 42.6 % de superar SPY.
- **Solapamiento significativo**: Los intervalos de confianza de los mejores modelos se solapan sustancialmente con el del benchmark, indicando que la superioridad no es estadísticamente conclusiva.

8.2 Test de Diebold-Mariano

8.2.1 Formulación

El test de ? evalúa si la diferencia en error de predicción entre dos modelos es estadísticamente significativa:

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \quad (20)$$

donde $d_t = L(e_{1,t}) - L(e_{2,t})$ es la diferencia en pérdida entre los dos modelos en el tiempo t , y $\hat{V}(\bar{d})$ es un estimador consistente de la varianza de $\bar{d}$ que considera autocorrelación.

Bajo la hipótesis nula de igual capacidad predictiva, $DM \xrightarrow{d} N(0, 1)$.

8.2.2 Resultados: Comparación con Benchmark

Cuadro 14: Test de Diebold-Mariano vs Modelo Naïve (Retorno = 0)

Modelo	Estadístico DM	p-valor	Significativo (5 %)	
Ridge	2.847	0.0044	Sí	<i>Nota: Estadístico DM positivo</i>
GradientBoosting	1.923	0.0545	No	
CNN_LSTM	2.412	0.0159	Sí	
BiGRU	2.156	0.0311	Sí	
RandomForest	1.284	0.1992	No	

indica que el modelo supera al benchmark naïve. Corrección Newey-West con 5 rezagos para autocorrelación.

8.3 Model Confidence Set (MCS)

8.3.1 Metodología

El Model Confidence Set de ? identifica el conjunto de modelos que contiene al mejor modelo verdadero con una probabilidad dada:

1. Comenzar con el conjunto completo de modelos $\mathcal{M}_0$
2. Testear la hipótesis de igual capacidad predictiva (EPA) sobre $\mathcal{M}_0$
3. Si EPA se rechaza, eliminar el peor modelo
4. Repetir hasta que EPA no se rechace

El MCS final $\hat{\mathcal{M}}_\alpha^*$ contiene todos los modelos que no pueden ser descartados como inferiores al nivel α .

8.3.2 Resultados

Al nivel de confianza del 90 %, el Model Confidence Set contiene:

$$\hat{\mathcal{M}}_{0,10}^* = \{\text{Ridge}, \text{CNN-LSTM}, \text{BiGRU}, \text{GradientBoosting}\} \quad (21)$$

Esto indica que estos cuatro modelos no pueden distinguirse estadísticamente como superiores entre sí, pero sí son estadísticamente superiores al resto.

8.4 Test de Clark-West

8.4.1 Formulación

El test de ? es apropiado para comparar modelos anidados (nested models):

$$CW_t = (e_{1,t}^2 - e_{2,t}^2) + (e_{1,t} - e_{2,t})^2 \quad (22)$$

donde el término de ajuste $(e_{1,t} - e_{2,t})^2$ corrige el sesgo que surge cuando el modelo restringido es verdadero.

8.4.2 Aplicación

Comparamos cada modelo contra el modelo naive (predicción = promedio histórico):

Cuadro 15: Test de Clark-West vs Modelo de Media Histórica

Modelo	CW Stat	p-valor (1-cola)	Conclusión	<i>Nota: H_0: el modelo extendido no tiene capacidad predictiva superior al modelo restringido. Test de una cola dado que la hipótesis alternativa es unidireccional.</i>
Ridge	2.31	0.010	Rechaza H_0	
CNN_LSTM	1.89	0.029	Rechaza H_0	
BiGRU	1.67	0.047	Rechaza H_0	
GradientBoosting	1.52	0.064	Marginal	

8.5 Análisis de Overfitting

8.5.1 Comparación In-Sample vs Out-of-Sample

Una señal de overfitting es una degradación significativa del rendimiento entre el período de entrenamiento y prueba:

Cuadro 16: Degradación del Sharpe Ratio: Entrenamiento vs Prueba

Modelo	Sharpe Train	Sharpe Test	Degradación	<i>Nota: Degradación = (Sharpe Test - Sharpe Train) / Sharpe Train. Mayor degradación sugiere mayor overfitting.</i>
Ridge	1.12	0.93	-17 %	
CNN_LSTM	0.98	0.74	-24 %	
RandomForest	1.45	0.39	-73 %	
XGBoost	1.89	0.16	-92 %	

Los resultados revelan:

- **Ridge**: Mínima degradación (-17 %), sugiriendo buen ajuste de regularización.
- **RandomForest y XGBoost**: Degradación severa (73-92 %), indicando overfitting significativo a pesar de validación cruzada.

8.5.2 Corrección por Multiple Testing

Con 23 modelos evaluados, el riesgo de falsos positivos por comparaciones múltiples es sustancial. Aplicamos la corrección de Bonferroni:

$$\alpha_{\text{Bonferroni}} = \frac{\alpha}{m} = \frac{0,05}{23} \approx 0,0022 \quad (23)$$

Bajo este criterio estricto, solo Ridge mantiene significancia estadística (p-valor DM = 0.0044).

8.5.3 False Discovery Rate (FDR)

Alternativamente, el procedimiento de q controla la proporción esperada de falsos positivos entre los rechazos:

1. Ordenar los p-valores: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$
2. Encontrar el mayor k tal que $p_{(k)} \leq \frac{k}{m} \cdot q$
3. Rechazar H_0 para los k menores p-valores

Con $q = 0,10$ (FDR del 10 %), identificamos 4 modelos significativos: Ridge, CNN-LSTM, BiGRU, y AutoARIMA.

8.6 Resumen de Validación Estadística

Cuadro 17: Resumen de Tests Estadísticos por Modelo

Modelo	P(S>0)	DM Test	CW Test	MCS	FDR
Ridge	99.8 %				
CNN_LSTM	99.1 %				
BiGRU	98.4 %				
GradientBoosting	96.8 %	—	—		—

= pasa el test al nivel de significancia estándar (5 % o 10 % según el test). — = no pasa.

8.7 Conclusiones de la Validación

La validación estadística proporciona evidencia mixta:

1. **Evidencia positiva:** Ridge, CNN-LSTM y BiGRU demuestran capacidad predictiva estadísticamente significativa bajo múltiples tests.
2. **Cautela necesaria:** Los intervalos de confianza del Sharpe Ratio se solapan sustancialmente con el benchmark, sugiriendo que la superioridad no es robusta.
3. **Overfitting parcial:** Modelos ensemble (RandomForest, XGBoost) muestran degradación severa entre entrenamiento y prueba.
4. **Modelos regularizados:** Ridge y redes con dropout (CNN-LSTM, BiGRU) mantienen mejor generalización.

Estos hallazgos son consistentes con la literatura que sugiere que modelos más simples y regularizados tienden a generalizar mejor en predicción financiera (?).

9. Análisis de Costos e Implementación

La viabilidad de una estrategia de trading depende críticamente de los costos de implementación. Esta sección presenta un análisis detallado de los costos de transacción y sus implicaciones para la implementación real.

9.1 Modelo de Costos Detallado

9.1.1 Componentes del Costo

Nuestro modelo de costos incluye tres componentes principales:

1. **Bid-Ask Spread:** Costo de cruzar el spread al ejecutar una orden
2. **Expense Ratio:** Costo anual del ETF prorrateado diariamente
3. **Volatility Drag:** Pérdida por rebalanceo diario en ETFs apalancados

9.1.2 Bid-Ask Spreads por Instrumento

Cuadro 18: Costos de Transacción por Instrumento

Instrumento	Tipo	Bid-Ask	Expense Ratio	Costo Total/Trade	<i>Nota: Bid-Ask</i>
UPRO	3x Long	5 bps	0.91 %/año	10 bps (round-trip)	
SPY	1x Long	2 bps	0.09 %/año	4 bps (round-trip)	
Cash	–	0 bps	0 %	0 bps	

basado en spreads típicos de mercado. Round-trip = entrada + salida. Expense ratio aplicado diariamente = ratio anual / 252.

9.1.3 Volatility Drag en ETFs Apalancados

Los ETFs apalancados sufren *volatility drag* debido al rebalanceo diario:

$$\text{Vol Drag} \approx -\frac{1}{2} \cdot (L^2 - L) \cdot \sigma^2 \quad (24)$$

donde L es el factor de apalancamiento (3 para UPRO) y σ la volatilidad del subyacente.

Para UPRO con volatilidad diaria típica de 1 %:

$$\text{Vol Drag} \approx -\frac{1}{2} \cdot (9 - 3) \cdot 0,01^2 = -0,03 \% \text{ por día} \quad (25)$$

Este costo se acumula significativamente: 7.5 % anual en condiciones normales, mayor en alta volatilidad.

9.2 Impacto de Costos por Modelo

9.2.1 Observaciones Clave

1. **Costos significativos:** El modelo promedio incurre \$1,806 en costos de transacción sobre capital inicial de \$10,000 (18.1 % del capital).

Cuadro 19: Impacto de Costos de Transacción por Modelo

Modelo	Capital Final	P&L Bruto	Tx Costs	Tx/P&L	Trades
Ridge	\$41,876	\$31,876	\$1,331	4.2 %	273
GradientBoosting	\$36,748	\$26,748	\$848	3.2 %	170
CNN_LSTM	\$30,711	\$20,711	\$1,085	5.2 %	250
BiGRU	\$22,767	\$12,767	\$1,361	10.7 %	331
RandomForest	\$19,791	\$9,791	\$1,580	16.1 %	366
NBEATS	\$19,352	\$9,352	\$1,602	17.1 %	378
LightGBM	\$18,523	\$8,523	\$1,658	19.5 %	475
CatBoost	\$17,152	\$7,152	\$1,456	20.4 %	455
XGBoost	\$17,126	\$7,126	\$100	1.4 %	20
SeasonalNaive	\$15,785	\$5,785	\$3,650	63.1 %	1041
BiLSTM	\$15,634	\$5,634	\$1,502	26.7 %	466
DLinear	\$14,137	\$4,137	\$1,512	36.5 %	397
NHiTS	\$13,859	\$3,859	\$1,708	44.3 %	393
LSTM_Attention	\$13,152	\$3,152	\$532	16.9 %	117
TFT	\$12,844	\$2,844	\$1,343	47.2 %	452
AutoARIMA	\$12,012	\$2,012	\$4	0.2 %	2
TCN	\$11,907	\$1,907	\$2,522	132.3 %	678
Prophet	\$11,656	\$1,656	\$2,060	124.4 %	449
ElasticNet	\$10,903	\$903	\$1,568	173.6 %	350
Lasso	\$10,334	\$334	\$1,558	467.1 %	348
ExponentialSmoothing	\$9,536	\$-464	\$4,518	—	1014
GARCH	\$9,379	\$-621	\$2,146	—	458
Theta	\$8,079	\$-1,921	\$4,237	—	860
<i>Promedio</i>	—	—	\$1,734	—	424

Nota: Capital inicial = \$10,000. Tx Costs incluye bid-ask spreads (UPRO: 10 bps, SPY: 4 bps) y expense ratios. Tx/P&L = proporción de costos respecto a ganancias brutas.

2. **Correlación turnover-costos:** Modelos con más trades (SeasonalNaive: 1,041 trades, \$3,650 en costos) sufren costos proporcionalmente mayores.
3. **Eficiencia de Ridge:** A pesar de 273 trades, Ridge mantiene costos moderados (\$1,331) debido a posicionamiento selectivo.
4. **XGBoost eficiente en costos:** Solo 20 trades resultan en \$100 de costos, pero esto refleja posicionamiento casi exclusivamente en UPRO (97 % del tiempo).

9.3 Relación Turnover-Rentabilidad




Figura 4: Relación entre Turnover (Número de Trades) y Retorno Neto. Cada punto representa un modelo. Línea punteada: regresión lineal. No hay correlación significativa ($R^2 = 0,02$).

9.3.1 Análisis de la Relación

Contrario a la intuición, no encontramos correlación significativa entre turnover y retorno:

- **Alto turnover, alto retorno:** Ridge (273 trades, +318.8 %)
- **Bajo turnover, alto retorno:** GradientBoosting (170 trades, +267.5 %)
- **Alto turnover, bajo retorno:** ExponentialSmoothing (1,014 trades, -4.6 %)
- **Bajo turnover, bajo retorno:** XGBoost (20 trades, +71.3 %)

La conclusión es que la calidad de las señales es más importante que la frecuencia de trading.

9.4 Análisis de Sensibilidad a Costos

9.4.1 Escenarios de Costo

Evaluamos la robustez de los resultados bajo diferentes supuestos de costos:

Cuadro 20: Sensibilidad del Retorno a Costos de Transacción

Modelo	Ret. Base	+50 % Costos	+100 % Costos	Break-even	<i>Nota:</i>
Ridge	+318.8 %	+312.1 %	+305.5 %	2,390 bps	
GradientBoosting	+267.5 %	+263.2 %	+258.9 %	3,147 bps	
CNN_LSTM	+207.1 %	+201.7 %	+196.3 %	1,907 bps	
BiGRU	+127.7 %	+120.9 %	+114.1 %	939 bps	

Break-even = costo por trade al cual el retorno neto sería 0 %. Calculado como Ret. Total / N Trades.

9.4.2 Robustez a Costos

Los resultados son robustos incluso bajo escenarios de costos significativamente mayores:

- Con costos duplicados, Ridge aún genera +305.5 % vs SPY +102.2 %
- Break-even de Ridge (2,390 bps por trade) es 24x el costo actual estimado

9.5 Consideraciones de Implementación Real

9.5.1 Costos Adicionales No Modelados

En implementación real, considerar:

1. **Slippage**: Diferencia entre precio esperado y ejecutado
2. **Market Impact**: Efecto de la orden propia en el precio
3. **Borrow Costs**: Para posiciones cortas (no aplica en Long-Only)
4. **Margin Interest**: Si se usa apalancamiento adicional

9.5.2 Estimación de Slippage

Para órdenes de tamaño institucional (\$1M+), estimamos slippage adicional:

$$\text{Slippage} \approx k \cdot \sqrt{\frac{\text{Order Size}}{\text{ADV}}} \quad (26)$$

donde ADV es Average Daily Volume y $k \approx 0,1$ para SPY/UPRO.

9.5.3 Capacidad de la Estrategia

Definimos capacidad como el AUM máximo antes de que market impact degrade significativamente el rendimiento:

Cuadro 21: Estimación de Capacidad de Estrategia

Instrumento	ADV (2024)	1 % ADV	Capacidad Est.	<i>Nota: Capacidad estimada para mantener slippage < 5 bps adicionales por trade.</i>
SPY	\$35B	\$350M	\$500M+	
UPRO	\$800M	\$8M	\$20-30M	

El cuello de botella es UPRO, limitando la capacidad práctica a \$20-30M para mantener ejecución eficiente.

9.5.4 Alternativas de Implementación

Para superar limitaciones de capacidad:

1. **Futuros E-mini:** Liquidez superior, permite apalancamiento directo
2. **Opciones:** Crear apalancamiento sintético via calls
3. **CFDs:** Disponibles en jurisdicciones específicas
4. **Total Return Swaps:** Para institucionales, elimina tracking error

9.6 Frecuencia de Rebalanceo

9.6.1 Sensibilidad a Latencia

Nuestro modelo asume ejecución al cierre. Evaluamos el impacto de ejecutar con delay:

Cuadro 22: Impacto de Latencia en la Ejecución

Latencia	Ridge Ret.	Degradación	Correlación Señales	<i>Nota: Simulación con precios de apertura y cierre del día siguiente a la señal.</i>
Cierre (T)	+318.8 %	—	1.00	
Apertura (T+1)	+294.2 %	-7.7 %	0.94	
Cierre (T+1)	+267.5 %	-16.1 %	0.89	

La estrategia tolera latencia de un día con degradación moderada, facilitando implementación en zonas horarias diferentes a EE.UU.

9.7 Resumen de Costos e Implementación

Resumen: Viabilidad de Implementación

- **Costos totales:** 3-5 % del P&L bruto para modelos eficientes
- **Robustez:** Estrategia rentable incluso con costos 2x mayores
- **Capacidad:** \$20-30M en UPRO, escalable via futuros
- **Latencia:** Tolera delay de apertura con -8 % degradación
- **Recomendación:** Viable para implementación con capital \$1-20M

10. Discusión: Contribuciones al Debate sobre Eficiencia de Mercado

10.1 Resumen de Hallazgos Empíricos

Los hallazgos empíricos principales de este estudio son:

1. El modelo Ridge genera un alfa de 216 puntos porcentuales sobre cinco años (318.8 % vs 102.2 % del mercado)
2. Este outperformance persiste después de costos de transacción realistas
3. El ratio de Sharpe de 0.93 supera al benchmark (0.88)
4. Cuatro de veintitrés modelos superan al benchmark en retorno total
5. La estrategia LONG-ONLY demuestra que es posible generar alfa sin posiciones cortas

10.2 Interpretación desde la Perspectiva de Eficiencia de Mercado

10.2.1 El Argumento contra la Eficiencia

Los resultados pueden interpretarse como evidencia contra la eficiencia de mercado:

Magnitud del outperformance: Un alfa de 216 puntos porcentuales es económicamente significativo y difícil de atribuir completamente a suerte o compensación por riesgo convencional.

Consistencia de resultados: Múltiples modelos con metodologías distintas logran outperformance, sugiriendo señal predictiva real.

Diversidad metodológica: Los modelos exitosos incluyen tanto métodos lineales como gradient boosting y deep learning.

10.2.2 El Argumento a Favor de la Eficiencia

Una interpretación alternativa es parcialmente consistente con mercados eficientes:

Complejidad computacional: La extracción de la señal predictiva requiere procesar 647 características con algoritmos sofisticados.

Prima de renta variable amplificada: Parte del rendimiento proviene de exposición larga promedio positiva.

Período de prueba específico: El período incluye recuperación post-COVID y mercados alcistas predominantes.

10.3 Reconciliando las Interpretaciones

Se considera que la verdad reside en un punto intermedio:

Ineficiencia explotable: Los resultados sugieren que el mercado no es perfectamente eficiente.

Eficiencia adaptativa con fricciones: Siguiendo el marco de “Mercados Adaptativos” de Lo (2019), los mercados son aproximadamente eficientes pero exhiben patrones predecibles explotables por participantes sofisticados.

11. Limitaciones y Consideraciones de Robustez

11.1 Limitaciones del Estudio

11.1.1 Período de Prueba

El período de prueba (octubre 2020 – diciembre 2025) comprende predominantemente mercados alcistas. Una evaluación completa requeriría desempeño a través de ciclos de mercado completos, incluyendo recesiones sostenidas.

11.1.2 Mercado Único

El análisis se enfoca exclusivamente en el S&P 500. La generalizabilidad a otros mercados no puede asumirse sin verificación empírica adicional.

11.1.3 Estabilidad de Parámetros

Los hiperparámetros fueron seleccionados una vez y mantenidos fijos. En implementación real, se requerirían procedimientos de recalibración periódica.

11.1.4 Impacto de Mercado No Modelado

El modelo de costos asume que las posiciones pueden ejecutarse sin impacto de mercado. Para capital significativo, el impacto podría reducir la rentabilidad.

11.2 Análisis de Robustez

11.2.1 Diversidad de Modelos Exitosos

Múltiples arquitecturas diferentes logran superar al benchmark:

- Ridge (regularización lineal): 318.8 %, Sharpe 0.93
- GradientBoosting (ensemble de árboles): 267.5 %, Sharpe 0.59
- CNN_LSTM (deep learning híbrido): 207.1 %, Sharpe 0.74
- BiGRU (red recurrente): 127.7 %, Sharpe 0.68

Esta diversidad metodológica sugiere que la señal predictiva puede ser capturada por enfoques conceptualmente distintos, proporcionando evidencia de robustez.

12. Conclusión

12.1 Resumen de Hallazgos

Este estudio ha investigado empíricamente la Hipótesis de Eficiencia de Mercado mediante un enfoque estructurado en dos hitos fundamentales:

Hito 1 – Predicción: Se entrenaron 23 modelos de aprendizaje automático y profundo utilizando 647 características derivadas de 92 variables de Bloomberg.

Hito 2 – Implementación: Las predicciones se tradujeron en una estrategia LONG-ONLY de posiciones discretas.

Los hallazgos principales son:

Primero, el modelo Ridge alcanza un ratio de Sharpe de 0.93 con retornos acumulados del 318.8 % sobre el período de prueba, superando al benchmark pasivo (102.2 %). La estrategia genera un alfa de 216 puntos porcentuales después de costos.

Segundo, cuatro de veintitrés modelos superan al benchmark pasivo en retorno total, demostrando que superar al mercado es difícil pero no imposible.

Tercero, la diversidad metodológica de los modelos exitosos sugiere que la señal predictiva es robusta y puede ser capturada por enfoques conceptualmente distintos.

Cuarto, el modelo Ridge permanece en efectivo el 62 % del tiempo, ejemplificando un enfoque conservador que prioriza la preservación de capital.

12.2 Contribuciones al Debate sobre Eficiencia de Mercado

Los resultados presentan un desafío matizado a la Hipótesis de Eficiencia de Mercado. Se documenta rendimientos anormales sistemáticos de magnitud sustancial que persisten utilizando

únicamente información pública y una estrategia de implementación práctica.

Se considera que los hallazgos son más consistentes con una forma de “eficiencia adaptativa” donde los mercados son aproximadamente eficientes pero no perfectamente eficientes.

12.3 Implicaciones Prácticas

Para practicantes, este estudio ofrece varias lecciones:

1. **Simplicidad sobre complejidad:** Modelos simples como Ridge pueden superar a arquitecturas sofisticadas
2. **Direccionalidad sobre precisión:** El objetivo debe ser capturar la dirección del mercado con suficiente precisión
3. **Costos de transacción:** Las estrategias de alto turnover raramente son viables
4. **Ingeniería de características:** La extracción sistemática de información genera valor predictivo
5. **Apalancamiento selectivo:** La estrategia LONG-ONLY con niveles discretos permite capturar alfa mientras se gestiona el riesgo

12.4 Direcciones para Investigación Futura

Extensión a otros mercados: ¿Se generalizan los hallazgos a otros índices de renta variable o clases de activos?

Análisis de régimen: ¿Puede mejorarse el desempeño mediante detección explícita de regímenes de mercado?

Optimización de costos: ¿Pueden desarrollarse modelos que optimicen explícitamente el trade-off entre señal predictiva y turnover?

Integración de datos alternativos: ¿Agregarían valor fuentes de datos no tradicionales?

12.5 Reflexiones Finales

La búsqueda de rendimientos superiores en los mercados financieros representa uno de los ejercicios más desafiantes en la intersección de finanzas, estadística e inteligencia artificial. El presente estudio sugiere que oportunidades explotables pueden existir para aquellos dispuestos a combinar rigurosidad académica con pragmatismo de practicante.

Sin embargo, se mantiene humildad respecto a los resultados. Los mercados financieros son sistemas adaptativos complejos donde el éxito pasado no garantiza desempeño futuro. Se anima a otros investigadores a validar, extender, y desafiar los hallazgos.

Referencias

- Ang, A., Hodrick, R. J., Xing, Y., & Zhang, X. (2006). The Cross-Section of Volatility and Expected Returns. *The Journal of Finance*, 61(1), 259–299.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dong, X., Li, Y., Rapach, D., & Zhou, G. (2022). Anomalies and the Expected Market Return. *The Journal of Finance*, 77(1), 639–681.
- Elder, A. (1993). *Trading for a Living: Psychology, Trading Tactics, Money Management*. John Wiley & Sons.
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.
- Grossman, S. J., & Stiglitz, J. E. (1980). On the Impossibility of Informationally Efficient Markets. *American Economic Review*, 70(3), 393–408.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The Model Confidence Set. *Econometrica*, 79(2), 453–497.
- Lo, A. W. (2019). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128.

A. Especificación Completa de Variables

Este apéndice documenta el conjunto completo de 92 variables base empleadas en el análisis. Todos los datos provienen de Bloomberg Terminal.

Las variables se organizan en siete categorías:

- **Variables de Mercado (M1–M18):** ETFs de renta variable y renta fija
- **Variables Macroeconómicas (E1–E10):** Indicadores de actividad económica
- **Variables de Tasas de Interés (I1–I20):** Rendimientos y spreads
- **Variables de Commodities (P1–P13):** Futuros y divisas
- **Variables de Volatilidad (V1–V13):** VIX y estructura de términos
- **Variables de Sentimiento (S1–S11):** Encuestas y ratios
- **Variables Dummy de Calendario (D1–D7):** Efectos de calendario

B. Detalles de Ingeniería de Características

Las 647 características se derivan de las 92 variables base mediante:

- Retornos multi-horizonte: $h \in \{1, 5, 21, 63, 126, 252\}$ días
- Indicadores técnicos: RSI, MACD, Bollinger %B, ATR
- Estimadores de volatilidad OHLC: Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang
- Características Triple Screen: Indicadores semanales y diarios
- Estructura de términos de volatilidad: Pendientes y z-scores del VIX
- Correlaciones cross-asset: Correlaciones móviles de 21 días
- Rezagos y estadísticas móviles

C. Hiperparámetros de Modelos

Esta sección detalla los hiperparámetros utilizados para cada uno de los 23 modelos evaluados. Los valores fueron seleccionados mediante validación cruzada temporal (TimeSeriesSplit con 5 folds) sobre el conjunto de entrenamiento.

Cuadro 23: Hiperparámetros: Modelos de Regresión Lineal Regularizada

Modelo	Parámetro	Valor/Descripción
Ridge	alpha	1.0 (regularización L2)
	solver	'auto' (selección automática)
	fit_intercept	True
Lasso	alpha	0.001 (regularización L1)
	max_iter	10,000
	tol	10^{-4}
ElasticNet	alpha	0.001
	l1_ratio	0.5 (balance L1/L2)
	max_iter	10,000

Cuadro 24: Hiperparámetros: Modelos Ensemble

Modelo	Parámetro	Valor
RandomForest	n_estimators	200
	max_depth	10
	min_samples_split	20
	min_samples_leaf	10
	max_features	'sqrt'
	bootstrap	True
	n_jobs	-1
GradientBoosting	n_estimators	200
	max_depth	5
	learning_rate	0.05
	subsample	0.8
	min_samples_split	20

Cuadro 25: Hiperparámetros: XGBoost, LightGBM, CatBoost

Modelo	Parámetro	Valor
XGBoost	n_estimators	200
	max_depth	6
	learning_rate	0.05
	subsample	0.8
	colsample_bytree	0.8
	reg_alpha	0.1 (L1)
	reg_lambda	1.0 (L2)
	early_stopping_rounds	50
LightGBM	n_estimators	200
	max_depth	8
	learning_rate	0.05
	num_leaves	31
	subsample	0.8
	colsample_bytree	0.8
	reg_alpha	0.1
	reg_lambda	1.0
CatBoost	iterations	200
	depth	6
	learning_rate	0.05
	l2_leaf_reg	3.0
	random_strength	1.0
	bagging_temperature	0.5

Cuadro 26: Hiperparámetros: Modelos de Series Temporales

Modelo	Parámetro	Valor
AutoARIMA	max_p	5
	max_q	5
	max_d	2
	seasonal	False
	stepwise	True
	suppress_warnings	True
ExponentialSmoothing	trend	'add'
	seasonal	None
	damped_trend	True
Theta	theta	0 (optimizado automáticamente)
	deseasonalize	True
SeasonalNaive	K	5 (días de rezago)
Prophet	changepoint_prior_scale	0.05
	seasonality_prior_scale	10
	yearly_seasonality	True
	weekly_seasonality	True
	daily_seasonality	False
GARCH	p	1
	q	1
	vol	'GARCH'
	dist	'normal'

Cuadro 27: Hiperparámetros: Modelos Deep Learning (Darts)

Modelo	Parámetro	Valor
DLinear	input_chunk_length	30
	output_chunk_length	1
	n_epochs	100
	batch_size	32
	optimizer_kwargs	{'lr': 0.001}
N-BEATS	input_chunk_length	30
	output_chunk_length	1
	num_stacks	30
	num_blocks	1
	num_layers	4
	layer_widths	256
	n_epochs	100
N-HiTS	input_chunk_length	30
	output_chunk_length	1
	num_stacks	3
	num_blocks	1
	num_layers	2
	layer_widths	256
	n_epochs	100
TCN	input_chunk_length	30
	output_chunk_length	1
	kernel_size	3
	num_filters	32
	dilation_base	2
	n_epochs	100
	dropout	0.2
TFT	input_chunk_length	30
	output_chunk_length	1
	hidden_size	64
	lstm_layers	1
	attention_heads	4
	dropout	0.1
	n_epochs	100

C.1 Modelos de Machine Learning Clásico**C.2 Modelos de Gradient Boosting****C.3 Modelos de Series Temporales****C.4 Modelos de Deep Learning (Darts)****C.5 Modelos RNN Bidireccionales**

Cuadro 28: Hiperparámetros: Bi-LSTM y Bi-GRU

Modelo	Parámetro	Valor
BiLSTM	input_chunk_length	30
	output_chunk_length	1
	hidden_dim	64
	n_rnn_layers	2
	bidirectional	True
	dropout	0.2
	n_epochs	100
	batch_size	32
	optimizer_kwargs	{'lr': 0.001}
BiGRU	input_chunk_length	30
	output_chunk_length	1
	hidden_dim	64
	n_rnn_layers	2
	bidirectional	True
	dropout	0.2
	n_epochs	100
	batch_size	32

C.6 Modelos Híbridos y Attention (PyTorch)**C.7 Configuración de Entrenamiento Común****D. Parámetros Óptimos de Umbral**

Esta sección presenta los parámetros óptimos de posicionamiento por percentil para cada modelo, obtenidos mediante grid search sobre el conjunto de validación.

D.1 Metodología de Optimización*D.1.1 Función Objetivo*

Optimizamos el Sharpe Ratio neto (después de costos) sobre el período de validación:

$$(q_{3x}^*, q_{1x}^*) = \arg \max_{q_{3x}, q_{1x}} \text{Sharpe}(R_{net}(q_{3x}, q_{1x})) \quad (27)$$

Cuadro 29: Hiperparámetros: CNN-LSTM y LSTM+Attention

Modelo	Parámetro	Valor
CNN-LSTM	sequence_length	30
	cnn_filters	[32, 64]
	cnn_kernel_size	3
	lstm_hidden_size	64
	lstm_layers	2
	dropout	0.3
	n_epochs	100
	batch_size	32
	learning_rate	0.001
LSTM+Attention (Luong)	sequence_length	30
	lstm_hidden_size	64
	lstm_layers	2
	attention_type	'general'
	dropout	0.3
	n_epochs	100
	batch_size	32

Cuadro 30: Configuración de Entrenamiento Común

Parámetro	Valor
Período de entrenamiento	Enero 2015 - Septiembre 2020
Período de prueba	Octubre 2020 - Diciembre 2025
División temporal	Sin shuffle, estrictamente cronológica
Validación cruzada	TimeSeriesSplit, 5 folds
Normalización	StandardScaler, fit solo en train
Features eliminados	Constantes, >50 % NaN, correlación >0.95
Warmup para percentiles	63 días (usando predicciones de train)
Early stopping	10-50 epochs sin mejora (según modelo)
GPU	NVIDIA RTX 3090 (24GB)
Seed	42 (reproducibilidad)

sujeto a $q_{3x} < q_{1x}$ (percentil para 3x debe ser más selectivo que para 1x).

D.1.2 Grid de Búsqueda

- $q_{3x} \in \{5, 10, 15, 20, 25, 30\}$ (percentil superior para posición UPRO)
- $q_{1x} \in \{20, 30, 40, 50, 60\}$ (percentil superior para posición SPY)
- Total: 30 combinaciones evaluadas por modelo

D.1.3 Restricciones

1. $q_{3x} < q_{1x}$: Asegura que UPRO (3x) requiera mayor confianza que SPY (1x)
2. Ventana rolling: 63 días para cálculo de percentiles
3. Warmup: Predicciones de training para los primeros 63 días de test

D.2 Tabla de Parámetros Óptimos

Cuadro 31: Parámetros Óptimos de Umbral por Modelo

Modelo	Categoría	q_{3x} (%)	q_{1x} (%)	Interpretación
Ridge	ML	20	30	Top 20 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
GradientBoosting	ML	30	60	Top 30 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
CNN_LSTM	Hybrid	30	60	Top 30 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
BiGRU	RNN	15	50	Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
RandomForest	ML	15	50	Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
NBEATS	DeepLearning	10	20	Top 10 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
LightGBM	GradientBoosting	10	50	Top 10 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
CatBoost	GradientBoosting	5	30	Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
XGBoost	GradientBoosting	15	20	Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
SeasonalNaive	TimeSeries	5	40	Top 5 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
BiLSTM	RNN	5	30	Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
DLinear	DeepLearning	10	20	Top 10 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
NHiTS	DeepLearning	15	20	Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
LSTM_Attention	Attention	15	50	Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
TFT	DeepLearning	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
AutoARIMA	TimeSeries	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
TCN	DeepLearning	15	50	Top 15 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
Prophet	Prophet	30	50	Top 30 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
ElasticNet	ML	15	20	Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
Lasso	ML	15	20	Top 15 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
ExponentialSmoothing	TimeSeries	5	50	Top 5 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
GARCH	GARCH	25	30	Top 25 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
Theta	TimeSeries	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x

Nota: q_{3x} = percentil para posición UPRO (3x). q_{1x} = percentil para posición SPY (1x). Predicciones por debajo del percentil q_{1x} resultan en posición Cash (0). Parámetros optimizados mediante grid search sobre conjunto de validación.

D.3 Análisis de Parámetros

D.3.1 Patrones Observados

1. **Modelos conservadores** (AutoARIMA, TFT, BiLSTM): $q_{3x} = 5$, requieren alta confianza para apalancar.
2. **Modelos agresivos** (GradientBoosting, Prophet, CNN-LSTM): $q_{3x} \geq 30$, más dispuestos a apalancar.
3. **Modelos equilibrados** (Ridge, BiGRU): $q_{3x} \in [15, 20]$, balance entre agresividad y conservadurismo.

D.3.2 Relación Parámetros-Rendimiento

Cuadro 32: Correlación entre Parámetros y Métricas

Correlación	q_{3x}	q_{1x}
vs Retorno Total	0.42	0.38
vs Sharpe Ratio	0.15	0.22
vs Max Drawdown	0.51	0.33
vs % Tiempo en 3x	0.89	0.24

Nota: Correlaciones calculadas sobre los 23 modelos. q_{3x} más alto implica más tiempo en UPRO, mayor retorno pero mayor drawdown.

D.3.3 Implicaciones

- q_{3x} **alto** + **buen rendimiento**: El modelo tiene señales fuertes frecuentes (GradientBoosting).
- q_{3x} **bajo** + **buen rendimiento**: El modelo es selectivo pero preciso (Ridge).
- q_{3x} **alto** + **mal rendimiento**: El modelo sobreestima señales positivas (XGBoost).

D.4 Sensibilidad a Parámetros

D.4.1 Ridge: Análisis de Sensibilidad

La sensibilidad moderada sugiere que los resultados son robustos a variaciones razonables en los parámetros.

Cuadro 33: Sensibilidad de Ridge a Parámetros de Umbral

q_{3x}	q_{1x}	Retorno	Sharpe	Max DD
10	30	+245.2 %	0.87	-32.1 %
15	30	+287.6 %	0.91	-35.4 %
20	30	+318.8 %	0.93	-38.6 %
25	30	+301.3 %	0.85	-42.3 %
20	40	+298.4 %	0.89	-36.2 %
20	50	+276.1 %	0.84	-34.8 %

Nota: Valores en negrita indican parámetros óptimos seleccionados.

D.5 Estabilidad Temporal de Parámetros

D.5.1 Walk-Forward Optimization

Evaluamos si los parámetros óptimos son estables en el tiempo usando walk-forward optimization:

1. Dividir el período de prueba en 5 sub-períodos de 260 días
2. Re-optimizar parámetros al inicio de cada sub-período
3. Comparar parámetros seleccionados vs parámetros fijos

Cuadro 34: Estabilidad de Parámetros: Ridge

Sub-período	q_{3x} Óptimo	q_{1x} Óptimo
Oct 2020 - Sep 2021	20	30
Oct 2021 - Sep 2022	15	30
Oct 2022 - Sep 2023	20	30
Oct 2023 - Sep 2024	25	30
Oct 2024 - Dic 2025	20	30
Moda	20	30

Los parámetros óptimos de Ridge son estables, con $q_{3x} = 20$, $q_{1x} = 30$ siendo óptimos en 3 de 5 sub-períodos.

D.6 Interpretación de Umbrales

D.6.1 Significado de los Percentiles

Para Ridge con $(q_{3x}, q_{1x}) = (20, 30)$:

- **Predicción en top 20 %:** Posición UPRO (3x leverage)
- **Predicción en top 20-30 %:** Posición SPY (1x)

- **Predicción debajo de top 30 %:** Cash (tasa libre de riesgo)

Esto significa que Ridge solo toma posiciones de riesgo cuando su predicción está en el tercio superior de su distribución histórica reciente.

D.6.2 Percentiles vs Valores Absolutos

El uso de percentiles rolling en lugar de umbrales fijos tiene ventajas:

1. **Adaptabilidad:** Se ajusta automáticamente a cambios en la distribución de predicciones.
2. **Robustez:** Menos sensible a drift en el modelo.
3. **Consistencia:** Mantiene proporción constante de días en cada posición (aproximadamente).