

Explorando los Límites de la Eficiencia del Mercado:

Enfoques Clásicos y Contemporáneos de Modelado Cuantitativo para la Predicción Direccional y Generación de Alfa en el S&P 500

David González Cañón

Magíster en Finanzas

Profesor guía: David Díaz Solís

Julio de 2026

Resumen

Este documento examina la posibilidad de generar alfa en el S&P 500 mediante técnicas de aprendizaje automático y profundo. Se propone la hipótesis de que modelos computacionales suficientemente sofisticados pueden capturar patrones direccionales explotables en los retornos del índice, generando rentabilidad positiva después de costos de transacción. A través del entrenamiento de 23 modelos (desde regresiones regularizadas hasta redes neuronales con mecanismos de atención) se transforman 92 variables financieras y macroeconómicas en 536 características predictivas, y se traducen las predicciones resultantes en una estrategia de inversión *Long-Only* con posiciones discretas en efectivo, SPY y UPRO 3x. Los umbrales de posicionamiento se determinan dinámicamente mediante un metamodelo entrenado exclusivamente con datos históricos, evitando toda filtración de información futura. Los resultados sugieren que cuatro de los veintitrés modelos habrían superado al *benchmark* pasivo en el período analizado (octubre 2020–diciembre 2025), liderados por LSTM con Atención (+395 %, Sharpe 1.32) y Ridge (+253 %, Sharpe 0.86). Se documenta, además, un hallazgo contraintuitivo, a saber, los modelos más rentables no parecen ser necesariamente aquellos con mayor tasa de acierto direccional, sino aquellos capaces de concentrar sus posiciones apalancadas en los momentos donde efectivamente aciertan, lo que sugiere que la selectividad temporal desempeña un papel más relevante que la frecuencia de aciertos. La evidencia es compatible con la Hipótesis de Mercados Adaptativos, donde las ineficiencias residuales compensan la sofisticación computacional requerida para su explotación.

Palabras clave

Marcos Teóricos. Hipótesis de Mercados Adaptativos, Paradoja de Grossman-Stiglitz, Ley del Arcoseno, Hipótesis de Eficiencia de Mercado (HEM)

Metodología e Ingeniería de Características. Triple Screen de Elder, Estimadores de Volatilidad OHLC (Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang), Filtración de Información (*data leakage*), Umbrales Cuantílicos, Percentiles Rolling, TimeSeriesSplit

Estrategia e Instrumentos. Estrategia Long-Only, *Volatility Drag*, ETFs Apalancados (UPRO), Paradoja de Precisión Direccional, DA@3x, *Profit Factor*, Ratio de Calmar, Ratio de Sortino

Validación Estadística. *Model Confidence Set* (Hansen), Test de Diebold-Mariano, Test de Clark-West, Corrección de Bonferroni, Tasa de Falso Descubrimiento (Benjamini-Hochberg), Corrección de Newey-West, *Bootstrap* No Paramétrico

Arquitecturas de Aprendizaje Profundo. N-BEATS, N-HiTS, TFT (*Temporal Fusion Transformer*), TCN (*Temporal Convolutional Network*), DLinear, LSTM con Atención, CNN-LSTM

Clasificación JEL. G14, G17, C45, C53

Índice

1. Introducción	6
1.1. Objetivos de esta Tesis	6
1.2. Estructura del Documento	8
2. Revisión de Literatura y Fundamentos Teóricos	8
2.1. Origen y Evolución de la Hipótesis de Eficiencia de Mercado	8
2.1.1. Fundamentos Conceptuales	8
2.1.2. La Paradoja de Grossman-Stiglitz	8
2.2. Anomalías de Mercado y Evidencia Contra la HEM	9
2.3. Alternativas Teóricas a la HEM	9
2.4. <i>Random Walk</i> y Representación Martingala	10
2.4.1. Ley del Arcoseno e Implicaciones para la Predictibilidad	11
2.4.2. Justificación Teórica del Enfoque Cuantitativo	11
2.5. Evolución del Modelado Cuantitativo en la Valoración de Activos	12
3. Datos y Metodología	13
3.1. Fuentes de Datos e Ingeniería de Características	15
3.1.1. Universo de Datos	15
3.1.2. Proceso de Construcción de Características	15
3.1.3. Garantías contra Filtración de Información	16
3.1.4. Conjunto de Datos Resultante	16
3.2. Variable Objetivo y División de Muestra	16
3.3. Especificaciones de Modelos	17
3.3.1. Preparación de Datos para Entrenamiento	18
3.3.2. Modelos Tabulares con Validación Cruzada	18
3.3.3. Modelos Univariados de Series Temporales	18
3.3.4. Modelos de Deep Learning	19
3.3.5. Implementación Computacional	19
3.4. Estrategia de Inversión	19
3.4.1. Conversión de Predicciones en Posiciones Discretas	19
3.4.2. Optimización de Umbrales por Modelo	20
3.4.3. Modelo de Costos	21
4. Resultados Empíricos	21
4.1. Rendimiento General	21
4.2. Análisis por Familia de Modelos	23
4.3. Dinámica de la Estrategia	24
4.4. Comparación con Estrategias de Referencia Alternativas	25
4.5. La Paradoja del <i>Directional Accuracy</i>	25
4.5.1. Discrepancia entre Precisión Direccional y Rentabilidad	26
4.5.2. Factores de Rentabilidad no Capturados por el <i>Directional Accuracy</i>	26
4.5.3. Definición del Indicador DA@3x	27
4.5.4. Implicaciones para el Diseño de Estrategias	28

5. Análisis de Robustez	28
5.1. Gestión de Riesgo	28
5.1.1. Métricas de Riesgo Ajustado	29
5.1.2. Riesgo de Cola y <i>Drawdown</i>	29
5.1.3. Ratios de Captura de Mercado	30
5.2. Validación Estadística	30
5.2.1. Bootstrap de Sharpe Ratios	31
5.2.2. Test de Diebold-Mariano	31
5.2.3. Test de Clark-West	31
5.2.4. Model Confidence Set	32
5.2.5. Análisis de <i>Overfitting</i> y Comparaciones Múltiples	32
5.2.6. Síntesis de la Validación Estadística	32
5.3. Costos de Transacción	33
5.3.1. Modelo de Costos y Estructura	33
5.3.2. Desglose de Costos e Impacto	33
5.3.3. Análisis de Sensibilidad a Costos	34
5.3.4. Limitaciones del Modelo de Costos	34
6. Discusión	34
7. Conclusión	37
Apéndices	43
A. Especificación Completa de Variables	43
B. Detalles de Ingeniería de Características	45
C. Hiperparámetros de Modelos	50
C.1. Esquema de Escalado por Familia	50
C.2. Modelos de Regresión Lineal Regularizada (<i>GridSearchCV</i>)	50
C.3. Modelos <i>Ensemble</i> (<i>GridSearchCV</i>)	51
C.4. Modelos de <i>Gradient Boosting</i> Especializado	51
C.5. Modelos de Series Temporales (Darts Clásicos)	52
C.6. GARCH (<i>arch library</i>)	52
C.7. Modelos de <i>Deep Learning</i> (Darts)	53
C.8. Modelos <i>Custom PyTorch</i>	53
C.9. Configuración de Entrenamiento Común	55
C.10. Entorno Computacional	56
D. Parámetros Óptimos de Umbral	56
D.1. Metodología de Optimización mediante Meta-KNN	56
D.2. Tabla de Parámetros Dinámicos	57
D.3. Ejemplos Ilustrativos de la Estrategia	57
D.4. Análisis de Parámetros	59
D.4.1. Diversidad de Umbrales por Modelo	59
D.4.2. Implicaciones	59
D.5. Interpretación de los Umbrales Dinámicos	59
D.5.1. Significado de los Percentiles	59
D.5.2. Percentiles vs Valores Absolutos	60

E.	Tablas y Figuras Complementarias	60
E.1.	Figuras Complementarias de la Revisión de Literatura	60
E.2.	Tablas y Figuras de Resultados Empíricos	61
E.3.	Tablas de Gestión de Riesgo	62
E.4.	Tablas de Validación Estadística	63
E.5.	Tablas y Figuras de Costos de Transacción	64
F.	Glosario de Términos	66

1. Introducción

La Hipótesis de Eficiencia de Mercado (HEM), formalizada por Fama (1970) hace más de cinco décadas, permanece como una de las proposiciones más influyentes y debatidas en la economía financiera contemporánea. En su formulación más estricta, la hipótesis postula que los precios de los activos incorporan instantánea y completamente toda la información disponible, haciendo imposible la obtención de rendimientos anormales sistemáticos a través de cualquier estrategia de *trading* basada en datos históricos o información pública.

Sin embargo, el panorama empírico ha evolucionado considerablemente desde el trabajo seminal de Fama. La proliferación de anomalías documentadas, la sofisticación creciente de las técnicas de aprendizaje automático, y la disponibilidad de conjuntos de datos cada vez más ricos han reavivado el debate fundamental, ¿procesan realmente los mercados financieros la información de manera eficiente, o existen ineficiencias persistentes susceptibles de explotación por inversores sofisticados?

Este debate trasciende, además, el ámbito puramente académico y tiene implicaciones profundas para la industria de gestión de activos, la regulación financiera y las decisiones de inversión individuales. Si los mercados son verdaderamente eficientes, los gestores activos de fondos destruyen valor para sus clientes a través de comisiones y costos de transacción sin generar rendimientos superiores al mercado. En este escenario, la inversión pasiva a través de fondos indexados representaría la estrategia óptima para todos los inversores.

Por el contrario, si existen ineficiencias sistemáticas y explotables, surge la posibilidad de que estrategias cuantitativas sofisticadas puedan generar rendimientos ajustados por riesgo superiores. Esta posibilidad ha impulsado el crecimiento exponencial de la industria de hedge funds cuantitativos, que según estimaciones de la industria gestiona más de un billón de dólares en activos globalmente.

En este contexto, el presente estudio examina si las técnicas más avanzadas de aprendizaje automático, combinadas con indicadores técnicos probados en la práctica, pueden identificar patrones predecibles en los retornos del mercado de valores. Para ello se adopta un enfoque empírico estructurado en **dos hitos**.

El primer hito consiste en la **predicción**, es decir, entrenar múltiples modelos de aprendizaje automático y profundo (23 en total) para generar predicciones sobre los retornos del S&P 500. El objetivo no es predecir con exactitud el valor numérico del retorno de mañana (tarea que la literatura ha demostrado extremadamente difícil), sino obtener suficiente *precisión direccional* para tomar decisiones de inversión.

El segundo hito aborda la **implementación**, es decir, traducir las predicciones de los modelos en una estrategia de *trading* práctica que aproveche el apalancamiento disponible en ETFs (UPRO 3x, SPY 1x, efectivo) para generar alfa positivo después de costos de transacción realistas.

Este enfoque reconoce una distinción crucial, dado que mientras que predecir el retorno exacto del mercado puede ser imposible, identificar la *dirección* con precisión suficiente puede ser económicamente explotable cuando se combina con una estrategia de posicionamiento inteligente.

1.1 Objetivos de esta Tesis

1. Presentar un marco metodológico de dos hitos: Se propone un enfoque estructurado que separa explícitamente la fase de *predicción* de la fase de *implementación*. Esta separación, poco común en la literatura donde predicción y posicionamiento suelen evaluarse conjuntamente,

busca aislar la fuente del rendimiento, es decir, ¿proviene el alfa de la capacidad predictiva de los modelos, o de las reglas de posicionamiento y gestión de riesgo de la estrategia? Al desacoplar ambas dimensiones, se evita la falacia común de atribuir rendimientos superiores exclusivamente a la inteligencia del modelo cuando en realidad pueden originarse en el diseño de la estrategia, o viceversa.

2. Comparar de forma sistemática 23 modelos: Se entrenan y evalúan 23 modelos que abarcan un amplio espectro de técnicas disponibles, desde regresión lineal regularizada (Ridge, Lasso, ElasticNet), pasando por métodos de ensemble basados en árboles (RandomForest, GradientBoosting, XGBoost, LightGBM, CatBoost), modelos estadísticos clásicos de series temporales (ExponentialSmoothing, Theta, Prophet, GARCH), hasta arquitecturas recientes de *deep learning* (TCN, N-BEATS, N-HiTS, TFT, DLinear, CNN-LSTM, LSTM con atención, Bi-LSTM, Bi-GRU). Esta evaluación transversal busca explorar qué paradigmas de modelado podrían capturar la señal predictiva en retornos financieros. El hallazgo de que el modelo con mejor rendimiento en esta muestra (LSTM+Attention) emplea mecanismos de atención, mientras que el segundo lugar corresponde a un modelo lineal regularizado (Ridge), sugiere que tanto las dependencias temporales complejas como las relaciones lineales capturan señal predictiva en retornos financieros.

3. Aportar evidencia empírica sobre la Hipótesis de Eficiencia de Mercado: Este constituye el objetivo central del estudio. La HEM en su formulación semifuerte (Fama, 1970) plantea que ninguna estrategia basada en información pública debería generar rendimientos anormales sistemáticos. Los resultados obtenidos sugieren evidencia inconsistente con esta predicción para el período y los instrumentos analizados, dado que cuatro de veintitrés modelos, entrenados exclusivamente con información pública histórica, parecen generar alfa positivo sobre el S&P 500 durante un período de prueba de cinco años, incluso después de incorporar costos de transacción realistas. La magnitud de la diferencia registrada (el modelo LSTM+Attention acumula un exceso de retorno de 294 puntos porcentuales sobre *buy-and-hold*) resulta difícil de atribuir únicamente a compensación por riesgo convencional, aunque el tamaño de la muestra no permite descartar por completo el papel del azar.

Estos hallazgos no implican que los mercados sean completamente ineficientes, sino que ofrecen cierto respaldo a marcos teóricos más contemporáneos que reconocen la existencia de ineficiencias explotables. La paradoja de Grossman & Stiglitz (1980) ya anticipaba esta conclusión al demostrar la imposibilidad lógica de mercados perfectamente eficientes, dado que si los precios reflejaran toda la información, nadie tendría incentivos para incurrir en el costo de adquirirla, y por tanto los precios dejarían de ser informativos. De manera más reciente, la Hipótesis de Mercados Adaptativos de Lo (2019) propone que la eficiencia no es una propiedad estática del mercado sino un fenómeno dinámico y evolutivo, donde las ineficiencias emergen, son explotadas por participantes sofisticados, y eventualmente se disipan, solo para que nuevas ineficiencias surjan en un ciclo continuo de adaptación. Los resultados de este estudio parecen compatibles con este paradigma adaptativo; la señal predictiva parece existir y ser capturada por múltiples metodologías independientes, pero su explotación requiere sofisticación computacional significativa, como la que demanda el enfoque adoptado en este trabajo al procesar las 536 características mediante algoritmos avanzados de aprendizaje automático, lo cual podría limitar el número de participantes capaces de arbitrarla y ayudaría a explicar su persistencia.

1.2 Estructura del Documento

El documento comienza estableciendo las bases teóricas del problema, revisando la literatura sobre eficiencia de mercado, las anomalías documentadas y el estado del arte en aplicaciones de aprendizaje automático a finanzas. A partir de ese fundamento, se desarrolla el Hito 1 (Predicción), donde se describen las fuentes de datos, el proceso de ingeniería de características, las especificaciones técnicas de los 23 modelos y el marco de evaluación empleado. El Hito 2 (Implementación) presenta los resultados empíricos del *backtesting*, incluyendo el análisis de la paradoja del *Directional Accuracy*. Posteriormente se somete la solidez de los hallazgos a un análisis de robustez que abarca la gestión de riesgo, la validación estadística y el impacto de los costos de transacción. Sobre esa base, la discusión sintetiza la evidencia, la contrasta con los marcos teóricos de la eficiencia de mercado, deriva sus implicaciones prácticas y expone las limitaciones del estudio. El documento cierra con una conclusión breve que recapitula los hallazgos y propone direcciones futuras de investigación. Los apéndices complementan el cuerpo principal con documentación técnica detallada sobre hiperparámetros, umbrales óptimos y el conjunto completo de variables utilizadas.

2. Revisión de Literatura y Fundamentos Teóricos

2.1 Origen y Evolución de la Hipótesis de Eficiencia de Mercado

2.1.1 Fundamentos Conceptuales

La noción de que los precios de mercado reflejan la información disponible tiene raíces que se remontan a los trabajos pioneros de Louis Bachelier a principios del siglo XX. Sin embargo, la formulación moderna de la Hipótesis de Eficiencia de Mercado se atribuye principalmente a Eugene Fama, cuyo artículo seminal de 1970 estableció el marco conceptual que domina el pensamiento financiero hasta el día de hoy.

Fama (1970) definió un mercado eficiente como aquel en el que los precios “reflejan completamente” la información disponible. Esta definición aparentemente simple encierra profundas implicaciones para la práctica de inversión y la teoría financiera. Fama distinguió tres formas de eficiencia de mercado.

La **eficiencia en forma débil** postula que los precios actuales incorporan completamente toda la información contenida en la secuencia histórica de precios.

La **eficiencia en forma semifuerte** extiende esta noción al postular que los precios reflejan toda la información públicamente disponible.

La **eficiencia en forma fuerte** representa la proposición más extrema, según la cual los precios reflejan toda la información, incluyendo información privada.

2.1.2 La Paradoja de Grossman-Stiglitz

Si la hipótesis de eficiencia se toma al pie de la letra, surge una contradicción que Grossman & Stiglitz (1980) formalizaron y que se conoce como la *paradoja de la información*. El razonamiento es sencillo; si los precios ya reflejan toda la información disponible, ningún participante podría obtener rendimientos superiores al mercado por investigar o analizar datos. Pero si no hay rendimientos que compensen el costo de adquirir información, nadie tiene incentivos para hacerlo.

Y si nadie recopila ni procesa información, los precios no pueden incorporarla, lo cual contradice la premisa inicial de que los precios son perfectamente informativos.

Lo interesante de esta paradoja es que no se trata de una crítica empírica sino de una contradicción lógica interna. Grossman & Stiglitz (1980) la resuelven proponiendo que los mercados operan en un equilibrio de desequilibrio, lo suficientemente ineficientes como para que existan oportunidades que compensen los costos de investigación, pero no tanto como para permitir ganancias sistemáticas sin esfuerzo. En este equilibrio, los participantes informados obtienen rendimientos que justifican marginalmente su inversión, y los precios se mantienen informativos en términos generales, aunque no de manera perfecta.

Esta idea tiene implicaciones directas para el presente estudio. Si los mercados fueran perfectamente eficientes, ningún modelo de aprendizaje automático, por sofisticado que fuera, podría generar alfa de manera consistente. Sin embargo, el marco de eficiencia ineficiente es compatible con la hipótesis que este trabajo busca examinar, a saber, que algoritmos capaces de procesar cientos de características de forma simultánea podrían identificar ineficiencias residuales que persisten precisamente porque su detección requiere un esfuerzo computacional que la mayoría de los participantes no puede asumir.

2.2 Anomalías de Mercado y Evidencia Contra la HEM

Si bien la HEM ofrece un marco teórico coherente, décadas de investigación empírica han documentado numerosas *anomalías*, es decir, patrones sistemáticos en los rendimientos que aparentemente contradicen sus predicciones. Dong et al. (2022) recopilan una amplia variedad de estos patrones documentados en la literatura académica, tales como el efecto enero, el *momentum* y las anomalías de valor. La persistencia de estos patrones sugiere que los mercados no son completamente eficientes y que inversores suficientemente informados pueden, al menos en ciertos períodos, obtener rendimientos anormales.

El campo de las *finanzas conductuales* ha proporcionado una explicación de por qué estas ineficiencias surgen y persisten. Kahneman & Tversky (1979) demostraron que los agentes económicos exhiben sesgos sistemáticos en la toma de decisiones bajo incertidumbre, en particular la aversión a la pérdida, por la cual las pérdidas pesan desproporcionadamente más que las ganancias equivalentes, generando desviaciones predecibles entre los precios de mercado y los valores fundamentales. Lo relevante es que estos sesgos no son aleatorios, sino patrones recurrentes de la psicología humana que crean ineficiencias potencialmente explotables.

La *teoría del operador ruidoso* de De Long et al. (1990) formalizó esta idea, mostrando que participantes irracionales pueden causar desviaciones significativas y persistentes en los precios respecto a los valores fundamentales. Se podría pensar que el arbitraje corregiría rápidamente estos errores, pero Shleifer & Vishny (1997) documentaron lo que denominaron *límites al arbitraje*, según los cuales los costos de transacción, el riesgo de posición y las restricciones regulatorias impiden que los arbitrajistas racionales eliminen completamente las ineficiencias, permitiendo que ciertos errores de valoración persistan incluso cuando son conocidos por los participantes del mercado.

2.3 Alternativas Teóricas a la HEM

Dado el volumen de evidencia contra la eficiencia en su formulación clásica, han surgido marcos teóricos alternativos que intentan reconciliar la utilidad descriptiva de la HEM con las

ineficiencias observadas en la práctica.

Quizás la alternativa más influyente sea la *Hipótesis del Mercado Adaptativo* (HMA), articulada en detalle por [Lo \(2019\)](#). La idea central es que la eficiencia del mercado no es una propiedad fija sino una variable dinámica que fluctúa según el entorno competitivo, de forma análoga a un ecosistema biológico. Las estrategias que generan alfa en un período pueden dejar de funcionar cuando suficientes participantes las adoptan, y nuevas oportunidades emergen a medida que cambian las condiciones. Para este estudio, la HMA es particularmente relevante, dado que justifica tanto la búsqueda de señales predictivas como la expectativa de que su eficacia varíe entre regímenes de mercado.

Por otro lado, la *Hipótesis del Mercado Fractal* de [Peters \(1994\)](#) propone que los mercados exhiben autosimilitud, es decir, que los patrones de precios se repiten a través de diferentes escalas temporales. Esta propiedad proporciona respaldo teórico al análisis multitemporal, dado que si las dinámicas de precios presentan estructuras similares en múltiples horizontes, la extracción de características a distintas ventanas temporales (como la que realiza el *pipeline* de ingeniería de características de este estudio) puede capturar información complementaria en cada escala.

El *Modelo Conductual de Valoración de Activos* (BAPM) de [Shefrin & Statman \(1994\)](#) extiende los modelos tradicionales incorporando factores psicológicos de manera explícita, ofreciendo un marco formal para entender cómo los sesgos humanos influyen en los precios. La *econofísica* ([Mantegna & Stanley, 2000](#)), por su parte, aplica herramientas de la física estadística al análisis financiero, mostrando propiedades como colas pesadas y agrupamiento de volatilidad que los modelos tradicionales no capturan.

Ninguna de estas alternativas ha desplazado a la HEM de su posición central en las finanzas modernas. Sin embargo, en conjunto ofrecen un marco teórico más rico que justifica la búsqueda de señales predictivas en datos históricos, que es precisamente el enfoque de este estudio.

2.4 *Random Walk* y Representación Martingala

Que los precios sigan un camino aleatorio no descalifica automáticamente a los modelos cuantitativos de predicción. Para entender por qué, es necesario distinguir entre los dos modelos estocásticos más utilizados para describir la dinámica de precios, a saber, el camino aleatorio y el proceso de martingala.

Un *camino aleatorio* genera una secuencia de precios donde ninguna combinación de observaciones pasadas ofrece información sobre el siguiente movimiento. Su limitación como modelo de mercado es que asume una progresión horizontal del precio, donde el valor esperado futuro es simplemente el precio actual, sin tendencia. Dado que más de un siglo de evidencia muestra que los mercados accionarios han generado rendimientos positivos en el largo plazo, esta asunción resulta empíricamente inadecuada.

Un *proceso de martingala*, en cambio, incorpora un factor de deriva que captura la expectativa de acumulación de riqueza de los inversores. [Samuelson \(1965\)](#) demostró que, bajo competencia informacional, los precios anticipados correctamente fluctúan como una martingala con deriva. Formalmente, si P_t denota el precio en el período t y μ la tasa esperada de retorno, el proceso satisface $E[P_{t+1}|\mathcal{F}_t] = P_t(1 + \mu)$, donde $\mathcal{F}_t$ es toda la información disponible hasta t . Al igual que en el camino aleatorio, los movimientos individuales son impredecibles. La diferencia clave es que el precio medio esperado sigue una trayectoria ascendente cuando $\mu > 0$, reflejando la prima de riesgo histórica del mercado accionario.

2.4.1 Ley del Arcoseno e Implicaciones para la Predictibilidad

Un argumento común contra los modelos de predicción de precios es que los patrones observados en series financieras son ilusiones estadísticas. Malkiel (1973) popularizó la metáfora del *paseo aleatorio*, sugiriendo que los movimientos de precios son impredecibles y que cualquier patrón aparente es producto del sesgo humano de encontrar orden donde solo hay ruido.

A primera vista, este argumento parece sólido. Sin embargo, la *ley del arcoseno*, descubierta por Lévy (1940) para el movimiento browniano y desarrollada por Feller (1968) para caminos aleatorios discretos, muestra algo contraintuitivo, a saber, la fracción del tiempo que un proceso aleatorio pasa en territorio positivo sigue una distribución en forma de U (Figura 4), de modo que lo más probable es que la trayectoria pase la mayor parte del tiempo de un mismo lado del origen, generando *tendencias persistentes* incluso sin estructura predictiva subyacente. La implicación es directa, dado que las tendencias son una propiedad matemática inevitable de cualquier serie temporal, de modo que el reto consiste en identificar cuándo esas tendencias contienen información explotable más allá de lo que la aleatoriedad pura produciría.

2.4.2 Justificación Teórica del Enfoque Cuantitativo

Esta distinción es importante porque, bajo un proceso de martingala, aunque predecir el precio exacto del siguiente período sea imposible, identificar cuándo el precio está significativamente por debajo o por encima de su tendencia esperada constituye una forma legítima de explotar dependencias estadísticas. La ley del arcoseno sugiere además que estas desviaciones tenderían a ser prolongadas y no meramente transitorias.

De aquí surgen dos justificaciones teóricas complementarias para el uso de modelos de aprendizaje automático en mercados financieros.

1. **Identificación de tendencias (ley del arcoseno).** Las tendencias son una propiedad matemática inevitable de cualquier serie temporal, incluyendo las puramente aleatorias. Los modelos cuantitativos pueden identificar y explotar estas tendencias persistentes de forma sistemática, posicionándose en la dirección dominante durante los períodos prolongados que la distribución del arcoseno predice.
2. **Posicionamiento relativo (marco de la martingala).** Bajo el modelo de martingala con deriva, los modelos no necesitan predecir el nivel de precio futuro, sino solo estimar si el precio actual está por debajo o por encima de la tendencia esperada. Esta tarea de clasificación relativa es fundamentalmente más abordable que la predicción puntual, y es precisamente lo que realizan los modelos de este estudio al generar señales discretas de posicionamiento (CASH, SPY, UPRO).

En suma, incluso aceptando la premisa de la HEM de que los precios pasados no predicen con precisión los precios futuros, los modelos cuantitativos conservan utilidad para evaluar riesgo, identificar posicionamientos favorables y filtrar decisiones de inversión. Bajo esta lógica, no buscan predecir precios, sino identificar estados probabilísticamente favorables dentro de un mercado aproximadamente eficiente que, no obstante, exhibe tendencias económicamente explotables.

2.5 Evolución del Modelado Cuantitativo en la Valoración de Activos

La aplicación de técnicas computacionales a la predicción de mercados financieros no es un fenómeno reciente, sino el resultado de una evolución que abarca más de cuatro décadas. En sus orígenes, los modelos cuantitativos en finanzas se limitaban a especificaciones econométricas clásicas; los modelos ARIMA para la estructura temporal de retornos y los modelos GARCH (Bollerslev, 1986) para la dinámica de volatilidad condicional constituían el estado del arte durante las décadas de 1980 y 1990. Estos enfoques, si bien rigurosos en su fundamentación estadística, operaban bajo supuestos restrictivos (linealidad, estacionariedad, distribuciones paramétricas) que limitaban su capacidad para capturar la complejidad inherente de los mercados financieros.

La irrupción del aprendizaje automático en finanzas cuantitativas, acelerada por el crecimiento de la capacidad computacional y la disponibilidad de datos, modificó este panorama de forma considerable. A diferencia de los modelos econométricos tradicionales, donde el investigador debe especificar de antemano la forma funcional de la relación entre predictores y variable objetivo, los algoritmos de aprendizaje automático descubren estas relaciones directamente a partir de los datos. Esta flexibilidad resulta particularmente valiosa en mercados financieros, donde las dependencias entre variables macroeconómicas, indicadores técnicos y retornos futuros son potencialmente no lineales, cambiantes en el tiempo y de alta dimensionalidad.

Gu et al. (2020) ofrecen uno de los tratamientos empíricos más amplios sobre esta cuestión, mostrando que las redes neuronales, el *gradient boosting* y otros métodos no lineales superan a la regresión lineal en la predicción de rendimientos de acciones individuales. Su trabajo documenta que la ganancia predictiva del aprendizaje automático proviene precisamente de su capacidad para capturar interacciones complejas entre cientos de predictores, una tarea para la cual los modelos lineales están estructuralmente limitados. Sin embargo, esta mayor capacidad de representación conlleva un riesgo proporcional de sobreajuste, especialmente en datos financieros donde la relación señal-ruido es notoriamente baja. El desafío central no es simplemente maximizar la precisión en datos históricos, sino lograr que los patrones aprendidos generalicen a períodos futuros no observados.

Un hallazgo complementario de Zeng et al. (2023) resulta igualmente pertinente; un modelo simple de descomposición lineal (DLinear) supera a arquitecturas sofisticadas basadas en Transformers en múltiples *benchmarks* de pronóstico de series temporales. Este resultado, aparentemente paradójico, sugiere una lección relevante para la aplicación de aprendizaje automático en finanzas, esto es, la complejidad arquitectural no garantiza superioridad predictiva, y en contextos de baja relación señal-ruido, los modelos más parsimoniosos pueden exhibir mejor generalización al evitar la memorización de patrones espúreos. La tensión entre complejidad y generalización constituye, en última instancia, una pregunta empírica que solo puede resolverse mediante la evaluación sistemática de múltiples familias de modelos sobre los datos específicos del problema.

Estas consideraciones motivaron la decisión metodológica central de este estudio, a saber, evaluar un espectro amplio de 23 modelos que abarca desde técnicas lineales regularizadas hasta arquitecturas de *deep learning* de última generación. El propósito no es encontrar un único modelo *mejor*, sino descubrir qué tipo de relación captura mejor la señal predictiva en los retornos del S&P 500, es decir, si es lineal, no lineal, temporal o una combinación de ellas. Si esa señal es predominantemente lineal, los modelos regularizados deberían dominar; si involucra interacciones complejas entre predictores, los métodos de ensemble serán superiores; si depende de dependencias temporales a largo plazo, las arquitecturas recurrentes y de atención tendrán ventaja. Solo la

comparación transversal permite responder esta pregunta.

Los 23 modelos evaluados abarcan cuatro familias principales, organizadas en orden creciente de complejidad. La hipótesis nula del estudio es **SeasonalNaive** ($K=5$), un modelo sin parámetros aprendidos cuya predicción para cada día es simplemente el retorno observado hace una semana hábil ($\hat{y}_t = y_{t-5}$). Cualquier modelo que no supere esta referencia elemental no justifica su complejidad adicional, razón por la cual SeasonalNaive aparece destacado en todas las tablas de resultados.

Los **modelos estadísticos de series temporales** (Suavizado Exponencial, Theta, Prophet (Taylor & Letham, 2018) y GARCH (Bollerslev, 1986)) explotan la estructura temporal que los modelos transversales no capturan directamente, y su parsimonia los protege del sobreajuste, una ventaja documentada en competencias formales de pronóstico (Makridakis et al., 2018). GARCH modela la volatilidad condicional en lugar del nivel de retornos, capturando el agrupamiento de volatilidad, una de las regularidades más robustas en mercados financieros.

Los **modelos lineales regularizados** (Ridge (Hoerl & Kennard, 1970), Lasso (Tibshirani, 1996) y ElasticNet) constituyen la referencia más simple entre los modelos que aprovechan las 536 características; si una combinación lineal captura la señal disponible, recurrir a arquitecturas más complejas es potencialmente contraproducente. Con 536 predictores, la regularización cumple una función análoga a la diversificación, distribuyendo el riesgo de error entre múltiples fuentes de información.

Los **métodos de ensemble basados en árboles** (Random Forest (Breiman, 2001), Gradient Boosting (Friedman, 2001), XGBoost (Chen & Guestrin, 2016), LightGBM y CatBoost) capturan interacciones no lineales de manera natural al particionar el espacio de predictores, y existe evidencia creciente de su superioridad sobre redes neuronales en datos tabulares como los financieros.

Las **arquitecturas de deep learning** (LSTM (Hochreiter & Schmidhuber, 1997; Gers et al., 2000) y variantes bidireccionales, CNN-LSTM, LSTM con Atención (Vaswani et al., 2017), TFT (Lim et al., 2021), N-BEATS (Oreshkin et al., 2020), N-HiTS, TCN y DLinear) ofrecen la mayor capacidad de representación pero también el mayor riesgo de sobreajuste. La diversidad de subfamilias (recurrentes, basadas en atención, convolucionales y *feed-forward*) permite evaluar si alguna estructura temporal específica domina la señal predictiva o si la ventaja del *deep learning* es limitada en este contexto.

3. Datos y Metodología

En esta sección se describe el marco empírico del estudio en cuatro componentes. Primero, se detalla la construcción del conjunto de datos a partir de 92 variables financieras obtenidas de Bloomberg Terminal y el proceso sistemático de ingeniería de características que las transforma en 536 predictores. A continuación se define la variable objetivo y la división temporal de la muestra, se presentan las especificaciones de los 23 modelos evaluados, y se formaliza el sistema de posicionamiento que convierte predicciones continuas en decisiones discretas de inversión. La Figura 1 ofrece una vista panorámica del flujo metodológico completo, desde los datos de entrada hasta la validación estadística, que las subsecciones siguientes desarrollan en detalle.

TESIS · MAGÍSTER EN FINANZAS · DIAGRAMA DE FLUJO METODOLÓGICO

Pipeline Metodológico: Predicción y Estrategia Long-Only sobre el S&P 500




Figura 1: Pipeline metodológico del estudio, desde las 92 variables de Bloomberg hasta la validación estadística de los cuatro modelos con mayor retorno acumulado en el período de prueba.

3.1 Fuentes de Datos e Ingeniería de Características

3.1.1 Universo de Datos

El análisis emplea datos diarios obtenidos de Bloomberg Terminal para el período comprendido entre el 31 de enero de 2000 y el 11 de diciembre de 2025. El dataset resultante comprende 6,507 observaciones diarias.

El universo de variables base se compone de 92 series temporales organizadas en siete categorías temáticas, seleccionadas para capturar las múltiples dimensiones que la literatura ha identificado como relevantes para la predicción de retornos accionarios (Gu et al., 2020). Las 18 variables de índices y ETFs de mercado capturan flujos de capital entre regiones y sectores; las 19 de indicadores macroeconómicos recogen actividad real, empleo e inflación (Chen et al., 1986); las 20 de tasas de interés y curva de rendimiento abarcan la estructura temporal completa y *spreads* de crédito (Harvey, 1989; Fama & French, 1989); las 11 de *commodities* cubren energía, metales preciosos e índices amplios (Hong & Yogo, 2012); las 13 de volatilidad incluyen el VIX y su estructura temporal (Ang et al., 2006); y las 10 de sentimiento de mercado integran encuestas, ratios *put/call* y amplitud de mercado (Baker & Wurgler, 2006). El conjunto se completa con los datos OHLCV del SPY y la tasa libre de riesgo derivada del *T-Bill* a 3 meses. El Apéndice A presenta la descripción completa de cada categoría, su justificación teórica y las variables específicas que la componen.

3.1.2 Proceso de Construcción de Características

Las variables en bruto suelen requerir transformación antes de funcionar como predictores, ya que en su forma original ofrecen una representación estática del estado del mercado. Siguiendo la recomendación de Gu et al. (2020) sobre la utilidad de espacios amplios de características con regularización adecuada, se implementa un *pipeline* que transforma las 92 variables base en 536 predictores organizados en las familias que resume la Tabla 1, a saber, indicadores técnicos clásicos (RSI, MACD, Bollinger, etc.), *momentum* y retornos históricos a múltiples horizontes, análisis técnico avanzado (Ichimoku, Fibonacci, Donchian, flujo de dinero, confluencia estratégica), análisis multitemporal Triple Screen (Elder, 1993), estimadores de volatilidad OHLC (Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang y extensiones contemporáneas de Alizadeh et al. (2002) y Chou (2005)), relaciones *cross-asset* con condiciones macro y estructura temporal del VIX, y variables rezagadas con estadísticos móviles y transformaciones de factores de estilo. El Apéndice B describe cada familia en detalle.

El conjunto resultante constituye deliberadamente una representación *sobrecompleta*, dado que algunas variables capturan la misma dinámica bajo formulaciones distintas. Se opta por delegar la selección a los propios modelos, cuyos mecanismos internos gestionan la colinealidad, ya sea mediante penalizaciones L1/L2 en modelos regularizados, selección por ganancia de información en árboles de decisión, o *dropout* con capas de atención en redes neuronales, consistente con la evidencia de Gu et al. (2020). Todas las transformaciones operan sobre datos diarios mediante ventanas retrospectivas (*lookback windows*) que en cada día t utilizan exclusivamente observaciones disponibles hasta ese momento, $\{t - n, \dots, t - 1, t\}$, sin incorporar información futura.

3.1.3 Garantías contra Filtración de Información

La prevención de filtración de información futura (*data leakage*) se implementa en tres niveles (López de Prado, 2018). **Nivel 1** (división temporal estricta), donde la partición entrenamiento-prueba es cronológica (todo dato anterior a octubre 2020 es entrenamiento, todo dato posterior es prueba) sin aleatorización; la selección de hiperparámetros emplea *TimeSeriesSplit* con 5 particiones, preservando la causalidad temporal incluso durante la validación cruzada. **Nivel 2** (preprocesamiento sin contaminación), donde el escalado y la imputación se ajustan exclusivamente sobre el conjunto de entrenamiento mediante `fit_transform()`, aplicando los parámetros ya estimados al conjunto de prueba mediante `transform()` sin recalcularlos. **Nivel 3** (características retrospectivas), donde todas las transformaciones de la Sección 3.1 emplean funciones que miran hacia atrás (`pct_change()`, `rolling()`, `shift(n)` con $n > 0$); el único `shift(-1)` aparece en la construcción de la variable objetivo (Sección 3.2), donde define lo que el modelo debe predecir, no lo que puede observar.

3.1.4 Conjunto de Datos Resultante

En conjunto, el *pipeline* descrito transforma un universo de 92 variables financieras en bruto (que por sí solas ofrecen una representación estática del estado del mercado en cada día) en un espacio de características mucho más rico que captura dinámicas temporales (retornos, *momentum*, *lags*), relaciones entre activos (correlaciones *cross-asset*, dispersión sectorial), estados latentes del mercado (régimen, volatilidad, sentimiento) y la coherencia multitemporal del sistema Triple Screen. Cada observación diaria queda descrita no solo por el valor contemporáneo de las variables, sino también por su evolución reciente, su posición relativa respecto a su propia historia y su relación con otras dimensiones del mercado. Esta representación más amplia podría ayudar a los modelos, en particular a los de aprendizaje profundo, a captar patrones no lineales menos accesibles a partir de los datos originales.

Tras la eliminación de columnas con más del 50 % de valores faltantes, la sustitución de infinitos, la exclusión de filas con más del 50 % de valores faltantes en sus características y la eliminación de filas sin variable objetivo válida, el dataset final comprende 6,507 observaciones y 536 características. A estas se añaden las cinco series OHLCV crudas del SPY (apertura, máximo, mínimo, cierre y volumen), que se conservan como entradas directas a los modelos, de modo que el vector de entrada efectivo asciende a 541 columnas; dichos niveles se normalizan mediante el escalado por familia ajustado exclusivamente sobre el conjunto de entrenamiento. Los valores faltantes residuales, concentrados en las primeras filas por el calentamiento de las ventanas móviles y en variables con disponibilidad histórica parcial, se imputan durante el preprocesamiento específico de cada familia de modelos (Sección 3.3.1). La Tabla 1 presenta la composición por familia de transformación.

3.2 Variable Objetivo y División de Muestra

El objetivo de predicción es el **retorno en exceso** del S&P 500 sobre la tasa libre de riesgo

$$y_t = r_{t+1}^{SPY} - r_t^f \quad (1)$$

donde $r_{t+1}^{SPY} = P_{t+1}/P_t - 1$ es el retorno del SPY y r_t^f la tasa diaria derivada del *T-Bill* a 3 meses. El retorno en exceso aísla la prima de riesgo (la remuneración por soportar incertidumbre), de

Tabla 1: Composición del Espacio de Características por Familia de Transformación

Familia de Transformación	Características
Indicadores técnicos (TA-Lib)	19
<i>Momentum</i> y retornos históricos	30
Volumen	2
Análisis multitemporal (Triple Screen)	24
Volatilidad OHLC clásica ^a	8
Volatilidad contemporánea ^b	54
Microestructura	19
Correlaciones <i>cross-asset</i>	10
VIX y estructura temporal	10
Curva de rendimiento y crédito	13
Dispersión sectorial	5
Indicadores macroeconómicos	21
Régimen de mercado e interacciones	7
Variables rezagadas (<i>lags</i>)	54
Estadísticos móviles (<i>rolling</i>)	24
Análisis técnico avanzado ^c	60
Transformaciones y extensiones adicionales ^d	176
Total	536

^aParkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang. ^bEntropía Intrínseca (5), Log-Range (20), CARR (13), Range-GARCH (16). ^cIchimoku (13), Fibonacci (18), Donchian (8), Keltner (3), flujo de dinero (8), confluencia estratégica (10). ^dIncluye factores Value/Growth/Size, transformaciones de variables macro y de tasas (cambio porcentual, momentum), características VIX extendidas, variables base residuales y microestructura avanzada.

modo que $\hat{y}_t > 0$ indica que el mercado compensará el riesgo y $\hat{y}_t \leq 0$ sugiere permanecer en efectivo, lo cual se traduce naturalmente en la decisión de inversión del sistema.

La construcción del vector objetivo emplea `shift(-1)`, el único desplazamiento temporal hacia el futuro en todo el sistema, para ubicar en la fila t el retorno que se materializará entre t y $t+1$. De este modo, cada fila contiene características disponibles hasta t y el retorno en exceso del día siguiente como variable a predecir, y el modelo aprende $\hat{y}_t = f(\mathbf{X}_t)$.

Definida la variable objetivo, la muestra se divide de forma estrictamente cronológica y sin aleatorización para aproximar una evaluación fuera de muestra, con entrenamiento de enero 2000 a septiembre 2020 (5,205 días, 80 %) y prueba de octubre 2020 a diciembre 2025 (1,302 días, 20 %). El período de prueba abarca la recuperación post-COVID, el endurecimiento monetario de 2022–2023, un mercado bajista (−25 % en el S&P 500), y el posterior rally impulsado por inteligencia artificial, proporcionando diversidad de regímenes que prueba la capacidad de generalización.

3.3 Especificaciones de Modelos

Se implementan 23 modelos que abarcan cuatro familias metodológicas, a saber, aprendizaje automático clásico (4), *boosting* (4), series temporales (6) y *deep learning* (9). AutoARIMA, si bien pertenece a la familia de series temporales, permanece en efectivo el 100 % del período, ya que el filtro de calidad de señal clasifica sus predicciones como degeneradas. Esta sección no describe la teoría detrás de cada algoritmo (disponible en la bibliografía de referencia), sino las decisiones de implementación, es decir, cómo se preprocesaron los datos para cada familia, cómo se seleccionaron los hiperparámetros y qué produce cada modelo como salida.

3.3.1 Preparación de Datos para Entrenamiento

Todos los modelos reciben las mismas 536 características, con excepción de los univariados que operan exclusivamente sobre la serie de retornos en exceso. Los valores faltantes residuales, que representan aproximadamente el 3 % del total, se imputan por mediana en los modelos tabulares y de PyTorch, y mediante *forward fill* en los modelos Darts. Cada familia recibe los datos con el preprocesamiento que su arquitectura requiere para producir gradientes informativos y predicciones comparables; en todos los casos, los escaladores se ajustan exclusivamente sobre datos de entrenamiento y las predicciones se revierten a la escala original antes de la evaluación. El Apéndice C.1 detalla el esquema específico por familia.

3.3.2 Modelos Tabulares con Validación Cruzada

Los ocho modelos de ML clásico y *boosting* se implementan dentro de un esquema unificado de selección de hiperparámetros. Para cada modelo se define una grilla de valores candidatos para sus parámetros principales, a saber, el coeficiente de regularización en los modelos lineales, la profundidad máxima y número de estimadores en los modelos de ensamble, y la [tasa de aprendizaje](#) en los métodos de *boosting*. La búsqueda de la combinación óptima se realiza mediante *GridSearchCV* con *TimeSeriesSplit* de cinco particiones, preservando el orden temporal en cada partición de validación cruzada. El criterio de selección es el error cuadrático medio.

Una vez entrenado, cada modelo genera predicciones sobre dos períodos. Las predicciones *out-of-sample* del conjunto de prueba (2020–2025) son las que se utilizan para evaluar el rendimiento real del modelo. Las predicciones *in-sample* del conjunto de entrenamiento (2000–2020) no se usan para evaluar, dado que el modelo ya observó esos datos durante el entrenamiento, sino para inicializar el sistema de percentiles *rolling* descrito en la Sección 3.4, ya que dicho sistema requiere una ventana de 63 predicciones previas para calcular el percentil del primer día de prueba; las predicciones de entrenamiento proveen esa historia inicial.

3.3.3 Modelos Univariados de Series Temporales

Seis modelos se entrenan exclusivamente sobre la serie del retorno en exceso, sin utilizar las 536 características, para examinar una pregunta metodológica relevante, *¿aportan las características cross-asset y macroeconómicas información predictiva más allá de lo que la propia serie ya contiene?*

Entre ellos, **SeasonalNaive** ($K=5$) cumple el rol de *benchmark* de complejidad mínima del estudio. Su funcionamiento es elemental; para cada día t , la predicción es simplemente el retorno observado hace cinco días hábiles ($\hat{y}_t = y_{t-5}$), sin parámetros aprendidos, sin optimización y sin acceso a ninguna variable externa. Un modelo que no logra superar a SeasonalNaive difícilmente justificaría su complejidad adicional, ya que esta no se traduciría en mejor desempeño. El contraste entre este *benchmark* y los modelos más complejos ofrece una referencia para estimar en qué medida la complejidad adicional aporta desempeño.

Los demás modelos de esta familia son ExponentialSmoothing, que captura nivel y tendencia con pesos exponencialmente decrecientes; Theta, que descompone la serie en componentes de largo y corto plazo; Prophet (Taylor & Letham, 2018), que modela componentes aditivos de tendencia y estacionalidad; GARCH (Bollerslev, 1986), que modela la volatilidad condicional como proceso autorregresivo; y AutoARIMA, con selección automática de órdenes (p, d, q), que sin embargo permanece en efectivo el 100 % del tiempo porque el filtro de calidad clasifica sus

predicciones como degeneradas, dado que la desviación estándar de las mismas (3.9×10^{-5}) es inferior al umbral mínimo requerido (10^{-3}). Las predicciones *in-sample* se generan mediante *historical forecasts* un paso adelante sin reentrenamiento.

3.3.4 Modelos de Deep Learning

Los nueve modelos se dividen en dos grupos. Los **Darts Deep Learning** (DLinear, N-BEATS, N-HiTS, TCN, TFT) reciben la serie objetivo escalada y las 536 covariables pasadas, procesando ventanas de 30 días para generar predicciones un paso adelante, con 100 épocas máximas y lotes de 32 observaciones. Los **PyTorch Custom** (CNN-LSTM, LSTM+Attention, BiLSTM, BiGRU) se implementan directamente en PyTorch; CNN-LSTM combina capas convolucionales con recurrentes; LSTM+Attention añade atención estilo Luong sobre un LSTM bidireccional; BiLSTM y BiGRU son variantes bidireccionales. Todos emplean el optimizador Adam (Kingma & Ba, 2015), error cuadrático medio como función de pérdida, *dropout* como regularización y semilla 42 para reproducibilidad. El Apéndice C detalla los hiperparámetros de cada modelo.

3.3.5 Implementación Computacional

El entrenamiento se ejecuta mediante un *pipeline* secuencial de tres etapas, (1) construcción del dataset, (2) entrenamiento de modelos, y (3) optimización de umbrales y *backtesting* final con costos, combinadas estas dos últimas en un único *script*. El cómputo se realizó en una instancia EC2 de Amazon Web Services; las especificaciones del entorno y la configuración de software se detallan en el Apéndice C.10.

3.4 Estrategia de Inversión

3.4.1 Conversión de Predicciones en Posiciones Discretas

Independientemente de su arquitectura, cada uno de los 23 modelos produce una predicción continua $\hat{y}_t$ del retorno en exceso para cada día t del período de prueba. Estas predicciones son valores continuos cuya escala varía entre modelos, lo que impide aplicar umbrales absolutos. Para normalizar esta heterogeneidad, cada predicción se compara con las predicciones recientes del mismo modelo mediante un *percentil rolling* sobre una ventana de 63 días. Formalmente

$$\text{percentil}_t = \frac{n_t}{N} \times 100 \quad (2)$$

donde $N = 63$ y n_t es el número de predicciones en la ventana $W_t = \{\hat{y}_{t-62}, \dots, \hat{y}_t\}$ menores o iguales a $\hat{y}_t$; un percentil de 90 indica que el modelo es inusualmente optimista respecto a su comportamiento reciente, independientemente de su escala. Para el primer día de prueba, la ventana se inicializa con predicciones del entrenamiento (*warmup*). El percentil se mapea a una posición discreta

$$\text{posición}_t = \begin{cases} +3 \text{ (UPRO)} & \text{si } \text{percentil}_t \geq 100 - q_{\text{extreme}} \\ +1 \text{ (SPY)} & \text{si } 100 - q_{\text{moderate}} \leq \text{percentil}_t < 100 - q_{\text{extreme}} \\ 0 \text{ (Cash)} & \text{si } \text{percentil}_t < 100 - q_{\text{moderate}} \end{cases} \quad (3)$$

Conviene precisar que q_{extreme} y q_{moderate} no son percentiles en sí mismos, sino el tamaño de la franja superior de percentiles que activa cada posición, de modo que el umbral efectivo es $100 - q$.

Así, con $q_{\text{extreme}} = 5$ solo el 5 % de predicciones más optimistas del modelo, aquellas cuyo percentil *rolling* alcanza o supera 95, justifica la posición apalancada, mientras que con $q_{\text{moderate}} = 50$ la posición en SPY se abre a la mitad superior (percentil ≥ 50); valores menores de q vuelven la estrategia más selectiva y valores mayores, más permisiva. La estrategia opera exclusivamente *Long-Only*, con posición +3 mediante UPRO (ETF apalancado 3x) para convicción alta, +1 mediante SPY para convicción moderada, y efectivo cuando la convicción es insuficiente. No se toman posiciones cortas dado el sesgo alcista histórico del mercado (aproximadamente un 7 % anual).

3.4.2 Optimización de Umbrales por Modelo

Los umbrales q_{extreme} y q_{moderate} no pueden ser universales, dado que cada modelo genera predicciones con distribución y precisión distintas. Optimizarlos sobre el período de prueba constituiría *data snooping* (López de Prado, 2018). La solución adoptada consiste en un *metamodelo KNN* ($K=5$, ponderado por distancia inversa) que, para cada día del período de prueba, identifica los cinco episodios históricos en los que el modelo se comportó de manera más similar al momento presente y aplica los umbrales que mejor funcionaron en dichos episodios, utilizando exclusivamente información del período de entrenamiento.

El procedimiento consta de tres fases. En la **Fase 1** se construye, utilizando únicamente datos de entrenamiento, la base de conocimiento que después permitirá reconocer situaciones parecidas. Para ello se recorren las predicciones del modelo con dos ventanas consecutivas de 63 días que avanzan juntas en pasos de 21 días, cada una con un papel distinto. La primera ventana describe cómo se ha comportado el modelo en ese tramo, resumiendo sus predicciones recientes en siete *meta-features*

$$\mathbf{f}_w = (\bar{y}_w, \sigma_{\hat{y},w}, \gamma_{\hat{y},w}, \rho_{\hat{y},w}, \beta_{\hat{y},w}, \bar{\sigma}_{m,w}, R_{m,w}) \quad (4)$$

que capturan el régimen predictivo del modelo (media, volatilidad, asimetría, autocorrelación y tendencia de las predicciones) junto con el contexto de mercado (volatilidad promedio y retorno acumulado). La segunda ventana, que cubre los 63 días siguientes, mide qué umbrales habrían funcionado mejor, dado que sobre ella se ejecuta la estrategia completa con cada una de las 26 combinaciones válidas ($q_{\text{ext}} \in \{5, \dots, 30\}$, $q_{\text{mod}} \in \{20, \dots, 60\}$, $q_{\text{mod}} > q_{\text{ext}}$) y se retiene la que maximiza el *Sharpe* penalizado por *drawdown*. Cada posición de este par de ventanas genera así un ejemplo etiquetado que vincula un perfil de comportamiento del modelo, dado por las *meta-features* de la primera ventana, con los umbrales que mejor le funcionaron justo después, de modo que el recorrido completo del período de entrenamiento produce alrededor de 242 ejemplos por modelo.

En la **Fase 2** se entrena el clasificador KNN sobre ese conjunto de ejemplos, de modo que aprende a asociar cada perfil de comportamiento con sus umbrales óptimos. En la **Fase 3**, ya durante el período de prueba, el sistema opera día a día, calcula el perfil vigente del modelo a partir de sus 63 predicciones más recientes, y el KNN recupera los cinco perfiles históricos más parecidos para devolver los umbrales que resultaron óptimos en ellos. De esta manera, los umbrales se adaptan a las condiciones de cada día sin que ningún dato del período de prueba intervenga en el entrenamiento del metamodelo. El Apéndice D detalla el espacio de búsqueda, la función objetivo y los parámetros resultantes.

Adicionalmente, el sistema incorpora un filtro de calidad que detecta modelos cuyas pre-

dicciones son prácticamente constantes, dado que en esos casos los percentiles responden a ruido numérico en lugar de señal genuina. Si la desviación estándar *rolling* de las últimas 63 predicciones es inferior a $\tau = 0,001$, la posición se establece en efectivo independientemente de los umbrales. Los modelos con predicciones ricas (LSTM+Attention, CNN-LSTM) superan este umbral el 100 % de los días; en contraste, AutoARIMA (0 %), Theta (4,7 %) y GradientBoosting (13,7 %) permanecen mayoritariamente en efectivo. La Tabla 2 resume los umbrales resultantes y la distribución de posiciones de los cuatro modelos que registran el mayor retorno acumulado.

Tabla 2: Características Dinámicas y Distribución de Posiciones de los Cuatro Modelos con Mayor Retorno Acumulado

Modelo	$(q_{\text{ext}}, q_{\text{mod}})^*$	Combos	%Frec.	%UPRO	%SPY	%Cash
LSTM+Attention	(5, 50)	22	26.5	12.2	32.7	55.1
Ridge	(20, 30)	21	47.4	20.8	17.0	62.3
RandomForest	(5, 40)	4	83.9	5.2	16.9	77.9
CNN-LSTM	(20, 40)	18	24.9	12.1	28.6	59.3

Nota: $(q_{\text{ext}}, q_{\text{mod}})^*$ es la combinación de umbrales más frecuente seleccionada por el Meta-KNN. “Combos” indica el número de combinaciones distintas utilizadas durante los 1,302 días de prueba, y %Frec. el porcentaje de días en que se aplicó la combinación más frecuente. %UPRO/SPY/Cash indica la proporción del período en cada posición.

3.4.3 Modelo de Costos

Los retornos de la estrategia incorporan tres fuentes de costos reales que reflejan las fricciones de implementación, a saber, los *expense ratios* de cada ETF, los *spreads bid-ask* en cada operación de compra y venta, y el *volatility drag* de los ETFs apalancados. El análisis completo del impacto de costos se presenta en la Sección 5.3.

El retorno diario neto de la estrategia se calcula mediante la siguiente expresión.

$$r_t^{\text{estrategia}} = r_t^f + \text{posición}_t \times (r_t^{\text{SPY}} - r_t^f) - \text{costos}_t \quad (5)$$

donde r_t^f es la tasa libre de riesgo diaria, r_t^{SPY} el retorno del mercado, $\text{posición}_t \in \{0, 1, 3\}$ el grado de exposición, y costos_t la suma del *expense ratio* diario, los costos de transacción (si hubo cambio de posición) y el *volatility drag* (si la posición es apalancada). Con posición 0 la estrategia obtiene la tasa libre de riesgo; con posición 1 replica el retorno del SPY; con posición 3 triplica la exposición al retorno en exceso, amplificando tanto ganancias como pérdidas.

4. Resultados Empíricos

En esta sección se presentan los resultados del *backtesting* de los 23 modelos durante el período de prueba (octubre 2020 a diciembre 2025, 1,302 días de *trading*).

4.1 Rendimiento General

La Tabla 3 presenta las métricas de rendimiento completas para los 23 modelos evaluados.

Cuatro de veintitrés modelos superan al *benchmark* SPY Buy & Hold (+101.3 %), a saber, LSTM+Attention (+395 %), Ridge (+253 %), RandomForest (+128 %) y CNN-LSTM (+122 %). La arquitectura con mecanismo de atención (LSTM+Attention) obtiene el mejor rendimiento

Tabla 3: Rendimiento de los 23 Modelos en el Período de Prueba (Oct 2020 - Dic 2025)

Rank	Modelo	Categoría	Ret. Total	Ret. Anual	Sharpe	Max DD
1	LSTM_Attention	Deep learning	395.4 %	36.3 %	1.319	20.5 %
2	Ridge	ML clásico	252.5 %	27.6 %	0.856	31.8 %
3	RandomForest	ML clásico	127.5 %	17.3 %	0.651	15.0 %
4	CNN_LSTM	Deep learning	122.2 %	16.7 %	0.572	35.9 %
5	DLinear	Deep learning	67.7 %	10.5 %	0.425	33.4 %
6	GradientBoosting	Boosting	66.3 %	10.4 %	0.617	8.3 %
7	CatBoost	Boosting	46.0 %	7.6 %	0.221	31.4 %
8	Theta	Series temporales	44.4 %	7.4 %	0.560	12.6 %
9	NBEATS	Deep learning	43.9 %	7.3 %	0.178	25.2 %
10	SeasonalNaive [†]	Series temporales	43.0 %	7.2 %	0.142	33.6 %
11	Lasso	ML clásico	37.7 %	6.4 %	0.190	19.5 %
12	GARCH	Series temporales	26.6 %	4.7 %	0.188	22.1 %
13	LightGBM	Boosting	25.5 %	4.5 %	0.088	24.4 %
14	NHiTS	Deep learning	21.4 %	3.8 %	0.031	48.3 %
15	AutoARIMA [‡]	Series temporales	18.3 %	3.3 %	0.387	0.0 %
16	TCN	Deep learning	18.0 %	3.3 %	0.000	35.0 %
17	TFT	Deep learning	13.5 %	2.5 %	-0.028	45.2 %
18	Prophet	Series temporales	7.8 %	1.5 %	-0.230	11.7 %
19	ElasticNet	ML clásico	7.8 %	1.5 %	-0.085	40.4 %
20	XGBoost	Boosting	7.1 %	1.3 %	-0.060	45.7 %
21	BiLSTM	Deep learning	4.9 %	0.9 %	-0.091	55.1 %
22	ExponentialSmoothing	Series temporales	-15.4 %	-3.2 %	-0.241	60.3 %
23	BiGRU	Deep learning	-33.2 %	-7.5 %	-0.467	59.0 %
–	SPY (B&H)	Benchmark	101.3 %	–	0.657	25.4 %

Nota: Los modelos en negrita superan al benchmark SPY Buy & Hold. [†]SeasonalNaive = *benchmark* de complejidad mínima. [‡]AutoARIMA permanece el 100 % del período en efectivo (filtro de calidad de señal), por lo que su retorno corresponde a la tasa libre de riesgo y su Sharpe, calculado sobre una volatilidad casi nula (0.14 %), no es comparable con el de los modelos con operación activa. Retorno total calculado como producto de $(1+r)$ - 1 sobre el período completo. Sharpe ratio anualizado con tasa libre de riesgo promedio del período.

tanto en términos absolutos como ajustados por riesgo, mientras que la arquitectura híbrida convolucional-recurrente (CNN-LSTM) también supera al *benchmark*, si bien con un retorno inferior, lo que sugiere que estas arquitecturas capturan dependencias temporales en los retornos del S&P 500 que los modelos más simples no logran explotar.

La variabilidad entre modelos es significativa, dado que los retornos totales abarcan un rango de 429 puntos porcentuales, desde el +395 % de LSTM+Attention hasta el -33 % de BiGRU. No obstante, 16 de 23 modelos logran un *Sharpe ratio* positivo, lo que indica retornos ajustados por riesgo positivos en la mayoría de los casos, aunque solo cuatro alcanzan el alfa necesario para superar al *benchmark* pasivo.

La Tabla 4 sintetiza las métricas principales de los cuatro modelos ganadores frente a los *benchmarks*.

Tabla 4: Resumen Ejecutivo: Top 5 Modelos vs Benchmark

Modelo	Ret. Total	Sharpe	Max DD	Capital Final	α vs SPY
LSTM_Attention	395.4 %	1.319	20.5 %	\$49,538	294.1 %
Ridge	252.5 %	0.856	31.8 %	\$35,254	151.2 %
RandomForest	127.5 %	0.651	15.0 %	\$22,749	26.2 %
CNN_LSTM	122.2 %	0.572	35.9 %	\$22,222	20.9 %
DLinear	67.7 %	0.425	33.4 %	\$16,771	-33.6 %
SPY (B&H)	101.3 %	0.657	25.4 %	\$20,131	—

Nota: Período de prueba: Oct 2020 a Dic 2025 (1,302 días). Capital inicial: \$10,000. α = exceso de retorno sobre SPY Buy & Hold.

4.2 Análisis por Familia de Modelos

La Tabla 5 agrupa los 23 modelos por familia metodológica.

Tabla 5: Rendimiento Promedio por Categoría de Modelo

Categoría	N	Ret. Prom.	Mejor Ret.	Sharpe Prom.	Mejor Modelo
ML clásico	4	106.4 %	252.5 %	0.403	Ridge
Deep learning	9	72.6 %	395.4 %	0.215	LSTM_Attention
Boosting	4	36.2 %	66.3 %	0.217	GradientBoosting
Series temporales	6	20.8 %	44.4 %	0.134	Theta

Nota: N = número de modelos en la categoría. ML clásico = Ridge/Lasso/ElasticNet/RandomForest; Boosting = GradientBoosting (sklearn) y las librerías XGBoost/LightGBM/CatBoost; Series temporales = AutoARIMA/ETS/Theta/SeasonalNaive/Prophet/GARCH; Deep learning = redes Darts (DLinear/N-BEATS/N-HiTS/TCN/TFT) y arquitecturas *custom* en PyTorch (CNN-LSTM/LSTM+Attention/BiLSTM/BiGRU).

Dentro del **ML clásico**, Ridge destaca con un retorno del +253 % y un Sharpe de 0.86, posicionándose como el segundo mejor modelo del estudio, y RandomForest (+128 %, Sharpe 0.65) constituye el otro integrante de esta familia que supera al *benchmark*, ambos analizados con mayor detalle en las secciones de gestión de riesgo y validación estadística. Lasso (+38 %) y ElasticNet (+8 %), en cambio, presentan un rendimiento marcadamente inferior, lo que sugiere que la regularización L_1 , que fuerza coeficientes a cero, resulta demasiado agresiva para este problema, eliminando predictores que contienen señal útil. La penalización L_2 de Ridge, que

contrae los coeficientes sin eliminarlos, se adapta mejor a un espacio de 536 características donde la señal está distribuida entre múltiples predictores.

En la categoría de **boosting**, GradientBoosting lidera con un retorno del +66 % y un Sharpe de 0.62, destacándose además por el menor *drawdown* máximo de todo el estudio entre los modelos con operación activa (8.3 %), si bien la baja variabilidad de sus predicciones (apenas 16 valores únicos) lo mantiene filtrado en efectivo el 86 % del tiempo. Le siguen CatBoost (+46 %, Sharpe 0.22), LightGBM (+25 %) y XGBoost (+7 %). Ninguno de los cuatro supera al *benchmark*, lo que indica que los umbrales dinámicos del Meta-KNN resultan menos efectivos para estos modelos basados en árboles cuando sus predicciones presentan baja variabilidad, dado que XGBoost, por ejemplo, genera apenas 26 valores únicos y permanece filtrado el 62 % del tiempo, lo que degrada la calidad de la señal de posicionamiento.

Los modelos de **deep learning implementados en Darts** exhiben un rendimiento inferior al esperado dada su complejidad arquitectural. DLinear obtiene el mejor resultado de la subcategoría con +68 %, seguido por NBEATS (+44 %), NHiTS (+22 %) y TCN (+18 %). TFT (+14 %), pese a incorporar atención temporal, parece no traducir su complejidad arquitectural en rendimiento práctico en este período, un resultado consistente con la observación de Zeng et al. (2023) sobre el mejor rendimiento de modelos simples en ciertos contextos de pronóstico.

En contraste, las **arquitecturas híbridas y de atención implementadas en PyTorch** ocupan las posiciones más altas del *ranking* general. El modelo LSTM+Attention alcanza un retorno del +395 % con un Sharpe de 1.32 y un *drawdown* máximo del 20.5 %, mientras que CNN-LSTM obtiene +122 % con un Sharpe de 0.57 y un *drawdown* del 35.9 %. BiLSTM (+5 %) y BiGRU (−33 %), si bien bidireccionales, logran rendimientos marcadamente inferiores, lo que sugiere que el mecanismo de atención, más que la bidireccionalidad, es el componente arquitectural determinante.

Finalmente, las **series temporales y modelos univariados especializados** presentan un rendimiento modesto en general. Dentro de esta familia, Theta (+45 %) es el único modelo que supera, y solo de forma marginal, al *benchmark* de complejidad mínima del estudio, SeasonalNaive (+43 %), mientras que GARCH (+27 %), Prophet (+8 %) y ExponentialSmoothing (−15 %) quedan por debajo de esa referencia elemental sin parámetros, lo que sugiere que la sofisticación de estos modelos univariados aporta poco frente a una regla ingenua. Este último registra uno de los dos retornos negativos del estudio (junto con BiGRU), sugiriendo que los modelos univariados carecen de la información necesaria para generar alfa consistente en este contexto. AutoARIMA, por su parte, permanece el 100 % del período en efectivo debido al filtro de calidad de señal, de modo que su retorno (+18 %) refleja únicamente la acumulación de la tasa libre de riesgo.

4.3 Dinámica de la Estrategia

La Figura 2 muestra patrones diferenciados entre los modelos líderes. El modelo LSTM+Attention presenta la trayectoria más estable del grupo, con retrocesos contenidos durante los episodios de estrés, alcanzando un *drawdown* máximo del 20.5 %. Ridge ocupa la segunda posición con buena estabilidad, seguido por RandomForest (15.0 % de *drawdown*, el menor del grupo) y CNN-LSTM. Los cuatro modelos finalizan el período por encima del SPY, si bien su posición relativa varía a lo largo del trayecto y las diferencias se consolidan sobre todo hacia el tramo final.

Detrás de esas trayectorias hay distribuciones de posiciones notablemente distintas entre




Figura 2: Curvas de *equity* de los cinco mejores modelos vs SPY Buy & Hold (oct. 2020 a dic. 2025, capital inicial \$10,000).

modelos, como muestra la Tabla 34. LSTM+Attention distribuye su tiempo entre UPRO (12.2%), SPY (32.7%) y efectivo (55.1%), lo que refleja una estrategia selectiva que combina exposición apalancada en momentos de alta convicción con posiciones moderadas cuando la señal es menos intensa. En contraste, modelos como ExponentialSmoothing mantienen exposición casi permanente (72% del tiempo), mientras que AutoARIMA permanece 100% en efectivo.

Ese comportamiento selectivo se refleja también en las estadísticas de operación que resume la Tabla 35. LSTM+Attention presenta un *profit factor* de 1.52 (el más alto del grupo), con ganancias promedio de +1.5% y pérdidas de -1.2% por *trade*, lo que contribuye a la asimetría positiva visible en la Figura 5. RandomForest mantiene un *win rate* del 52.8% con solo 175 *trades*, consistente con su posicionamiento conservador.

4.4 Comparación con Estrategias de Referencia Alternativas

La Tabla 36 compara los modelos ganadores contra *benchmarks* alternativos. Frente a la retención pasiva de UPRO 3x (+123%, *drawdown* -69.0%), LSTM+Attention registra un retorno mayor (+395%), un *drawdown* de -20.5% y un Sharpe de 1.32 frente a 0.26, sugiriendo que la selección temporal de la exposición apalancada genera un perfil cualitativamente diferente al de la retención pasiva del ETF 3x. Los cuatro modelos finalizan asimismo por encima del portafolio 60/40 (+71%) y del SPY en retorno total acumulado.

4.5 La Paradoja del *Directional Accuracy*

En los datos analizados se observa una desconexión entre el *Directional Accuracy* (DA), la métrica más usada para evaluar predicciones de dirección, y la rentabilidad, de modo que el DA no resulta un predictor confiable del rendimiento de una estrategia.

4.5.1 Discrepancia entre Precisión Direccional y Rentabilidad

Intuitivamente, un modelo que acierta más la dirección del mercado debería generar mayores retornos. Los resultados, sin embargo, no se alinean con esta expectativa.

$$\rho(\text{DA}, \text{Return}) = -0.37 \quad (6)$$

La correlación entre *Directional Accuracy* y retorno total, computada sobre los 23 modelos y de carácter ilustrativo dado el tamaño muestral reducido, es moderadamente negativa, lo que sugiere que modelos con mayor DA no generan necesariamente mejores retornos.

La Tabla 6 presenta casos ilustrativos de esta paradoja.

Tabla 6: Paradoja DA vs Retorno: Casos Ilustrativos

Modelo	DA General	Retorno Total	Categoría
GARCH	54.3 %	+26.6 %	Alto DA, Retorno Modesto
Theta	54.6 %	+44.4 %	Alto DA, Retorno Modesto
ExponentialSmoothing	51.3 %	-15.4 %	Alto DA, Retorno Negativo
LSTM+Attention	47.0 %	+395 %	DA Bajo, Mejor Retorno
Ridge	46.8 %	+253 %	DA Bajo, Alto Retorno
CNN-LSTM	45.5 %	+122 %	DA Bajo, Alto Retorno

Nota: DA calculado como porcentaje de días donde la predicción de dirección coincide con el movimiento realizado del mercado.




Figura 3: La Paradoja del *Directional Accuracy*. Panel izquierdo: *Scatter plot* de DA vs Retorno Total mostrando correlación negativa ($\rho = -0.37$). Panel derecho: Comparación de DA General vs DA@3x (*hit rate* en posiciones apalancadas) para modelos seleccionados. Los retornos se indican sobre cada par de barras.

La Figura 3 ilustra gráficamente esta relación inversa entre precisión direccional y rentabilidad.

4.5.2 Factores de Rentabilidad no Capturados por el Directional Accuracy

El DA asigna el mismo peso a cada predicción, sin distinguir entre la magnitud del movimiento, el tamaño de la posición o el momento del ciclo de mercado. El siguiente ejemplo ilustra esta limitación.

Día	Movimiento	Predicción	Resultado
1	Mercado +0.1 %	Correcta	✓
2	Mercado +0.1 %	Correcta	✓
3	Mercado −3.0 %	Incorrecta	✗

DA = 66.7 % (2/3 aciertos), pero el P&L acumulado es **negativo**, dado que la pérdida del día 3 (−3.0 %) supera las ganancias combinadas de los días 1 y 2 (+0.2 %).

La rentabilidad de una estrategia de *trading* depende de tres factores que el DA no captura. En primer lugar, *cuándo* se acierta, dado que acertar en días de movimientos grandes importa más que acertar en días tranquilos, ya que el P&L se determina por la magnitud del movimiento, no por haber acertado la dirección. En segundo lugar, *cuánto* se expone, ya que el tamaño de la posición cuando se acierta frente al tamaño cuando se falla determina la contribución neta de cada predicción al resultado. En tercer lugar, la asimetría entre ganancias y pérdidas, donde el ratio entre la ganancia promedio y la pérdida promedio por *trade* (*Profit Factor*) puede compensar una tasa de aciertos moderada si las ganancias son sustancialmente mayores que las pérdidas.

4.5.3 Definición del Indicador DA@3x

Se propone el indicador **DA@3x** (*Directional Accuracy* en posiciones apalancadas) como una métrica que podría resultar más informativa sobre la rentabilidad en este contexto.

$$DA@3x = \frac{\sum_{t=1}^T \mathbf{1}[\text{pos}_t = 3 \wedge r_t^{\text{mkt}} > 0]}{\sum_{t=1}^T \mathbf{1}[\text{pos}_t = 3]} \quad (7)$$

donde $\mathbf{1}[\cdot]$ es la función indicadora, pos_t es la posición asignada en el día t y r_t^{mkt} es el retorno del mercado en ese día. El numerador cuenta los días en los que el modelo mantiene la posición apalancada máxima (UPRO, 3x) y el mercado efectivamente sube; el denominador cuenta el total de días en posición 3x. Así, el DA@3x mide exclusivamente la precisión del modelo en sus decisiones de mayor convicción, es decir, aquellas en las que la exposición y, por tanto, el impacto sobre el portafolio son máximos. La Tabla 7 compara ambas métricas para los modelos más representativos.

Tabla 7: Comparación entre DA General y DA@3x por modelo

Modelo	DA General	DA@3x	% Tiempo 3x	Retorno
LSTM+Attention	47.0 %	62.3 %	12.2 %	+395 %
Ridge	46.8 %	58.5 %	20.8 %	+253 %
RandomForest	45.9 %	51.5 %	5.2 %	+128 %
CNN-LSTM	45.5 %	58.6 %	12.1 %	+122 %
GARCH	54.3 %	63.6 %	1.7 %	+26.6 %
Theta	54.6 %	53.3 %	2.3 %	+44.4 %

Nota: DA@3x = hit rate cuando el modelo está en posición 3x (UPRO). % Tiempo 3x indica qué fracción del período el modelo estuvo en posición apalancada.

En esta muestra, los modelos con mejor rendimiento comparten tres características interrelacionadas. En primer lugar, exhiben un DA@3x superior a su DA general; LSTM+Attention

registra un 47.0 % de DA general pero un 62.3 % de DA@3x, lo que indica que, en el período de prueba, su tasa de aciertos es mayor cuando asume mayor exposición. En segundo lugar, son selectivos en el uso del apalancamiento; LSTM+Attention reserva la posición 3x para el 12.2 % del tiempo, activándola cuando las predicciones alcanzan los percentiles más extremos. En tercer lugar, permanecen en efectivo cuando la señal del modelo no alcanza los umbrales requeridos para tomar posición, un 55 % del tiempo en el caso de LSTM+Attention. En contraste, GARCH presenta un DA@3x del 63.6 % (el más alto del estudio), pero apenas asigna la posición 3x el 1.7 % del tiempo, lo que limita su capacidad de generar retornos, a pesar de una precisión condicional alta sobre un número reducido de observaciones. Theta (54.6 % DA general vs 53.3 % DA@3x) ejemplifica el caso opuesto, donde su precisión direccional se concentra en movimientos de mercado de pequeña magnitud que no compensan los errores en los días críticos.

4.5.4 Implicaciones para el Diseño de Estrategias

Este hallazgo tiene implicaciones directas para el diseño de estrategias, dado que optimizar un modelo para maximizar el DA puede resultar contraproducente, ya que favorece modelos que aciertan frecuentemente en movimientos pequeños a costa de fallar en los días de mayor impacto. Resulta preferible evaluar los modelos mediante métricas que capturen la asimetría condicional, como el *Sharpe Ratio*, el *Profit Factor* o el DA@3x propuesto en este estudio. El caso de LSTM+Attention resulta ilustrativo, ya que su DA general del 47.0 % lo descalificaría bajo evaluaciones convencionales, pero su DA@3x del 62.3 % y su permanencia en efectivo el 55 % del tiempo coinciden con el retorno más alto del estudio (+395 %), lo que sugiere que la rentabilidad observada se asocia más con la concentración de aciertos en momentos de alta asimetría que con su frecuencia.

5. Análisis de Robustez

Los resultados documentados en la sección anterior plantean tres interrogantes que conviene resolver antes de interpretar su alcance. La primera es si los mayores retornos registrados encubren una exposición desproporcionada al riesgo; la segunda, si la diferencia observada podría atribuirse al azar, dado el número de especificaciones evaluadas; la tercera, si los resultados sobreviven a la incorporación de fricciones de mercado realistas. Esta sección examina cada una de estas dimensiones, comenzando por el perfil de riesgo de las estrategias, continuando con la validación estadística formal y cerrando con el análisis de los costos de transacción.

5.1 Gestión de Riesgo

Una rentabilidad elevada solo resulta valiosa si el riesgo asumido para obtenerla se mantiene dentro de límites razonables, dado que exposiciones excesivas pueden comprometer la viabilidad de una estrategia por más atractivos que parezcan sus retornos. Por ello, en esta sección se examina el perfil de riesgo de los cuatro modelos ganadores (LSTM+Attention, Ridge, RandomForest y CNN-LSTM), con el propósito de valorar en qué medida los retornos registrados guardan proporción con los riesgos asumidos durante el período de prueba.

5.1.1 Métricas de Riesgo Ajustado

Se emplean tres ratios ampliamente utilizados en gestión de portafolios. El *Sharpe Ratio* (Sharpe, 1966) mide el exceso de retorno por unidad de volatilidad total ($\text{Sharpe} = E[R_p - R_f] / \sigma_p \cdot \sqrt{252}$). El *Sortino Ratio* (Sortino & van der Meer, 1991) reemplaza σ_p por la desviación estándar exclusivamente negativa σ_d , penalizando únicamente la volatilidad a la baja. El *Calmar Ratio* relaciona el retorno anualizado con el máximo *drawdown* histórico ($\text{Calmar} = \text{CAGR} / |\text{Max DD}|$); un valor superior a 1.0 indica que el retorno anualizado supera la peor caída observada.

Tabla 8: Métricas de riesgo ajustado de los modelos que superan al benchmark

Modelo	Sharpe	Sortino	Calmar
LSTM+Attention	1.319	2.606	1.770
Ridge	0.856	1.250	0.868
RandomForest	0.651	1.337	1.153
CNN-LSTM	0.572	1.100	0.466
SPY (B&H)	0.657	0.944	0.571

La Tabla 8 muestra una jerarquía consistente. LSTM+Attention registra un Sharpe de 1.319 frente al 0.657 del *benchmark*, y su Sortino (2.606) es prácticamente el doble de su Sharpe, lo que indica que la volatilidad proviene desproporcionadamente del lado positivo, patrón consistente con una estrategia que permanece en efectivo la mayor parte del tiempo y genera retornos concentrados en días de exposición apalancada. LSTM+Attention y RandomForest son los únicos que superan el umbral de Calmar > 1.0 , mientras que CNN-LSTM, pese a superar al *benchmark* en retorno total (+122 %), presenta un Calmar (0.466) inferior al del SPY (0.571), dado que su *drawdown* máximo (−35.9 %) excede significativamente el del índice (−25.4 %).

5.1.2 Riesgo de Cola y Drawdown

Las métricas de riesgo de cola cuantifican las pérdidas potenciales en escenarios adversos. El VaR histórico se calcula mediante percentiles empíricos sobre ventanas móviles de N días.

$$\text{VaR}_\alpha^{(N)} = -\text{Percentil}_\alpha \left(\prod_{j=0}^{N-1} (1 + R_{t-j}) - 1 \right) \quad (8)$$

El *Expected Shortfall* (CVaR) mide la pérdida promedio condicional en las ventanas que exceden el VaR, satisfaciendo la propiedad de subaditividad que lo convierte en una medida coherente de riesgo (López de Prado, 2018). Los resultados a horizontes de 30 y 90 días (Tabla 37) muestran que LSTM+Attention presenta un VaR a 30 días (−6.18 %) inferior al del SPY (−7.81 %) y un VaR a 90 días (−3.77 %) que es cercano a un tercio del *benchmark* (−10.80 %), lo que sugiere que la selectividad temporal reduce el riesgo de pérdidas sostenidas. En contraste, Ridge y CNN-LSTM exhiben CVaR a 90 días de −21.88 % y −23.05 %, superando al SPY (−13.85 %). RandomForest exhibe el perfil más conservador (VaR 90d de −0.67 %).

La Tabla 38 complementa este análisis. LSTM+Attention experimenta su máximo *drawdown* (−20.5 %) durante la volatilidad arancelaria de abril 2025 y se recupera en un único día gracias a la posición apalancada 3x durante el fuerte rebote de comienzos de abril de 2025. Ridge y CNN-LSTM registran caídas del 31.8 % y 35.9 % durante el mercado bajista de 2022, con tiempos de recuperación de 56 y 566 días respectivamente. Los 566 días de CNN-LSTM reflejan las

consecuencias duraderas del posicionamiento agresivo durante el período observado. RandomForest exhibe el perfil más conservador (-15.0% , recuperación en 23 días).

5.1.3 Ratios de Captura de Mercado

El *Upside/Downside Capture Ratio* descompone qué proporción de los retornos del mercado en días alcistas y bajistas captura cada estrategia.

$$\text{Upside Capture} = \frac{\overline{R_p | R_m > 0}}{\overline{R_m | R_m > 0}} \times 100, \quad \text{Downside Capture} = \frac{\overline{R_p | R_m < 0}}{\overline{R_m | R_m < 0}} \times 100 \quad (9)$$

Tabla 9: *Upside/Downside Capture* de los modelos que superan al benchmark

Modelo	Upside Capture	Downside Capture	Capture Ratio
LSTM+Attention	90.1 %	67.2 %	1.34×
Ridge	99.5 %	84.3 %	1.18×
RandomForest	45.5 %	33.0 %	1.38×
CNN-LSTM	70.1 %	61.8 %	1.14×
SPY (B&H)	100.0 %	100.0 %	1.00×

Nota: Calculado sobre los 1,301 retornos diarios evaluados del período de prueba (710 días alcistas, 589 días bajistas, 2 días neutros). SPY B&H = 100 % por definición.

Como muestra la Tabla 9, LSTM+Attention captura en promedio el 90.1 % de las alzas y participa del 67.2 % de las caídas. Esta brecha de 22.9 puntos se acumula a través del interés compuesto a lo largo del período de prueba, lo que podría ayudar a explicar por qué un *Directional Accuracy* inferior al 50 % llega a asociarse con el mejor retorno del estudio. RandomForest exhibe el *Capture Ratio* más alto (1.38×) gracias a una participación muy selectiva (45.5 % alzas, 33.0 % caídas), lo que produce el *drawdown* más contenido del grupo pero también el retorno más modesto. CNN-LSTM presenta la menor asimetría (8 puntos de brecha, 1.14×), consistente con su *drawdown* más profundo y su Calmar más bajo, ya documentados.

El análisis del *Capture Ratio* complementa la paradoja del *Directional Accuracy* documentada en la Sección 4.5, dado que los modelos con mayor rentabilidad en esta muestra no parecen distinguirse por predecir correctamente la dirección del mercado con mayor frecuencia, sino por registrar una asimetría entre su participación en alzas y en caídas. La estrategia *Long-Only* implementada incorpora un control de riesgo que se deriva del propio diseño del sistema de posicionamiento; cuando las predicciones no superan el umbral q_{mod} , la posición por defecto es 100 % en efectivo, lo que operaría como un *stop-loss* implícito, ya que reduce la exposición durante períodos de incertidumbre sin requerir reglas explícitas predefinidas.

5.2 Validación Estadística

Más allá de la comparación directa de retornos presentada en secciones anteriores, se requiere validación estadística formal para evaluar en qué medida los resultados observados podrían ser atribuibles al azar muestral. A continuación se presentan los tests estadísticos aplicados a los cuatro modelos ganadores (LSTM+Attention, Ridge, RandomForest y CNN-LSTM) y al *benchmark* SPY *Buy & Hold*, todos computados a partir de los retornos diarios del período de prueba (1,302 días).

5.2.1 Bootstrap de Sharpe Ratios

Se emplea *bootstrap* no paramétrico (Efron, 1979) con $B = 5,000$ muestras con reemplazo para construir intervalos de confianza al 95 % del Sharpe Ratio de cada estrategia. Se incorpora la corrección de Lo (2002) al error estándar para ajustar por la autocorrelación de primer orden de los retornos.

$$SE(\hat{S}) = \sqrt{\frac{1 + \frac{\hat{S}^2}{2} \cdot (1 + \hat{\rho}_1)}{T \cdot (1 - \hat{\rho}_1)}} \quad (10)$$

Los resultados (Tabla 39) sugieren que LSTM+Attention es el único modelo cuyo intervalo de confianza se mantiene íntegramente positivo (0.375–2.424), con 99.6 % de probabilidad de Sharpe positivo y 83.1 % de superar al *benchmark*. Ridge alcanza 94.9 % de probabilidad positiva pero su límite inferior se mantiene ligeramente negativo (−0.121), mientras que RandomForest y CNN-LSTM presentan probabilidades cercanas al 50 % de superar al SPY (49.9 % y 44.4 %), indicando evidencia débil de que el mejor rendimiento observado sea estadísticamente distinguible del *benchmark* pese a retornos absolutos positivos.

5.2.2 Test de Diebold-Mariano

El test de Diebold & Mariano (1995) evalúa si la diferencia en rendimiento económico entre dos estrategias es estadísticamente significativa, definiendo $d_t = L(\text{benchmark}_t) - L(\text{estrategia}_t)$ con función de pérdida igual al retorno negativo.

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \quad (11)$$

donde $\hat{V}(\bar{d})$ incorpora la corrección de Newey & West (1987) con cinco rezagos. La Tabla 40 sugiere que LSTM+Attention es el único modelo que alcanza significancia al 5 % ($DM = 2.296$, $p = 0.011$), permitiendo rechazar la hipótesis nula de retornos indistinguibles del *benchmark*. Ridge se sitúa en la zona marginal ($p = 0.101$), mientras que RandomForest y CNN-LSTM no presentan evidencia de mejor rendimiento respecto al *benchmark* ($p > 0.35$), lo que ilustra la asimetría habitual entre significancia económica y estadística en la predicción de retornos.

5.2.3 Test de Clark-West

El test de Clark & West (2007) evalúa la capacidad predictiva de modelos anidados comparando cada modelo contra el predictor de media histórica ($\bar{r}_{\text{train}} = 0.025$ % diario).

$$CW_t = (e_{1,t}^2 - e_{2,t}^2) + (\hat{y}_{1,t} - \hat{y}_{2,t})^2 \quad (12)$$

La Tabla 41 es consistente con el patrón identificado, dado que LSTM+Attention es nuevamente el único modelo significativo ($CW = 1.901$, $p = 0.029$). La convergencia de ambos tests, que evalúan dimensiones distintas del rendimiento (retornos de estrategia vs. error de predicción), sobre el mismo modelo es compatible con la interpretación de un error de predicción menor al del predictor de media histórica en este período. El valor negativo de RandomForest ($CW = -0.336$) indica que sus predicciones no mejoran respecto a la media histórica, sugiriendo

que la rentabilidad de la estrategia proviene de señales direccionales asimétricas (Pesaran & Timmermann, 2002).

5.2.4 Model Confidence Set

El *Model Confidence Set* (MCS) de Hansen et al. (2011) identifica el subconjunto de modelos que contiene al mejor con probabilidad dada, mediante el estadístico $T_{\max}$ con *bootstrap* de bloques estacionarios ($B = 3,000$) al nivel $\alpha = 0.10$. Aplicado a las 24 estrategias (23 modelos + SPY), el procedimiento no logra eliminar ningún modelo del conjunto.

$$\hat{\mathcal{M}}_{0.10}^* = \mathcal{M}_0 \quad (24 \text{ modelos, } 0 \text{ eliminados}) \quad (13)$$

Este resultado se explica por la elevada varianza de los retornos diarios de renta variable, dado que la desviación estándar diaria del S&P 500 ($\approx 1.1\%$) excede ampliamente la diferencia media entre estrategias ($\approx 0.05\%$), generando una relación señal-ruido insuficiente para discriminar con 1,302 observaciones, resultado consistente con Hansen et al. (2011).

5.2.5 Análisis de Overfitting y Comparaciones Múltiples

La Tabla 42 muestra que LSTM+Attention exhibe la menor degradación en precisión direccional entre entrenamiento y prueba (-4.6%), con un error cuadrático que *disminuye* en el período fuera de muestra ($0.68\times$), lo que sugiere que el mecanismo de atención captura patrones con cierta capacidad de generalización. Ridge y RandomForest muestran mayor degradación (-18.6% y -20.9%) con ratios de MSE superiores a uno, indicando sobreajuste más pronunciado aunque sin anular la rentabilidad. XGBoost, como contraejemplo, muestra mínima degradación (-1.6%) pero un Sharpe de -0.024 , dado que su baja degradación refleja ausencia de señal en ambos períodos.

Con 23 modelos evaluados simultáneamente, la corrección de Bonferroni establece un umbral de $\alpha_{\text{adj}} = 0.05/23 \approx 0.0022$ bajo el cual ningún modelo alcanza significancia ($p_{\text{mín}} = 0.011$ para LSTM+Attention). El procedimiento de Benjamini & Hochberg (1995) tampoco identifica modelos significativos al nivel $q = 0.10$, lo que indica que, bajo correcciones estándar por comparaciones múltiples, la evidencia de mejor rendimiento individual no alcanza umbrales convencionales.

5.2.6 Síntesis de la Validación Estadística

Tabla 10: Resumen de tests estadísticos por modelo

Modelo	P(S>0)	P(S>SPY)	DM (5 %)	CW (5 %)	Bonferroni
LSTM+Attention	99.6 %	83.1 %	✓	✓	×
Ridge	94.9 %	60.4 %	×	×	×
RandomForest	93.3 %	49.9 %	×	×	×
CNN-LSTM	89.3 %	44.4 %	×	×	×

✓ = significativo al nivel indicado. × = no significativo. El MCS no se incluye porque no logró eliminar ningún modelo del conjunto completo.

La Tabla 10 sintetiza los resultados. LSTM+Attention es el único modelo que alcanza significancia en los tests de Diebold-Mariano y Clark-West al 5 %, mantiene un intervalo *bootstrap*

íntegramente positivo y presenta la menor degradación predictiva, y la coincidencia de varios tests que evalúan dimensiones distintas del rendimiento parece indicar que el mejor rendimiento observado en esta muestra no sería enteramente atribuible al azar.

No obstante, tres resultados atemperan esta conclusión. Bajo Bonferroni, incluso LSTM+Attention pierde significancia; el MCS no discrimina entre las 24 estrategias dado que la varianza diaria genera una relación señal-ruido insuficiente con 1,302 observaciones; y los tres modelos restantes no alcanzan significancia individual al 5 %. Estos hallazgos matizan la conclusión de Gu et al. (2020) sobre la superioridad general de métodos no lineales, puesto que en este contexto solo el modelo con mecanismo de atención alcanza los umbrales de significancia aplicados, hallazgo consistente con la advertencia de López de Prado (2018) sobre los riesgos de evaluar múltiples estrategias simultáneamente.

5.3 Costos de Transacción

5.3.1 Modelo de Costos y Estructura

Una crítica recurrente a las estrategias de *trading* activo es que los costos de transacción erosionan la rentabilidad que muestran en simulaciones históricas (Barber & Odean, 2000). El modelo de costos empleado en este estudio incorpora tres componentes (*bid-ask spread*, *expense ratio* y *volatility drag*), calibrados de forma conservadora, con *spreads bid-ask* que exceden los valores típicos de mercado, como se documenta más adelante. El retorno neto diario se obtiene como

$$r_{\text{neto}} = r_{\text{bruto}} - c_{\text{expense}} - c_{\text{trading}} - c_{\text{drag}} \quad (14)$$

donde $r_{\text{bruto}} = r_f + p \cdot (r_{\text{mkt}} - r_f)$ con $p \in \{0, 1, 3\}$ según la posición (CASH, SPY, UPRO). Los parámetros por instrumento se detallan en la Tabla 43; UPRO incurre en un *expense ratio* de 0.91 %/año y un *bid-ask spread* de 5 bps por transacción, SPY en 0.09 %/año y 2 bps, y la posición en efectivo no aplica costo alguno. Conviene precisar que la exposición apalancada se modela de forma sintética, a saber, aplicando tres veces el retorno en exceso del SPY menos los costos descritos, en lugar de emplear la serie histórica de precios del ETF UPRO; los *benchmarks* pasivos (SPY y UPRO *Buy & Hold*) se costean con el mismo modelo, de modo que las comparaciones relativas no se ven favorecidas por un tratamiento asimétrico de costos.

El *volatility drag* de los ETFs apalancados se modela según la aproximación de primer orden.

$$c_{\text{drag}} \approx \frac{1}{2}(L^2 - L)\sigma^2 \quad (15)$$

donde σ es la volatilidad diaria del subyacente. Para evitar subestimar el decaimiento en regímenes turbulentos, σ no se fija en un valor constante sino que se estima día a día mediante la volatilidad realizada de una ventana móvil retrospectiva de 21 días, sin incorporar información futura. Para UPRO ($L = 3$) con una volatilidad del orden de 1 % diario, el *drag* ronda 0.03 %/día (≈ 7.5 %/año) y se amplifica en períodos de alta volatilidad, constituyendo el componente de costo más significativo para los modelos con exposición apalancada frecuente.

5.3.2 Desglose de Costos e Impacto

La Tabla 44 presenta el desglose completo para los 23 modelos. Los cuatro modelos ganadores exhiben ratios Tx/P&L entre 15.8 % (RandomForest) y 39.0 % (CNN-LSTM), indicando que

entre aproximadamente tres quintos y cinco sextos de su rendimiento bruto sobrevive a los costos. LSTM+Attention acumula \$13,459 en costos sobre un capital inicial de \$10,000, con un retorno neto del +395 % una vez descontadas esas fricciones. El costo promedio de los 23 modelos asciende a \$3,749 (37.5 % del capital inicial), lo que sugiere la conveniencia de modelar costos al evaluar estrategias activas.

Para verificar que los parámetros reflejan condiciones reales, se contrastan con datos reportados por los emisores (ProShares, 2026; State Street, 2026) (Tabla 45). Los *expense ratios* son prácticamente idénticos a los vigentes (ratio $\approx 1.0\times$), pero los *bid-ask spreads* empleados sobreestiman los costos reales de manera sustancial, dado que la mediana reportada por ProShares para UPRO es 2 bps (vs. 5 bps en este estudio, un factor de $\approx 2.5\times$) y la de SPY es ≈ 0 bps (vs. 2 bps). Los retornos netos reportados incorporan, por tanto, una penalización por costos de ejecución significativamente mayor a la que enfrentaría un operador real.

5.3.3 Análisis de Sensibilidad a Costos

La Tabla 46 muestra que los cuatro modelos líderes mantienen rentabilidad positiva incluso con costos duplicados. LSTM+Attention registra +261 % con costos al doble, frente al +101 % del SPY, y su punto de *break-even* se sitúa en $3.9\times$ los costos actuales. RandomForest presenta el *break-even* más alejado ($6.3\times$, Tx/P&L de 15.8 %), mientras que CNN-LSTM resulta más sensible ($2.6\times$, Tx/P&L de 39.0 %) aunque mantiene retorno positivo en todos los escenarios.

La Figura 6 evalúa la hipótesis de que mayor *turnover* se traduce en menores retornos netos; el coeficiente de determinación prácticamente nulo ($R^2 = 0.00$) no la respalda, sugiriendo que la calidad de las señales de entrada resulta más relevante que la frecuencia de operación.

5.3.4 Limitaciones del Modelo de Costos

El modelo incorpora las fricciones consideradas más relevantes para una estrategia *Long-Only* basada en ETFs, pero una implementación real debería contemplar costos adicionales. El *slippage* y el *market impact* resultan insignificantes para capitales inferiores a varias decenas de millones de dólares, dado que SPY y UPRO figuran entre los ETFs con mayor volumen de negociación (\$35 mil millones y \$800 millones diarios, respectivamente); la restricción de escalabilidad que ello implica para capitales mayores se retoma en la Sección 6. Los impuestos sobre ganancias de capital representan otro costo no modelado que depende de la jurisdicción fiscal del inversor pero afecta simétricamente a todas las estrategias activas, por lo que las comparaciones relativas se mantienen válidas. Los costos de infraestructura (servidores, datos, mantenimiento) constituyen costos fijos amortizables que no escalan con el tamaño de las posiciones y no alteran la evaluación comparativa.

6. Discusión

Reunidos los resultados empíricos y las pruebas de robustez que los acompañan, es posible interpretar la evidencia en su conjunto. Las métricas de riesgo ajustado sugieren que los cuatro modelos con mayor retorno no lo obtienen mediante una exposición desproporcionada al riesgo de mercado; por el contrario, presentan *drawdowns* más breves, menor *Value at Risk* y *capture ratios* asimétricos que parecen indicar una protección relativa en períodos bajistas. La validación estadística, mediante pruebas de Diebold & Mariano (1995) y Clark & West (2007), sugiere

la significancia del modelo líder y es compatible con la interpretación de que la superioridad observada no sería atribuible al azar, aunque los modelos restantes no alcanzan significancia individual. Finalmente, el análisis de costos sugiere que el *alpha* documentado se mantiene bajo un modelo de fricciones deliberadamente conservador que sobreestima los *spreads* reales del mercado. En conjunto, la coincidencia de estos resultados en rendimiento, riesgo, significancia estadística y viabilidad económica sugiere que las ineficiencias residuales identificadas por los modelos ganadores no parecen atribuibles exclusivamente al azar, lo cual es consistente con el equilibrio informacional de Grossman & Stiglitz (1980) y con la naturaleza adaptativa de los mercados financieros descrita por Lo (2019).

Esa correspondencia con la teoría merece un examen más detenido a la luz de los marcos presentados en la Sección 2. La paradoja de Grossman & Stiglitz (1980), formulada originalmente como argumento lógico sobre la imposibilidad de mercados perfectamente eficientes, encuentra aquí una posible ilustración empírica. El concepto abstracto de *costo de adquirir y procesar información* adquiere una forma concreta, a saber, un costo computacional elevado que involucra el procesamiento simultáneo de cientos de características mediante arquitecturas de *deep learning* con mecanismos de atención, la optimización dinámica de umbrales por Meta-KNN y un protocolo de validación diseñado para eliminar toda filtración temporal. La estructura de los resultados parece compatible con el equilibrio predicho por la teoría; la gran mayoría de las especificaciones evaluadas fracasan en superar al *benchmark* pasivo, lo que podría interpretarse como indicación de que el mercado es lo suficientemente eficiente como para derrotar a la mayor parte de las estrategias, incluso cuando estas emplean algoritmos sofisticados. No obstante, cuatro modelos registran un retorno acumulado superior al de la referencia pasiva, con diferencias apreciables en magnitud. Esta distribución asimétrica, con muchos resultados por debajo de la referencia y unos pocos por encima en retorno absoluto, es consistente con lo que el equilibrio de Grossman-Stiglitz predice, dado que el mercado mantiene la ineficiencia mínima necesaria para compensar a los participantes capaces de procesarla, pero no la suficiente para que cualquier estrategia la capture. El *alpha* documentado no parece corresponder a una oportunidad de captura trivial y es compatible con la noción de que los mercados son, en términos generales, bastante eficientes; puede interpretarse como la compensación que el mercado ofrece a quienes invierten recursos significativos en procesar información, el mecanismo que Grossman & Stiglitz (1980) identificaron como condición necesaria para que los precios sean informativos.

Dicha compensación no tiene por qué manifestarse como la capacidad de acertar la dirección del mercado día tras día; los resultados sugieren que se materializa, más bien, en la identificación de momentos puntuales de asimetría favorable, y la paradoja del *Directional Accuracy* documentada en la Sección 4.5 constituye la ilustración más nítida de esta lectura. La tensión entre frecuencia de aciertos y magnitud de resultados no es nueva en la literatura; el criterio de Kelly (Kelly, 1956) demuestra que la riqueza de un agente puede crecer de forma sostenida aun con una tasa de aciertos inferior al 50%, siempre que las ganancias en los días acertados superen sustancialmente las pérdidas en los fallidos, que es precisamente la configuración que el sistema de posicionamiento por percentiles parece explotar. Si la rentabilidad depende del producto entre frecuencia y magnitud, se sigue que el DA resulta una métrica incompleta para evaluar estrategias de *trading*, conclusión que López de Prado (2018) desarrolla al argumentar que la evaluación debe centrarse en la rentabilidad ajustada por riesgo; que una métrica con limitaciones tan documentadas conserve su posición dominante en la práctica podría explicarse desde las finanzas conductuales, ya que Kahneman & Tversky (1979) documentaron que los agentes tienden a sobrevalorar la frecuencia

de los resultados favorables frente a su magnitud. Esta lectura encuentra apoyo empírico en [Gu et al. \(2020\)](#), quienes muestran que múltiples familias de modelos convergen en las mismas señales predictivas; de manera análoga, tanto Ridge como LSTM+Attention registran un DA inferior al 50 % y un retorno acumulado superior al del mercado en el período analizado, lo que apunta a que ambos detectan estados de asimetría favorable antes que dirección diaria. El círculo se cierra con la propia metodología de esta tesis, dado que la selectividad temporal que emerge de la paradoja coincide con la filosofía del Triple Screen de [Elder \(1993\)](#), donde la disciplina de no operar cuando la señal es ambigua resulta tan determinante como la precisión de la señal misma.

Los marcos teóricos restantes también encuentran cierto eco en los datos. La Hipótesis del Mercado Adaptativo ([Lo, 2019](#)) ofrece un marco para interpretar la coexistencia de señal explotable y dificultad de captura; la señal existe pero su extracción requiere una capacidad de cómputo considerable, y el dominio de las arquitecturas con mecanismos de atención sugiere que los patrones *fáciles* han sido arbitrados, persistiendo solo dependencias no lineales complejas. La Hipótesis del Mercado Fractal ([Peters, 1994](#)) podría recibir respaldo indirecto del comportamiento del enfoque multitemporal, dado que los modelos que procesan simultáneamente características de múltiples escalas registran mejores resultados que los univariados en esta muestra, lo que sugiere estructura informativa a través de los horizontes temporales, puesto que si los mercados fueran aleatorios en todas las escalas, las características multitemporales añadirían ruido en lugar de señal. Los límites al arbitraje ([Shleifer & Vishny, 1997](#)) explican la persistencia de estas ineficiencias bajo fricciones realistas. Por su parte, el marco de la martingala ([Samuelson, 1965](#)) junto con la ley del arcoseno ([Lévy, 1940](#); [Feller, 1968](#)) fundamentan la viabilidad de una estrategia basada en posicionamiento relativo más que en predicción puntual, dado que los modelos no predicen precios exactos sino que identifican asimetrías favorables en la relación riesgo-retorno, tarea que el marco teórico valida como legítima. La convergencia de estos marcos sobre los mismos datos ofrece una lectura coherente que ubica los hallazgos en una posición intermedia; no respaldan plenamente la HEM en su formulación clásica ni la refutan de manera categórica, sino que contribuyen con evidencia empírica preliminar a los marcos contemporáneos que reconocen la naturaleza adaptativa y contingente de la eficiencia de mercado.

En el plano operativo, la diversidad de enfoques con resultados favorables, que abarca desde técnicas de regularización lineal hasta arquitecturas de *deep learning* con mecanismos de atención, sugiere que los practicantes podrían seleccionar modelos en función de sus restricciones operativas, su tolerancia al riesgo de modelo y su capacidad de infraestructura computacional. Un gestor con recursos limitados puede optar por especificaciones parsimoniosas cuya implementación y mantenimiento exigen menor complejidad, mientras que instituciones con capacidades avanzadas de cómputo pueden explorar arquitecturas neuronales que, según la evidencia presentada, parecen capturar dependencias temporales de mayor orden. El mejor rendimiento de los modelos con mecanismos de atención en este estudio podría respaldar la exploración de capacidades de *deep learning* por parte de gestores cuantitativos, dado que estos mecanismos permiten a las redes identificar selectivamente los períodos históricos más informativos para la decisión actual.

La viabilidad de la estrategia tras incorporar costos de transacción conservadores, incluyendo el *volatility drag* inherente a los instrumentos apalancados, sugiere que el *alpha* documentado no sería exclusivamente un fenómeno estadístico. Conviene recordar que el modelo de costos fue diseñado deliberadamente para sobreestimar las fricciones reales, de modo que las cifras netas reportadas operarían como una cota conservadora frente a estimaciones más precisas de los *spreads*.

La interpretación anterior debe leerse a la luz de las limitaciones del estudio, entre las que se encuentran el sesgo alcista del período de prueba, la concentración en un único mercado, la ausencia de recalibración periódica de hiperparámetros y la sobreestimación conservadora de costos; conviene, además, señalar una restricción adicional que merece atención.

El modelo de costos empleado no incorpora el impacto de mercado que generaría la ejecución de órdenes con capital significativo. Para un portafolio de tamaño modesto, la diferencia entre el precio teórico y el precio efectivo de ejecución es despreciable, pero a medida que el volumen de las órdenes crece, la presión compradora o vendedora deteriora progresivamente los precios obtenidos, un fenómeno particularmente agudo en instrumentos como UPRO, cuya liquidez es considerablemente inferior a la del SPY. Esta limitación de escalabilidad implica que la rentabilidad neta documentada podría reducirse de manera no lineal con el tamaño del capital gestionado, estableciendo un límite práctico a la explotación de las ineficiencias detectadas que es consistente, una vez más, con la lógica del equilibrio de Grossman & Stiglitz (1980).

Estas limitaciones delimitan el alcance de los hallazgos sin anular su valor interpretativo, dado que los protocolos de prevención de filtración temporal, las pruebas estadísticas aplicadas y la diversidad de los modelos con mejor desempeño sugieren que la señal documentada no respondería únicamente a artefactos del procedimiento, si bien esta lectura queda circunscrita a la muestra estudiada.

7. Conclusión

En este trabajo se evaluó la capacidad de veintitrés modelos de aprendizaje automático y profundo, alimentados por un amplio conjunto de características derivadas de variables financieras, para generar rentabilidad ajustada por riesgo superior a la gestión pasiva del S&P 500 mediante una estrategia *long-only* con apalancamiento selectivo. Los hallazgos documentados, a saber, la convergencia de familias algorítmicas heterogéneas hacia *alpha* positivo, la reconciliación de la paradoja del *Directional Accuracy* mediante asimetría condicional, y la persistencia de los resultados tras incorporar costos conservadores junto con las pruebas estadísticas aplicadas, sugieren la presencia de ineficiencias residuales cuya eventual explotación requeriría una capacidad de procesamiento considerable, lectura desarrollada en la discusión precedente. Estas conclusiones deben ponderarse con las limitaciones ya expuestas, en particular el sesgo alcista del período de prueba y la restricción de escalabilidad del capital gestionado, que acotan el alcance de los hallazgos sin privarlos de valor interpretativo.

Quedan abiertas, con todo, varias líneas de investigación que conviene explorar. La extensión del análisis a otros índices de renta variable y clases de activos (renta fija, divisas, materias primas) permitiría evaluar si los patrones predictivos documentados son específicos del S&P 500 o reflejan una propiedad más general de los mercados financieros. La incorporación de detección explícita de regímenes de mercado, mediante modelos de cambio de régimen o arquitecturas de mezcla de expertos (*mixture of experts*), podría mejorar la adaptabilidad de las estrategias a entornos cambiantes, permitiendo que los modelos ajusten dinámicamente sus parámetros de posicionamiento en función del régimen identificado. El desarrollo de formulaciones que optimicen explícitamente el *trade-off* entre señal predictiva y *turnover* sería de utilidad práctica para la implementación, dado que los costos de transacción representan una restricción material sobre la rentabilidad neta que el marco actual aborda de manera ex-post. Finalmente, la integración de fuentes de datos alternativas (sentimiento en redes sociales, imágenes satelitales, datos de

transacciones con tarjetas de crédito) podría enriquecer el espacio de características y capturar dimensiones informativas no contenidas en los datos financieros tradicionales, una dirección que Gu et al. (2020) identificaron como particularmente prometedora para la siguiente generación de modelos de *asset pricing*.

Tanto esas extensiones como los resultados aquí documentados deben interpretarse con la cautela que impone la naturaleza adaptativa de los mercados financieros. Como advirtió Lo (2019), los mercados son sistemas adaptativos complejos donde las regularidades del pasado pueden desvanecerse cuando suficientes participantes las explotan, y los resultados observados en este período no garantizan rendimientos futuros equivalentes. El marco metodológico, documentado en detalle en este trabajo y sus apéndices, está diseñado precisamente para facilitar la validación, extensión y eventual refutación de estos hallazgos.

A título personal, el desarrollo de esta investigación ha representado un proceso de aprendizaje que trasciende los resultados numéricos aquí documentados. La construcción del *pipeline* completo, desde la obtención y transformación de datos en Bloomberg Terminal hasta la implementación de arquitecturas de *deep learning* y la simulación de una estrategia de *trading* con costos realistas, ha proporcionado una comprensión integral de las finanzas cuantitativas que complementa de manera sustancial la formación teórica del Magíster de Finanzas. El proceso de depurar meticulosamente cada etapa para prevenir la filtración de información futura, de interpretar resultados que desafían la intuición (como la paradoja del *Directional Accuracy*) y de enfrentar la tensión permanente entre complejidad del modelo y capacidad de generalización, ha forjado una perspectiva crítica sobre las posibilidades y limitaciones del aprendizaje automático aplicado a los mercados financieros. Si este trabajo contribuye, aunque sea modestamente, al debate sobre la eficiencia de mercado y sirve como punto de partida para futuras investigaciones, habrá cumplido su propósito.

Referencias

- Ang, A., Hodrick, R. J., Xing, Y., & Zhang, X. (2006). The Cross-Section of Volatility and Expected Returns. *The Journal of Finance*, 61(1), 259–299.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- De Long, J. B., Shleifer, A., Summers, L. H., & Waldmann, R. J. (1990). Noise Trader Risk in Financial Markets. *Journal of Political Economy*, 98(4), 703–738.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dong, X., Li, Y., Rapach, D., & Zhou, G. (2022). Anomalies and the Expected Market Return. *The Journal of Finance*, 77(1), 639–681.
- Feller, W. (1968). *An Introduction to Probability Theory and Its Applications*, Vol. 1, 3rd ed. New York: John Wiley & Sons.
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.
- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189–1232.
- Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). Learning to Forget: Continual Prediction with LSTM. *Neural Computation*, 12(10), 2451–2471.
- Grossman, S. J., & Stiglitz, J. E. (1980). On the Impossibility of Informationally Efficient Markets. *American Economic Review*, 70(3), 393–408.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The Model Confidence Set. *Econometrica*, 79(2), 453–497.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Kahneman, D., & Tversky, A. (1979). Prospect Theory: An Analysis of Decision under Risk. *Econometrica*, 47(2), 263–292.
- Lo, A. W. (2019). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press.
- Malkiel, B. G. (1973). *A Random Walk Down Wall Street*. New York: W. W. Norton & Company.

- Mantegna, R. N., & Stanley, H. E. (2000). *An Introduction to Econophysics: Correlations and Complexity in Finance*. Cambridge: Cambridge University Press.
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting. *Proceedings of the 8th International Conference on Learning Representations (ICLR)*.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- Peters, E. E. (1994). *Fractal Market Analysis: Applying Chaos Theory to Investment and Economics*. New York: John Wiley & Sons.
- Samuelson, P. A. (1965). Proof That Properly Anticipated Prices Fluctuate Randomly. *Industrial Management Review*, 6(2), 41–49.
- Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128.
- Benjamini, Y., & Hochberg, Y. (1995). Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- CMT Association. (2020). 1.4 The Opportunity of the Efficient Markets Hypothesis. En *CMT Level I: An Introduction to Technical Analysis*. CMT Association.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- Clark, T. E., & West, K. D. (2007). Approximately Normal Tests for Equal Predictive Accuracy in Nested Models. *Journal of Econometrics*, 138(1), 291–311.
- Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1), 1–26.
- Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, 35(4), 917–926.
- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- Lévy, P. (1940). Sur certains processus stochastiques homogènes. *Compositio Mathematica*, 7, 283–339.
- Lo, A. W. (2002). The Statistics of Sharpe Ratios. *Financial Analysts Journal*, 58(4), 36–52.
- Sharpe, W. F. (1966). Mutual Fund Performance. *The Journal of Business*, 39(1), 119–138.
- Shefrin, H., & Statman, M. (1994). Behavioral Capital Asset Pricing Theory. *Journal of Financial and Quantitative Analysis*, 29(3), 323–349.

- Shleifer, A., & Vishny, R. W. (1997). The Limits of Arbitrage. *The Journal of Finance*, 52(1), 35–55.
- Sortino, F. A., & van der Meer, R. (1991). Downside Risk. *The Journal of Portfolio Management*, 17(4), 27–31.
- Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37–45.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Elder, A. (1993). *Trading for a Living: Psychology, Trading Tactics, Money Management*. John Wiley & Sons.
- Parkinson, M. (1980). The Extreme Value Method for Estimating the Variance of the Rate of Return. *The Journal of Business*, 53(1), 61–65.
- Garman, M. B., & Klass, M. J. (1980). On the Estimation of Security Price Volatilities from Historical Data. *The Journal of Business*, 53(1), 67–78.
- Rogers, L. C. G., & Satchell, S. E. (1991). Estimating Variance from High, Low and Closing Prices. *The Annals of Applied Probability*, 1(4), 504–512.
- Yang, D., & Zhang, Q. (2000). Drift-Independent Volatility Estimation Based on High, Low, Open, and Close Prices. *The Journal of Business*, 73(3), 477–492.
- Vinté, C., Smeureanu, I., Furtună, T.-F., & Ausloos, M. (2019). An Intrinsic Entropy Model for Exchange-Traded Securities. *Entropy*, 21(12), 1173.
- Alizadeh, S., Brandt, M. W., & Diebold, F. X. (2002). Range-Based Estimation of Stochastic Volatility Models. *The Journal of Finance*, 57(3), 1047–1091.
- Chou, R. Y. (2005). Forecasting Financial Volatilities with Extreme Values: The Conditional Autoregressive Range (CARR) Model. *Journal of Money, Credit and Banking*, 37(3), 561–582.
- Fiszeder, P., & Perczak, G. (2016). Low and High Prices Can Improve Volatility Forecasts during the Turmoil Period. *International Journal of Forecasting*, 32(2), 398–410.
- Chen, N.-F., Roll, R., & Ross, S. A. (1986). Economic Forces and the Stock Market. *The Journal of Business*, 59(3), 383–403.
- Harvey, C. R. (1989). Forecasts of Economic Growth from the Bond and Stock Markets. *Financial Analysts Journal*, 45(5), 38–45.
- Fama, E. F., & French, K. R. (1989). Business Conditions and Expected Returns on Stocks and Bonds. *Journal of Financial Economics*, 25(1), 23–49.

- Baker, M., & Wurgler, J. (2006). Investor Sentiment and the Cross-Section of Stock Returns. *The Journal of Finance*, 61(4), 1645–1680.
- Hong, H., & Yogo, M. (2012). What Does Futures Market Interest Tell Us about the Macroeconomy and Asset Prices? *Journal of Financial Economics*, 105(3), 473–490.
- Jegadeesh, N., & Titman, S. (1993). Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. *The Journal of Finance*, 48(1), 65–91.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PLoS ONE*, 13(3), e0194889.
- Kingma, D. P. & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*.
- Barber, B. M., & Odean, T. (2000). Trading Is Hazardous to Your Wealth: The Common Stock Investment Performance of Individual Investors. *The Journal of Finance*, 55(2), 773–806.
- Newey, W. K., & West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, 55(3), 703–708.
- Pesaran, M. H., & Timmermann, A. (2002). Market Timing and Return Prediction under Model Instability. *Journal of Empirical Finance*, 9(5), 495–510.
- ProShares (2026). UPRO, UltraPro S&P500. Recuperado de <https://www.proshares.com/our-etfs/leveraged-and-inverse/upro>. Consultado en julio 2026.
- State Street Global Advisors (2026). SPDR S&P 500 ETF Trust (SPY). Recuperado de <https://www.ssga.com/us/en/intermediary/etfs/spdr-sp-500-etf-trust-spy>. Consultado en julio 2026.

Apéndices

A. Especificación Completa de Variables

Este apéndice documenta el conjunto completo de 92 variables base empleadas en el análisis, todas obtenidas de Bloomberg Terminal. A continuación se describe cada una de las siete categorías que las organizan, su justificación teórica y las variables específicas que las componen.

Índices y ETFs de mercado (18 variables). La dinámica de retornos entre clases de activos, regiones geográficas y sectores económicos puede aportar información predictiva relevante. Los flujos de capital entre mercados desarrollados y emergentes, la rotación sectorial y los movimientos cambiarios reflejan cambios en el apetito por riesgo que frecuentemente anticipan los retornos del mercado amplio. Esta categoría incluye (i) índices de referencia norteamericanos, a saber, SPY (S&P 500), QQQ (Nasdaq-100) e IWM (Russell 2000), que capturan la dispersión entre *large caps*, tecnología y *small caps*; (ii) ETFs internacionales, a saber, EFA (mercados desarrollados ex-US), EEM (mercados emergentes), VGK (Europa), EWJ (Japón) y FXI (China), que reflejan la dinámica global de riesgo; (iii) ETFs sectoriales del S&P 500, a saber, XLF (financiero), XLK (tecnología), XLE (energía), XLV (salud), XLI (industrial) y XLU (servicios públicos), que capturan la rotación sectorial; y (iv) divisas, a saber, DXY (índice dólar), EUR/USD y USD/JPY, que reflejan las condiciones de liquidez global y los diferenciales de política monetaria. Se incluye además el índice FTSE NAREIT (bienes raíces), sensible a las condiciones crediticias.

Indicadores macroeconómicos (19 variables). Las condiciones macroeconómicas fundamentales ejercen una influencia directa sobre los flujos de caja corporativos esperados y, por tanto, sobre la valoración de las acciones. Chen et al. (1986) demostraron que variables como la producción industrial, la inflación y los *spreads* de crédito explican una porción significativa de la variación transversal de retornos accionarios, estableciendo las bases de los modelos multifactoriales macroeconómicos. Esta categoría comprende indicadores de actividad real (PIB trimestral QoQ y YoY, producción industrial, utilización de capacidad y ventas minoristas); indicadores del mercado laboral (nóminas no agrícolas o *Non-Farm Payrolls*, tasa de desempleo, solicitudes iniciales de subsidio de desempleo e ingreso personal); indicadores de precios (IPC interanual y *Core PCE*); indicadores de confianza (sentimiento del consumidor de U. Michigan y confianza del consumidor del Conference Board); indicadores del sector vivienda (inicios de construcción o *Housing Starts*, ventas de vivienda nueva y existente); y los índices PMI manufacturero y de servicios (ISM), junto con el índice Líder Compuesto del Conference Board.

Tasas de interés y curva de rendimiento (20 variables). La estructura temporal de tasas de interés es uno de los predictores macroeconómicos más robustos documentados en la literatura. Harvey (1989) demostró que la pendiente de la curva de rendimiento anticipa recesiones económicas, mientras que Fama & French (1989) establecieron que los *spreads* de crédito y de término predicen retornos accionarios a horizontes intermedios. Esta categoría abarca la tasa de política monetaria (Fed Funds); la curva de rendimiento completa del Tesoro estadounidense, que incluye *T-Bills* a 3, 6 y 12 meses, y bonos a 2, 5, 10 y 30 años; los índices de rendimiento genérico de Bloomberg para los vencimientos a 10 y 2 años (USGG10YR y USGG2YR), que a diferencia

de los bonos individuales *on-the-run* reflejan un compuesto de emisiones cercanas a cada plazo; los *spreads* de término precalculados (10Y–2Y y 10Y–3M); la tasa interbancaria a corto plazo (Libor 3M) y la *tasa swap* a 10 años; los índices de *credit default swaps*, a saber, CDX *Investment Grade* y CDX *High Yield*, que capturan la percepción de riesgo crediticio corporativo; y los índices de bonos Bloomberg (US Aggregate Total Return, US Aggregate OAS, US Corporate Total Return), junto con el ETF LQD (*investment grade* corporativo).

Commodities (11 variables). Los precios de las materias primas operan como indicadores adelantados de presiones inflacionarias y cambios en la actividad económica global. Los movimientos en energía anticipan costos de producción; los metales preciosos reflejan la demanda por activos refugio; y la actividad en los mercados de futuros de *commodities* contiene información predictiva sobre condiciones macroeconómicas y precios de activos (Hong & Yogo, 2012). Se incluyen futuros de energía (WTI o *crude oil*, y *heating oil*); metales preciosos tanto en futuros (oro, plata) como en ETFs (GLD, SLV); el ETF de petróleo USO; índices amplios de *commodities* (DBC, Bloomberg BCOM y S&P GSCI); y el ETF DBA (agricultura).

Volatilidad (13 variables). La volatilidad implícita constituye una medida directa de la incertidumbre percibida por el mercado y exhibe una relación contemporánea negativa con los retornos accionarios ampliamente documentada en la literatura, el denominado *leverage effect*. Ang et al. (2006) muestran, además, que la exposición al riesgo de volatilidad agregada se refleja en la sección cruzada de retornos esperados. La estructura temporal de la volatilidad, en particular la relación entre VIX de corto y largo plazo, captura cambios en el régimen de riesgo que frecuentemente preceden movimientos direccionales del mercado. Esta categoría comprende el VIX y sus variantes por horizonte temporal, a saber, VIX1M (1 mes), VIX3M (3 meses) y VXV (3 meses, variante), cuya estructura temporal permite identificar inversiones indicativas de estrés; índices de volatilidad implícita para otras clases de activos (VXEEM para mercados emergentes, VXEFA para mercados desarrollados, GVZ para oro, OVX para petróleo, TYVIX para bonos del Tesoro y MOVE para el mercado de renta fija); el CVIX (divisas); el futuro VIX del mes próximo (VIY1); y el V2X (Euro Stoxx 50), que captura el régimen de volatilidad europeo.

Sentimiento de mercado (10 variables). El sentimiento inversor, definido como la propensión a especular no justificada por los fundamentales, genera desviaciones sistemáticas de precios respecto a su valor intrínseco. Baker & Wurgler (2006) demostraron que períodos de alto sentimiento preceden retornos bajos, especialmente en acciones difíciles de arbitrar, lo cual ofrece poder predictivo en la sección cruzada de retornos. Esta categoría incluye la encuesta AAII (*American Association of Individual Investors*) de sentimiento alcista; ratios *put/call* de opciones sobre acciones (CBOE Equity Put/Call y Put Index); indicadores de *breadth* de mercado (NYSE *New High–New Lows*, *Advance–Decline Line*, TICK y TRIN o *Arms Index*); el oscilador McClellan y su índice de sumación, que capturan la amplitud del mercado en múltiples horizontes; y el índice SRVOL (*Short-Range Volatility*), que captura la volatilidad de corto plazo.

Datos OHLCV del SPY y tasa libre de riesgo. Finalmente, se incluyen los cinco campos estándar del registro de precio diario del ETF SPY, a saber, apertura, máximo, mínimo, cierre y volumen (OHLCV), que constituyen la materia prima para el cálculo de indicadores técnicos, estimadores de volatilidad OHLC y características de microestructura. La tasa libre de riesgo,

derivada del *T-Bill* a 3 meses, se utiliza para el cálculo de retornos en exceso que conforman la variable objetivo del sistema.

B. Detalles de Ingeniería de Características

Las 536 características del sistema se derivan de las 92 variables base mediante ocho familias de transformación; a continuación se describe cada una, su motivación y las características que produce.

Indicadores técnicos clásicos (19 características). Los precios en bruto (apertura, máximo, mínimo, cierre y volumen) contienen información que no es directamente accesible para un modelo predictivo en su forma original. Un precio de cierre de \$450 no indica por sí solo si el mercado está sobrecomprado, si la tendencia se está agotando o si el volumen confirma el movimiento. Los indicadores técnicos resuelven esta limitación condensando la historia reciente de precio y volumen en señales interpretables que representan el estado actual del mercado. Para un modelo de *machine learning*, estos indicadores no funcionan como reglas de decisión (“comprar si $RSI < 30$ ”), sino como representaciones compactas del régimen de precio sobre las cuales el modelo puede aprender qué combinaciones de condiciones preceden retornos positivos o negativos.

A partir de los datos OHLCV del SPY y utilizando la librería [TA-Lib](#), se calculan el Índice de Fuerza Relativa (RSI) en ventanas de 7, 14 y 21 días, que mide la magnitud relativa de ganancias frente a pérdidas recientes; la Convergencia/Divergencia de Medias Móviles (MACD) con sus componentes de línea, señal e histograma; el Índice Direccional Medio (ADX) junto con los indicadores direccionales +DI y −DI, que cuantifican la fuerza y dirección de la tendencia; el Oscilador Estocástico (%K, %D) y el Williams %R, que identifican condiciones de sobrecompra y sobreventa; el Índice de Canal de *Commodities* (CCI); el Rango Verdadero Medio (ATR), que mide la volatilidad intradía; el *On-Balance Volume* (OBV), que acumula volumen ponderado por la dirección del precio; y la posición del precio dentro de las Bandas de Bollinger. Estos 19 indicadores constituyen el vocabulario base del análisis técnico sobre el cual se construyen las familias más especializadas que se describen a continuación.

Momentum, retornos y volumen (32 características). Mientras que los indicadores técnicos clásicos describen el *estado* actual del mercado, las características de *momentum* capturan su *inercia*, es decir, la velocidad y dirección del cambio de precio a distintas escalas temporales. Esta distinción es relevante porque la evidencia empírica muestra que el *momentum* opera de forma diferente según el horizonte, dado que a muy corto plazo (1–5 días) los retornos tienden a revertir, a mediano plazo (1–12 meses) tienden a persistir, y a largo plazo (3–5 años) vuelven a revertir. Proveer múltiples ventanas permite a los modelos aprender cuál de estas dinámicas domina en cada régimen de mercado.

Los retornos históricos se calculan mediante la función `pct_change(n)`, que computa el cambio porcentual entre el precio actual y el precio de hace n días hábiles, dado por $r_n[t] = (P[t] - P[t - n]) / P[t - n]$. Se generan retornos para ventanas de 1, 5, 21, 63, 126 y 252 días, junto con sus equivalentes expresados como tasa de cambio porcentual (*Rate of Change*). La distancia del precio a medias móviles de 10, 21, 50, 100 y 200 días captura la posición relativa del precio respecto a su tendencia de largo plazo. Los cruces de medias móviles (*crossovers*), es decir, señales binarias que indican cuándo una media móvil de corto plazo supera o cae por debajo

de una de largo plazo (pares 5/10, 10/21, 20/50, 50/200), codifican cambios de tendencia. La volatilidad realizada se estima como la desviación estándar móvil de retornos diarios, anualizada por $\sqrt{252}$, en ventanas de 5 a 126 días, junto con ratios de volatilidad entre ventanas (5/21 y 21/63) que detectan compresiones o expansiones de volatilidad. Completan esta familia dos características de volumen, a saber, el volumen relativo respecto a su media móvil de 20 y 63 días, que mide si la actividad de mercado reciente es atípicamente alta o baja.

Análisis técnico avanzado (60 características). Los indicadores clásicos descritos anteriormente miden una sola dimensión del mercado a la vez, dado que el RSI captura *momentum*, el ATR captura volatilidad y el OBV captura volumen. Sin embargo, las decisiones de inversión rara vez dependen de una única dimensión, y lo relevante es la *confluencia* de múltiples condiciones simultáneas y el *contexto* en que se producen (posición del precio dentro de un rango histórico, zona de soporte o resistencia, alineación de múltiples señales). Las seis familias que siguen capturan precisamente estas relaciones multidimensionales.

La **Nube de Ichimoku** genera 13 características a partir de cinco líneas calculadas sobre ventanas de 9, 26 y 52 días. La “nube” (espacio entre las líneas Senkou A y B) define zonas de soporte y resistencia dinámicas, y a partir de ella se codifica la posición del precio respecto a la nube (por encima, dentro o por debajo), el espesor de la nube como proporción del precio, las distancias a las líneas de referencia (Tenkan y Kijun) y los cruces entre ellas, que señalan cambios de tendencia. Una variable compuesta indica la confluencia alcista plena, es decir, precio sobre la nube y línea rápida sobre la lenta.

Los **retrocesos de Fibonacci** producen 18 características para ventanas de 63 y 126 días. En cada día se identifica el rango (máximo y mínimo del período) y se calcula la posición relativa del precio dentro de ese rango, su distancia a cada nivel de Fibonacci y variables binarias que indican si el precio se encuentra en una zona de proximidad ($\pm 2\%$) a los niveles 38.2 %, 50 % y 61.8 %, donde las reversiones son estadísticamente más frecuentes.

Los **canales de Donchian** aportan 8 características para períodos de 20 y 55 días, a saber, la posición del precio dentro del canal, su ancho como proporción del precio y señales binarias de ruptura al alza o a la baja. Los **canales de Keltner** complementan con 3 características que miden la posición del precio dentro de bandas basadas en el ATR, e incluyen un indicador de *squeeze* que detecta cuando las Bandas de Bollinger se comprimen dentro de los canales de Keltner, condición que frecuentemente anticipa expansiones de volatilidad.

El **flujo de dinero** se cuantifica mediante 8 características, a saber, el *Money Flow Index* (MFI) en ventanas de 14 y 21 días, un oscilador que pondera el volumen por la dirección del precio **típico** con señales de sobrecompra y sobreventa, y el *Chaikin Money Flow* (CMF) en ventanas de 20 y 50 días, que mide la presión acumulada de compra o venta según dónde cierra el precio dentro del rango intradía. Por último, 10 **señales de confluencia estratégica** codifican combinaciones binarias de condiciones de mercado, incluyendo estados del RSI, posición del precio respecto a medias móviles de largo plazo (SMA-200), cruces dorados y de muerte (SMA-50 vs. SMA-200), fuerza de tendencia ($ADX > 25$) y puntuaciones compuestas que requieren la alineación simultánea de al menos tres condiciones alcistas o bajistas.

Análisis multitemporal Triple Screen (24 características). Se implementa el sistema Triple Screen de [Elder \(1993\)](#), adaptado como generador de características; a diferencia de su uso como estrategia de *trading*, en este estudio se adopta exclusivamente como fuente de variables

predictivas. El principio central de este sistema es que una decisión de inversión mejora cuando se analiza el mercado en múltiples escalas temporales simultáneamente, dado que primero se identifica la tendencia dominante en un horizonte largo, luego se buscan puntos de entrada en un horizonte intermedio, y finalmente se confirma la señal con indicadores de corto plazo. Elder denominó a estos tres niveles de análisis *screens* (filtros), de ahí el nombre del sistema.

En el primer nivel, se simula un horizonte semanal a partir de datos diarios mediante ventanas móviles de cinco días, calculando un MACD con períodos expandidos (multiplicados por 5) para identificar la dirección de la tendencia de fondo. En el segundo nivel, se generan osciladores diarios que miden presiones de corto plazo *dentro* de esa tendencia, a saber, el Índice de Fuerza de Elder en versiones de 2 y 13 períodos, que combina cambio de precio y volumen normalizado por su desviación estándar móvil de 63 días, y el *Elder Ray* (*Bull/Bear Power*), que mide la distancia entre los extremos intradía y la media móvil exponencial (EMA) de 13 períodos. En el tercer nivel, el Sistema de Impulso combina la dirección de la EMA con la del histograma MACD para clasificar cada día como alcista (ambos subiendo), bajista (ambos cayendo) o neutral. La lógica subyacente es que las señales más fiables surgen cuando los tres niveles están alineados, es decir, una tendencia alcista de fondo, un retroceso temporal en los osciladores y una confirmación de impulso diario. Se incluyen además señales puras de Elder, a saber, compra cuando *Bear Power* es negativo pero creciente (anticipación de giro alcista) y venta cuando *Bull Power* es positivo pero decreciente, y un *score* compuesto que cuantifica el grado de alineación entre los tres niveles.

Estimadores de volatilidad OHLC y microestructura (81 características). La volatilidad calculada a partir de retornos *close-to-close*, es decir, la desviación estándar móvil de los retornos diarios ya incluida en la familia de *momentum*, presenta una limitación importante, ya que descarta la información contenida en el movimiento intradía del precio. Un día en que el mercado sube un 3% y luego retrocede para cerrar sin cambios registra retorno cero y, por tanto, volatilidad *close-to-close* nula, a pesar de haber experimentado una dispersión de precio considerable. Los datos OHLC (apertura, máximo, mínimo y cierre) capturan esta información perdida, y la literatura financiera ha producido una secuencia de estimadores progresivamente más eficientes para explotarla.

Parkinson (1980) propone el primer estimador basado exclusivamente en el rango *High-Low*, sugiriendo que es aproximadamente cinco veces más eficiente estadísticamente que la volatilidad *close-to-close*. Garman & Klass (1980) mejoran esta eficiencia incorporando la relación *Close-Open*, que añade información sobre la dirección del movimiento intradía. Ambos estimadores asumen, sin embargo, que la serie no presenta tendencia (*drift*), supuesto frecuentemente violado en mercados accionarios, donde los retornos esperados de largo plazo son positivos. Rogers & Satchell (1991) eliminan esta limitación con un estimador que separa explícitamente el *drift* de la volatilidad. Finalmente, Yang & Zhang (2000) integran los aportes anteriores en un estimador que descompone la varianza total en tres componentes, a saber, *overnight* (el *gap* entre cierre anterior y apertura), *open-to-close* (movimiento intradía direccional) y Rogers-Satchell (dispersión pura), combinados con una ponderación óptima ($k = 0.34$) que minimiza la varianza del estimador. Cada uno de estos cuatro estimadores se calcula en ventanas de 21 y 63 días, produciendo 8 características clásicas.

Un conjunto posterior de trabajos no se limita a estimar la volatilidad puntual, sino que busca extraer características adicionales de la dinámica del rango. Alizadeh et al. (2002) demuestran que

el logaritmo del rango, $\ln(H/L)$, sigue una distribución aproximadamente gaussiana (a diferencia de la volatilidad misma, que es marcadamente asimétrica), lo que permite aplicar herramientas estadísticas estándar (medias, desviaciones, percentiles, momentos de orden superior) directamente sobre esta variable. [Chou \(2005\)](#) modela el rango diario como un proceso autorregresivo condicional (CARR), capturando su persistencia temporal mediante rezagos, innovaciones (rango observado menos rango esperado) e indicadores de *shock* cuando el rango excede dos desviaciones estándar de su distribución reciente. [Fiszeder & Perczak \(2016\)](#) combinan retornos y rango en un marco unificado (*Range-GARCH*), aportando medidas de eficiencia de precio (qué fracción del rango intradía se traduce en retorno direccional) y descomposiciones de la varianza en componentes *overnight* e intradía. [Vinté et al. \(2019\)](#) aplican teoría de información al análisis de la dispersión intradía, midiendo la entropía de la posición del precio dentro del rango diario ponderada por el volumen negociado; un día donde apertura y cierre coinciden con volumen elevado (alta entropía) refleja indecisión activa del mercado, mientras que uno donde el precio recorre el rango completo (baja entropía) refleja convicción direccional. En conjunto, estos estimadores contemporáneos generan 54 características.

Complementan esta dimensión 19 características de **microestructura** que diseccionan la anatomía de cada sesión individual, incluyendo el rango intradía y el *True Range*, la posición del cierre dentro del rango diario (0 = cerró en el mínimo, 1 = cerró en el máximo), la magnitud y dirección de los *gaps overnight* junto con un indicador de si el *gap* fue “llenado” durante la sesión, patrones de velas japonesas (proporción de cuerpo, sombras superior e inferior, detección de *doji*), volumen relativo respecto a promedios de 21 y 63 días, y el producto rango-volumen como indicador compuesto de actividad de mercado.

Relaciones *cross-asset*, VIX y condiciones macro (66 características). Las familias anteriores analizan el S&P 500 en aislamiento, considerando su precio, su volumen y su volatilidad. Sin embargo, el mercado accionario no se mueve de forma independiente, sino que reacciona a flujos de capital entre clases de activos, a cambios en las expectativas de política monetaria y al estado del ciclo económico real. La literatura ha documentado ampliamente estos vínculos; [Chen et al. \(1986\)](#) demuestran que variables macroeconómicas como la producción industrial, la inflación y la estructura de tasas de interés explican una parte significativa de los retornos accionarios; [Fama & French \(1989\)](#) muestran que los *spreads* de crédito y el *dividend yield* predicen retornos del mercado a horizontes de uno a cuatro años; [Baker & Wurgler \(2006\)](#) documentan que el sentimiento del inversor afecta la sección transversal de retornos esperados; y [Hong & Yogo \(2012\)](#) encuentran que la actividad en los mercados de *commodities* anticipa movimientos en el mercado accionario. Sin estas variables, el modelo solo observa el precio del SPY; con ellas, dispone del contexto de otras clases de activos que podrían influir en su comportamiento.

Las relaciones *cross-asset* se cuantifican mediante correlaciones móviles entre los retornos del SPY y cinco activos de referencia (bonos del Tesoro a 10 años, oro, petróleo, dólar y VIX) en ventanas de 21 y 63 días. Estas correlaciones son dinámicas, dado que en períodos de *risk-off* acciones y bonos se descorrelacionan (los inversores venden renta variable y compran deuda soberana como refugio), mientras que en períodos de *risk-on* la correlación se estrecha. Las características del VIX incluyen cambios a 1, 5 y 21 días, indicadores de régimen basados en percentiles históricos (percentil 75 y 25 sobre una ventana móvil de 252 días), la estructura temporal (en particular la relación VIX3M/VIX, donde un ratio mayor a 1 indica *contango* y un ratio menor a 1 indica *backwardation*) y la prima de riesgo de volatilidad, definida como la

diferencia entre la volatilidad implícita y la volatilidad realizada.

Se incorporan características de la curva de rendimiento, el predictor macroeconómico de recesiones más documentado en la literatura (Harvey, 1989), incluyendo el *spread* 10Y–2Y y 10Y–3M, indicadores de inversión y el *butterfly* 2–5–10, junto con *spreads* de crédito (*investment grade* y *high yield*) cuya ampliación anticipa deterioro en las condiciones financieras. Los indicadores macroeconómicos se transforman en características de *momentum* (cambio a 21 y 63 días) y tendencia (cruce de media móvil de 5 contra 21 días) para siete indicadores clave (PIB, PMI, empleo, desempleo, IPC, producción industrial y confianza del consumidor). Completan esta familia cuatro indicadores compuestos de régimen de mercado (basados en precio vs. MA-200, *momentum*, nivel del VIX y proporción de sectores positivos) y términos de interacción entre variables ($VIX \times$ curva de rendimiento, *momentum* condicionado a régimen de volatilidad).

Variables rezagadas y estadísticos móviles (78 características). Esta familia aplica dos tipos de transformaciones diseñadas para enriquecer la representación temporal de las variables y facilitar el aprendizaje de los modelos.

La primera transformación genera **variables rezagadas** (*lags*) que proporcionan al modelo memoria explícita del estado pasado de las variables. Formalmente, un *lag* de orden n desplaza la serie temporal n días hacia el pasado, dado por $X_{\text{lag}(n)}[t] = X[t - n]$. Por ejemplo, $VIX_lag5[t]$ contiene el nivel del VIX de hace cinco días hábiles. Se generan *lags* para 18 variables clave, entre ellas tasas de interés a lo largo de la curva (Fed Funds, T-Bills, bonos a 2, 5, 10 y 30 años), VIX, índices de mercado (Russell 2000, EFA, EEM, XLF, XLU) e indicadores económicos (PIB, NFP, ventas minoristas), en tres horizontes (1, 5 y 21 días), totalizando 54 características. Estos *lags* permiten a los modelos detectar patrones de cambio temporal; por ejemplo, si el VIX se disparó hace 5 días pero ha revertido a su nivel actual, esa trayectoria contiene información predictiva que el valor contemporáneo por sí solo no captura.

La segunda transformación calcula **estadísticos móviles** (*rolling statistics*) mediante ventanas móviles (*rolling windows*) de 21 y 63 días. Para cada día t y cada ventana de tamaño w , se computa la media $\bar{X}_w[t] = \frac{1}{w} \sum_{i=0}^{w-1} X[t - i]$ y la desviación estándar $s_w[t]$ sobre las últimas w observaciones. La media móvil suaviza las fluctuaciones diarias y revela la tendencia subyacente de la variable; por ejemplo, una media móvil de 63 días del VIX indica su nivel típico del último trimestre, permitiendo distinguir si el valor actual está por encima o por debajo de lo habitual. La desviación estándar móvil cuantifica cuán estable o volátil ha sido la variable en el período reciente. Se aplican estas transformaciones a un subconjunto de variables de referencia, generando 24 características.

Transformaciones adicionales y factores (176 características). Las variables en bruto descritas en la Sección 3.1.1 capturan *niveles*, como el precio del oro hoy, la tasa de desempleo este mes o el VIX esta mañana. Sin embargo, los modelos predictivos aprenden con mayor facilidad a partir de *cambios* que de *niveles*, por dos razones. En primer lugar, los cambios son más estacionarios que los niveles (un retorno del 2 % tiene el mismo significado en 2005 que en 2025, mientras que un precio de \$150 no). En segundo lugar, los cambios capturan la dinámica reciente de la variable, que es la información predictivamente más relevante para horizontes cortos.

Todas las variables base de interés reciben un conjunto uniforme de dos transformaciones, a saber, cambio porcentual diario (**pct_change**) y *momentum* a 5 días (diferencia entre el valor

actual y el de hace 5 días). Se añaden características de factores de estilo, inspiradas en la literatura de *asset pricing*. Estas incluyen el *spread* valor/crecimiento (diferencial de retornos entre XLF y XLK como *proxies* de *value* y *growth*), tamaño (*small vs. large cap*, IWM vs. SPY) y *momentum* tecnológico (rendimiento relativo de XLK frente al mercado amplio). Completan esta familia características adicionales del sistema Elder y extensiones de las variables de VIX y curva de rendimiento.

C. Hiperparámetros de Modelos

A continuación se detallan los hiperparámetros de cada uno de los 23 modelos evaluados. Para los modelos que emplean *GridSearchCV*, se presenta el *grid* de búsqueda explorado mediante validación cruzada temporal (*TimeSeriesSplit* con 5 *folds*) sobre el conjunto de entrenamiento, junto con los parámetros fijos establecidos en el constructor del modelo. Para los modelos restantes se documentan los parámetros explícitamente configurados en el código.

C.1 Esquema de Escalado por Familia

Cada familia de modelos requiere un preprocesamiento específico según las restricciones de su arquitectura. Los modelos lineales regularizados necesitan normalización para que las penalizaciones L_1/L_2 operen equitativamente sobre todas las características. Los modelos de *deep learning* requieren además escalar la variable objetivo, dado que los retornos diarios tienen magnitudes del orden de 10^{-3} y la función de pérdida MSE sobre valores tan pequeños produce gradientes insuficientes para un aprendizaje efectivo. Los modelos basados en árboles son teóricamente invariantes a la escala, ya que sus decisiones se basan en umbrales de orden. Los modelos univariados operan exclusivamente sobre la serie de retornos en exceso sin transformación adicional. La Tabla 11 sintetiza el esquema aplicado.

Tabla 11: Esquema de escalado por familia de modelos. Todos los escaladores se ajustan exclusivamente sobre el conjunto de entrenamiento.

Familia	Features	Target	Reescalado*
Tabulares (8)	<i>StandardScaler</i>	sin escalar	no
PyTorch custom (4)	<i>StandardScaler</i>	<i>StandardScaler</i>	sí
Darts DL (5)	<i>MinMaxScaler</i> [0, 1]	<i>MinMaxScaler</i> [0, 1]	sí
Univariados (6)	no usan	sin escalar	no

*Indica si las predicciones requieren transformación inversa para volver a la escala original de retornos antes de la evaluación.

C.2 Modelos de Regresión Lineal Regularizada (*GridSearchCV*)

Tabla 12: Ridge, parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
<i>Grid</i>	alpha	{0.01, 0.1, 1, 10, 100}

Tabla 13: Lasso, parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	max_iter	5,000
Grid	alpha	$\{10^{-7}, 10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}\}$

Tabla 14: ElasticNet, parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	max_iter	50,000
Fijo	tol	10^{-3}
Fijo	selection	'random'
Grid	alpha	$\{10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}\}$
Grid	l1_ratio	$\{0.3, 0.5, 0.7, 0.9\}$

C.3 Modelos *Ensemble* (*GridSearchCV*)

Tabla 15: RandomForest, parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	n_jobs	-1 (todos los núcleos)
Grid	n_estimators	$\{100, 200, 500\}$
Grid	max_depth	$\{10, 20, 50, \text{None}\}$

Tabla 16: GradientBoosting, parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Grid	n_estimators	$\{100, 200, 500\}$
Grid	learning_rate	$\{0.01, 0.05, 0.1\}$
Grid	max_depth	$\{3, 5, 10, 15\}$
Grid	subsample	$\{0.8, 1.0\}$

C.4 Modelos de *Gradient Boosting* Especializado

Tabla 17: XGBoost (*GridSearchCV*), parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	n_jobs	-1
Fijo	tree_method	'hist'
Grid	n_estimators	$\{100, 200\}$
Grid	learning_rate	$\{0.01, 0.05\}$
Grid	max_depth	$\{3, 5\}$

Tabla 18: LightGBM (*GridSearchCV*), parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	n_jobs	-1
Fijo	verbosity	-1
<i>Grid</i>	n_estimators	{100, 200, 500}
<i>Grid</i>	learning_rate	{0.01, 0.05, 0.1}
<i>Grid</i>	num_leaves	{31, 63, 127}

Tabla 19: CatBoost, parámetros explícitos (sin *GridSearchCV*)

Parámetro	Valor
iterations	200
learning_rate	0.05
depth	6
random_state	42
verbose	0

C.5 Modelos de Series Temporales (Darts Clásicos)

Tabla 20: Hiperparámetros de modelos de series temporales clásicos

Modelo	Parámetro	Valor
AutoARIMA	—	Parámetros por defecto de Darts (selección automática de p, d, q)
ExponentialSmoothing	seasonal_periods (resto)	None Parámetros por defecto de Darts
Theta	—	Parámetros por defecto de Darts (los valores negativos del <i>target</i> se desplazan hacia valores positivos antes del ajuste)
Prophet	—	Parámetros por defecto de Darts
SeasonalNaive	K	5 (rezago semanal en días hábiles) Modelo sin parámetros entrenables, que replica el valor observado K períodos atrás

C.6 GARCH (*arch library*)

Tabla 21: Hiperparámetros de GARCH

Parámetro	Valor
vol	'Garch'
p	1 (rezagos del término GARCH)
q	1 (rezagos del término ARCH)
mean	'AR' (modelo de media autoregresivo)
lags	1 (rezagos del componente AR)

Los retornos se escalan a porcentaje ($\times 100$) antes del ajuste para estabilidad numérica. Las predicciones de prueba se generan mediante predicción *one-step-ahead* re-estimando el modelo

con una ventana móvil de hasta 500 observaciones.

C.7 Modelos de *Deep Learning* (Darts)

Todos los modelos de *deep learning* de Darts comparten la configuración base descrita en la Tabla 22. Los parámetros de arquitectura no listados explícitamente conservan sus valores por defecto según la implementación de Darts 0.41.

Tabla 22: Configuración común de modelos Darts *Deep Learning*

Parámetro	Valor
input_chunk_length	30
output_chunk_length	21
n_epochs	100 (máximo)
batch_size	32
random_state	42
force_reset	True
<i>Early stopping</i>	PLEarlyStopping(monitor='train_loss', patience=5, mode='min')
gradient_clip_val	1.0

Tabla 23: Parámetros específicos de cada modelo Darts *Deep Learning*

Modelo	Parámetro específico	Valor
DLinear	—	Solo parámetros comunes (Tabla 22)
N-BEATS	—	Solo parámetros comunes (arquitectura por defecto de Darts)
N-HiTS	—	Solo parámetros comunes (arquitectura por defecto de Darts)
TCN	—	Solo parámetros comunes (arquitectura por defecto de Darts)
TFT	add_relative_index	True

C.8 Modelos *Custom* PyTorch

Los cuatro modelos *custom* de PyTorch comparten la configuración de entrenamiento descrita en la Tabla 24. A continuación se detallan los parámetros de arquitectura específicos de cada modelo.

Tabla 24: Configuración común de entrenamiento PyTorch *custom*

Parámetro	Valor
sequence_length (<i>lookback</i>)	30
n_epochs	100 (máximo)
batch_size	32
optimizador	Adam
learning_rate	0.0005
weight_decay	10^{-5}
scheduler	ReduceLROnPlateau(patience=5, factor=0.5)
early stopping	patience=10 (sobre pérdida de entrenamiento)
gradient_clip_norm	1.0
función de pérdida	MSELoss
escalado del <i>target</i>	StandardScaler (ajustado solo en <i>train</i>)

Tabla 25: CNN-LSTM, arquitectura

Componente	Parámetro	Valor
Conv1d (capa 1)	n_filters	128
	kernel_size	3 (padding=1)
Conv1d (capa 2)	n_filters	256 (128×2)
	kernel_size	3 (padding=1)
MaxPool1d	kernel_size	2
Dropout (CNN)	p	0.2
LSTM	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	False
Capa densa	Linear	hidden_dim $\rightarrow$ 1

Tabla 26: LSTM+Attention (Luong), arquitectura

Componente	Parámetro	Valor
LSTM	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	True
Atención	tipo	<i>dot-product</i> (Luong)
	dimensión	hidden_dim $\times$ 2 = 256
Dropout (salida)	p	0.2
Capa densa	Linear	hidden_dim $\times$ 2 $\rightarrow$ 1

Tabla 27: BiLSTM, arquitectura

Componente	Parámetro	Valor
LSTM	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	True
Dropout (salida)	p	0.1
Capa densa	Linear	hidden_dim $\times$ 2 $\rightarrow$ 1

Tabla 28: BiGRU, arquitectura

Componente	Parámetro	Valor
GRU	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	True
Dropout (salida)	p	0.1
Capa densa	Linear	hidden_dim $\times$ 2 $\rightarrow$ 1

C.9 Configuración de Entrenamiento Común

Tabla 29: Configuración general de entrenamiento

Parámetro	Valor
Período de entrenamiento	Enero 2000 a septiembre 2020
Período de prueba	Octubre 2020 a diciembre 2025
División temporal	80/20 sin <i>shuffle</i> , estrictamente cronológica
Validación cruzada	TimeSeriesSplit, 5 <i>folds</i> (modelos con <i>GridSearchCV</i>)
Imputación	SimpleImputer(strategy='median')
Normalización	StandardScaler, ajustado solo en <i>train</i>
<i>Early stopping</i> (Darts DL)	PLEarlyStopping, patience=5
<i>Early stopping</i> (PyTorch <i>custom</i>)	patience=10
Semilla	42 (NumPy, PyTorch, sklearn)

C.10 Entorno Computacional

Tabla 30: Especificaciones del entorno computacional

Componente	Especificación
Instancia	AWS EC2 g4dn.xlarge
GPU	NVIDIA T4 (16 GB VRAM)
CPU	4 vCPUs (Intel Cascade Lake)
RAM	16 GB
Python	3.12
PyTorch	2.6 (CUDA)
Darts	0.41
scikit-learn	1.7.2
Formato modelos sklearn/ <i>boosting</i>	.joblib
Formato modelos Darts	directorios nativos
Formato modelos PyTorch	.pt
Metadata y predicciones	trained_artifacts.pkl

Nota: Todos los modelos se entrenaron en esta instancia. Los modelos de deep learning aprovechan la aceleración GPU mediante CUDA, mientras que los modelos clásicos utilizan CPU. Todas las dependencias se fijan con versiones exactas (==) en requirements.txt para garantizar reproducibilidad.

D. Parámetros Óptimos de Umbral

Los umbrales de posicionamiento (q_{extreme} , q_{moderate}) se determinan dinámicamente para cada modelo y cada día del período de prueba mediante un metamodelo *K-Nearest Neighbors* (KNN) entrenado exclusivamente con datos del período de entrenamiento. A continuación se detallan los parámetros del procedimiento y las configuraciones resultantes.

D.1 Metodología de Optimización mediante Meta-KNN

La descripción narrativa completa del procedimiento, incluyendo la construcción del meta-dataset y las siete *meta-features* que describen el régimen predictivo de cada ventana, se presenta en la Sección 3.4.2; este apéndice documenta la especificación exacta empleada. El espacio de búsqueda comprende las 26 combinaciones válidas con $q_{\text{extreme}} \in \{5, 10, 15, 20, 25, 30\}$, $q_{\text{moderate}} \in \{20, 30, 40, 50, 60\}$ y la restricción $q_{\text{moderate}} > q_{\text{extreme}}$, dado que la posición apalancada exige mayor convicción que la moderada. El metamodelo emplea $K = 5$ vecinos ponderados por distancia inversa sobre *meta-features* estandarizadas mediante *StandardScaler*, con ventanas deslizantes de 63 días que avanzan en pasos de 21 y un horizonte de evaluación de otros 63 días, lo que produce alrededor de 242 muestras de entrenamiento por modelo.

Para cada ventana de evaluación del meta-dataset se selecciona la combinación que maximiza el *Sharpe ratio* penalizado.

$$\text{score}(q_{\text{ext}}, q_{\text{mod}}) = \begin{cases} \text{Sharpe}(R_{\text{net}}) - 0,5 & \text{si MaxDD} > 20\% \\ \text{Sharpe}(R_{\text{net}}) & \text{en caso contrario} \end{cases} \quad (16)$$

La penalización de 0,5 desincentiva combinaciones que generan *drawdowns* excesivos. Se aplica además un filtro basado en la desviación estándar *rolling* de las predicciones; si $\sigma_{\text{rolling},63} < \tau = 0,001$, la estrategia se posiciona en efectivo con independencia de los umbrales predichos por el

KNN, lo que protege contra predicciones cuasiconstantes que generarían percentiles aleatorios.

D.2 Tabla de Parámetros Dinámicos

La Tabla 31 presenta los parámetros dinámicos más frecuentes para cada modelo.

Tabla 31: Parámetros Óptimos de Umbral por Modelo

Modelo	Categoría	q_{3x} (%)	q_{1x} (%)	Interpretación
LSTM_Attention	Deep learning	5	50	Top 5 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
Ridge	ML clásico	20	30	Top 20 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
RandomForest	ML clásico	5	40	Top 5 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
CNN_LSTM	Deep learning	20	40	Top 20 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
DLinear	Deep learning	5	60	Top 5 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
GradientBoosting	Boosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
CatBoost	Boosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
Theta	Series temporales	15	60	Top 15 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
NBEATS	Deep learning	10	20	Top 10 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
SeasonalNaive [†]	Series temporales	5	60	Top 5 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
Lasso	ML clásico	5	40	Top 5 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
GARCH	Series temporales	5	30	Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
LightGBM	Boosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
NHiTS	Deep learning	5	60	Top 5 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
AutoARIMA	Series temporales	10	30	Top 10 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
TCN	Deep learning	5	30	Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
TFT	Deep learning	20	60	Top 20 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
Prophet	Series temporales	15	60	Top 15 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
ElasticNet	ML clásico	10	60	Top 10 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
XGBoost	Boosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
BiLSTM	Deep learning	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
ExponentialSmoothing	Series temporales	30	60	Top 30 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
BiGRU	Deep learning	30	40	Top 30 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x

Nota: q_{3x} = percentil para posición UPRO (3x). q_{1x} = percentil para posición SPY (1x). Predicciones por debajo del percentil q_{1x} resultan en posición Cash (0). [†]SeasonalNaive = *benchmark* de complejidad mínima. Parámetros mostrados corresponden a la combinación más frecuente seleccionada por el Meta-KNN dinámico; los umbrales reales varían por día.

D.3 Ejemplos Ilustrativos de la Estrategia

Ejemplo de umbrales dinámicos con Ridge. Para ilustrar cómo los umbrales se adaptan al contexto, considérese el modelo Ridge durante cinco días consecutivos. En t , $t+1$ y $t+2$, el mercado presenta baja volatilidad; el Meta-KNN identifica este patrón como similar a ventanas históricas donde los umbrales ($q_{\text{extreme}}=20$, $q_{\text{moderate}}=30$) resultaron óptimos, es decir, UPRO si el percentil ≥ 80 y SPY si ≥ 70 . En $t+3$, un incremento en la volatilidad del mercado altera las *meta-features* y el KNN selecciona (10, 40), lo que implica UPRO si ≥ 90 y SPY si ≥ 60 . La Tabla 32 ilustra cómo un mismo percentil puede generar posiciones distintas según los umbrales vigentes.

Tabla 32: Ejemplo de Conversión de Predicciones a Posiciones con Umbrales Dinámicos (Ridge)

Día	$\hat{y}_t$	Pctil	$(q_{\text{ext}}, q_{\text{mod}})$	Umbrales	Posición
t	-0.005	45	(20, 30)	≥ 80 / ≥ 70	Cash
$t+1$	+0.002	74	(20, 30)	≥ 80 / ≥ 70	SPY (+1)
$t+2$	+0.004	91	(20, 30)	≥ 80 / ≥ 70	UPRO (+3)
$t+3$	+0.003	84	(10, 40)	≥ 90 / ≥ 60	SPY (+1)
$t+4$	-0.000	53	(10, 40)	≥ 90 / ≥ 60	Cash

Nótese que la predicción de $t+2$ (percentil 91) activa la posición apalancada bajo los umbrales (20, 30), pero en $t+3$ un percentil de 84 (que habría activado UPRO bajo esos mismos umbrales) genera solo posición SPY porque el Meta-KNN ha elevado el requisito a percentil ≥ 90 al detectar un cambio en las condiciones de mercado. Este mecanismo adapta automáticamente no solo la escala de las predicciones (función del percentil *rolling*) sino también la agresividad del posicionamiento (función de los umbrales dinámicos).

La Tabla 2 resume las características de los cuatro modelos que superan al *benchmark* SPY Buy & Hold (+101 %, Sharpe 0,66) con la metodología Meta-KNN. La diversidad en el número de combinaciones empleadas refleja la naturaleza dinámica del sistema, dado que LSTM+Attention utiliza 22 configuraciones distintas de umbrales a lo largo de los 1,302 días de prueba, con su combinación más frecuente representando apenas el 26,5 % de los días, mientras que RandomForest mantiene una configuración dominante el 83,9 % del tiempo. Ninguno de estos cuatro modelos se ve afectado significativamente por el filtro de calidad, puesto que todos superan τ al menos el 53 % de los días, lo que sugiere que sus predicciones contienen variación susceptible de ser explotada por el sistema de percentiles.

Ejemplo de *backtesting* con costos de transacción. Para ilustrar la interacción entre posiciones, retornos y costos, la Tabla 33 presenta cinco días consecutivos hipotéticos del modelo LSTM+Attention. Se supone que el Meta-KNN selecciona la configuración ($q_{\text{extreme}} = 5$, $q_{\text{moderate}} = 20$) durante estos días, lo que implica que la posición UPRO se activa cuando el percentil alcanza o supera 95 y la posición SPY cuando alcanza o supera 80. Se parte de un capital inicial de \$10,000 y una tasa libre de riesgo diaria de $r^f = 0,02\%$ ($\approx 5\%$ anual).

Tabla 33: Ejemplo de *Backtesting*, Cinco Días con LSTM+Attention

Día	Pctil	Pos.	r_t^{SPY}	Cambio	Costos	r_t^{estrat}	Capital
t	62	Cash	+0.80 %	—	0 bps	+0.02 %	\$10,002
$t+1$	83	SPY	+1.20 %	Cash→SPY	2 bps	+1.18 %	\$10,120
$t+2$	96	UPRO	+0.50 %	SPY→UPRO	10 bps	+1.36 %	\$10,257
$t+3$	97	UPRO	-0.30 %	—	3 bps	-0.97 %	\$10,157
$t+4$	71	Cash	+0.40 %	UPRO→Cash	5 bps	-0.03 %	\$10,154

Nota: La columna Costos muestra los costos totales diarios redondeados a puntos básicos. En t , la estrategia está en Cash y gana solo r^f , evitando el +0.80 % del mercado. En $t+2$, la posición 3x amplifica el exceso de retorno: $3 \times (0.50\% - 0.02\%) = +1.44\%$, más r^f da +1.46 % bruto; se restan 10 bps de costos: 7 bps de bid-ask (salida de SPY + entrada a UPRO) y 3 bps de volatility drag. En $t+3$, sin cambio de posición, los costos se reducen a 3 bps diarios de volatility drag; la amplificación 3x opera en contra: $3 \times (-0.32\%) = -0.96\%$ de exceso, produciendo -0.94 % bruto. En $t+4$, la salida de UPRO cuesta 5 bps de spread, que exceden la tasa libre de riesgo (+0.02 %), resultando en un retorno neto ligeramente negativo (-0.03 %).

Este ejemplo ilustra un principio central de la estrategia, a saber, la selectividad temporal.

El modelo LSTM+Attention permanece en efectivo el 55,1 % del tiempo, buscando capturar los momentos donde las *meta-features* y las condiciones de mercado se asemejan a períodos históricos de alto rendimiento. El costo de esta selectividad (perder días alcistas como t y $t+4$) se compensa con la evitación de días bajistas y la amplificación 3x en los días de alta convicción correcta. El análisis completo del impacto de costos sobre los 23 modelos se presenta en la Sección 5.3.

D.4 Análisis de Parámetros

D.4.1 Diversidad de Umbrales por Modelo

La naturaleza dinámica del Meta-KNN implica que cada modelo utiliza múltiples combinaciones de umbrales a lo largo del período de prueba. Se distinguen tres patrones.

1. **Modelos altamente dinámicos** (>15 combinaciones), entre los que destacan LSTM+Attention (22), Ridge (21) y CNN-LSTM (18). El KNN adapta activamente los umbrales a las condiciones cambiantes. Predominan las arquitecturas de *deep learning* y modelos lineales con predicciones ricas.
2. **Modelos moderadamente dinámicos** (5–15 combinaciones), entre los que destacan CatBoost (10), Theta (9), SeasonalNaive (7), LightGBM (7) y GARCH (7). El KNN encuentra un rango limitado de configuraciones útiles.
3. **Modelos estáticos o filtrados** (<5 combinaciones o mayoritariamente en Cash), entre los que destacan RandomForest (4), XGBoost (4), NBEATS (2), NHiTS (1), GradientBoosting (1) y AutoARIMA (0, 100 % filtrado). Predicciones insuficientemente variables o patrón dominante claro.

D.4.2 Implicaciones

- **Alta diversidad + buen rendimiento.** El modelo captura distintos regímenes de mercado y el KNN adapta los umbrales adecuadamente (LSTM+Attention con 22 combinaciones y +395 %).
- **Baja diversidad + buen rendimiento.** Una configuración robusta funciona consistentemente (RandomForest con 4 combinaciones y +128 %).
- **Filtrado mayoritario.** Predicciones cuasiconstantes impiden la generación de señales, y el filtro de calidad protege correctamente (AutoARIMA permanece 100 % en Cash).

D.5 Interpretación de los Umbrales Dinámicos

D.5.1 Significado de los Percentiles

Para LSTM+Attention, cuya combinación más frecuente es ($q_{\text{extreme}}=5$, $q_{\text{moderate}}=50$).

- **Predicción en top 5 %.** Posición UPRO (3x *leverage*)
- **Predicción en top 5–50 %.** Posición SPY (1x)
- **Predicción debajo del top 50 %.** Cash (tasa libre de riesgo)

Sin embargo, estos umbrales varían dinámicamente. En períodos de alta volatilidad, el KNN puede seleccionar (5, 20), reservando SPY solo para el top 20 %, mientras que en períodos estables puede ampliar a (20, 60), adoptando mayor exposición. El modelo utilizó 22 combinaciones distintas a lo largo del período de prueba, lo que indica una adaptación activa a las condiciones de mercado.

D.5.2 Percentiles vs Valores Absolutos

El uso de percentiles *rolling* en lugar de umbrales fijos tiene ventajas.

1. **Adaptabilidad.** Se ajusta automáticamente a cambios en la distribución de predicciones.
2. **Robustez.** Menos sensible a *drift* en el modelo.
3. **Normalización.** Permite comparar la convicción de modelos con escalas muy distintas.

Combinados con los umbrales dinámicos del Meta-KNN, los percentiles *rolling* proporcionan un sistema de posicionamiento doblemente adaptativo, tanto a la escala del modelo (vía percentiles) como a las condiciones de mercado (vía KNN).

E. Tablas y Figuras Complementarias

Este apéndice reúne las tablas de soporte y figuras complementarias referenciadas en el cuerpo del trabajo, organizadas según la sección a la que complementan.

E.1 Figuras Complementarias de la Revisión de Literatura




Figura 4: Distribución del arcoseno, donde la probabilidad de que un camino aleatorio permanezca en territorio de precios altos o bajos es mucho mayor que la de oscilar simétricamente alrededor del precio inicial, generando tendencias persistentes de manera natural. Adaptado de [CMT Association \(2020\)](#).

E.2 Tablas y Figuras de Resultados Empíricos

Tabla 34: Distribución de Posiciones por Modelo (Estrategia Long-Only)

Modelo	UPRO (3x)	SPY (1x)	Cash (0)	Total Long	N° Trades
LSTM_Attention	12.2 %	32.7 %	55.1 %	44.9 %	465
Ridge	20.8 %	17.0 %	62.3 %	37.7 %	409
RandomForest	5.2 %	16.9 %	77.9 %	22.1 %	175
CNN_LSTM	12.1 %	28.6 %	59.3 %	40.7 %	633
DLinear	6.6 %	52.2 %	41.2 %	58.8 %	788
GradientBoosting	4.2 %	4.0 %	91.9 %	8.1 %	11
CatBoost	4.0 %	9.1 %	86.9 %	13.1 %	224
Theta	2.3 %	2.2 %	95.5 %	4.5 %	36
NBEATS	13.9 %	10.3 %	75.8 %	24.2 %	507
SeasonalNaive [†]	20.2 %	39.7 %	40.0 %	60.0 %	1042
Lasso	1.4 %	4.8 %	93.9 %	6.1 %	90
GARCH	1.7 %	6.2 %	92.1 %	7.9 %	126
LightGBM	3.7 %	6.3 %	90.0 %	10.0 %	134
NHiTS	7.1 %	52.4 %	40.4 %	59.6 %	805
AutoARIMA	0.0 %	0.0 %	100.0 %	0.0 %	0
TCN	7.7 %	20.7 %	71.6 %	28.4 %	383
TFT	21.4 %	38.7 %	39.9 %	60.1 %	804
Prophet	2.3 %	8.8 %	88.9 %	11.1 %	77
ElasticNet	3.7 %	9.4 %	86.9 %	13.1 %	175
XGBoost	29.1 %	3.8 %	67.1 %	32.9 %	42
BiLSTM	12.1 %	20.1 %	67.8 %	32.2 %	546
ExponentialSmoothing	26.7 %	45.3 %	28.0 %	72.0 %	904
BiGRU	15.7 %	27.5 %	56.8 %	43.2 %	752

Nota: Porcentajes representan la proporción de días en cada posición. UPRO = 3x apalancado largo, SPY = 1x largo, Cash = tasa libre de riesgo. [†]SeasonalNaive = *benchmark* de complejidad mínima. Número de trades = cambios de posición.

Tabla 35: Estadísticas de Trading por Modelo (Top 5)

Modelo	N Trades	Win Rate	Avg Win	Avg Loss	Profit Factor
LSTM+Attention	465	53.9 %	+1.5 %	−1.2 %	1.52
Ridge	409	55.8 %	+1.9 %	−1.8 %	1.35
RandomForest	175	52.8 %	+1.6 %	−1.2 %	1.49
CNN-LSTM	633	51.4 %	+1.4 %	−1.1 %	1.29
DLinear	788	53.6 %	+0.9 %	−0.9 %	1.16

Nota: N Trades = cambios de posición. Win Rate, Avg Win, Avg Loss y Profit Factor calculados sobre días activos (posición $\neq 0$). Profit Factor = $|Avg Win / Avg Loss|$.

Tabla 36: Modelos Ganadores vs Múltiples Benchmarks

Estrategia	Ret. Total	Sharpe	Max DD	Calmar
LSTM+Attention	+395 %	1.32	−20.5 %	1.77
Ridge	+253 %	0.86	−31.8 %	0.87
RandomForest	+128 %	0.65	−15.0 %	1.15
CNN-LSTM	+122 %	0.57	−35.9 %	0.47
SPY Buy & Hold	+101.3 %	0.66	−25.4 %	0.57
UPRO 3x (B&H)	+122.8 %	0.26	−69.0 %	0.24
60/40 Portfolio	+70.6 %	0.67	−21.1 %	0.52

Nota: UPRO 3x B&H incluye expense ratio (0.91 %/año) y bid-ask spread; el volatility decay está implícito en la composición diaria de retornos 3×. 60/40 = 60 % SPY + 40 % LF98TRUU Index (Bloomberg US Aggregate Bond Total Return) con rebalanceo mensual.




Figura 5: Distribución de retornos diarios en exceso sobre la tasa libre de riesgo del modelo LSTM+Attention. Histograma calculado sobre los días activos (posición $\neq 0$). Verde = días ganadores, Rojo = días perdedores. Línea vertical en 0 %.

E.3 Tablas de Gestión de Riesgo

Tabla 37: Value at Risk y Expected Shortfall al 95 % por horizonte temporal

Modelo	VaR 95 % (30d)	CVaR 95 % (30d)	VaR 95 % (90d)	CVaR 95 % (90d)
LSTM+Attention	−6.18 %	−10.39 %	−3.77 %	−6.51 %
Ridge	−11.25 %	−19.71 %	−14.33 %	−21.88 %
RandomForest	−3.87 %	−5.75 %	−0.67 %	−3.18 %
CNN-LSTM	−9.02 %	−14.84 %	−16.29 %	−23.05 %
SPY (B&H)	−7.81 %	−10.83 %	−10.80 %	−13.85 %

Nota: VaR y CVaR calculados sobre retornos acumulados en ventanas móviles de 30 y 90 días de operación (1,272 y 1,212 ventanas respectivamente).

Tabla 38: Análisis de máximo *drawdown* por modelo

Modelo	MaxDD	Pico	Valle	Duración	Recuperación
LSTM+Attention	−20.5 %	2025-02-18	2025-04-07	34 días	1 día
Ridge	−31.8 %	2021-09-14	2022-03-07	120 días	56 días
RandomForest	−15.0 %	2022-04-01	2022-05-19	33 días	23 días
CNN-LSTM	−35.9 %	2022-03-24	2022-07-15	77 días	566 días
SPY (B&H)	−25.4 %	2021-12-31	2022-10-11	195 días	318 días

Nota: Duración = días de operación desde el pico hasta el valle. Recuperación = días desde el valle hasta alcanzar un nuevo máximo.

E.4 Tablas de Validación Estadística

Tabla 39: Intervalos de confianza del Sharpe Ratio (*bootstrap* 95 %, $B = 5,000$)

Modelo	Sharpe	IC 95 % Inf	IC 95 % Sup	P(S>0)	P(S>SPY)
LSTM+Attention	1.319	0.375	2.424	99.6 %	83.1 %
Ridge	0.856	−0.121	2.115	94.9 %	60.4 %
RandomForest	0.651	−0.218	1.480	93.3 %	49.9 %
CNN-LSTM	0.572	−0.292	1.485	89.3 %	44.4 %
SPY (B&H)	0.657	−0.253	1.730	91.4 %	—

Nota: $P(S>0)$ = probabilidad de Sharpe positivo. $P(S>SPY)$ = probabilidad de superar el Sharpe del benchmark. Intervalos calculados con 5,000 iteraciones bootstrap, semilla 42.

Tabla 40: Test de Diebold-Mariano (retornos de estrategia vs SPY *Buy & Hold*)

Modelo	Estadístico DM	p-valor (1 cola)	Significativo (5 %)
LSTM+Attention	2.296	0.0108	Sí
Ridge	1.275	0.1012	No
RandomForest	0.363	0.3584	No
CNN-LSTM	0.325	0.3725	No

Nota: $DM > 0$ indica que la estrategia genera retornos superiores al benchmark. Corrección Newey-West con 5 rezagos. Hipótesis alternativa unidireccional (estrategia > benchmark).

Tabla 41: Test de Clark-West (predicciones vs media histórica del entrenamiento)

Modelo	CW Stat	p-valor (1 cola)	Conclusión
LSTM+Attention	1.901	0.029	Rechaza H_0 (5 %)
Ridge	1.215	0.112	No rechaza
CNN-LSTM	0.641	0.261	No rechaza
RandomForest	−0.336	0.631	No rechaza

Nota: H_0 establece que el modelo no posee capacidad predictiva superior a la media histórica. Test de una cola. Corrección Newey-West con 5 rezagos.

Tabla 42: Degradación de métricas predictivas entre entrenamiento y prueba

Modelo	DA Train	DA Test	Degradación DA	MSE Test/Train
LSTM+Attention	0.492	0.470	−4.6 %	0.68×
CNN-LSTM	0.501	0.455	−9.3 %	0.87×
Ridge	0.575	0.468	−18.6 %	2.55×
RandomForest	0.580	0.459	−20.9 %	1.86×
XGBoost	0.552	0.543	−1.6 %	0.89×

Nota: DA = directional accuracy (proporción de predicciones con signo correcto). MSE Test/Train > 1 indica que el error cuadrático medio aumenta en el período fuera de muestra. XGBoost se incluye como ejemplo de modelo degenerado (Sharpe test = −0.024).

E.5 Tablas y Figuras de Costos de Transacción

Tabla 43: Parámetros de Costo por Instrumento

Instrumento	Bid-Ask	Expense Ratio	Round-Trip
UPRO (3x Long)	5 bps	0.91 %/año	10 bps
SPY (1x Long)	2 bps	0.09 %/año	4 bps
Cash	0 bps	0 %	0 bps

Nota: Round-trip = bid-ask de entrada + bid-ask de salida. Expense ratio aplicado diariamente como ratio anual / 252.

Tabla 44: Impacto de Costos de Transacción por Modelo

Modelo	Capital Final	P&L Bruto	Tx Costs	Tx/P&L	Trades
LSTM_Attention	\$49,538	\$52,996	\$13,459	25.4 %	465
Ridge	\$35,254	\$36,983	\$11,729	31.7 %	409
RandomForest	\$22,749	\$15,148	\$2,398	15.8 %	175
CNN_LSTM	\$22,222	\$20,022	\$7,800	39.0 %	633
DLinear	\$16,771	\$11,584	\$4,813	41.5 %	788
GradientBoosting	\$16,629	\$7,061	\$432	6.1 %	11
CatBoost	\$14,601	\$6,169	\$1,568	25.4 %	224
Theta	\$14,442	\$4,954	\$512	10.3 %	36
NBEATS	\$14,387	\$8,824	\$4,437	50.3 %	507
SeasonalNaive [†]	\$14,300	\$12,816	\$8,516	66.4 %	1042
Lasso	\$13,768	\$4,379	\$611	13.9 %	90
GARCH	\$12,659	\$3,337	\$679	20.3 %	126
LightGBM	\$12,553	\$3,588	\$1,035	28.8 %	134
NHiTS	\$12,141	\$6,043	\$3,902	64.6 %	805
AutoARIMA	\$11,827	\$1,827	\$0	0.0 %	0
TCN	\$11,796	\$3,876	\$2,080	53.7 %	383
TFT	\$11,350	\$7,571	\$6,221	82.2 %	804
Prophet	\$10,784	\$1,221	\$436	35.7 %	77
ElasticNet	\$10,779	\$1,894	\$1,116	58.9 %	175
XGBoost	\$10,710	\$3,167	\$2,457	77.6 %	42
BiLSTM	\$10,494	\$3,625	\$3,131	86.4 %	546
ExponentialSmoothing	\$8,463	\$4,473	\$6,011	134.4 %	904
BiGRU	\$6,683	\$-436	\$2,881	–	752
Promedio	–	–	\$3,749	–	397

Nota: Capital inicial = \$10,000. [†]SeasonalNaive = *benchmark* de complejidad mínima. Tx Costs incluye bid-ask spreads (UPRO 5 bps, SPY 2 bps por operación; 10 y 4 bps ida y vuelta), expense ratios y volatility drag. Tx/P&L = proporción de costos respecto a ganancias brutas.

Tabla 45: Validación de Parámetros de Costo, Estudio vs. Mercado Real

Parámetro	Este estudio	Mercado real	Fuente	Ratio
Expense ratio UPRO	0.91 %/año	0.89 %/año	ProShares ^a	1.02×
Expense ratio SPY	0.09 %/año	0.0945 %/año	State Street ^b	0.95×
Bid-ask UPRO	5 bps	2 bps	ProShares ^a (mediana 30d)	2.50×
Bid-ask SPY	2 bps	≈0 bps	State Street ^b (mediana 30d)	>2.5×
σ diaria (vol drag)	realizada 21d	0.95–1.26 %	S&P 500 histórico	~1.0×

Nota: ^aProShares reporta un expense ratio de 0.89 % bajo un fee waiver contractual vigente hasta septiembre 2026. ^bState Street reporta un gross expense ratio de 0.0945 % y una mediana de bid-ask spread de 0.00 % a 30 días. Datos consultados en julio 2026 desde las páginas oficiales de los emisores.

Tabla 46: Sensibilidad del Retorno a Costos de Transacción

Modelo	Ret. Base	+50 % Costos	+100 % Costos	Break-even	Tx/P&L
LSTM+Attention	+395 %	+328 %	+261 %	3.9×	25.4 %
Ridge	+253 %	+194 %	+135 %	3.2×	31.7 %
RandomForest	+128 %	+116 %	+103 %	6.3×	15.8 %
CNN-LSTM	+122 %	+83 %	+44 %	2.6×	39.0 %

Nota: Aproximación lineal donde el retorno ajustado $\approx (P\&L \text{ bruto} - \text{costos} \times \text{multiplicador}) / \text{capital inicial}$. Break-even = $P\&L \text{ bruto} / \text{costos totales}$, es decir, el multiplicador máximo de costos antes de que la estrategia genere pérdidas. Tx/P&L = costos totales como porcentaje del P&L bruto.




Figura 6: Relación entre *turnover* (número de *trades*) y retorno neto. Cada punto representa un modelo. La línea punteada representa la regresión lineal ($R^2 = 0.00$).

F. Glosario de Términos

Este apéndice reúne las definiciones de los términos técnicos empleados a lo largo del trabajo. Los términos resaltados en el texto contienen hipervínculos que conducen a esta sección.

Advance-Dcline Líne

Acumula diariamente la diferencia entre el número de acciones que suben y las que bajan, proporcionando una medida tendencial de la amplitud del mercado. Su divergencia respecto al índice de precios, por ejemplo cuando este marca nuevos máximos mientras la línea desciende, se interpreta como señal de debilitamiento interno del movimiento.

Backtesting

Procedimiento de simulación histórica que aplica una estrategia de inversión a datos pasados para evaluar cómo habría funcionado en condiciones reales de mercado. La validez del ejercicio depende de que la simulación respete estrictamente la secuencia temporal de la información, es decir, que en ningún momento se utilicen datos futuros para tomar decisiones presentes, condición conocida como ausencia de *data leakage*.

Bootstrap

Técnica de remuestreo estadístico que genera miles de series alternativas extrayendo observaciones al azar, con reemplazo, de la muestra original. Aplicada a los retornos de una estrategia, permite estimar la distribución empírica de una métrica como el *Sharpe ratio* y construir intervalos de confianza sin asumir normalidad en los datos.

Breadth (amplitud de mercado)

Mide qué proporción de las acciones individuales participa en un movimiento del índice.

Un mercado que sube con alta amplitud (muchas acciones subiendo) se considera más sano que uno impulsado por pocas acciones de gran capitalización.

Butterfly spread

Medida de la curvatura de la curva de rendimiento, definida como $(Y_2 + Y_{10}) - 2 \cdot Y_5$, donde Y_n es el rendimiento al plazo n . Un valor positivo indica una curva cóncava (“joroba” en el plazo medio); un valor negativo, una curva convexa.

Calmar Ratio

Razón entre el retorno anualizado de una estrategia y el valor absoluto de su *maximum drawdown*. Responde a una pregunta concreta, cuánto retorno anual genera la estrategia por cada unidad de pérdida máxima sufrida; un valor superior a 1 indica que el crecimiento anual típico excede la peor caída observada.

CARR (Conditional Autoregressive Range)

Análogo al modelo GARCH pero aplicado al rango en lugar de a los retornos al cuadrado. Captura la persistencia empírica del rango, dado que días de rango amplio tienden a ser seguidos por días de rango amplio.

Contango / Backwardation

Contango ($VIX3M > VIX \text{ spot}$) refleja condiciones normales de mercado; *backwardation* ($VIX3M < VIX \text{ spot}$) señala estrés agudo, dado que la volatilidad de corto plazo supera las expectativas a mediano plazo.

Core PCE

Personal Consumption Expenditures excluyendo alimentos y energía. Es la medida de inflación preferida por la Reserva Federal para decisiones de política monetaria, por ser menos volátil que el IPC.

Credit Default Swap (CDS)

Contrato derivado que funciona como un seguro contra el incumplimiento de pago de un emisor de deuda. Los índices CDX agregan *spreads* de CDS de múltiples emisores, ofreciendo una medida amplia del riesgo crediticio corporativo.

Análisis cross-asset

Estudio de las correlaciones y dinámicas entre mercados diferentes (acciones, bonos, materias primas, divisas) para extraer información que un análisis de cada mercado por separado no capturaría.

Data snooping

Sesgo que surge al ajustar o seleccionar un modelo, sus parámetros o sus umbrales utilizando información del período de prueba, lo que infla artificialmente el rendimiento aparente fuera de muestra. Evitarlo exige que toda decisión metodológica se tome exclusivamente con datos de entrenamiento.

Directional Accuracy (DA)

Proporción de días en que la predicción de un modelo acierta el signo del retorno del día siguiente, sin considerar su magnitud. Aunque es una de las métricas más difundidas para evaluar predictores financieros, este trabajo documenta que un DA elevado no

garantiza rentabilidad, dado que la métrica ignora la asimetría entre la magnitud de los aciertos y la de los errores.

Doji Vela japonesa cuyo cuerpo (la distancia entre apertura y cierre) es inferior al 10 % del rango total del día. Refleja equilibrio entre compradores y vendedores y frecuentemente precede cambios de tendencia.

Canales de Donchian

Desarrollados por Richard Donchian en la década de 1960, definen un canal formado por el máximo más alto y el mínimo más bajo de los últimos n días. Las rupturas del canal se interpretan como señales de continuación de tendencia.

Drawdown

Caída acumulada desde un máximo histórico del portafolio hasta el punto más bajo subsiguiente, expresada como porcentaje. El *maximum drawdown* mide la peor pérdida que un inversor habría experimentado de haber ingresado en el punto más alto, y constituye una métrica fundamental de riesgo porque captura la magnitud de las pérdidas extremas que indicadores basados en promedios, como la desviación estándar, no reflejan.

Drift (deriva)

Tendencia determinista de una serie temporal, por ejemplo, el rendimiento esperado positivo de largo plazo del mercado accionario. Cuando existe *drift*, algunos estimadores de volatilidad lo confunden con dispersión aleatoria, sobreestimando la volatilidad real.

Expense ratio

Costo anual de gestión de un ETF, expresado como porcentaje de los activos bajo administración. Equivalente a 0.91 % anual para UPRO y 0.09 % para SPY.

Factores de estilo (*asset pricing*)

Derivan de la observación empírica de que ciertas características sistemáticas de las acciones, como su valoración relativa (*value*), su tamaño de mercado (*size*) o su *momentum* reciente, explican una parte significativa de la variación en retornos esperados. La rotación entre estos factores es un indicador reconocido de cambios en el régimen de mercado.

Niveles de Fibonacci

Los niveles 23.6 %, 38.2 %, 50 %, 61.8 % y 78.6 % derivan de la razón áurea y se utilizan ampliamente en análisis técnico como niveles probables de soporte y resistencia durante correcciones de precio.

Gap overnight

Diferencia entre el precio de apertura de una sesión y el precio de cierre de la sesión anterior. Refleja la reacción del mercado a noticias y eventos ocurridos fuera del horario de negociación.

Ichimoku Kinko Hyo

Sistema de análisis técnico desarrollado por el periodista japonés Goichi Hosoda en la década de 1960. A diferencia de la mayoría de indicadores occidentales, que miden una

sola dimensión (tendencia, *momentum* o volatilidad), Ichimoku integra las tres en una estructura visual unificada.

Investment Grade / High Yield

Investment Grade (grado de inversión) designa emisores con calificación crediticia BBB– o superior, considerados de bajo riesgo de impago. *High Yield* (alto rendimiento) designa emisores por debajo de BBB–, que ofrecen mayores rendimientos como compensación por su mayor riesgo.

Large caps / Small caps

Empresas de gran y pequeña capitalización bursátil, donde la capitalización corresponde al valor total de mercado de la compañía (precio de la acción multiplicado por las acciones en circulación). El diferencial de rendimiento entre ambos grupos, aproximado en este estudio mediante IWM frente a SPY, captura el factor tamaño documentado en la literatura de *asset pricing* y funciona como indicador del apetito por riesgo.

Tasa de aprendizaje (*learning rate*)

Controla la magnitud del ajuste que el modelo realiza a sus parámetros en cada iteración de entrenamiento. Valores pequeños producen un aprendizaje más lento pero estable; valores grandes aceleran la convergencia pero arriesgan inestabilidad.

Meta-KNN

Meta-modelo basado en *K-Nearest Neighbors* que, para cada día del período de prueba, identifica los episodios históricos del entrenamiento en que el modelo de predicción se comportó de forma más similar al momento presente y aplica los umbrales de posicionamiento que mejor funcionaron en dichos episodios. Permite adaptar los umbrales al régimen de mercado sin utilizar información futura.

Momentum

Tendencia empírica de los activos con buen rendimiento reciente a seguir rindiendo bien en el corto plazo, y viceversa. Este fenómeno, documentado por [Jegadeesh & Titman \(1993\)](#), constituye una de las anomalías más robustas frente a la hipótesis de eficiencia de mercado.

New Highs–New Lows

Diferencia diaria entre el número de acciones que alcanzan máximos de 52 semanas y las que tocan mínimos del mismo período. Como medida de amplitud, complementa a los índices ponderados por capitalización, ya que un mercado que sube mientras este indicador se deteriora sugiere que el avance descansa en pocas acciones grandes, señal históricamente asociada a techos de mercado.

OHLCV

Acrónimo de *Open, High, Low, Close, Volume*, los cinco campos estándar de un registro de precio diario. Estos campos constituyen la materia prima de buena parte de la ingeniería de características del estudio, dado que de ellos se derivan los indicadores técnicos, los estimadores de volatilidad basados en rango y las medidas de microestructura de cada sesión.

On-the-run (bonos)

Emisión más reciente del Tesoro para un plazo dado. Su alta liquidez puede distorsionar el rendimiento observado respecto al nivel “real” de la curva. Los índices genéricos de Bloomberg promedian emisiones cercanas a cada vencimiento, ofreciendo una medida más estable.

Percentil móvil (rolling percentile)

Posición relativa de una observación dentro de la distribución de sus últimos n valores, expresada entre 0 y 100. En este sistema, cada predicción diaria se compara con las 63 predicciones previas del mismo modelo, de modo que la señal refleja cuán optimista es el modelo respecto a su propio comportamiento reciente y no respecto a una escala absoluta, lo que permite comparar modelos con escalas de predicción muy distintas.

Precio típico / MFI

El precio típico se define como $(High + Low + Close)/3$. El *Money Flow Index* (MFI) multiplica este precio por el volumen para obtener el “flujo de dinero”, cuya proporción positiva/negativa genera un oscilador entre 0 y 100.

Profit factor

Razón entre la suma de todas las ganancias y la suma de todas las pérdidas generadas por una estrategia en un período dado. Un valor superior a 1 indica que el sistema genera más dinero del que pierde; valores por debajo de 1 señalan que las pérdidas superan a las ganancias. Se complementa con el *win rate* para evaluar la calidad de las operaciones.

Proxy Variable observable que se utiliza como aproximación de un concepto que no es directamente medible. En este estudio, XLF (sector financiero) y XLK (sector tecnológico) se emplean como *proxies* de *value* y *growth*, respectivamente.

Ratio put/call

Mide el volumen de opciones de venta (*puts*) relativo al volumen de opciones de compra (*calls*). Un ratio elevado indica sentimiento pesimista (más inversores comprando protección a la baja); un ratio bajo indica optimismo.

Sharpe Ratio

Medida clásica de rentabilidad ajustada por riesgo, definida como el exceso de retorno de una estrategia sobre la tasa libre de riesgo dividido por la desviación estándar de sus retornos, habitualmente anualizada (Sharpe, 1966). Permite comparar estrategias con niveles de riesgo distintos; un valor más alto indica mayor compensación por cada unidad de volatilidad total asumida.

Sortino Ratio

Variante del *Sharpe ratio* que divide el exceso de retorno únicamente por la desviación estándar de los retornos negativos (Sortino & van der Meer, 1991). Al penalizar solo la volatilidad a la baja, distingue entre estrategias cuya variabilidad proviene de ganancias y aquellas cuya variabilidad proviene de pérdidas, distinción que el *Sharpe* tradicional no realiza.

Spread (diferencial)

Diferencia entre dos tasas de interés o rendimientos. El *spread* de crédito, por ejemplo, mide la prima que exige el mercado por prestar a un emisor corporativo frente a un bono del Tesoro de igual plazo; cuanto mayor el *spread*, mayor el riesgo crediticio percibido.

Spread bid-ask

Diferencia entre el precio de compra y el precio de venta de un activo. Representa un costo implícito de cada transacción, estimado en 0.05 % para UPRO y 0.02 % para SPY.

Squeeze (compresión)

Ocurre cuando las Bandas de Bollinger se contraen dentro de los canales de Keltner, indicando que la volatilidad es inusualmente baja. Históricamente, los períodos de compresión preceden movimientos direccionales fuertes.

Tasa swap de interés

Tasa fija que se intercambia por una tasa variable en un contrato de derivados (*interest rate swap*). La tasa *swap* a 10 años refleja las expectativas del mercado sobre tasas de interés futuras y riesgo crediticio bancario.

TA-Lib (Technical Analysis Library)

Librería estándar de la industria financiera cuyos indicadores están diseñados para operar exclusivamente sobre datos históricos, sin incorporar observaciones futuras.

TICK / TRIN (Arms Index)

El TICK mide la diferencia instantánea entre acciones cotizando al alza y a la baja. El TRIN relaciona la razón de acciones que suben/bajan con la razón de volumen al alza/a la baja; valores < 1 indican presiones alcistas y > 1 presiones bajistas.

T-Bills / T-Notes / T-Bonds

Treasury Bills (T-Bills) son instrumentos de deuda a corto plazo (hasta 1 año) emitidos por el Tesoro de EE.UU., considerados libres de riesgo crediticio. Los *T-Notes* (2–10 años) y *T-Bonds* (20–30 años) son sus equivalentes a mayor plazo.

True Range

Máximo entre (i) rango intradía ($H - L$), (ii) distancia del máximo al cierre anterior, y (iii) distancia del mínimo al cierre anterior. Captura la volatilidad real incluyendo *gaps* entre sesiones.

Turnover

Frecuencia con la que una estrategia modifica sus posiciones en un período determinado. Un *turnover* elevado implica mayor actividad de negociación y, en consecuencia, mayores costos de transacción (*spreads* de compra-venta, comisiones e impacto de mercado) que pueden erosionar significativamente los retornos brutos de la estrategia.

Volatility drag

Pérdida sistemática que sufren los ETFs apalancados por su rebalanceo diario. Formalmente, $\text{drag} \approx \frac{1}{2}(L^2 - L) \cdot \sigma^2$, donde L es el factor de apalancamiento y σ^2 la varianza diaria del subyacente.