

Desafiando la Eficiencia del Mercado:

Enfoques Clásicos y Contemporáneos de Modelado Cuantitativo para la Predicción Direccional y Generación de Alfa en el S&P 500

David González Cañón

Magíster en Finanzas

Marzo 2026

Resumen

Este documento examina la posibilidad de generar alfa en el S&P 500 mediante técnicas de aprendizaje automático y profundo. Se propone la hipótesis de que modelos computacionales suficientemente sofisticados pueden capturar patrones direccionales explotables en los retornos del índice, generando rentabilidad positiva después de costos de transacción. A través del entrenamiento de 23 modelos—desde regresiones regularizadas hasta redes neuronales con mecanismos de atención—se transforman 92 variables financieras y macroeconómicas en 536 características predictivas, y se traducen las predicciones resultantes en una estrategia de inversión *Long-Only* con posiciones discretas en efectivo, SPY y UPRO 3x. Los umbrales de posicionamiento se determinan dinámicamente mediante un meta-modelo entrenado exclusivamente con datos históricos, evitando toda filtración de información futura. Los resultados muestran que cuatro de los veintitrés modelos superan al *benchmark* pasivo en el período octubre 2020–diciembre 2025, liderados por LSTM con Atención (+400 %, Sharpe 1.33) y Ridge (+263 %, Sharpe 0.88). Se documenta, además, un hallazgo contraintuitivo—los modelos más rentables no son aquellos con mayor tasa de acierto direccional, sino aquellos capaces de concentrar sus posiciones apalancadas en los momentos donde efectivamente aciertan—lo que sugiere que la selectividad temporal resulta más determinante que la frecuencia de aciertos. El texto concluye que la evidencia es consistente con la Hipótesis de Mercados Adaptativos, donde las ineficiencias residuales compensan la sofisticación computacional requerida para su explotación.

Palabras clave

Marcos Teóricos: Hipótesis de Mercados Adaptativos, Paradoja de Grossman-Stiglitz, Ley del Arcoseno, Hipótesis de Eficiencia de Mercado (HEM)

Metodología e Ingeniería de Características: Triple Screen de Elder, Estimadores de Volatilidad OHLC (Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang), Filtración de Información (*data leakage*), Umbrales Cuantílicos, Percentiles Rolling, TimeSeriesSplit

Estrategia e Instrumentos: Estrategia Long-Only, *Volatility Drag*, ETFs Apalancados (UPRO), Paradoja de Precisión Direccional, DA@3x, *Profit Factor*, Ratio de Calmar, Ratio de Sortino

Validación Estadística: *Model Confidence Set* (Hansen), Test de Diebold-Mariano, Test de Clark-West, Corrección de Bonferroni, Tasa de Falso Descubrimiento (Benjamini-Hochberg), Corrección de Newey-West, *Bootstrap* No Paramétrico

Arquitecturas de Aprendizaje Profundo: N-BEATS, N-HiTS, TFT (*Temporal Fusion Transformer*), TCN (*Temporal Convolutional Network*), DLinear, LSTM con Atención, CNN-LSTM

Clasificación JEL: G14, G17, C45, C53

Índice

1. Introducción	8
1.1. Contexto y Motivación	8
1.2. La Relevancia del Debate sobre Eficiencia de Mercado	8
1.3. Contribuciones al Conocimiento	9
1.4. Estructura del Documento	10
2. Revisión de Literatura y Fundamentos Teóricos	11
2.1. La Hipótesis de Eficiencia de Mercado: Origen y Evolución	11
2.1.1. Fundamentos Conceptuales	11
2.1.2. La Paradoja de Grossman-Stiglitz	11
2.1.3. La Ley del Arcoseno y la Inevitabilidad Matemática de las Tendencias . .	12
2.2. Anomalías de Mercado y Evidencia Contra la HEM	13
2.3. Alternativas Teóricas a la HEM	14
2.4. Del Camino Aleatorio a la Martingala: Justificación de los Modelos Predictivos .	15
2.5. Evolución del Modelado Cuantitativo en la Valoración de Activos	16
2.5.1. Modelos Lineales Regularizados	18
2.5.2. Métodos de Ensemble Basados en Árboles	18
2.5.3. Modelos Estadísticos de Series Temporales	19
2.5.4. Arquitecturas de Deep Learning	20
3. Datos y Metodología	21
3.1. Fuentes de Datos e Ingeniería de Características	21
3.1.1. Universo de Datos	21
3.1.2. Pipeline de Ingeniería de Características	24
3.1.3. Garantías contra Filtración de Información	33
3.1.4. Dataset Resultante	34
3.2. Variable Objetivo y División de Muestra	35
3.2.1. Retorno en Exceso como Variable Objetivo	35
3.2.2. Alineación Temporal: el Desplazamiento del Vector Objetivo	36
3.2.3. División Temporal de la Muestra	37
3.3. Especificaciones de Modelos	37
3.3.1. Preparación de Datos para Entrenamiento	37
3.3.2. Modelos Tabulares con Validación Cruzada	40

3.3.3. Modelos de Series Temporales (Baselines Univariados)	40
3.3.4. Modelos de Deep Learning	41
3.3.5. Implementación Computacional	42
3.4. Estrategia de Inversión	43
3.4.1. De Predicciones Continuas a Posiciones Discretas	43
3.4.2. Optimización de Umbrales por Modelo	45
3.4.3. Modelo de Costos	50
4. Resultados Empíricos	51
4.1. Resumen de Rendimiento	51
4.1.1. Tabla Principal de Rendimiento	51
4.1.2. Hallazgos Principales	51
4.1.3. Tabla Resumen Ejecutivo	53
4.2. Análisis por Familia de Modelos	53
4.2.1. Comparación por Categoría	53
4.2.2. Interpretación por Categoría	54
4.3. Curvas de Equity	55
4.4. Distribución de Posiciones	55
4.4.1. Patrones de Posicionamiento	55
4.5. Análisis de Trades	56
4.5.1. Estadísticas de Trading	56
4.5.2. Distribución de P&L Diario	57
4.6. Comparación con Benchmarks Adicionales	57
4.7. Aplicación Interactiva	58
5. La Paradoja del <i>Directional Accuracy</i>	58
5.1. El Hallazgo Contraintuitivo	58
5.1.1. Intuición Naïve vs Realidad	58
5.1.2. Evidencia Empírica	58
5.2. Explicación de la Paradoja	60
5.2.1. El DA Trata Todos los Días como Iguales	60
5.2.2. Lo Que Realmente Importa: Asimetría Condicional	60
5.3. El Indicador DA@3x: Una Métrica Más Relevante	60
5.4. Implicaciones para el Diseño de Estrategias	61
5.4.1. No Optimizar por DA	61

5.4.2. Métricas Alternativas Recomendadas	62
5.4.3. El Valor de la Selectividad	62
5.5. Conexión con la Literatura	62
5.6. Resumen de la Sección	64
6. Marco de Gestión de Riesgo	64
6.1. Métricas de Riesgo Ajustado	65
6.1.1. Sharpe Ratio	65
6.1.2. Sortino Ratio	65
6.1.3. Calmar Ratio	66
6.2. Value at Risk (VaR) y Expected Shortfall	67
6.3. Análisis de <i>Drawdown</i>	68
6.4. Participación en Movimientos del Mercado	70
6.5. Control de Riesgo Implícito en la Estrategia	71
7. Validación Estadística	72
7.1. Bootstrap de Sharpe Ratios	72
7.2. Test de Diebold-Mariano	74
7.3. Test de Clark-West	75
7.4. Model Confidence Set	76
7.5. Análisis de <i>Overfitting</i>	77
7.5.1. Degradación de métricas de predicción	77
7.5.2. Corrección por comparaciones múltiples	78
7.6. Síntesis de la validación estadística	78
8. Análisis de Costos de Transacción	79
8.1. Costos de Transacción en Estrategias Activas	79
8.2. Estructura del Modelo de Costos	80
8.2.1. <i>Expense Ratio</i>	80
8.2.2. <i>Bid-Ask Spread</i>	80
8.2.3. <i>Volatility Drag</i>	81
8.3. Desglose de Costos por Modelo	81
8.4. Validación Empírica de los Parámetros de Costo	83
8.5. Relación Rentabilidad-Turnover	84
8.6. Análisis de Sensibilidad	85
8.7. Costos No Considerados	86

9. Aportes al Debate sobre la Eficiencia de Mercado	87
9.1. Síntesis de los Hallazgos Empíricos	87
9.2. La Evidencia contra la Forma Semi-fuerte de la HEM	88
9.3. La Paradoja de Grossman-Stiglitz: Del Argumento Teórico a la Verificación Em- pírica	90
9.4. La Hipótesis del Mercado Adaptativo y los Fundamentos Teóricos del Estudio . .	92
9.5. Síntesis: Una Visión Integradora	95
10. Conclusión	96
10.1. Síntesis y Limitaciones	96
10.2. Implicaciones Prácticas	96
10.3. Direcciones para Investigación Futura	97
10.4. Reflexión Final	98
Apéndices	104
A. Especificación Completa de Variables	104
B. Detalles de Ingeniería de Características	104
C. Hiperparámetros de Modelos	104
C.1. Modelos de Regresión Lineal Regularizada (<i>GridSearchCV</i>)	105
C.2. Modelos <i>Ensemble</i> (<i>GridSearchCV</i>)	105
C.3. Modelos de <i>Gradient Boosting</i> Especializado	106
C.4. Modelos de Series Temporales (Darts Clásicos)	106
C.5. GARCH (<i>arch library</i>)	107
C.6. Modelos de <i>Deep Learning</i> (Darts)	107
C.7. Modelos <i>Custom</i> PyTorch	108
C.8. Configuración de Entrenamiento Común	109
D. Parámetros Óptimos de Umbral	109
D.1. Metodología de Optimización: Meta-KNN	110
D.1.1. Espacio de Búsqueda	110
D.1.2. Función Objetivo	110
D.1.3. Meta-Features	110
D.1.4. Parámetros del KNN	110
D.1.5. Filtro de Calidad de Señal	111
D.2. Tabla de Parámetros Dinámicos	111
D.3. Análisis de Parámetros	112

D.3.1. Diversidad de Umbrales por Modelo	112
D.3.2. Implicaciones	112
D.4. Interpretación de los Umbrales Dinámicos	112
D.4.1. Significado de los Percentiles	112
D.4.2. Percentiles vs Valores Absolutos	113

1. Introducción

1.1 Contexto y Motivación

La Hipótesis de Eficiencia de Mercado (HEM), formalizada por [Fama \(1970\)](#) hace más de cinco décadas, permanece como una de las proposiciones más influyentes y debatidas en la economía financiera contemporánea. En su formulación más estricta, la hipótesis postula que los precios de los activos incorporan instantánea y completamente toda la información disponible, haciendo imposible la obtención de rendimientos anormales sistemáticos a través de cualquier estrategia de *trading* basada en datos históricos o información pública.

Sin embargo, el panorama empírico ha evolucionado considerablemente desde el trabajo seminal de Fama. La proliferación de anomalías documentadas, la sofisticación creciente de las técnicas de aprendizaje automático, y la disponibilidad de conjuntos de datos cada vez más ricos han reavivado el debate fundamental: ¿procesan realmente los mercados financieros la información de manera eficiente, o existen ineficiencias persistentes susceptibles de explotación por inversores sofisticados?

Este trabajo aborda el debate mediante un enfoque empírico estructurado en **dos hitos fundamentales**:

Hito 1 – Predicción. Entrenar múltiples modelos de aprendizaje automático y profundo (23 en total) para generar predicciones sobre los retornos del S&P 500. El objetivo no es predecir con exactitud el valor numérico del retorno de mañana—tarea que la literatura ha demostrado extremadamente difícil—sino obtener suficiente *precisión direccional* para tomar decisiones de inversión.

Hito 2 – Implementación. Traducir las predicciones de los modelos en una estrategia de *trading* práctica que aproveche el apalancamiento disponible en ETFs (UPRO 3x, SPY 1x, efectivo) para generar alfa positivo después de costos de transacción realistas.

Este enfoque reconoce una distinción crucial: mientras que predecir el retorno exacto del mercado puede ser imposible, identificar la *dirección* con precisión suficiente puede ser económicamente explotable cuando se combina con una estrategia de posicionamiento inteligente.

1.2 La Relevancia del Debate sobre Eficiencia de Mercado

El debate sobre la eficiencia de mercado trasciende el ámbito puramente académico y tiene implicaciones profundas para la industria de gestión de activos, la regulación financiera y las decisiones de inversión individuales. Si los mercados son verdaderamente eficientes, los gestores activos de fondos destruyen valor para sus clientes a través de comisiones y costos de transacción

sin generar rendimientos superiores al mercado. En este escenario, la inversión pasiva a través de fondos indexados representaría la estrategia óptima para todos los inversores.

Por el contrario, si existen ineficiencias sistemáticas y explotables, surge la posibilidad de que estrategias cuantitativas sofisticadas puedan generar rendimientos ajustados por riesgo superiores. Esta posibilidad ha impulsado el crecimiento exponencial de la industria de hedge funds cuantitativos, que según estimaciones de la industria gestiona más de un billón de dólares en activos globalmente.

En este contexto, el presente estudio examina si las técnicas más avanzadas de aprendizaje automático, combinadas con indicadores técnicos probados en la práctica, pueden identificar patrones predecibles en los retornos del mercado de valores.

1.3 Contribuciones al Conocimiento

Este estudio aporta tres contribuciones originales:

Primera contribución – Marco metodológico de dos hitos. Se presenta un enfoque estructurado que separa explícitamente la fase de predicción (Hito 1: entrenamiento de modelos) de la fase de implementación (Hito 2: estrategia de *trading*). Esta separación, poco común en la literatura donde predicción y posicionamiento suelen evaluarse conjuntamente, permite aislar con precisión la fuente del rendimiento—¿proviene el alfa de una genuina capacidad predictiva de los modelos, o de las reglas de posicionamiento y gestión de riesgo de la estrategia? Al desacoplar ambas dimensiones, se evita la falacia común de atribuir rendimientos superiores exclusivamente a la inteligencia del modelo cuando en realidad pueden originarse en el diseño de la estrategia—o viceversa. Esta claridad metodológica facilita la replicabilidad del estudio y permite a futuros investigadores sustituir componentes individuales (modelos alternativos, reglas de posicionamiento diferentes) sin invalidar el marco completo.

Segunda contribución – Comparación exhaustiva y transversal de 23 modelos. Se entrenan y evalúan 23 modelos que abarcan el espectro completo de técnicas disponibles: desde regresión lineal regularizada (Ridge, Lasso, ElasticNet), pasando por métodos de ensemble basados en árboles (RandomForest, GradientBoosting, XGBoost, LightGBM, CatBoost), modelos estadísticos clásicos de series temporales (ExponentialSmoothing, Theta, Prophet, GARCH), hasta arquitecturas de *deep learning* de última generación (TCN, N-BEATS, N-HiTS, TFT, DLinear, CNN-LSTM, LSTM con atención, Bi-LSTM, Bi-GRU). A diferencia de estudios previos que típicamente comparan un número reducido de modelos dentro de una misma familia metodológica, esta evaluación transversal permite identificar qué paradigmas de modelado capturan mejor la señal predictiva en retornos financieros. El hallazgo de que las arquitecturas de

deep learning con mecanismos de atención (LSTM+Attention, CNN-LSTM) superan a todos los demás enfoques—incluyendo métodos de ensemble y modelos lineales—demuestra que los patrones temporales en retornos financieros pueden ser explotados por arquitecturas diseñadas para capturar dependencias de largo plazo, validando el uso de aprendizaje profundo en finanzas cuantitativas.

Tercera contribución – Evidencia empírica contra la Hipótesis de Eficiencia de Mercado. Esta constituye la contribución central del estudio. La HEM en su formulación semi-fuerte (Fama, 1970) plantea que ninguna estrategia basada en información pública debería generar rendimientos anormales sistemáticos. Los resultados obtenidos contradicen directamente esta predicción: cuatro de veintitrés modelos, entrenados exclusivamente con información pública histórica, generan alfa positivo y económicamente significativo sobre el S&P 500 durante un período de prueba de cinco años, incluso después de incorporar costos de transacción realistas. La magnitud del *outperformance*—el modelo LSTM+Attention acumula un exceso de retorno de 298 puntos porcentuales sobre *buy-and-hold*—excede lo atribuible a compensación por riesgo convencional o a suerte estadística.

Estos hallazgos no implican que los mercados sean completamente ineficientes, sino que respaldan marcos teóricos más contemporáneos que reconocen la existencia de ineficiencias explotables. La paradoja de Grossman & Stiglitz (1980) ya anticipaba esta conclusión al demostrar la imposibilidad lógica de mercados perfectamente eficientes: si los precios reflejaran toda la información, nadie tendría incentivos para incurrir en el costo de adquirirla, y por tanto los precios dejarían de ser informativos. De manera más reciente, la Hipótesis de Mercados Adaptativos de Lo (2019) propone que la eficiencia no es una propiedad estática del mercado sino un fenómeno dinámico y evolutivo, donde las ineficiencias emergen, son explotadas por participantes sofisticados, y eventualmente se disipan—solo para que nuevas ineficiencias surjan en un ciclo continuo de adaptación. Los resultados de este estudio son consistentes con este paradigma adaptativo: la señal predictiva existe y es capturada por múltiples metodologías independientes, pero su explotación requiere sofisticación computacional significativa (procesamiento de 536 características con algoritmos avanzados de aprendizaje profundo), lo cual limita naturalmente el número de participantes capaces de arbitrarla y explica su persistencia.

1.4 Estructura del Documento

El documento está organizado de manera que el lector comprenda el proceso de principio a fin. La estructura es la siguiente:

Contexto teórico (Sección 2), revisión de la literatura sobre eficiencia de mercado, anoma-

lías documentadas y aplicaciones de aprendizaje automático en finanzas.

Hito 1 – Predicción (Sección 3), fuentes de datos, ingeniería de características, especificaciones de los 23 modelos y marco de evaluación.

Hito 2 – Implementación (Secciones 4–8), resultados empíricos, paradoja del *Directional Accuracy*, gestión de riesgo, validación estadística y costos de transacción.

Discusión y cierre (Secciones 9–10), aportes al debate sobre eficiencia de mercado y conclusiones. Los apéndices proporcionan documentación técnica detallada.

2. Revisión de Literatura y Fundamentos Teóricos

2.1 La Hipótesis de Eficiencia de Mercado: Origen y Evolución

2.1.1 Fundamentos Conceptuales

La noción de que los precios de mercado reflejan la información disponible tiene raíces que se remontan a los trabajos pioneros de Louis Bachelier a principios del siglo XX. Sin embargo, la formulación moderna de la Hipótesis de Eficiencia de Mercado se atribuye principalmente a Eugene Fama, cuyo artículo seminal de 1970 estableció el marco conceptual que domina el pensamiento financiero hasta el día de hoy.

[Fama \(1970\)](#) definió un mercado eficiente como aquel en el que los precios “reflejan completamente” la información disponible. Esta definición aparentemente simple encierra profundas implicaciones para la práctica de inversión y la teoría financiera. Fama distinguió tres formas de eficiencia de mercado.

La **eficiencia en forma débil** postula que los precios actuales incorporan completamente toda la información contenida en la secuencia histórica de precios.

La **eficiencia en forma semi-fuerte** extiende esta noción al postular que los precios reflejan toda la información públicamente disponible.

La **eficiencia en forma fuerte** representa la proposición más extrema: los precios reflejan toda la información, incluyendo información privada.

2.1.2 La Paradoja de Grossman-Stiglitz

Si la hipótesis de eficiencia se toma al pie de la letra, surge una contradicción que [Grossman & Stiglitz \(1980\)](#) formalizaron y que se conoce como la “paradoja de la información”. El razonamiento es sencillo: si los precios ya reflejan toda la información disponible, ningún participante podría obtener rendimientos superiores al mercado por investigar o analizar datos. Pero si no hay rendimientos que compensen el costo de adquirir información, nadie tiene incentivos para

hacerlo. Y si nadie recopila ni procesa información, los precios no pueden incorporarla—lo cual contradice la premisa inicial de que los precios son perfectamente informativos.

Lo interesante de esta paradoja es que no se trata de una crítica empírica sino de una contradicción lógica interna. Grossman & Stiglitz (1980) la resuelven proponiendo que los mercados operan en un equilibrio de desequilibrio: lo suficientemente ineficientes como para que existan oportunidades que compensen los costos de investigación, pero no tanto como para permitir ganancias sistemáticas sin esfuerzo. En este equilibrio, los participantes informados obtienen rendimientos que justifican marginalmente su inversión, y los precios se mantienen *aproximadamente*—pero no perfectamente—informativos.

Esta idea tiene implicaciones directas para el presente estudio. Si los mercados fueran perfectamente eficientes, ningún modelo de aprendizaje automático, por sofisticado que fuera, podría generar alfa de manera consistente. Sin embargo, el marco de eficiencia ineficiente predice precisamente lo que este trabajo busca demostrar: que algoritmos capaces de procesar 536 características de forma simultánea pueden identificar y explotar ineficiencias residuales que persisten precisamente porque su detección requiere un esfuerzo computacional que la mayoría de los participantes no puede asumir.

2.1.3 La Ley del Arcoseno y la Inevitabilidad Matemática de las Tendencias

Un argumento común contra los modelos de predicción de precios es que los patrones observados en series financieras son ilusiones estadísticas. Malkiel (1973) popularizó la metáfora del “paseo aleatorio”, sugiriendo que los movimientos de precios son impredecibles y que cualquier patrón aparente es producto del sesgo humano de encontrar orden donde solo hay ruido.

A primera vista, este argumento parece sólido. Sin embargo, un resultado clásico de la teoría de probabilidades ofrece una perspectiva distinta. La *ley del arcoseno*, descubierta por Lévy (1940) para el movimiento browniano y desarrollada por Feller (1968) para caminos aleatorios discretos, muestra algo contraintuitivo: la fracción del tiempo que un proceso aleatorio pasa en territorio positivo no se distribuye de manera uniforme, como uno esperaría, sino que sigue una distribución en forma de U (Figura 1).




Figura 1: Distribución del arcoseno: la probabilidad de que un camino aleatorio permanezca en territorio de precios altos o bajos es mucho mayor que la de oscilar simétricamente alrededor del precio inicial, generando tendencias persistentes de manera natural. Fuente: [CMT Association \(2020\)](#).

Dicho de otro modo, en un camino aleatorio puro, lo más probable es que la trayectoria pase la mayor parte del tiempo de un mismo lado del origen, generando lo que visualmente parece una tendencia sostenida. Incluso sin ninguna estructura predictiva subyacente, los datos aleatorios producen *tendencias persistentes* de manera natural.

La implicación para este estudio es directa. Que existan tendencias en los precios no es, por sí solo, evidencia de ineficiencia ni de predictibilidad—las tendencias son una propiedad matemática inevitable de cualquier serie temporal, incluyendo las puramente aleatorias. Lo que distingue a una estrategia de inversión exitosa no es detectar tendencias, que la ley del arcoseno garantiza, sino identificar cuándo esas tendencias contienen información explotable más allá de lo que la aleatoriedad pura produciría. Los modelos de aprendizaje automático empleados en este trabajo no necesitan predecir el precio exacto de un activo; lo que buscan es capturar la dirección tendencial con suficiente precisión para generar rendimientos ajustados al riesgo superiores al *benchmark*.

2.2 Anomalías de Mercado y Evidencia Contra la HEM

Si bien la HEM ofrece un marco teórico elegante, décadas de investigación empírica han documentado numerosas “anomalías”—patrones sistemáticos en los rendimientos que aparentemente contradicen sus predicciones. [Dong et al. \(2022\)](#) documentan 100 anomalías de retornos identificadas en la literatura académica, incluyendo el efecto enero, el momentum y las anoma-

lías de valor. La persistencia de estos patrones sugiere que los mercados no son completamente eficientes y que inversores suficientemente informados pueden, al menos en ciertos períodos, obtener rendimientos anormales.

El campo de las *finanzas conductuales* ha proporcionado una explicación de por qué estas ineficiencias surgen y persisten. [Kahneman & Tversky \(1979\)](#) demostraron que los agentes económicos exhiben sesgos sistemáticos en la toma de decisiones bajo incertidumbre—en particular, la aversión a la pérdida, por la cual las pérdidas pesan desproporcionadamente más que las ganancias equivalentes—que generan desviaciones predecibles entre los precios de mercado y los valores fundamentales. Lo relevante es que estos sesgos no son aleatorios, sino patrones recurrentes de la psicología humana que crean ineficiencias potencialmente explotables.

La *teoría del operador ruidoso* de [De Long et al. \(1990\)](#) formalizó esta idea, mostrando que participantes irracionales pueden causar desviaciones significativas y persistentes en los precios respecto a los valores fundamentales. Se podría pensar que el arbitraje corregiría rápidamente estos errores, pero [Shleifer & Vishny \(1997\)](#) documentaron lo que denominaron *límites al arbitraje*: los costos de transacción, el riesgo de posición y las restricciones regulatorias impiden que los arbitrajistas racionales eliminen completamente las ineficiencias, permitiendo que ciertos errores de valoración persistan incluso cuando son conocidos por los participantes del mercado.

2.3 Alternativas Teóricas a la HEM

Dado el volumen de evidencia contra la eficiencia estricta, han surgido marcos teóricos alternativos que intentan reconciliar la utilidad descriptiva de la HEM con las ineficiencias observadas en la práctica.

Quizás la alternativa más influyente sea la *Hipótesis del Mercado Adaptativo* (HMA), articulada en detalle por [Lo \(2019\)](#). La idea central es que la eficiencia del mercado no es una propiedad fija sino una variable dinámica que fluctúa según el entorno competitivo—de forma análoga a un ecosistema biológico. Las estrategias que generan alfa en un período pueden dejar de funcionar cuando suficientes participantes las adoptan, y nuevas oportunidades emergen a medida que cambian las condiciones. Para este estudio, la HMA es particularmente relevante: justifica tanto la búsqueda de señales predictivas como la expectativa de que su eficacia varíe entre regímenes de mercado.

Por otro lado, la *Hipótesis del Mercado Fractal* de [Peters \(1994\)](#) propone que los mercados exhiben autosimilitud, es decir, que los patrones de precios se repiten a través de diferentes escalas temporales. Esta propiedad proporciona respaldo teórico al análisis multi-temporal: si las dinámicas de precios presentan estructuras similares en múltiples horizontes, la extracción

de características a distintas ventanas temporales—como la que realiza el pipeline de ingeniería de características de este estudio—puede capturar información complementaria en cada escala.

El *Modelo Conductual de Valoración de Activos* (BAPM) de Shefrin & Statman (1994) extiende los modelos tradicionales incorporando factores psicológicos de manera explícita, ofreciendo un marco formal para entender cómo los sesgos humanos influyen en los precios. La *econofísica* (Mantegna & Stanley, 2000), por su parte, aplica herramientas de la física estadística al análisis financiero, revelando propiedades como colas pesadas y clustering de volatilidad que los modelos tradicionales no capturan.

Ninguna de estas alternativas ha desplazado a la HEM de su posición central en las finanzas modernas. Sin embargo, en conjunto ofrecen un marco teórico más rico que justifica la búsqueda sistemática de señales predictivas en datos históricos—que es precisamente el enfoque de este estudio.

2.4 Del Camino Aleatorio a la Martingala: Justificación de los Modelos Predictivos

Que los precios sigan un camino aleatorio no descalifica automáticamente a los modelos cuantitativos de predicción. Para entender por qué, es necesario distinguir entre los dos modelos estocásticos más utilizados para describir la dinámica de precios: el camino aleatorio y el proceso de martingala.

Un *camino aleatorio* genera una secuencia de precios donde ninguna combinación de observaciones pasadas ofrece información sobre el siguiente movimiento. Su limitación como modelo de mercado es que asume una progresión horizontal del precio: el valor esperado futuro es simplemente el precio actual, sin tendencia. Dado que más de un siglo de evidencia muestra que los mercados accionarios han generado rendimientos positivos en el largo plazo, esta asunción resulta empíricamente inadecuada.

Un *proceso de martingala*, en cambio, incorpora un factor de deriva que captura la expectativa de acumulación de riqueza de los inversores. Samuelson (1965) demostró que, bajo competencia informacional, los precios anticipados correctamente fluctúan como una martingala con deriva. Formalmente, si P_t denota el precio en el período t y μ la tasa esperada de retorno, el proceso satisface $E[P_{t+1}|\mathcal{F}_t] = P_t(1 + \mu)$, donde $\mathcal{F}_t$ es toda la información disponible hasta t . Al igual que en el camino aleatorio, los movimientos individuales son impredecibles. La diferencia clave es que el precio medio esperado sigue una trayectoria ascendente cuando $\mu > 0$, reflejando la prima de riesgo histórica del mercado accionario.

Esta distinción es importante porque, bajo un proceso de martingala, aunque predecir el precio exacto del siguiente período sea imposible, identificar cuándo el precio está significati-

vamente por debajo o por encima de su tendencia esperada constituye una forma legítima de explotar dependencias estadísticas. La ley del arcoseno, discutida en la Sección 2.1.3, garantiza además que estas desviaciones serán prolongadas y no meramente transitorias.

De aquí surgen dos justificaciones teóricas complementarias para el uso de modelos de aprendizaje automático en mercados financieros:

1. **Identificación de tendencias (ley del arcoseno):** Las tendencias son una propiedad matemática inevitable de cualquier serie temporal, incluyendo las puramente aleatorias. Los modelos de ML pueden identificar y explotar estas tendencias persistentes de forma sistemática, posicionándose en la dirección dominante durante los períodos prolongados que la distribución del arcoseno predice.
2. **Posicionamiento relativo (marco de la martingala):** Bajo el modelo de martingala con deriva, los modelos no necesitan predecir el nivel de precio futuro—solo necesitan estimar si el precio actual está por debajo o por encima de la tendencia esperada. Esta tarea de clasificación relativa es fundamentalmente más abordable que la predicción puntual, y es precisamente lo que realizan los modelos de este estudio al generar señales discretas de posicionamiento (CASH, SPY, UPRO).

En suma, incluso aceptando la premisa de la HEM de que los precios pasados no predicen con precisión los precios futuros, los modelos cuantitativos conservan utilidad para evaluar riesgo, identificar posicionamientos favorables y filtrar decisiones de inversión. Los modelos de aprendizaje automático son la evolución computacional de esta lógica: no buscan predecir precios, sino identificar estados probabilísticamente favorables dentro de un mercado que, aunque aproximadamente eficiente, exhibe tendencias matemáticamente inevitables y económicamente explotables.

2.5 Evolución del Modelado Cuantitativo en la Valoración de Activos

La aplicación de técnicas computacionales a la predicción de mercados financieros no es un fenómeno reciente, sino el resultado de una evolución que abarca más de cuatro décadas. En sus orígenes, los modelos cuantitativos en finanzas se limitaban a especificaciones econométricas clásicas: los modelos ARIMA para la estructura temporal de retornos y los modelos GARCH (Bollerslev, 1986) para la dinámica de volatilidad condicional constituían el estado del arte durante las décadas de 1980 y 1990. Estos enfoques, si bien rigurosos en su fundamentación estadística, operaban bajo supuestos restrictivos—linealidad, estacionariedad, distribuciones paramétricas—que limitaban su capacidad para capturar la complejidad inherente de los mercados financieros.

La irrupción del aprendizaje automático en finanzas cuantitativas, acelerada por el crecimiento exponencial de la capacidad computacional y la disponibilidad de datos, transformó este panorama de manera fundamental. A diferencia de los modelos econométricos tradicionales, donde el investigador debe especificar de antemano la forma funcional de la relación entre predictores y variable objetivo, los algoritmos de aprendizaje automático descubren estas relaciones directamente a partir de los datos. Esta flexibilidad resulta particularmente valiosa en mercados financieros, donde las dependencias entre variables macroeconómicas, indicadores técnicos y retornos futuros son potencialmente no lineales, cambiantes en el tiempo y de alta dimensionalidad.

Gu et al. (2020) proporcionan el tratamiento empírico más completo hasta la fecha sobre esta cuestión, mostrando que las redes neuronales, el *gradient boosting* y otros métodos no lineales superan sustancialmente a la regresión lineal en la predicción de rendimientos de acciones individuales. Su trabajo demuestra que la ganancia predictiva del aprendizaje automático proviene precisamente de su capacidad para capturar interacciones complejas entre cientos de predictores—una tarea para la cual los modelos lineales están estructuralmente limitados. Sin embargo, esta mayor capacidad de representación conlleva un riesgo proporcional de sobreajuste, especialmente en datos financieros donde la relación señal-ruido es notoriamente baja. El desafío central no es simplemente maximizar la precisión en datos históricos, sino lograr que los patrones aprendidos generalicen a períodos futuros no observados.

Un hallazgo complementario de Zeng et al. (2023) resulta igual de revelador: un modelo simple de descomposición lineal (DLinear) supera a arquitecturas sofisticadas basadas en Transformers en múltiples *benchmarks* de pronóstico de series temporales. Este resultado, aparentemente paradójico, subraya una lección fundamental para la aplicación de aprendizaje automático en finanzas: la complejidad arquitectural no garantiza superioridad predictiva, y en contextos de baja relación señal-ruido, los modelos más parsimoniosos pueden exhibir mejor generalización al evitar la memorización de patrones espúreos. La tensión entre complejidad y generalización constituye, en última instancia, una pregunta empírica que solo puede resolverse mediante la evaluación sistemática de múltiples familias de modelos sobre los datos específicos del problema.

Estas consideraciones motivaron la decisión metodológica central de este estudio, a saber, evaluar un espectro amplio de 23 modelos que abarca desde técnicas lineales regularizadas hasta arquitecturas de *deep learning* de última generación. El propósito no es encontrar un único modelo “mejor”, sino descubrir qué tipo de relación captura mejor la señal predictiva en los retornos del S&P 500: si es lineal, no lineal, temporal o una combinación de ellas. Si esa señal es predominantemente lineal, los modelos regularizados deberían dominar; si involucra interacciones

complejas entre predictores, los métodos de ensemble serán superiores; si depende de dependencias temporales a largo plazo, las arquitecturas recurrentes y de atención tendrán ventaja. Solo la comparación transversal permite responder esta pregunta con rigor.

2.5.1 Modelos Lineales Regularizados

Iniciar la evaluación con modelos lineales no es una concesión a la simplicidad sino una decisión metodológica deliberada. En finanzas cuantitativas, la regresión lineal constituye la hipótesis nula natural: si un modelo lineal puede capturar la señal predictiva disponible, recurrir a arquitecturas más complejas no solo es innecesario sino potencialmente contraproducente, dado el riesgo adicional de sobreajuste que conllevan. Además, los modelos lineales ofrecen interpretabilidad directa—los coeficientes indican la contribución marginal de cada predictor—una propiedad valiosa para entender qué variables impulsan las predicciones.

Cuando el número de características es elevado—536 en este estudio—el riesgo de sobreajuste se convierte en un problema central, incluso para modelos lineales. Los métodos de regularización abordan esta dificultad imponiendo restricciones sobre la magnitud de los coeficientes. Ridge (Hoerl & Kennard, 1970) aplica una penalización L_2 que contrae los coeficientes hacia cero sin eliminarlos, preservando la información de todos los predictores en forma atenuada. Lasso (Tibshirani, 1996) emplea una penalización L_1 que puede reducir coeficientes exactamente a cero, realizando selección automática de variables—una forma implícita de determinar qué predictores son verdaderamente relevantes entre los 536 disponibles. ElasticNet combina ambas penalizaciones, ofreciendo un balance entre retención de información y esparsidad. En el contexto financiero, donde la señal disponible es débil frente al volumen de predictores, la regularización cumple una función análoga a la diversificación en un portafolio: distribuye el riesgo de error entre múltiples fuentes de información en lugar de concentrarlo en un subconjunto reducido de variables.

2.5.2 Métodos de Ensemble Basados en Árboles

Si la señal predictiva en los retornos financieros involucra interacciones no lineales entre variables—por ejemplo, que el efecto de la pendiente de la curva de rendimientos sobre los retornos dependa del nivel de volatilidad del mercado—los modelos lineales serán incapaces de capturarla independientemente de cuántas características se les proporcionen. Los métodos basados en árboles de decisión abordan esta limitación al particionar el espacio de predictores en regiones donde la relación con la variable objetivo es localmente simple, capturando así interacciones complejas de manera natural y sin necesidad de que el investigador las especifique

de antemano.

Random Forest ([Breiman, 2001](#)) implementa esta idea construyendo múltiples árboles de decisión sobre submuestras aleatorias del conjunto de datos y agregando sus predicciones para reducir la varianza. Gradient Boosting ([Friedman, 2001](#)) adopta un enfoque distinto: cada árbol nuevo corrige específicamente los errores residuales del anterior, construyendo el modelo de forma secuencial y concentrando progresivamente su capacidad en las observaciones más difíciles de predecir. Tres implementaciones optimizadas de este principio—XGBoost ([Chen & Guestrin, 2016](#)), LightGBM y CatBoost—incorporan regularización explícita, muestreo por columnas y optimizaciones computacionales que los han convertido en los métodos dominantes en competiciones de aprendizaje automático aplicado durante la última década.

La relevancia de estos métodos para el presente estudio es doble. En primer lugar, los datos financieros son inherentemente tabulares—cada observación es un vector de indicadores numéricos—y existe evidencia creciente de que los métodos de ensemble basados en árboles superan consistentemente a las redes neuronales profundas en datos de esta naturaleza. En segundo lugar, su capacidad para manejar valores faltantes, variables de distintas escalas y distribuciones no gaussianas los hace particularmente robustos ante las irregularidades típicas de los datos financieros.

2.5.3 Modelos Estadísticos de Series Temporales

Los retornos financieros son, ante todo, una serie temporal, y la estructura temporal de los datos contiene información que los modelos transversales—como los de regresión y ensemble descritos anteriormente—no están diseñados para explotar directamente. Los modelos estadísticos de series temporales capturan esta estructura a través de supuestos explícitos sobre la dinámica generadora de los datos, y su inclusión en este estudio cumple un doble propósito: por un lado, constituyen *benchmarks* naturales contra los cuales evaluar si los modelos más complejos añaden valor genuino; por otro, su parsimonia los protege del sobreajuste, una ventaja no trivial en datos financieros.

Dentro de esta familia, es posible distinguir dos roles diferenciados. El Suavizado Exponencial, el método Theta y SeasonalNaive representan enfoques de pronóstico de tendencia que, pese a su simplicidad aparente, han demostrado competitividad sorprendente en competiciones formales de pronóstico. Prophet ([Taylor & Letham, 2018](#)), desarrollado por Facebook, extiende estos enfoques al descomponer la serie en componentes de tendencia, estacionalidad y efectos de calendario, ofreciendo flexibilidad y robustez ante datos faltantes o irregulares. GARCH ([Bollerslev, 1986](#)), por su parte, cumple un rol conceptualmente distinto: no modela el nivel de los retor-

nos sino su volatilidad condicional, capturando el fenómeno de agrupamiento de volatilidad—períodos de alta volatilidad tienden a ser seguidos por períodos igualmente volátiles—una de las regularidades empíricas más robustas documentadas en los mercados financieros. Si la señal predictiva relevante reside en la dinámica de la volatilidad más que en la dirección del retorno, GARCH debería capturarla con mayor eficacia que los modelos de regresión.

2.5.4 Arquitecturas de Deep Learning

Las redes neuronales profundas representan el extremo opuesto del espectro de complejidad respecto a los modelos lineales regularizados: ofrecen la mayor capacidad de representación pero también el mayor riesgo de sobreajuste. Su inclusión en este estudio responde a la pregunta de si la señal predictiva en los retornos del S&P 500 contiene patrones temporales complejos que las familias anteriores no pueden capturar. Si los modelos de *deep learning* superan significativamente a los lineales y a los ensembles, ello constituiría evidencia de que la estructura subyacente es genuinamente compleja; si no lo hacen, el resultado sugeriría que la complejidad adicional se disipa en ruido.

Dentro de las arquitecturas recurrentes, la red LSTM (*Long Short-Term Memory*), introducida por Hochreiter & Schmidhuber (1997), resolvió el problema del gradiente desvaneciente mediante celdas de memoria con compuertas de entrada y salida—extendidas posteriormente con la compuerta de olvido por Gers et al. (2000)—, lo que permite capturar dependencias temporales a largo plazo—por ejemplo, que el comportamiento del mercado durante una crisis refleje patrones observados meses antes. Las variantes bidireccionales (Bi-LSTM, Bi-GRU) procesan la secuencia en ambas direcciones temporales, mientras que la arquitectura híbrida CNN-LSTM aplica capas convolucionales para extraer patrones locales en ventanas cortas antes de alimentar el procesamiento recurrente, combinando así detección de patrones a corto plazo con memoria a largo plazo.

El mecanismo de atención (Vaswani et al., 2017) introdujo un paradigma distinto al permitir que el modelo pondere dinámicamente la importancia de cada paso temporal, en lugar de procesar la secuencia de forma estrictamente secuencial. Este principio se incorpora en el modelo LSTM con Atención y, de manera más sofisticada, en el Temporal Fusion Transformer (TFT) de Lim et al. (2021), que combina atención multi-cabeza con selección automática de variables—una propiedad particularmente útil cuando se dispone de cientos de predictores y no es claro cuáles son relevantes en cada momento del tiempo.

Finalmente, N-BEATS (Oreshkin et al., 2020) y N-HiTS representan una filosofía arquitectural distinta: redes puramente *feed-forward* diseñadas específicamente para pronóstico de series

temporales, que descomponen la señal en bloques interpretables de tendencia y estacionalidad sin recurrir a mecanismos recurrentes o de atención. La Temporal Convolutional Network (TCN), por su parte, aplica convoluciones causales dilatadas para capturar dependencias a múltiples escalas temporales simultáneamente. La diversidad de estas subfamilias—recurrentes, basadas en atención, convolucionales y *feed-forward*—permite evaluar si alguna estructura temporal específica domina la señal predictiva o si, por el contrario, la ventaja del *deep learning* es limitada en este contexto.

3. Datos y Metodología

En esta sección se describe el marco empírico del estudio en cuatro componentes. Primero, se detalla la construcción del conjunto de datos a partir de 92 variables financieras obtenidas de Bloomberg Terminal y el proceso sistemático de ingeniería de características que las transforma en 536 predictores. A continuación se define la variable objetivo y la división temporal de la muestra, se presentan las especificaciones de los 23 modelos evaluados, y se formaliza el sistema de posicionamiento que convierte predicciones continuas en decisiones discretas de inversión.

3.1 Fuentes de Datos e Ingeniería de Características

3.1.1 Universo de Datos

El análisis emplea datos diarios obtenidos de Bloomberg Terminal para el período comprendido entre el 31 de enero de 2000 y el 11 de diciembre de 2025. El dataset resultante comprende 6,507 observaciones diarias.

El universo de variables base se compone de 92 series temporales organizadas en siete categorías temáticas, seleccionadas para capturar las múltiples dimensiones que la literatura ha identificado como relevantes para la predicción de retornos accionarios (Gu et al., 2020). A continuación se describe cada categoría, su justificación teórica y las variables específicas que la componen.

Índices y ETFs de mercado (18 variables). La dinámica de retornos entre clases de activos, regiones geográficas y sectores económicos constituye una fuente fundamental de información predictiva. Los flujos de capital entre mercados desarrollados y emergentes, la rotación sectorial y los movimientos cambiarios reflejan cambios en el apetito por riesgo que frecuentemente anticipan los retornos del mercado amplio. Esta categoría incluye: (i) índices de referencia norteamericanos—SPY (S&P 500), QQQ (Nasdaq-100) e IWM (Russell 2000)—que capturan

la dispersión entre *large caps*¹, tecnología y *small caps*; (ii) ETFs internacionales—EFA (mercados desarrollados ex-US), EEM (mercados emergentes), VGK (Europa), EWJ (Japón) y FXI (China)—que reflejan la dinámica global de riesgo; (iii) ETFs sectoriales del S&P 500—XLF (financiero), XLK (tecnología), XLE (energía), XLV (salud), XLI (industrial) y XLU (servicios públicos)—que capturan la rotación sectorial; y (iv) divisas—DXY (índice dólar), EUR/USD y USD/JPY—que reflejan las condiciones de liquidez global y los diferenciales de política monetaria. Se incluye además el índice FTSE NAREIT (bienes raíces), sensible a las condiciones crediticias.

Indicadores macroeconómicos (19 variables). Las condiciones macroeconómicas fundamentales ejercen una influencia directa sobre los flujos de caja corporativos esperados y, por tanto, sobre la valoración de las acciones. Chen et al. (1986) demostraron que variables como la producción industrial, la inflación y los *spreads*² de crédito explican una porción significativa de la variación transversal de retornos accionarios, estableciendo las bases de los modelos multifactoriales macroeconómicos. Esta categoría comprende indicadores de actividad real—PIB trimestral (QoQ y YoY), producción industrial, utilización de capacidad y ventas minoristas—; indicadores del mercado laboral—nóminas no agrícolas (*Non-Farm Payrolls*), tasa de desempleo, solicitudes iniciales de subsidio de desempleo e ingreso personal—; indicadores de precios—IPC interanual y *Core PCE*³—; indicadores de confianza—sentimiento del consumidor (U. Michigan) y confianza del consumidor (Conference Board)—; indicadores del sector vivienda—inicios de construcción (*Housing Starts*), ventas de vivienda nueva y existente—; y los índices PMI manufacturero y de servicios (ISM), junto con el índice Líder Compuesto del Conference Board.

Tasas de interés y curva de rendimiento (20 variables). La estructura temporal de tasas de interés es uno de los predictores macroeconómicos más robustos documentados en la literatura. Harvey (1989) demostró que la pendiente de la curva de rendimiento anticipa recesiones económicas, mientras que Fama & French (1989) establecieron que los *spreads* de crédito y de término predicen retornos accionarios a horizontes intermedios. Esta categoría abarca: la tasa de política monetaria (Fed Funds); la curva de rendimiento completa del Tesoro estadounidense—*T-Bills*⁴ a 3, 6 y 12 meses, y bonos a 2, 5, 10 y 30 años—; los índices de rendimiento genérico

¹*Large caps* y *small caps* designan empresas de gran y pequeña capitalización bursátil, respectivamente. La capitalización se define como el precio de la acción multiplicado por el número de acciones en circulación.

²Un *spread* es la diferencia entre dos tasas de interés o rendimientos. El *spread* de crédito, por ejemplo, mide la prima que exige el mercado por prestar a un emisor corporativo frente a un bono del Tesoro de igual plazo; cuanto mayor el *spread*, mayor el riesgo crediticio percibido.

³*Core PCE* (*Personal Consumption Expenditures* excluyendo alimentos y energía) es la medida de inflación preferida por la Reserva Federal para decisiones de política monetaria, por ser menos volátil que el IPC.

⁴*Treasury Bills* (T-Bills) son instrumentos de deuda a corto plazo (hasta 1 año) emitidos por el Tesoro de EE.UU., considerados libres de riesgo crediticio. Los *T-Notes* (2–10 años) y *T-Bonds* (20–30 años) son sus equi-

de Bloomberg para los vencimientos a 10 y 2 años (USGG10YR y USGG2YR), que a diferencia de los bonos individuales *on-the-run*⁵ reflejan un compuesto de emisiones cercanas a cada plazo; los *spreads* de término precalculados (10Y–2Y y 10Y–3M); la tasa interbancaria a corto plazo (Libor 3M) y la tasa *swap*⁶ a 10 años; los índices de *credit default swaps*⁷—CDX *Investment Grade* y CDX *High Yield*⁸—que capturan la percepción de riesgo crediticio corporativo; y los índices de bonos Bloomberg (US Aggregate Total Return, US Aggregate OAS, US Corporate Total Return), junto con el ETF LQD (*investment grade* corporativo).

Commodities (11 variables). Los precios de las materias primas operan como indicadores adelantados de presiones inflacionarias y cambios en la actividad económica global. Los movimientos en energía anticipan costos de producción; los metales preciosos reflejan la demanda por activos refugio; y la actividad en los mercados de futuros de *commodities* contiene información predictiva sobre condiciones macroeconómicas y precios de activos (Hong & Yogo, 2012). Se incluyen: futuros de energía—WTI (*crude oil*) y *heating oil*—; metales preciosos tanto en futuros (oro, plata) como en ETFs (GLD, SLV); el ETF de petróleo USO; índices amplios de *commodities*—DBC, Bloomberg BCOM y S&P GSCI—; y el ETF DBA (agricultura).

Volatilidad (13 variables). La volatilidad implícita constituye una medida directa de la incertidumbre percibida por el mercado y exhibe una relación contemporánea negativa con los retornos accionarios ampliamente documentada en la literatura—el denominado *leverage effect*. Ang et al. (2006) muestran, además, que la exposición al riesgo de volatilidad agregada se refleja en la sección cruzada de retornos esperados. La estructura temporal de la volatilidad—en particular la relación entre VIX de corto y largo plazo—captura cambios en el régimen de riesgo que frecuentemente preceden movimientos direccionales del mercado. Esta categoría comprende: el VIX y sus variantes por horizonte temporal—VIX1M⁹ (1 mes), VIX3M (3 meses) y VXV (3 meses, variante)—cuya estructura temporal permite identificar inversiones indicativas de estrés;

valentes a mayor plazo.

⁵Un bono *on-the-run* es la emisión más reciente del Tesoro para un plazo dado. Su alta liquidez puede distorsionar el rendimiento observado respecto al nivel “real” de la curva. Los índices genéricos de Bloomberg promedian emisiones cercanas a cada vencimiento, ofreciendo una medida más estable.

⁶Una tasa *swap* de interés es la tasa fija que se intercambia por una tasa variable en un contrato de derivados (*interest rate swap*). La tasa *swap* a 10 años refleja las expectativas del mercado sobre tasas de interés futuras y riesgo crediticio bancario.

⁷Un *credit default swap* (CDS) es un contrato derivado que funciona como un seguro contra el incumplimiento de pago de un emisor de deuda. Los índices CDX agregan *spreads* de CDS de múltiples emisores, ofreciendo una medida amplia del riesgo crediticio corporativo.

⁸*Investment Grade* (grado de inversión) designa emisores con calificación crediticia BBB– o superior, considerados de bajo riesgo de impago. *High Yield* (alto rendimiento) designa emisores por debajo de BBB–, que ofrecen mayores rendimientos como compensación por su mayor riesgo.

⁹Si bien el VIX estándar ya aproxima la volatilidad implícita a 30 días, VIX1M emplea una metodología que fija con mayor precisión el horizonte exacto de un mes calendario. Ambos índices son altamente correlacionados, pero su diferencia contiene información sobre la microestructura temporal de la volatilidad de muy corto plazo.

índices de volatilidad implícita para otras clases de activos—VXEEM (mercados emergentes), VXEFA (mercados desarrollados), GVZ (oro), OVX (petróleo), TYVIX (bonos del Tesoro) y MOVE (mercado de renta fija)—; el CVIX (divisas); el futuro VIX del mes próximo (VIY1); y el V2X (Euro Stoxx 50), que captura el régimen de volatilidad europeo.

Sentimiento de mercado (10 variables). El sentimiento inversor, definido como la propensión a especular no justificada por los fundamentales, genera desviaciones sistemáticas de precios respecto a su valor intrínseco. Baker & Wurgler (2006) demostraron que períodos de alto sentimiento preceden retornos bajos, especialmente en acciones difíciles de arbitrar, lo cual ofrece poder predictivo en la sección cruzada de retornos. Esta categoría incluye: la encuesta AAII (*American Association of Individual Investors*) de sentimiento alcista; ratios *put/call*¹⁰ de opciones sobre acciones (CBOE Equity Put/Call y Put Index); indicadores de *breadth*¹¹ de mercado—NYSE *New Highs–New Lows*¹², *Advance–Decline Line*¹³, TICK y TRIN (*Arms Index*)¹⁴—; el oscilador McClellan y su índice de sumación, que capturan la amplitud del mercado en múltiples horizontes; y el índice SRVOL (*Short-Range Volatility*), que captura la volatilidad de corto plazo.

Datos OHLCV del SPY y tasa libre de riesgo. Finalmente, se incluyen los cinco campos estándar del registro de precio diario del ETF SPY—apertura, máximo, mínimo, cierre y volumen (OHLCV¹⁵)—que constituyen la materia prima para el cálculo de indicadores técnicos, estimadores de volatilidad OHLC y características de microestructura. La tasa libre de riesgo, derivada del *T-Bill* a 3 meses, se utiliza para el cálculo de retornos en exceso que conforman la variable objetivo del sistema.

3.1.2 Pipeline de Ingeniería de Características

Las variables en bruto raramente sirven como predictores efectivos en su forma original. Como documentan Gu et al. (2020), la transformación sistemática de las variables base en

¹⁰El ratio *put/call* mide el volumen de opciones de venta (*puts*) relativo al volumen de opciones de compra (*calls*). Un ratio elevado indica sentimiento pesimista (más inversores comprando protección a la baja); un ratio bajo indica optimismo.

¹¹*Breadth* (amplitud de mercado) mide qué proporción de las acciones individuales participa en un movimiento del índice. Un mercado que sube con alta amplitud (muchas acciones subiendo) se considera más sano que uno impulsado por pocas acciones de gran capitalización.

¹²*New Highs–New Lows*: diferencia diaria entre el número de acciones que alcanzan máximos de 52 semanas y las que tocan mínimos. Un valor positivo indica predominio alcista.

¹³La *Advance–Decline Line* acumula diariamente la diferencia entre el número de acciones que suben y las que bajan, proporcionando una medida tendencial de la amplitud del mercado.

¹⁴El TICK mide la diferencia instantánea entre acciones cotizando al alza y a la baja. El TRIN (*Arms Index*) relaciona la razón de acciones que suben/bajan con la razón de volumen al alza/a la baja; valores < 1 indican presiones alcistas y > 1 presiones bajistas.

¹⁵Acrónimo de *Open, High, Low, Close, Volume*: los cinco campos estándar de un registro de precio diario.

características que capturen dinámicas temporales, relaciones cruzadas y estados de régimen es un paso determinante para el rendimiento predictivo de los modelos. Siguiendo esta lógica, se implementa un *pipeline*¹⁶ que transforma las 92 variables base en 536 predictores.

Dada la dimensionalidad del espacio resultante, esta sección no pretende detallar cada característica individualmente, sino describir la lógica de construcción de las principales familias de transformación. Cabe señalar que el conjunto de 536 características constituye deliberadamente una representación *sobre-completa*: algunas variables capturan la misma dinámica subyacente bajo formulaciones distintas. Por ejemplo, el estimador de volatilidad de Parkinson (1980), basado en el rango intradía, aparece tanto en la familia de estimadores clásicos como en la de estimadores contemporáneos de rango logarítmico de Alizadeh et al. (2002), quienes reformulan el mismo cálculo en un marco distribucional distinto. Estas redundancias se mantienen de forma intencional. Eliminarlas mediante un filtro de correlación requeriría decisiones subjetivas—qué umbral emplear, cuál de dos variables equivalentes descartar—cuyo resultado variaría según el criterio del investigador sin una justificación teórica clara para preferir una elección sobre otra. Se opta, en cambio, por delegar esa selección a los propios modelos, que poseen mecanismos internos para gestionar la colinealidad: las penalizaciones L1 y L2 de los modelos regularizados anulan o distribuyen los coeficientes de variables redundantes; los algoritmos basados en árboles de decisión seleccionan *splits* por ganancia de información, ignorando las variables sin poder discriminante marginal; y las arquitecturas de *deep learning* aprenden representaciones comprimidas mediante *dropout* y capas de atención. Delegar la selección de características a estos mecanismos—en lugar de imponer un criterio externo de filtrado—es consistente con la recomendación de Gu et al. (2020), quienes argumentan que los modelos flexibles de *machine learning* se benefician de espacios de características amplios, siempre que cuenten con regularización adecuada.

Es fundamental aclarar que todas las transformaciones descritas a continuación operan sobre datos diarios. Cuando se hace referencia a *ventanas* u *horizontes* de 5, 21, 63 o 252 días, se trata de ventanas retrospectivas (*lookback windows*) que, en cada día t , utilizan exclusivamente observaciones pasadas $\{t - n, \dots, t\}$ para calcular un valor en t . El dato resultante se registra diariamente; lo que varía es la profundidad del historial empleado en el cálculo. De este modo, una característica como `SPY_return_252d[t]` no representa un dato anual, sino el retorno acumulado del precio entre $t - 252$ y t , calculado *cada día* t .

¹⁶Un *pipeline* (tubería de procesamiento) es una secuencia automatizada de etapas de transformación donde la salida de cada etapa alimenta la entrada de la siguiente. En este contexto, transforma datos en bruto en características aptas para modelado predictivo.

Indicadores técnicos clásicos (19 características). Los precios en bruto—apertura, máximo, mínimo, cierre y volumen—contienen información que no es directamente accesible para un modelo predictivo en su forma original. Un precio de cierre de \$450 no indica por sí solo si el mercado está sobrecomprado, si la tendencia se está agotando o si el volumen confirma el movimiento. Los indicadores técnicos resuelven esta limitación condensando la historia reciente de precio y volumen en señales interpretables que representan el estado actual del mercado. Para un modelo de *machine learning*, estos indicadores no funcionan como reglas de decisión (“comprar si $RSI < 30$ ”), sino como representaciones compactas del régimen de precio sobre las cuales el modelo puede aprender qué combinaciones de condiciones preceden retornos positivos o negativos.

A partir de los datos OHLCV del SPY y utilizando la librería TA-Lib¹⁷, se calculan: el Índice de Fuerza Relativa (RSI) en ventanas de 7, 14 y 21 días, que mide la magnitud relativa de ganancias frente a pérdidas recientes; la Convergencia/Divergencia de Medias Móviles (MACD) con sus componentes de línea, señal e histograma; el Índice Direccional Medio (ADX) junto con los indicadores direccionales +DI y −DI, que cuantifican la fuerza y dirección de la tendencia; el Oscilador Estocástico (%K, %D) y el Williams %R, que identifican condiciones de sobrecompra y sobreventa; el Índice de Canal de *Commodities* (CCI); el Rango Verdadero Medio (ATR), que mide la volatilidad intradía; el *On-Balance Volume* (OBV), que acumula volumen ponderado por la dirección del precio; y la posición del precio dentro de las Bandas de Bollinger. Estos 19 indicadores constituyen el vocabulario base del análisis técnico sobre el cual se construyen las familias más especializadas que se describen a continuación.

Momentum, retornos y volumen (32 características). Mientras que los indicadores técnicos clásicos describen el *estado* actual del mercado, las características de *momentum* capturan su *inercia*—la velocidad y dirección del cambio de precio a distintas escalas temporales. Esta distinción es relevante porque la evidencia empírica muestra que el *momentum*¹⁸ opera de forma diferente según el horizonte: a muy corto plazo (1–5 días) los retornos tienden a revertir, a mediano plazo (1–12 meses) tienden a persistir, y a largo plazo (3–5 años) vuelven a revertir. Proveer múltiples ventanas permite a los modelos aprender cuál de estas dinámicas domina en cada régimen de mercado.

Los retornos históricos se calculan mediante la función `pct_change(n)`, que computa el cambio porcentual entre el precio actual y el precio de hace n días hábiles: $r_n[t] = (P[t] - P[t -$

¹⁷TA-Lib (*Technical Analysis Library*) es una librería estándar de la industria financiera cuyos indicadores están diseñados para operar exclusivamente sobre datos históricos, sin incorporar observaciones futuras.

¹⁸En finanzas, *momentum* designa la tendencia empírica de los activos con buen rendimiento reciente a seguir rindiendo bien en el corto plazo, y viceversa. Este fenómeno, documentado por Jegadeesh & Titman (1993), constituye una de las anomalías más robustas frente a la hipótesis de eficiencia de mercado.

$n)/P[t - n]$. Se generan retornos para ventanas de 1, 5, 21, 63, 126 y 252 días, junto con sus equivalentes expresados como tasa de cambio porcentual (*Rate of Change*). La distancia del precio a medias móviles de 10, 21, 50, 100 y 200 días captura la posición relativa del precio respecto a su tendencia de largo plazo. Los cruces de medias móviles (*crossovers*)—señales binarias que indican cuándo una media móvil de corto plazo supera o cae por debajo de una de largo plazo (pares 5/10, 10/21, 20/50, 50/200)—codifican cambios de tendencia. La volatilidad realizada se estima como la desviación estándar móvil de retornos diarios, anualizada por $\sqrt{252}$, en ventanas de 5 a 126 días, junto con ratios de volatilidad entre ventanas (5/21 y 21/63) que detectan compresiones o expansiones de volatilidad. Completan esta familia dos características de volumen: el volumen relativo respecto a su media móvil de 20 y 63 días, que mide si la actividad de mercado reciente es atípicamente alta o baja.

Análisis técnico avanzado (60 características). Los indicadores clásicos descritos anteriormente miden una sola dimensión del mercado a la vez: el RSI captura *momentum*, el ATR captura volatilidad, el OBV captura volumen. Sin embargo, las decisiones de inversión rara vez dependen de una única dimensión—lo relevante es la *confluencia* de múltiples condiciones simultáneas y el *contexto* en que se producen (posición del precio dentro de un rango histórico, zona de soporte o resistencia, alineación de múltiples señales). Las seis familias que siguen capturan precisamente estas relaciones multidimensionales.

La **Nube de Ichimoku**¹⁹ genera 13 características a partir de cinco líneas calculadas sobre ventanas de 9, 26 y 52 días. La “nube” (espacio entre las líneas Senkou A y B) define zonas de soporte y resistencia dinámicas: se codifica la posición del precio respecto a la nube (por encima, dentro o por debajo), el espesor de la nube como proporción del precio, las distancias a las líneas de referencia (Tenkan y Kijun) y los cruces entre ellas, que señalan cambios de tendencia. Una variable compuesta indica la confluencia alcista plena: precio sobre la nube y línea rápida sobre la lenta.

Los **retrocesos de Fibonacci**²⁰ producen 18 características para ventanas de 63 y 126 días. En cada día se identifica el rango (máximo y mínimo del período) y se calcula la posición relativa del precio dentro de ese rango, su distancia a cada nivel de Fibonacci y variables binarias que indican si el precio se encuentra en una zona de proximidad ($\pm 2\%$) a los niveles 38.2 %, 50 % y 61.8 %, donde las reversiones son estadísticamente más frecuentes.

¹⁹El Ichimoku Kinko Hyo (“vista instantánea del equilibrio”) es un sistema de análisis técnico desarrollado por el periodista japonés Goichi Hosoda en la década de 1960. A diferencia de la mayoría de indicadores occidentales—que miden una sola dimensión (tendencia, *momentum* o volatilidad)—, Ichimoku integra las tres en una estructura visual unificada.

²⁰Los niveles de Fibonacci (23.6 %, 38.2 %, 50 %, 61.8 %, 78.6 %) derivan de la razón áurea y se utilizan ampliamente en análisis técnico como niveles probables de soporte y resistencia durante correcciones de precio.

Los **canales de Donchian**²¹ aportan 8 características para períodos de 20 y 55 días: la posición del precio dentro del canal, su ancho como proporción del precio y señales binarias de ruptura al alza o a la baja. Los **canales de Keltner** complementan con 3 características que miden la posición del precio dentro de bandas basadas en el ATR, e incluyen un indicador de *squeeze*²² que detecta cuando las Bandas de Bollinger se comprimen dentro de los canales de Keltner—una condición que anticipa expansiones de volatilidad.

El **flujo de dinero** se cuantifica mediante 8 características: el *Money Flow Index* (MFI) en ventanas de 14 y 21 días—un oscilador que pondera el volumen por la dirección del precio típico²³, con señales de sobrecompra y sobreventa—y el *Chaikin Money Flow* (CMF) en ventanas de 20 y 50 días, que mide la presión acumulada de compra o venta según dónde cierra el precio dentro del rango intradía. Por último, 10 **señales de confluencia estratégica** codifican combinaciones binarias de condiciones de mercado: estados del RSI, posición del precio respecto a medias móviles de largo plazo (SMA-200), cruces dorados y de muerte (SMA-50 vs. SMA-200), fuerza de tendencia ($ADX > 25$) y puntuaciones compuestas que requieren la alineación simultánea de al menos tres condiciones alcistas o bajistas.

Análisis multi-temporal Triple Screen (24 características). Se implementa el sistema Triple Screen de Elder (1993), adaptado como generador de características²⁴. El principio central de este sistema es que una decisión de inversión mejora cuando se analiza el mercado en múltiples escalas temporales simultáneamente: primero se identifica la tendencia dominante en un horizonte largo, luego se buscan puntos de entrada en un horizonte intermedio, y finalmente se confirma la señal con indicadores de corto plazo. Elder denominó a estos tres niveles de análisis *screens* (filtros), de ahí el nombre del sistema.

En el primer nivel, se simula un horizonte semanal a partir de datos diarios mediante ventanas móviles de cinco días, calculando un MACD con períodos expandidos (multiplicados por 5) para identificar la dirección de la tendencia de fondo. En el segundo nivel, se generan osciladores diarios que miden presiones de corto plazo *dentro* de esa tendencia: el Índice de Fuerza de Elder en versiones de 2 y 13 períodos—que combina cambio de precio y volumen, normalizado por su

²¹Los canales de Donchian, desarrollados por Richard Donchian en la década de 1970, definen un canal formado por el máximo más alto y el mínimo más bajo de los últimos n días. Las rupturas del canal se interpretan como señales de continuación de tendencia.

²²Un *squeeze* (compresión) ocurre cuando las Bandas de Bollinger se contraen dentro de los canales de Keltner, indicando que la volatilidad es inusualmente baja. Históricamente, los períodos de compresión preceden movimientos direccionales fuertes.

²³El precio típico se define como $(High + Low + Close)/3$. El MFI multiplica este precio por el volumen para obtener el “flujo de dinero”, cuya proporción positiva/negativa genera un oscilador entre 0 y 100.

²⁴Es importante distinguir entre el uso de Triple Screen como *estrategia de trading* (comprar/vender según sus señales) y su uso como *generador de features* (alimentar modelos predictivos con la información multi-temporal que el marco captura). En este estudio se adopta exclusivamente la segunda interpretación.

desviación estándar móvil de 63 días—y el *Elder Ray* (*Bull/Bear Power*), que mide la distancia entre los extremos intradía y la media móvil exponencial (EMA) de 13 períodos. En el tercer nivel, el Sistema de Impulso combina la dirección de la EMA con la del histograma MACD para clasificar cada día como alcista (ambos subiendo), bajista (ambos cayendo) o neutral. La lógica subyacente es que las señales más fiables surgen cuando los tres niveles están alineados: una tendencia alcista de fondo, un retroceso temporal en los osciladores y una confirmación de impulso diario. Se incluyen además señales puras de Elder—compra cuando *Bear Power* es negativo pero creciente (anticipación de giro alcista) y venta cuando *Bull Power* es positivo pero decreciente—y un *score* compuesto que cuantifica el grado de alineación entre los tres niveles.

Estimadores de volatilidad OHLC y microestructura (81 características). La volatilidad calculada a partir de retornos *close-to-close*—la desviación estándar móvil de los retornos diarios, ya incluida en la familia de *momentum*—presenta una limitación fundamental: descarta toda la información contenida en el movimiento intradía del precio. Un día en que el mercado sube un 3% y luego retrocede para cerrar sin cambios registra retorno cero y, por tanto, volatilidad *close-to-close* nula, a pesar de haber experimentado una dispersión de precio considerable. Los datos OHLC (apertura, máximo, mínimo y cierre) capturan esta información perdida, y la literatura financiera ha producido una secuencia de estimadores progresivamente más eficientes para explotarla.

Parkinson (1980) propone el primer estimador basado exclusivamente en el rango *High-Low*, demostrando que es aproximadamente cinco veces más eficiente estadísticamente que la volatilidad *close-to-close*. Garman & Klass (1980) mejoran esta eficiencia incorporando la relación *Close-Open*, que añade información sobre la dirección del movimiento intradía. Ambos estimadores asumen, sin embargo, que la serie no presenta tendencia (*drift*)²⁵—un supuesto frecuentemente violado en mercados accionarios, donde los retornos esperados de largo plazo son positivos. Rogers & Satchell (1991) eliminan esta limitación con un estimador que separa explícitamente el *drift* de la volatilidad. Finalmente, Yang & Zhang (2000) integran los aportes anteriores en un estimador que descompone la varianza total en tres componentes—*overnight* (el *gap* entre cierre anterior y apertura), *open-to-close* (movimiento intradía direccional) y Rogers-Satchell (dispersión pura)—combinados con una ponderación óptima ($k = 0.34$) que minimiza la varianza del estimador. Cada uno de estos cuatro estimadores se calcula en ventanas de 21 y 63 días, produciendo 8 características clásicas.

Una segunda generación de trabajos trasciende la mera estimación puntual de la volatilidad

²⁵ *Drift* (deriva) es la tendencia determinista de una serie temporal—por ejemplo, el rendimiento esperado positivo de largo plazo del mercado accionario. Cuando existe *drift*, algunos estimadores de volatilidad lo confunden con dispersión aleatoria, sobreestimando la volatilidad real.

para extraer características más ricas de la dinámica del rango. Alizadeh et al. (2002) demuestran que el logaritmo del rango, $\ln(H/L)$, sigue una distribución aproximadamente gaussiana— a diferencia de la volatilidad misma, que es marcadamente asimétrica—lo que permite aplicar herramientas estadísticas estándar (medias, desviaciones, percentiles, momentos de orden superior) directamente sobre esta variable. Chou (2005) modela el rango diario como un proceso autorregresivo condicional (CARR²⁶), capturando su persistencia temporal mediante rezagos, innovaciones (rango observado menos rango esperado) e indicadores de *shock* cuando el rango excede dos desviaciones estándar de su distribución reciente. Fiszeder & Perczak (2016) combinan retornos y rango en un marco unificado (*Range-GARCH*), aportando medidas de eficiencia de precio—qué fracción del rango intradía se traduce en retorno direccional—y descomposiciones de la varianza en componentes *overnight* e intradía. Vinté et al. (2019) aplican teoría de información al análisis de la dispersión intradía, midiendo la entropía de la posición del precio dentro del rango diario ponderada por el volumen negociado: un día donde apertura y cierre coinciden con volumen elevado (alta entropía) refleja indecisión activa del mercado, mientras que uno donde el precio recorre el rango completo (baja entropía) refleja convicción direccional. En conjunto, estos estimadores contemporáneos generan 54 características.

Complementan esta dimensión 19 características de **microestructura** que diseccionan la anatomía de cada sesión individual: el rango intradía y el *True Range*²⁷, la posición del cierre dentro del rango diario (0 = cerró en el mínimo, 1 = cerró en el máximo), la magnitud y dirección de los *gaps overnight*²⁸ junto con un indicador de si el *gap* fue “llenado” durante la sesión, patrones de velas japonesas (proporción de cuerpo, sombras superior e inferior, detección de doji²⁹), volumen relativo respecto a promedios de 21 y 63 días, y el producto rango-volumen como indicador compuesto de actividad de mercado.

Relaciones *cross-asset*, VIX y condiciones macro (59 características). Las familias anteriores analizan el S&P 500 en aislamiento—su precio, su volumen, su volatilidad. Sin embargo, el mercado accionario no se mueve de forma independiente: reacciona a flujos de capital entre clases de activos, a cambios en las expectativas de política monetaria y al estado del ciclo económico real. La literatura ha documentado ampliamente estos vínculos: Chen et al. (1986)

²⁶CARR: *Conditional Autoregressive Range*. Análogo al modelo GARCH pero aplicado al rango en lugar de a los retornos al cuadrado. Captura la persistencia empírica del rango: días de rango amplio tienden a ser seguidos por días de rango amplio.

²⁷El *True Range* es el máximo entre: (i) rango intradía ($H - L$), (ii) distancia del máximo al cierre anterior, y (iii) distancia del mínimo al cierre anterior. Captura la volatilidad real incluyendo *gaps* entre sesiones.

²⁸Un *gap overnight* es la diferencia entre el precio de apertura de una sesión y el precio de cierre de la sesión anterior. Refleja la reacción del mercado a noticias y eventos ocurridos fuera del horario de negociación.

²⁹Un doji es una vela japonesa cuyo cuerpo—la distancia entre apertura y cierre—es inferior al 10 % del rango total del día. Refleja equilibrio entre compradores y vendedores y frecuentemente precede cambios de tendencia.

demuestran que variables macroeconómicas como la producción industrial, la inflación y la estructura de tasas de interés explican una parte significativa de los retornos accionarios; Fama & French (1989) muestran que los *spreads* de crédito y el *dividend yield* predicen retornos del mercado a horizontes de uno a cuatro años; Baker & Wurgler (2006) documentan que el sentimiento del inversor afecta la sección transversal de retornos esperados; y Hong & Yogo (2012) encuentran que la actividad en los mercados de *commodities* anticipa movimientos en el mercado accionario. Sin estas variables, el modelo solo observa el precio del SPY; con ellas, observa el ecosistema financiero que lo determina.

Las relaciones *cross-asset*³⁰ se cuantifican mediante correlaciones móviles entre los retornos del SPY y cinco activos de referencia (bonos del Tesoro a 10 años, oro, petróleo, dólar y VIX) en ventanas de 21 y 63 días. Estas correlaciones son dinámicas: en períodos de *risk-off*, acciones y bonos se descorrelacionan (los inversores venden renta variable y compran deuda soberana como refugio), mientras que en períodos de *risk-on* la correlación se estrecha. Las características del VIX incluyen cambios a 1, 5 y 21 días, indicadores de régimen basados en percentiles históricos (percentil 75 y 25 sobre una ventana móvil de 252 días), la estructura temporal—en particular la relación VIX3M/VIX, donde un ratio mayor a 1 indica *contango*³¹ y un ratio menor a 1 indica *backwardation*—y la prima de riesgo de volatilidad, definida como la diferencia entre la volatilidad implícita y la volatilidad realizada.

Se incorporan características de la curva de rendimiento—el predictor macroeconómico de recesiones más documentado en la literatura (Harvey, 1989)—incluyendo el *spread* 10Y–2Y y 10Y–3M, indicadores de inversión y el *butterfly*³² 2–5–10, junto con *spreads* de crédito (*investment grade* y *high yield*) cuya ampliación anticipa deterioro en las condiciones financieras. Los indicadores macroeconómicos se transforman en características de *momentum* (cambio a 21 y 63 días) y tendencia (cruce de media móvil de 5 contra 21 días) para siete indicadores clave (PIB, PMI, empleo, desempleo, IPC, producción industrial y confianza del consumidor). Completan esta familia cuatro indicadores compuestos de régimen de mercado—basados en precio vs. MA-200, *momentum*, nivel del VIX y proporción de sectores positivos—y términos de interacción entre variables ($VIX \times$ curva de rendimiento, *momentum* condicionado a régimen de volatilidad).

³⁰El análisis *cross-asset* (entre clases de activos) estudia las correlaciones y dinámicas entre mercados diferentes—acciones, bonos, materias primas, divisas—para extraer información que un análisis de cada mercado por separado no capturaría.

³¹*Contango* ($VIX3M > VIX$ spot) refleja condiciones normales de mercado; *backwardation* ($VIX3M < VIX$ spot) señala estrés agudo, dado que la volatilidad de corto plazo supera las expectativas a mediano plazo.

³²El *butterfly spread* de la curva de rendimiento mide su curvatura: se define como $(Y_2 + Y_{10}) - 2 \cdot Y_5$, donde Y_n es el rendimiento al plazo n . Un valor positivo indica una curva cóncava (“joroba” en el plazo medio); un valor negativo, una curva convexa.

Variables rezagadas y estadísticos móviles (78 características). Esta familia aplica dos tipos de transformaciones diseñadas para enriquecer la representación temporal de las variables y facilitar el aprendizaje de los modelos.

La primera transformación genera **variables rezagadas** (*lags*) que proporcionan al modelo memoria explícita del estado pasado de las variables. Formalmente, un *lag* de orden n desplaza la serie temporal n días hacia el pasado: $X_{\text{lag}(n)}[t] = X[t - n]$. Por ejemplo, `VIX_lag5[t]` contiene el nivel del VIX de hace cinco días hábiles. Se generan *lags* para 18 variables clave—tasas de interés a lo largo de la curva (Fed Funds, T-Bills, bonos a 2, 5, 10 y 30 años), VIX, índices de mercado (Russell 2000, EFA, EEM, XLF, XLU) e indicadores económicos (PIB, NFP, ventas minoristas)—en tres horizontes (1, 5 y 21 días), totalizando 54 características. Estos *lags* permiten a los modelos detectar patrones de cambio temporal: por ejemplo, si el VIX se disparó hace 5 días pero ha revertido a su nivel actual, esa trayectoria contiene información predictiva que el valor contemporáneo por sí solo no captura.

La segunda transformación calcula **estadísticos móviles** (*rolling statistics*) mediante ventanas móviles (*rolling windows*) de 21 y 63 días. Para cada día t y cada ventana de tamaño w , se computa la media $\bar{X}_w[t] = \frac{1}{w} \sum_{i=0}^{w-1} X[t - i]$ y la desviación estándar $s_w[t]$ sobre las últimas w observaciones. La media móvil suaviza las fluctuaciones diarias y revela la tendencia subyacente de la variable—por ejemplo, una media móvil de 63 días del VIX indica su nivel típico del último trimestre, permitiendo distinguir si el valor actual está por encima o por debajo de lo habitual. La desviación estándar móvil cuantifica cuán estable o volátil ha sido la variable en el período reciente. Se aplican estas transformaciones a un subconjunto de variables de referencia, generando 24 características.

Transformaciones adicionales y factores (176 características). Las variables en bruto descritas en la Sección 3.2.1 capturan *niveles*—el precio del oro hoy, la tasa de desempleo este mes, el VIX esta mañana. Sin embargo, los modelos predictivos aprenden con mayor facilidad a partir de *cambios* que de niveles, por dos razones: primero, los cambios son más estacionarios que los niveles (un retorno del 2 % tiene el mismo significado en 2005 que en 2025, mientras que un precio de \$150 no); segundo, los cambios capturan la dinámica reciente de la variable, que es la información predictivamente más relevante para horizontes cortos.

Todas las variables base de interés reciben un conjunto uniforme de dos transformaciones: cambio porcentual diario (`pct_change`) y *momentum* a 5 días (diferencia entre el valor actual y el de hace 5 días). Se añaden características de factores de estilo, inspiradas en la literatura de *asset pricing*³³. Estas incluyen el *spread* valor/crecimiento (diferencial de retornos entre XLF y XLK

³³Los factores de estilo derivan de la observación empírica de que ciertas características sistemáticas de las

como *proxies*³⁴ de *value* y *growth*), tamaño (*small vs. large cap*, IWM vs. SPY) y *momentum* tecnológico (rendimiento relativo de XLK frente al mercado amplio). Completan esta familia características adicionales del sistema Elder y extensiones de las variables de VIX y curva de rendimiento.

3.1.3 Garantías contra Filtración de Información

La prevención de filtración de información futura (*data leakage*) constituye un requisito crítico en cualquier sistema de predicción financiera, dado que su presencia—incluso en formas sutiles—invalida la totalidad de la evaluación fuera de muestra y genera una ilusión de rendimiento predictivo que se desvanece en la operación real (López de Prado, 2018). En el presente estudio, las garantías se implementan en cuatro niveles, organizados desde la decisión arquitectónica más fundamental hasta las verificaciones programáticas específicas.

Nivel 1: División temporal estricta. La partición entrenamiento-prueba es la garantía más fundamental de todo el sistema: si esta falla, ninguna otra precaución es suficiente. La división es estrictamente cronológica—todo dato anterior a octubre de 2020 pertenece al entrenamiento y todo dato posterior a esa fecha pertenece a la prueba—sin aleatorización ni estratificación de ningún tipo. A diferencia de la validación cruzada clásica (*k-fold cross-validation*)³⁵, que asume independencia entre observaciones y las mezcla libremente, la división temporal preserva la estructura causal inherente a los datos financieros: el modelo solo puede aprender de eventos pasados para predecir eventos futuros, replicando las condiciones que enfrentaría un inversor en tiempo real. Una división aleatoria permitiría que el modelo “viera” datos de 2024 durante el entrenamiento y luego fuera evaluado sobre datos de 2021, violando la causalidad y produciendo métricas artificialmente infladas. Adicionalmente, la selección de hiperparámetros mediante *GridSearchCV*³⁶ emplea *TimeSeriesSplit*³⁷ con 5 particiones, garantizando que incluso la bús-

acciones—como su valoración relativa (*value*), su tamaño de mercado (*size*) o su *momentum* reciente—explican una parte significativa de la variación en retornos esperados. La rotación entre estos factores es un indicador reconocido de cambios en el régimen de mercado.

³⁴*Proxy*: variable observable que se utiliza como aproximación de un concepto que no es directamente medible. XLF (sector financiero) y XLK (sector tecnológico) se emplean como *proxies* de *value* y *growth*, respectivamente, dado que sus perfiles fundamentales se alinean con dichos estilos.

³⁵En la validación cruzada *k-fold*, el dataset se divide aleatoriamente en *k* subconjuntos; el modelo se entrena *k* veces, cada vez usando *k* - 1 subconjuntos para entrenamiento y el restante para validación. Esta técnica es estándar en aprendizaje automático general, pero viola la estructura temporal de los datos financieros al mezclar pasado y futuro.

³⁶*GridSearchCV* (*Grid Search Cross-Validation*) es un método de búsqueda exhaustiva que evalúa todas las combinaciones posibles de hiperparámetros de un modelo, seleccionando la combinación que maximiza el rendimiento en validación cruzada. Los hiperparámetros—como la tasa de aprendizaje, la profundidad máxima de un árbol o el coeficiente de regularización—controlan el comportamiento del algoritmo y no se aprenden directamente de los datos.

³⁷*TimeSeriesSplit* es una variante de validación cruzada diseñada para series temporales: en cada iteración, el conjunto de entrenamiento comprende todas las observaciones hasta un punto de corte y el conjunto de validación

queda de parámetros respeta la causalidad temporal.

Nivel 2: Preprocesamiento ajustado solo en entrenamiento. El escalado (*StandardScaler*)³⁸ y la imputación de valores faltantes (*SimpleImputer*)³⁹ con estrategia de mediana se ajustan exclusivamente sobre el conjunto de entrenamiento mediante `fit_transform()`⁴⁰. Los parámetros estimados—media, desviación estándar y valores de imputación—se aplican al conjunto de prueba mediante `transform()`, sin recalcularlos. De este modo, el preprocesamiento del conjunto de prueba no contiene información estadística del período que se pretende evaluar. Para los modelos de la librería Darts (DLinear, N-BEATS, N-HiTS, TCN, TFT), se emplea un *Scaler* propio que sigue la misma lógica: ajuste sobre las series de entrenamiento y transformación de las series completas con los parámetros previamente estimados.

Nivel 3: Características exclusivamente retrospectivas. Todas las transformaciones descritas en la Sección 3.1 emplean exclusivamente información pasada y contemporánea. Las funciones `pct_change()`, `rolling()` y `shift(n)` con $n > 0$ miran hacia atrás por diseño; los indicadores de TA-Lib están concebidos para operar sobre datos históricos; y ninguna ventana móvil utiliza el parámetro `center=True`, lo cual incluiría observaciones futuras en el cálculo. El único desplazamiento hacia el futuro (`shift(-1)`) aparece en la construcción de la variable objetivo (Sección 3.2.2), donde es intencional: define lo que el modelo debe predecir, no lo que puede observar.

3.1.4 Dataset Resultante

En conjunto, el *pipeline* descrito transforma un universo de 92 variables financieras en bruto—que por sí solas ofrecen una representación estática del estado del mercado en cada día—en un espacio de características mucho más rico que captura dinámicas temporales (retornos, *momentum*, *lags*), relaciones entre activos (correlaciones *cross-asset*, dispersión sectorial), estados latentes del mercado (régimen, volatilidad, sentimiento) y la coherencia multi-temporal del sistema

las observaciones inmediatamente posteriores, respetando siempre el orden cronológico.

³⁸*StandardScaler* estandariza cada característica restando su media y dividiendo por su desviación estándar, de modo que todas las variables queden centradas en cero con dispersión unitaria. Esto es necesario porque muchos algoritmos son sensibles a la escala de las variables: sin estandarizar, una variable medida en miles (como el volumen) dominaría sobre una medida en centésimas (como un retorno).

³⁹*SimpleImputer* reemplaza los valores faltantes (NaN) en el dataset por un estadístico calculado a partir de los datos disponibles. En este estudio se utiliza la mediana, que es robusta ante valores extremos frecuentes en datos financieros.

⁴⁰La operación `fit_transform()` calcula los parámetros (media, desviación estándar, mediana de imputación) a partir de los datos proporcionados y simultáneamente los transforma. La operación `transform()`, en cambio, aplica los parámetros *ya calculados* a datos nuevos sin recalcularlos. Esta distinción es crítica: usar `fit_transform()` sobre el conjunto de prueba recalcularía los parámetros incluyendo información del período de evaluación, constituyendo una forma sutil de filtración.

Triple Screen. Cada observación diaria queda descrita no solo por el valor contemporáneo de las variables, sino también por su evolución reciente, su posición relativa respecto a su propia historia y su relación con otras dimensiones del mercado. Esta profundidad de representación permite a los modelos de aprendizaje automático—en particular a los de aprendizaje profundo—explotar patrones no lineales que escaparían a un análisis basado únicamente en los datos originales.

Tras la eliminación de columnas con más del 50 % de valores faltantes, la sustitución de infinitos, la exclusión de filas con más del 50 % de valores faltantes en sus características y la eliminación de filas sin variable objetivo válida, el dataset final comprende 6,507 observaciones y 536 características. Los valores faltantes residuales—concentrados en las primeras filas por el calentamiento de las ventanas móviles y en variables con disponibilidad histórica parcial—se imputan durante el preprocesamiento específico de cada familia de modelos (Sección 3.3.1). La Tabla 1 presenta la composición por familia de transformación.

Cuadro 1: Composición del Espacio de Características por Familia de Transformación

Familia de Transformación	Características
Indicadores técnicos (TA-Lib)	19
<i>Momentum</i> y retornos históricos	30
Volumen	2
Análisis multi-temporal (Triple Screen)	24
Volatilidad OHLC clásica ^a	8
Volatilidad contemporánea ^b	54
Microestructura	19
Correlaciones <i>cross-asset</i>	10
VIX y estructura temporal	10
Curva de rendimiento y crédito	13
Dispersión sectorial	5
Indicadores macroeconómicos	21
Régimen de mercado e interacciones	7
Variables rezagadas (<i>lags</i>)	54
Estadísticos móviles (<i>rolling</i>)	24
Análisis técnico avanzado ^c	60
Transformaciones y extensiones adicionales ^d	176
Total	536

^a Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang. ^b Entropía Intrínseca (5), Log-Range (20), CARR (13), Range-GARCH (16). ^c Ichimoku (13), Fibonacci (18), Donchian (8), Keltner (3), flujo de dinero (8), confluencia estratégica (10). ^d Incluye factores Value/Growth/Size, transformaciones de variables macro y de tasas (cambio porcentual, momentum), características VIX extendidas, variables base residuales y microestructura avanzada.

3.2 Variable Objetivo y División de Muestra

3.2.1 Retorno en Exceso como Variable Objetivo

El objetivo de predicción no es el retorno bruto del S&P 500, sino su **retorno en exceso** sobre la tasa libre de riesgo:

$$y_t = r_{t+1}^{SPY} - r_t^f \quad (1)$$

donde $r_{t+1}^{SPY} = P_{t+1}/P_t - 1$ es el retorno del SPY entre el día t y $t + 1$, y r_t^f es la tasa diaria libre de riesgo derivada del *T-Bill* a 3 meses, conocida y publicada en t .

La elección del retorno en exceso frente al retorno bruto responde a una lógica económica precisa. El retorno bruto de una acción incluye implícitamente la compensación por el valor temporal del dinero—es decir, el rendimiento mínimo que un inversor podría obtener sin asumir ningún riesgo, simplemente colocando su capital en un instrumento del Tesoro. Si en un día determinado el SPY rinde $+0.03\%$ pero el *T-Bill* también rinde $+0.03\%$, el retorno bruto sugiere que fue un día positivo para el mercado cuando, en términos económicos, el inversor no recibió ninguna compensación adicional por haber asumido riesgo de mercado. El retorno en exceso aísla precisamente esa **prima de riesgo**: la remuneración que el mercado otorga—o no—por soportar incertidumbre. Un modelo que predice el retorno en exceso está, por tanto, estimando directamente si vale la pena asumir exposición al mercado en un día dado, lo cual se traduce naturalmente en una decisión de inversión: si $\hat{y}_t > 0$, el mercado compensará el riesgo; si $\hat{y}_t \leq 0$, es preferible permanecer en efectivo.

3.2.2 Alineación Temporal: el Desplazamiento del Vector Objetivo

La construcción del vector objetivo requiere un paso técnico que merece explicación detallada, dado que involucra el único desplazamiento temporal hacia el futuro en todo el sistema.

En cada día t , al cierre del mercado, el inversor dispone de toda la información histórica hasta t (precios, volúmenes, indicadores) y debe decidir su posición para el día siguiente. El resultado de esa decisión—el retorno que se materializará entre t y $t + 1$ —es, por definición, una cantidad futura que aún no se conoce en t . Sin embargo, para que el modelo pueda aprender la relación entre las características observadas en t y el retorno que se producirá después, es necesario que ambos estén en la misma fila del conjunto de datos.

La implementación utiliza la operación `shift(-1)`, que desplaza el vector de retornos una posición hacia atrás en el tiempo. Concretamente:

1. Se calcula el retorno diario estándar: $r_t = P_t/P_{t-1} - 1$ (retorno de *ayer* a *hoy*, conocido en t).
2. Se aplica `shift(-1)`, que “trae” el retorno de la fila $t + 1$ a la fila t : el resultado es $r_{t+1} = P_{t+1}/P_t - 1$, es decir, el retorno de *hoy* a *mañana*.
3. Se resta la tasa libre de riesgo conocida en t : $y_t = r_{t+1} - r_t^f$.

De este modo, la fila t del dataset contiene: en las columnas de características, información disponible hasta t ; y en la columna objetivo, el retorno en exceso que se producirá entre t y $t + 1$. El modelo aprende la función $\hat{y}_t = f(\mathbf{X}_t)$, donde $\mathbf{X}_t$ son las características observadas al cierre del día t y $\hat{y}_t$ es la predicción del retorno en exceso del día siguiente. Este desplazamiento es el único `shift(-1)` en todo el *pipeline*—todas las demás transformaciones emplean exclusivamente desplazamientos positivos (hacia el pasado)—y su presencia es intencional: no constituye filtración de información sino la definición misma de la variable que el modelo debe aprender a predecir.

3.2.3 División Temporal de la Muestra

Para asegurar una evaluación rigurosa fuera de muestra, se emplea una división temporal estricta sin aleatorización:

- **Entrenamiento:** Enero 2000 – Septiembre 2020 (5,205 días, 80 %)
- **Prueba:** Octubre 2020 – Diciembre 2025 (1,302 días, 20 %)

El período de prueba abarca un entorno de mercado particularmente exigente para cualquier sistema de predicción: incluye la recuperación post-COVID, el ciclo de endurecimiento monetario más agresivo en cuatro décadas (2022–2023), un mercado bajista significativo (−25 % en el S&P 500 durante 2022) y el posterior rally impulsado por inteligencia artificial (2023–2025). Esta diversidad de regímenes proporciona una prueba robusta de la capacidad de generalización de los modelos.

3.3 Especificaciones de Modelos

Se implementan 23 modelos que abarcan cuatro familias metodológicas: aprendizaje automático clásico (5), *gradient boosting* avanzado (3), series temporales (6)⁴¹ y *deep learning* (9). Esta sección no describe la teoría detrás de cada algoritmo—disponible en la bibliografía de referencia—sino las decisiones de implementación: cómo se preprocesaron los datos para cada familia, cómo se seleccionaron los hiperparámetros y qué produce cada modelo como salida.

3.3.1 Preparación de Datos para Entrenamiento

Todos los modelos reciben el mismo dataset de 536 características producido en la Sección 3.1. Sin embargo, este dataset conserva aproximadamente un 3 % de valores faltantes, concentrados

⁴¹AutoARIMA fue incluido en la evaluación; sin embargo, el filtro de calidad de señal lo mantiene en efectivo el 100 % del tiempo (0 operaciones en 1,302 días), ya que la desviación estándar de sus predicciones (3.9×10^{-5}) es inferior al umbral mínimo requerido (10^{-3}). Su retorno del +18.3 % corresponde íntegramente a la tasa libre de riesgo acumulada, lo que indica ausencia de capacidad predictiva genuina.

en dos orígenes: el calentamiento inicial de las ventanas móviles y los *lags*, que genera valores faltantes en las primeras filas del dataset; y la disponibilidad histórica parcial de ciertas variables de Bloomberg—principalmente tasas *swap*⁴² (I11–I19) y *spreads* de crédito (I15, I16)—que comenzaron a publicarse años después del inicio del dataset. Estos valores faltantes residuales deben resolverse antes de alimentar los modelos, y la forma de hacerlo depende de los requisitos técnicos de cada librería—no de una elección metodológica. En la práctica, las 536 características son idénticas para todos los modelos; lo único que varía es cómo se resuelve ese 3 % residual de valores ausentes.

Imputación de valores faltantes. Los modelos tabulares y de *deep learning* custom (12 modelos: Ridge, Lasso, ElasticNet, RandomForest, GradientBoosting, XGBoost, LightGBM, CatBoost, CNN-LSTM, LSTM+Attention, BiLSTM y BiGRU) imputan los valores faltantes con la mediana de cada columna, un estadístico robusto ante valores extremos y el estándar de scikit-learn para datos tabulares. Los modelos secuenciales Darts (5 modelos: DLinear, N-BEATS, N-HiTS, TCN y TFT) requieren series temporales sin interrupciones—la librería no tolera valores ausentes en sus objetos *TimeSeries* y la ejecución falla si alguna observación contiene un `NaN`. Por esta razón, sus valores faltantes se imputan con *forward fill*⁴³—el último valor conocido de cada variable, que es lo que estaría disponible en una operación en tiempo real. Para las primeras filas, donde no existe un valor previo que propagar, los valores restantes se rellenan con cero; si bien no es ideal, su impacto es marginal dado que estas filas se concentran al inicio del periodo de entrenamiento (año 2000), lejos del periodo de prueba. Los seis modelos univariados (AutoARIMA, ExponentialSmoothing, Theta, SeasonalNaive, Prophet y GARCH) operan exclusivamente sobre la serie del retorno en exceso y no requieren imputación, dado que dicha serie no contiene valores faltantes tras la limpieza. Su rol como *baselines*⁴⁴ se detalla en la Sección 3.3.3.

Escalado de características y variable objetivo. El escalado presenta diferencias más sustantivas entre familias, pero cada una responde a una razón técnica específica. La Tabla 2 sintetiza el esquema completo; a continuación se explica la lógica detrás de cada decisión.

Los **modelos tabulares** escalan las características a media cero y varianza unitaria (*Stan-*

⁴²Véase nota al pie correspondiente en la Sección 3.1.

⁴³*Forward fill*: método de imputación que reemplaza cada valor faltante con el último valor conocido de la misma variable. Respeta la causalidad temporal: en el día t , utiliza exclusivamente información disponible hasta t .

⁴⁴*Baseline*: modelo de referencia contra el cual se compara el rendimiento de modelos más complejos. Si un modelo multivariado con 536 características no supera a un modelo univariado, las características adicionales no aportan valor predictivo.

Cuadro 2: Esquema de escalado por familia de modelos. Todos los escaladores se ajustan exclusivamente sobre el conjunto de entrenamiento.

Familia	Features	Target	Reescalado*
Tabulares (8)	<i>StandardScaler</i>	sin escalar	no
PyTorch custom (4)	<i>StandardScaler</i>	<i>StandardScaler</i>	sí
Darts DL (5)	<i>MinMaxScaler</i> [0, 1]	<i>MinMaxScaler</i> [0, 1]	sí
Univariados (6)	no usan	sin escalar	no

*Indica si las predicciones requieren transformación inversa para volver a la escala original de retornos antes de la evaluación.

*dardScaler*⁴⁵). Esta normalización es necesaria para los modelos lineales regularizados (Ridge, Lasso, ElasticNet): sin ella, variables medidas en escalas grandes—como el volumen de operaciones—dominarían sobre variables medidas en centésimas—como un retorno porcentual—distorsionando los coeficientes. Los modelos basados en árboles (RandomForest, GradientBoosting, XGBoost, LightGBM, CatBoost) son invariantes a la escala por diseño, pero reciben el mismo escalado por simplicidad de implementación. La variable objetivo no se escala porque estos modelos operan correctamente con retornos del orden de centésimas de punto porcentual.

Los **modelos de deep learning custom** (CNN-LSTM, LSTM+Attention, BiLSTM, BiGRU) reciben las mismas características escaladas con *StandardScaler*, reorganizadas en secuencias de 30 días. A diferencia de los tabulares, estos modelos también escalan la variable objetivo con *StandardScaler*. La razón es que los retornos financieros diarios son del orden de centésimas de punto porcentual: cuando la función de pérdida (error cuadrático medio) opera sobre valores tan pequeños, los gradientes resultantes son insuficientes para actualizar los pesos de la red de forma efectiva, y el modelo converge a predecir un valor cercano a cero independientemente de la entrada. Normalizar el *target* a media cero y varianza unitaria resuelve este problema. Las predicciones se transforman de vuelta a la escala original mediante la transformación inversa del escalador antes de cualquier evaluación.

Los **modelos secuenciales Darts** escalan tanto las características como la variable objetivo al rango [0, 1] mediante *MinMaxScaler*⁴⁶. Este es el escalador por defecto de la librería Darts, y cumple la misma función que el escalado del *target* en los modelos PyTorch: normalizar los valores a un rango donde los gradientes sean informativos. Las 536 características se proporcionan como covariables⁴⁷ pasadas, y las predicciones se transforman de vuelta a la escala original antes de la evaluación.

⁴⁵*StandardScaler*: transforma cada variable mediante $x' = (x - \mu)/\sigma$, donde μ y σ se calculan exclusivamente sobre el conjunto de entrenamiento.

⁴⁶*MinMaxScaler*: transforma cada variable al rango [0, 1] mediante $x' = (x - x_{\min})/(x_{\max} - x_{\min})$, donde $x_{\min}$ y $x_{\max}$ se calculan exclusivamente sobre el conjunto de entrenamiento.

⁴⁷*Covariables (past covariates)*: variables adicionales que acompañan a la serie objetivo proporcionando información contextual. Estos modelos las procesan como secuencias temporales, no como observaciones aisladas.

Los **modelos univariados** no utilizan las 536 características y operan directamente sobre la serie de retornos en exceso sin escalar. GARCH constituye una excepción menor: convierte internamente los retornos a porcentaje (multiplicación por 100) para estabilidad numérica de la librería `arch`, y revierte la transformación en las predicciones.

Garantía de comparabilidad. A pesar de las diferencias en imputación y escalado, todos los modelos son evaluados en condiciones equivalentes. Cada modelo produce predicciones en la escala original de los retornos—aplicando la transformación inversa correspondiente cuando es necesario—y se evalúa sobre idéntico período de prueba (octubre 2020 – diciembre 2025) con las mismas métricas. Además, en todos los casos los escaladores se ajustan exclusivamente sobre datos de entrenamiento, garantizando que ninguna información del período de evaluación influya en el preprocesamiento.

3.3.2 Modelos Tabulares con Validación Cruzada

Los ocho modelos de ML clásico y *gradient boosting* se implementan dentro de un esquema unificado de selección de hiperparámetros. Para cada modelo se define una grilla de valores candidatos para sus parámetros principales (el coeficiente de regularización en los modelos lineales, la profundidad máxima y número de estimadores en los modelos de ensamble, la tasa de aprendizaje⁴⁸ en los métodos de boosting). La búsqueda de la combinación óptima se realiza mediante *GridSearchCV* con *TimeSeriesSplit* de cinco particiones, preservando el orden temporal en cada partición de validación cruzada. El criterio de selección es el error cuadrático medio.

Una vez entrenado, cada modelo genera predicciones sobre dos períodos. Las predicciones sobre el conjunto de prueba (*out-of-sample*, 2020–2025) son las que se utilizan para evaluar el rendimiento real del modelo. Las predicciones sobre el conjunto de entrenamiento (*in-sample*, 2000–2020) no se usan para evaluar—sería circular, dado que el modelo ya observó esos datos—sino para inicializar el sistema de percentiles *rolling* descrito en la Sección 3.4: como dicho sistema requiere una ventana de 63 predicciones previas para calcular el percentil del primer día de prueba, las predicciones de entrenamiento proveen esa historia inicial.

3.3.3 Modelos de Series Temporales (Baselines Univariados)

A diferencia de los demás modelos del estudio, estos cinco modelos se entrenan exclusivamente sobre la serie temporal del retorno en exceso, sin utilizar ninguna de las 536 características construidas. Operan bajo la premisa de que el valor futuro de una serie puede inferirse a partir

⁴⁸La *tasa de aprendizaje* (*learning rate*) controla la magnitud del ajuste que el modelo realiza a sus parámetros en cada iteración de entrenamiento. Valores pequeños producen un aprendizaje más lento pero estable; valores grandes aceleran la convergencia pero arriesgan inestabilidad.

de sus propios valores pasados—sus patrones de autocorrelación⁴⁹, tendencia, estacionalidad y estructura de volatilidad.

Su inclusión responde a una pregunta metodológica fundamental: *¿aportan las 536 características cross-asset, macroeconómicas y de volatilidad información predictiva más allá de lo que la propia serie de retornos ya contiene?* Si un modelo multivariado con 536 variables no supera a un modelo univariado que solo observa retornos pasados, la ingeniería de características no se justifica. Comparar contra estos *baselines* es práctica estándar en la literatura de *forecasting* (Makridakis et al., 2018).

Cada modelo captura un aspecto distinto de la dinámica univariada:

- **ExponentialSmoothing:** Asigna pesos exponencialmente decrecientes a las observaciones pasadas, capturando el nivel y la tendencia de la serie con mayor énfasis en los datos recientes.
- **Theta:** Descompone la serie en componentes de largo y corto plazo, aplicando diferentes coeficientes de suavizamiento a cada uno.
- **SeasonalNaive:** Repite el valor observado hace K días (en este estudio, $K=5$, asumiendo un patrón semanal). Es el *baseline* más simple y sirve como cota inferior de rendimiento.
- **Prophet:** Modela la serie mediante componentes aditivos de tendencia, estacionalidad múltiple y efectos de calendario (días festivos, fin de semana).
- **GARCH:** Modela la *volatilidad condicional*—la varianza del retorno cambia en el tiempo y depende de la volatilidad reciente—mediante un proceso autorregresivo sobre la varianza. A diferencia de los demás, GARCH no predice primariamente la dirección del retorno sino la magnitud esperada de las fluctuaciones.

Las predicciones *in-sample* se generan mediante *historical forecasts*⁵⁰. Para cada día t del período de entrenamiento, el modelo genera una predicción un paso adelante sin reentrenarse, produciendo una secuencia que simula el comportamiento predictivo en condiciones reales de operación.

3.3.4 Modelos de Deep Learning

Los nueve modelos de *deep learning* se dividen en dos grupos según su implementación:

⁴⁹La *autocorrelación* mide la correlación de una serie temporal consigo misma desplazada en el tiempo. Una autocorrelación significativa en el *lag* 1 indicaría que el retorno de hoy contiene información sobre el retorno de mañana.

⁵⁰*Historical forecasts*: técnica de evaluación donde el modelo genera predicciones un paso adelante de forma secuencial sobre los datos de entrenamiento, sin reentrenarse en cada paso. Produce predicciones que simulan cómo el modelo habría predicho cada día en tiempo real.

Darts Deep Learning (5 modelos). DLinear, N-BEATS, N-HiTS, TCN y TFT se implementan mediante la librería Darts, que gestiona series temporales sobre PyTorch Lightning. Cada modelo recibe la serie objetivo escalada y las 536 covariables pasadas, procesando ventanas de 30 días hábiles⁵¹ para generar una predicción un paso adelante. El entrenamiento se ejecuta sobre GPU durante 100 épocas⁵² con lotes de 32 observaciones⁵³.

TFT (*Temporal Fusion Transformer*) incorpora un mecanismo de atención⁵⁴ que permite interpretar qué variables y qué momentos temporales contribuyen más a cada predicción, ofreciendo una capa de interpretabilidad poco común en modelos de *deep learning*.

PyTorch Custom (4 modelos). CNN-LSTM, LSTM+Attention, BiLSTM y BiGRU se implementan directamente en PyTorch, lo que permite diseñar arquitecturas no disponibles en Darts—en particular, el procesamiento bidireccional⁵⁵. CNN-LSTM combina capas convolucionales⁵⁶ para extraer patrones locales con capas recurrentes para capturar dependencias temporales de largo plazo. LSTM+Attention añade un mecanismo de atención estilo Luong sobre un LSTM bidireccional. BiLSTM y BiGRU son variantes bidireccionales de las arquitecturas recurrentes LSTM y GRU respectivamente.

Todos los modelos de *deep learning* se entrenan con el optimizador Adam⁵⁷, función de pérdida de error cuadrático medio y *dropout*⁵⁸ como técnica de regularización. Las semillas aleatorias se fijan en 42 para todos los modelos, garantizando reproducibilidad.

3.3.5 Implementación Computacional

El entrenamiento de los 23 modelos se ejecuta mediante un *pipeline* secuencial de cuatro etapas: (1) construcción del dataset (92 variables $\rightarrow$ 536 características), (2) entrenamiento de modelos, (3) optimización de umbrales por modelo, y (4) *backtesting* final con costos de transacción. Cada etapa produce artefactos intermedios que alimentan la siguiente, permitiendo

⁵¹La ventana de 30 días (*input chunk length*) significa que para predecir el retorno del día $t+1$, el modelo observa los valores de las 536 características desde el día $t-29$ hasta t .

⁵²Una época (*epoch*) es un recorrido completo del algoritmo de optimización sobre todos los datos de entrenamiento. Múltiples épocas permiten al modelo refinar progresivamente sus parámetros.

⁵³El tamaño de lote (*batch size*) determina cuántas observaciones procesa el modelo simultáneamente antes de actualizar sus parámetros internos.

⁵⁴El mecanismo de *atención* (*attention*) permite al modelo asignar pesos diferenciados a cada paso temporal de la secuencia de entrada, identificando qué días del pasado reciente son más relevantes para la predicción actual.

⁵⁵En un modelo *bidireccional*, la secuencia de entrada se procesa simultáneamente de izquierda a derecha y de derecha a izquierda, capturando dependencias en ambas direcciones temporales.

⁵⁶Las capas convolucionales (*Conv1D*) aplican filtros que detectan patrones locales en la secuencia temporal, como formaciones de precios de corto plazo, antes de pasar la representación a las capas recurrentes.

⁵⁷Adam (*Adaptive Moment Estimation*) es un algoritmo de optimización que ajusta automáticamente la tasa de aprendizaje de cada parámetro de la red en función de la magnitud y variabilidad de sus gradientes recientes. Combina las ventajas de dos métodos anteriores—*AdaGrad* y *RMSProp*—y es el optimizador más utilizado en *deep learning* por su convergencia rápida y bajo requerimiento de ajuste manual (Kingma & Ba, 2015).

⁵⁸*Dropout*: técnica de regularización que desactiva aleatoriamente una fracción de las neuronas durante cada paso de entrenamiento, forzando a la red a no depender excesivamente de ninguna neurona individual y reduciendo el sobreajuste.

reejecutar etapas individuales sin repetir el proceso completo.

El sistema de persistencia emplea un diseño de *checkpoints*⁵⁹ que separa los modelos entrenados de sus predicciones. Cada modelo se guarda individualmente en su formato nativo: los modelos de scikit-learn como archivos `.joblib`, los modelos Darts como directorios con pesos y configuración, y los modelos PyTorch como archivos `.pt`. El archivo central `trained_artifacts.pkl` almacena únicamente metadata y predicciones—no los modelos en sí—manteniendo un tamaño reducido mientras que los *checkpoints* individuales totalizan aproximadamente 198 MB. La memoria se libera explícitamente después de entrenar cada modelo, lo que permite ejecutar los 23 modelos secuencialmente sin exceder los límites de RAM.

El entrenamiento se ejecutó de forma remota en una instancia `g4dn.xlarge` de Amazon Web Services⁶⁰, equipada con una GPU NVIDIA T4 de 16 GB de memoria de video, lo que permitió acelerar mediante CUDA⁶¹ el entrenamiento de los nueve modelos de *deep learning*. Los 14 modelos restantes, al no requerir operaciones tensoriales intensivas, se ejecutaron sobre CPU en la misma instancia. El entorno de software comprende Python 3.12, PyTorch 2.6, Darts 0.41 y scikit-learn 1.7, con todas las dependencias fijadas en versiones exactas para garantizar reproducibilidad.

Salida unificada. Independientemente de su arquitectura o familia, cada uno de los 23 modelos produce una predicción continua $\hat{y}_t$ del retorno en exceso para cada día t del período de prueba. Esta predicción alimenta el sistema de posicionamiento por percentiles descrito en la Sección 3.4, que la transforma en una posición discreta de inversión.

Esto concluye el primer hito del estudio—la predicción. El segundo hito—la implementación—requiere resolver un problema distinto: dado que cada modelo produce predicciones continuas de diferente escala y distribución, ¿cómo convertirlas en decisiones de inversión comparables y económicamente rentables?

3.4 Estrategia de Inversión

3.4.1 De Predicciones Continuas a Posiciones Discretas

Las predicciones de los modelos son valores continuos—por ejemplo, $+0,12\%$ o $-0,03\%$ —cuya escala varía entre modelos: un Ridge genera predicciones en el orden de centésimas de

⁵⁹Un *checkpoint* es una copia intermedia del estado de un modelo guardada en disco, que permite reanudar el entrenamiento o la evaluación sin repetir cálculos previos.

⁶⁰Amazon Web Services Elastic Compute Cloud (AWS EC2): servicio de computación en la nube que proporciona capacidad de cómputo escalable bajo demanda.

⁶¹CUDA (*Compute Unified Device Architecture*): plataforma de computación paralela de NVIDIA que permite ejecutar operaciones tensoriales en GPU, acelerando el entrenamiento de redes neuronales en un orden de magnitud respecto a CPU.

punto porcentual mientras que un GARCH las genera en el orden de un punto porcentual. Esta heterogeneidad impide aplicar un umbral absoluto como “comprar si la predicción supera 0,05 %”, ya que un umbral que resulte selectivo para un modelo puede ser trivial o inalcanzable para otro.

Para resolver este problema, cada predicción se compara con las predicciones recientes del mismo modelo mediante un percentil *rolling*⁶² calculado sobre una ventana de 63 días hábiles (un trimestre bursátil). Si, por ejemplo, la ventana contiene las 63 predicciones más recientes (incluida la de hoy) y 57 de esas 63 son menores o iguales a la predicción actual, el percentil es $57/63 \times 100 \approx 90$. Esto indica que el modelo es inusualmente optimista en comparación con su propio comportamiento reciente. Un percentil de 90 tiene el mismo significado independientemente de si proviene de un Ridge cuyas predicciones oscilan entre $-0,05\%$ y $+0,08\%$ o de un GARCH cuyo rango es diez veces más amplio: en ambos casos, el modelo está prediciendo un retorno superior al que ha predicho el 90 % del tiempo durante el último trimestre.

Formalmente, para cada día t , el percentil se define como:

$$\text{percentil}_t = \frac{n_t}{N} \times 100 \quad (2)$$

donde $N = 63$ es el tamaño de la ventana y n_t es el número de predicciones dentro de la ventana $W_t = \{\hat{y}_{t-62}, \dots, \hat{y}_t\}$ que son menores o iguales a la predicción actual $\hat{y}_t$. En otras palabras, el percentil mide qué proporción de las predicciones recientes del modelo son menores o iguales a la de hoy: un percentil de 90 indica que el 90 % de las predicciones del último trimestre no superan a la actual. Para el primer día del período de prueba, la ventana se inicializa con las últimas predicciones del conjunto de entrenamiento (*warmup*), de modo que el sistema cuente con historia suficiente desde el primer día de evaluación.

El percentil se mapea a una posición discreta de inversión:

$$\text{posición}_t = \begin{cases} +3 \text{ (UPRO)} & \text{si } \text{percentil}_t \geq 100 - q_{\text{extreme}} \\ +1 \text{ (SPY)} & \text{si } \text{percentil}_t \geq 100 - q_{\text{moderate}} \\ 0 \text{ (Cash)} & \text{en caso contrario} \end{cases} \quad (3)$$

La estrategia opera exclusivamente en el lado largo del mercado (*Long-Only*): posición +3 mediante UPRO (ETF apalancado 3x) para convicción alcista alta, posición +1 mediante SPY para convicción moderada, y efectivo cuando la convicción es insuficiente. No se toman posiciones cortas porque el sesgo alcista histórico del mercado accionario ($\sim 7\%$ anual) las hace

⁶²El percentil *rolling* evalúa la posición relativa de un valor dentro de una ventana móvil de observaciones recientes, en lugar de compararlo contra toda la muestra histórica.

estadísticamente desfavorables en horizontes largos.

3.4.2 Optimización de Umbrales por Modelo

Los umbrales q_{extreme} y q_{moderate} determinan qué fracción de las predicciones activa cada nivel de posición. Un $q_{\text{extreme}} = 10$ reserva la posición apalancada 3x para el 10% superior de las predicciones recientes. Estos umbrales no pueden ser universales, ya que cada modelo genera predicciones con distribución, sesgo y precisión direccional distintos, y el umbral óptimo para Ridge resulta inadecuado para LSTM+Attention.

La alternativa más directa para determinar estos umbrales sería evaluar exhaustivamente todas las combinaciones posibles sobre el período de prueba y seleccionar la que maximice el *Sharpe ratio*⁶³. Sin embargo, esta aproximación utiliza retornos futuros para calibrar el sistema de posicionamiento—un caso clásico de *data snooping*⁶⁴ que invalida la evaluación fuera de muestra. Para evitar esta filtración se emplea un enfoque de meta-aprendizaje basado en *K-Nearest Neighbors* (KNN) que determina los umbrales de forma dinámica—potencialmente distintos cada día—utilizando exclusivamente información del período de entrenamiento.

Fase 1: construcción del meta-dataset (solo datos de entrenamiento). El objetivo de esta fase es extraer del período de entrenamiento un conjunto de “lecciones” que asocien el comportamiento reciente de un modelo con los umbrales de posicionamiento que mejor habrían funcionado. Cada lección responde a la pregunta: *dado que las predicciones del modelo lucen de cierta manera durante un trimestre, ¿qué umbrales habrían producido la mejor estrategia en el trimestre siguiente?*

El procedimiento opera con dos ventanas consecutivas que se deslizan a lo largo de las predicciones de entrenamiento de cada modelo, avanzando con un paso de 21 días hábiles (un mes bursátil)—este paso se utiliza únicamente para la construcción del meta-dataset; en el período de prueba, el KNN se consulta diariamente—. La primera es la **ventana de observación** (63 días, un trimestre), sobre la cual se describe cómo se está comportando el modelo. La segunda es la **ventana de evaluación** (los 63 días de entrenamiento inmediatamente posteriores), sobre la cual se prueba qué umbrales habrían funcionado mejor. La elección de 63 días obedece a que ventanas más cortas no proporcionan observaciones suficientes para calcular estadísticas estables—la asimetría y la autocorrelación, por ejemplo, requieren al menos varias decenas de datos—mientras que ventanas más largas suavizarían los cambios de régimen del modelo,

⁶³El *Sharpe ratio* mide el retorno en exceso por unidad de riesgo: $S = (r_p - r_f)/\sigma_p$, donde r_p es el retorno de la estrategia, r_f la tasa libre de riesgo y σ_p la volatilidad.

⁶⁴El *data snooping* (también denominado *look-ahead bias*) ocurre cuando información que no estaría disponible en tiempo real se emplea para tomar decisiones de inversión. Seleccionar umbrales óptimos sobre el período de prueba equivale a optimizar con la respuesta conocida.

reduciendo la capacidad del sistema para adaptarse a condiciones cambiantes; 63 días hábiles constituyen además una convención estándar en finanzas para la evaluación trimestral de desempeño. En cada posición de la ventana se ejecutan dos pasos: describir el contexto actual y evaluar los umbrales candidatos.

Describir el contexto actual (ventana de observación). Se calculan siete *meta-features* $\mathbf{f}_w$ que resumen el estado del modelo y del mercado durante la ventana:

$$\mathbf{f}_w = (\bar{y}_w, \sigma_{\hat{y},w}, \gamma_{\hat{y},w}, \rho_{\hat{y},w}, \beta_{\hat{y},w}, \bar{\sigma}_{m,w}, R_{m,w}) \quad (4)$$

Es fundamental subrayar que las primeras cinco características se derivan exclusivamente de las **predicciones** generadas por el modelo, no de los retornos reales del mercado. Estas cinco variables describen el régimen predictivo del modelo durante la ventana: si sus predicciones son en promedio optimistas o pesimistas ($\bar{y}_w$), si varían mucho o permanecen estables ($\sigma_{\hat{y},w}$), si están sesgadas hacia valores extremos ($\gamma_{\hat{y},w}$), si cada día tiende a parecerse al anterior ($\rho_{\hat{y},w}$), y si exhiben una tendencia alcista o bajista ($\beta_{\hat{y},w}$). Las dos características restantes incorporan el contexto de mercado: la volatilidad promedio en sub-ventanas de 21 días ($\bar{\sigma}_{m,w}$) y el retorno acumulado durante la ventana ($R_{m,w}$). En conjunto, estas siete variables no evalúan la calidad de las predicciones ni las comparan con los retornos reales; simplemente describen *cómo luce* la señal del modelo y en qué entorno de mercado se produce.

Evaluar los umbrales candidatos (ventana de evaluación). Sobre los 63 días siguientes se prueban las 26 combinaciones válidas de $(q_{\text{ext}}, q_{\text{mod}})$:

$$q_{\text{ext}} \in \{5, 10, 15, 20, 25, 30\}, \quad q_{\text{mod}} \in \{20, 30, 40, 50, 60\}, \quad q_{\text{mod}} > q_{\text{ext}}.$$

Para cada combinación se ejecuta la cadena completa de la estrategia sobre la ventana de evaluación: primero, los percentiles *rolling* de las predicciones—calculados según la Ecuación 2, comparando cada predicción únicamente con las predicciones anteriores del mismo modelo—se contrastan con los umbrales de la combinación para asignar posiciones (UPRO si el percentil $\geq 100 - q_{\text{ext}}$, SPY si $\geq 100 - q_{\text{mod}}$, Cash en caso contrario). Después, las posiciones resultantes se combinan con los retornos **reales** del mercado durante esos 63 días para calcular el retorno diario de la estrategia. Sobre estos retornos se obtiene el *Sharpe ratio* penalizado—con una deducción de 0,5 cuando el *drawdown*⁶⁵ máximo excede el 20 %—y la combinación con el mejor *score* se registra como la ganadora de esa ventana. Nótese que en ningún momento se comparan las predicciones con los retornos reales: los percentiles evalúan cada predicción respecto a predicciones anteriores

⁶⁵El *drawdown* mide la caída porcentual acumulada desde el máximo histórico de la curva de capital. Un *drawdown* del 20 % significa que la estrategia ha perdido un 20 % desde su punto más alto.

del mismo modelo, y los retornos reales solo intervienen para determinar qué combinación de umbrales produce la mejor estrategia cuando se traduce a posiciones de inversión.

Cada iteración produce así una muestra del meta-dataset: las siete *meta-features* como variables explicativas y la combinación ganadora como etiqueta. A modo de ejemplo, considérese la primera ventana de observación (días 1 a 63 del entrenamiento). Las predicciones de Ridge presentan media +0,02 %, baja volatilidad y autocorrelación moderada; sobre los días 64 a 126, la combinación ($q_{\text{extreme}}=20, q_{\text{moderate}}=30$) produce el mejor *Sharpe* penalizado porque esos umbrales, al reservar UPRO para el top 20 % de las predicciones y SPY para el top 30 %, capturan los días de retorno positivo sin incurrir en *drawdowns* excesivos. Se registra la muestra $\mathbf{f}_1 \rightarrow (20, 30)$. La ventana avanza 21 días y el proceso se repite: la segunda ventana (días 22 a 84) observa predicciones más volátiles en un mercado con mayor incertidumbre, y la evaluación sobre los días 85 a 147 indica que (5, 40)—umbrales más conservadores para UPRO pero amplios para SPY—es óptimo; se registra $\mathbf{f}_2 \rightarrow (5, 40)$. Deslizando la ventana a lo largo de todo el período de entrenamiento se obtienen aproximadamente 242 muestras por modelo, cada una asociando un perfil de comportamiento del modelo con los umbrales que mejor funcionaron bajo esas condiciones.

Fase 2: entrenamiento del meta-modelo. El meta-dataset resultante contiene aproximadamente 242 observaciones por modelo, cada una de las cuales asocia un perfil de comportamiento de las predicciones (siete *meta-features*) con la combinación de umbrales que produjo el mejor *Sharpe* penalizado en condiciones históricas similares. Las *meta-features* se estandarizan mediante *StandardScaler*⁶⁶ y se entrena un clasificador KNN con $K = 5$ vecinos ponderados por distancia inversa⁶⁷. A diferencia de un modelo paramétrico que aprendería una fórmula explícita para mapear características a umbrales, el KNN memoriza las 242 lecciones y, ante una consulta nueva, busca las cinco más similares y replica lo que funcionó. Esta naturaleza no paramétrica resulta apropiada dado que la relación entre el régimen predictivo de un modelo y los umbrales óptimos puede ser altamente no lineal y dependiente de la arquitectura del modelo.

Fase 3: aplicación dinámica en el período de prueba. El problema central que motiva el Meta-KNN es que, durante el período de prueba, no se dispone de retornos futuros para evaluar las 26 combinaciones de umbrales—hacerlo constituiría *data snooping*. El KNN entrenado en la Fase 2 resuelve esta limitación actuando como puente entre el entrenamiento—donde sí fue

⁶⁶La estandarización resta la media y divide por la desviación estándar de cada *meta-feature*, asegurando que las siete variables contribuyan de manera equitativa al cálculo de distancias en el KNN.

⁶⁷La ponderación por distancia inversa asigna mayor peso a los vecinos más cercanos en el espacio de características. Si tres de los cinco vecinos sugieren ($q_{\text{extreme}}=5, q_{\text{moderate}}=40$) y dos sugieren (10, 30), la predicción se inclina hacia la primera combinación con un peso proporcional a la similitud.

posible evaluar todos los combos con retornos reales—y el período de prueba, donde dicha evaluación directa es inviable. En lugar de probar las 26 combinaciones, el sistema describe el contexto actual y pregunta al KNN: *¿en qué momentos del entrenamiento las predicciones se veían de manera similar, y qué umbrales funcionaron mejor en esas situaciones?*

Concretamente, para cada día t del período de prueba se ejecutan tres pasos. Primero, se calculan las siete *meta-features* a partir de las 63 predicciones anteriores al día t —utilizando predicciones del entrenamiento como *warmup* para los primeros días del test—y se las presenta al KNN entrenado en la Fase 2. El clasificador identifica las cinco ventanas históricas cuyas *meta-features* son más similares al contexto actual y devuelve la combinación $(q_{\text{extreme}}, q_{\text{moderate}})$ que mejor funcionó en esas situaciones. Segundo, se aplican los umbrales predichos al percentil *rolling* del día t para determinar la posición según la Ecuación 3. Tercero, se calcula el retorno neto del día incorporando los costos de transacción correspondientes. Los umbrales pueden cambiar día a día si las condiciones varían, y ningún dato del período de prueba participa en el entrenamiento del KNN ni en la construcción del meta-dataset.

Intuición económica de la adaptación. La lógica que el Meta-KNN aprende de los datos de entrenamiento se alinea con un principio fundamental de gestión de riesgos: a mayor incertidumbre, mayor debe ser la convicción requerida para tomar posición. En períodos de alta volatilidad del mercado—donde la *meta-feature* $\bar{\sigma}_{m,w}$ es elevada y las predicciones del modelo tienden a ser erráticas—el KNN recupera ventanas históricas similares en las que los umbrales conservadores (por ejemplo, $q_{\text{extreme}}=5$, $q_{\text{moderate}}=20$) produjeron el mejor *Sharpe* penalizado. Estos umbrales implican que solo el 5 % superior de las predicciones activa la posición apalancada y solo el 20 % superior activa SPY, de modo que la estrategia permanece en efectivo la mayor parte del tiempo, protegiendo el capital durante turbulencias. En contraste, durante períodos estables—baja volatilidad, predicciones consistentes, retornos de mercado positivos—el KNN identifica ventanas históricas donde umbrales amplios ($q_{\text{extreme}}=20$, $q_{\text{moderate}}=60$) capturaron mayor rentabilidad sin incurrir en *drawdowns* excesivos: el 20 % superior accede a UPRO y el 60 % superior a SPY, manteniendo la estrategia invertida la mayor parte del tiempo. Esta adaptación no está codificada como regla explícita, sino que emerge del aprendizaje: el KNN simplemente busca los cinco contextos históricos más parecidos al actual y replica los umbrales que mejor funcionaron en esas condiciones.

Filtro de calidad de señal. No todos los modelos generan predicciones con variación suficiente para que el sistema de percentiles produzca señales significativas. Un modelo cuyas predicciones oscilan en un rango inferior a 0,001 puntos porcentuales durante 63 días genera

percentiles que responden a ruido numérico, no a información genuina sobre retornos futuros. Para evitar que predicciones degeneradas se amplifiquen en posiciones apalancadas, se introduce un filtro: si la desviación estándar *rolling* de las últimas 63 predicciones es inferior a $\tau = 0,001$, la estrategia se posiciona en efectivo para ese día, independientemente del percentil y de los umbrales predichos por el KNN. El umbral τ se calibró sobre datos de entrenamiento, donde separa con claridad los modelos con predicciones genuinamente variables de aquellos con predicciones cuasi-constantes. Los modelos de *deep learning* con predicciones ricas—LSTM+Attention, CNN-LSTM—superan el umbral el 100 % de los días y no se ven afectados; en contraste, Auto-ARIMA (0 % de días con señal válida), Theta (4,7 %) y GradientBoosting (13,7 %) permanecen mayoritariamente en efectivo.

Ejemplo: umbrales dinámicos con Ridge. Para ilustrar cómo los umbrales se adaptan al contexto, considérese el modelo Ridge durante cinco días consecutivos. En t , $t+1$ y $t+2$, el mercado presenta baja volatilidad; el Meta-KNN identifica este patrón como similar a ventanas históricas donde los umbrales ($q_{\text{extreme}}=20, q_{\text{moderate}}=30$) resultaron óptimos: UPRO si el percentil ≥ 80 , SPY si ≥ 70 . En $t+3$, un incremento en la volatilidad del mercado altera las *meta-features* y el KNN selecciona (10, 40): UPRO si ≥ 90 , SPY si ≥ 60 . La Tabla 3 ilustra cómo un mismo percentil puede generar posiciones distintas según los umbrales vigentes.

Cuadro 3: Ejemplo de Conversión de Predicciones a Posiciones con Umbrales Dinámicos (Ridge)

Día	$\hat{y}_t$	Pctil	($q_{\text{ext}}, q_{\text{mod}}$)	Umbrales	Posición
t	-0.005	45	(20, 30)	≥ 80 / ≥ 70	Cash
$t+1$	+0.002	74	(20, 30)	≥ 80 / ≥ 70	SPY (+1)
$t+2$	+0.004	91	(20, 30)	≥ 80 / ≥ 70	UPRO (+3)
$t+3$	+0.003	84	(10, 40)	≥ 90 / ≥ 60	SPY (+1)
$t+4$	-0.000	53	(10, 40)	≥ 90 / ≥ 60	Cash

Nótese que la predicción de $t+2$ (percentil 91) activa la posición apalancada bajo los umbrales (20,30), pero en $t+3$ un percentil de 84—que habría activado UPRO bajo esos mismos umbrales—genera solo posición SPY porque el Meta-KNN ha elevado el requisito a percentil ≥ 90 al detectar un cambio en las condiciones de mercado. Este mecanismo adapta automáticamente no solo la escala de las predicciones (función del percentil *rolling*) sino también la agresividad del posicionamiento (función de los umbrales dinámicos).

La Tabla 4 resume las características de los cuatro modelos que superan al *benchmark* SPY Buy & Hold (+102 %, Sharpe 0,66) con la metodología Meta-KNN. La diversidad en el número de combinaciones empleadas refleja la naturaleza dinámica del sistema: LSTM+Attention utiliza 22 configuraciones distintas de umbrales a lo largo de los 1,302 días de prueba, con su combi-

nación más frecuente representando apenas el 26,5 % de los días, mientras que RandomForest mantiene una configuración dominante el 83,9 % del tiempo. Ninguno de estos cuatro modelos se ve afectado significativamente por el filtro de calidad—todos superan τ al menos el 53 % de los días—lo que confirma que sus predicciones contienen variación genuina susceptible de ser explotada por el sistema de percentiles.

Cuadro 4: Características Dinámicas y Distribución de Posiciones de los Modelos Ganadores

Modelo	$(q_{ext}, q_{mod})^*$	Combos	%Frec.	%UPRO	%SPY	%Cash
LSTM+Attention	(5, 50)	22	26.5	12.2	32.7	55.1
Ridge	(20, 30)	21	47.4	20.8	17.0	62.3
RandomForest	(5, 40)	4	83.9	5.2	16.9	77.9
CNN-LSTM	(20, 40)	18	24.9	12.1	28.6	59.3

Nota: $(q_{ext}, q_{mod})^*$ es la combinación de umbrales más frecuente seleccionada por el Meta-KNN. “Combos” indica el número de combinaciones distintas utilizadas durante los 1,302 días de prueba, y %Frec. el porcentaje de días en que se aplicó la combinación más frecuente. %UPRO/SPY/Cash indica la proporción del período en cada posición.

3.4.3 Modelo de Costos

Los retornos de la estrategia incorporan tres fuentes de costos reales que reflejan las fricciones de implementación: los *expense ratios*⁶⁸ de cada ETF, los *spreads bid-ask*⁶⁹ en cada operación de compra y venta, y el *volatility drag*⁷⁰ de los ETFs apalancados. El análisis completo del impacto de costos se presenta en la Sección 8.

El retorno diario neto de la estrategia se calcula como:

$$r_t^{\text{estrategia}} = r_t^f + \text{posición}_t \times (r_t^{SPY} - r_t^f) - \text{costos}_t \quad (5)$$

donde r_t^f es la tasa libre de riesgo diaria, r_t^{SPY} el retorno del mercado, $\text{posición}_t \in \{0, 1, 3\}$ el grado de exposición, y costos_t la suma del *expense ratio* diario, los costos de transacción (si hubo cambio de posición) y el *volatility drag* (si la posición es apalancada). Con posición 0 la estrategia obtiene la tasa libre de riesgo; con posición 1 replica el retorno del SPY; con posición 3 triplica la exposición al retorno en exceso, amplificando tanto ganancias como pérdidas.

Ejemplo de *backtesting* con costos de transacción. Para ilustrar la interacción entre posiciones, retornos y costos, la Tabla 5 presenta cinco días consecutivos hipotéticos del modelo LSTM+Attention. Se supone que el Meta-KNN selecciona la configuración ($q_{\text{extreme}} =$

⁶⁸El *expense ratio* es el costo anual de gestión de un ETF, expresado como porcentaje de los activos bajo administración: 0.91 % anual para UPRO y 0.09 % para SPY.

⁶⁹El *spread bid-ask* es la diferencia entre el precio de compra y el precio de venta de un activo. Representa un costo implícito de cada transacción: 0.05 % para UPRO y 0.02 % para SPY.

⁷⁰El *volatility drag* es la pérdida sistemática que sufren los ETFs apalancados por su rebalanceo diario. Formalmente, $\text{drag} \approx \frac{1}{2}(L^2 - |L|) \cdot \sigma^2$, donde L es el factor de apalancamiento y σ^2 la varianza diaria del subyacente.

5, $q_{\text{moderate}} = 20$) durante estos días, lo que implica que la posición UPRO se activa cuando el percentil alcanza o supera 95 y la posición SPY cuando alcanza o supera 80. Se parte de un capital inicial de \$10,000 y una tasa libre de riesgo diaria de $r^f = 0,02\%$ ($\approx 5\%$ anual).

Cuadro 5: Ejemplo de *Backtesting*: Cinco Días con LSTM+Attention

Día	Pctil	Pos.	r_t^{SPY}	Cambio	Costos	r_t^{estrat}	Capital
t	62	Cash	+0.80 %	—	0 bps	+0.02 %	\$10,002
$t+1$	83	SPY	+1.20 %	Cash→SPY	2 bps	+1.18 %	\$10,120
$t+2$	96	UPRO	+0.50 %	SPY→UPRO	10 bps	+1.36 %	\$10,257
$t+3$	97	UPRO	-0.30 %	—	3 bps	-0.97 %	\$10,157
$t+4$	71	Cash	+0.40 %	UPRO→Cash	5 bps	-0.03 %	\$10,154

Nota: La columna Costos muestra los costos totales diarios redondeados a puntos básicos. En t , la estrategia está en Cash y gana solo r^f , evitando el +0.80 % del mercado. En $t+2$, la posición 3x amplifica el exceso de retorno: $3 \times (0.50\% - 0.02\%) = +1.44\%$, más r^f da +1.46 % bruto; se restan 10 bps de costos: 7 bps de bid-ask (salida de SPY + entrada a UPRO) y 3 bps de volatility drag. En $t+3$, sin cambio de posición, los costos se reducen a 3 bps diarios de volatility drag; la amplificación 3x opera en contra: $3 \times (-0.32\%) = -0.96\%$ de exceso, produciendo -0.94 % bruto. En $t+4$, la salida de UPRO cuesta 5 bps de spread, que exceden la tasa libre de riesgo (+0.02 %), resultando en un retorno neto ligeramente negativo (-0.03 %).

Este ejemplo ilustra un principio central de la estrategia: la selectividad temporal. El modelo LSTM+Attention permanece en efectivo el 55,1 % del tiempo, capturando solo los momentos donde las *meta-features* y las condiciones de mercado se asemejan a períodos históricos de alto rendimiento. El costo de esta selectividad—perder días alcistas como t y $t+4$ —se compensa con la evitación de días bajistas y la amplificación 3x en los días de alta convicción correcta. El análisis completo del impacto de costos sobre los 23 modelos se presenta en la Sección 8.

4. Resultados Empíricos

En esta sección se presentan los resultados del *backtesting* de los 23 modelos durante el período de prueba (Octubre 2020 – Diciembre 2025, 1,302 días de *trading*).

4.1 Resumen de Rendimiento

4.1.1 Tabla Principal de Rendimiento

La Tabla 6 presenta las métricas de rendimiento completas para los 23 modelos evaluados.

4.1.2 Hallazgos Principales

Cuatro de veintitrés modelos⁷¹ superan al *benchmark* SPY Buy & Hold (+102 %): LSTM+Attention (+400 %), Ridge (+263 %), RandomForest (+131 %) y CNN-LSTM (+129 %). Las arquitectu-

⁷¹AutoARIMA se incluye en el recuento de 23 modelos. Sin embargo, el filtro de calidad de señal lo mantiene en efectivo el 100 % del tiempo (sus predicciones carecen de variación suficiente), por lo que su retorno refleja únicamente la tasa libre de riesgo, sin evidencia de capacidad predictiva genuina.

Cuadro 6: Rendimiento de los 23 Modelos en el Período de Prueba (Oct 2020 - Dic 2025)

Rank	Modelo	Ret. Total	Sharpe	Sortino	Max DD
1	LSTM+Attention	+400.0 %	1.327	2.631	20.5 %
2	Ridge	+263.2 %	0.881	1.291	31.8 %
3	RandomForest	+131.0 %	0.666	1.380	14.7 %
4	CNN-LSTM	+129.0 %	0.599	1.161	35.6 %
5	DLinear	+67.9 %	0.426	0.681	33.1 %
6	GradientBoosting	+66.8 %	0.622	1.287	8.3 %
7	CatBoost	+47.4 %	0.232	0.456	30.9 %
8	Theta	+44.6 %	0.563	0.949	12.7 %
9	SeasonalNaive	+44.5 %	0.150	0.210	32.9 %
10	NBEATS	+44.4 %	0.182	0.319	25.5 %
11	Lasso	+39.0 %	0.202	0.466	19.3 %
12	GARCH	+27.2 %	0.202	0.287	21.8 %
13	LightGBM	+27.1 %	0.106	0.145	24.3 %
14	NHiTS	+22.1 %	0.038	0.053	48.1 %
15	AutoARIMA	+18.3 %	0.387	0.497	0.0 %
16	TCN	+18.1 %	0.001	0.002	35.0 %
17	TFT	+14.8 %	-0.020	-0.032	44.6 %
18	XGBoost	+13.5 %	-0.024	-0.034	43.1 %
19	ElasticNet	+9.8 %	-0.068	-0.110	39.6 %
20	Prophet	+7.6 %	-0.234	-0.311	11.7 %
21	BiLSTM	+6.2 %	-0.082	-0.133	54.7 %
22	ExponentialSmoothing	-14.5 %	-0.233	-0.311	59.6 %
23	BiGRU	-32.3 %	-0.457	-0.573	58.5 %
–	SPY (B&H)	+102.2 %	0.663	0.953	25.4 %
–	UPRO 3x (B&H)	+246.4 %	0.465	0.669	64.8 %

Nota: Los modelos en negrita superan al *benchmark* SPY Buy & Hold. UPRO 3x B&H incluye *expense ratio* (0.91 %/año) y *bid-ask spread*. El *volatility decay* inherente a los ETF apalancados está capturado por la composición diaria de retornos 3×.

ras de *deep learning* con mecanismos de atención—LSTM+Attention y CNN-LSTM—obtienen los mejores rendimientos tanto en términos absolutos como ajustados por riesgo, lo que sugiere que estas arquitecturas capturan dependencias temporales en los retornos del S&P 500 que los modelos más simples no explotan.

La variabilidad entre modelos es significativa: los retornos totales abarcan un rango de 432 puntos porcentuales, desde el +400 % de LSTM+Attention hasta el −32 % de BiGRU. No obstante, 16 de 23 modelos logran un *Sharpe ratio* positivo, lo que indica que la mayoría de los modelos genera cierto alfa, aunque no siempre suficiente para superar al *benchmark* pasivo.

4.1.3 Tabla Resumen Ejecutivo

La Tabla 7 sintetiza las métricas principales de los cuatro modelos ganadores frente a los *benchmarks*.

Cuadro 7: Resumen Ejecutivo: Top 4 Modelos vs Benchmarks

Modelo	Ret. Total	Sharpe	Max DD
LSTM+Attention	+400.0 %	1.327	20.5 %
Ridge	+263.2 %	0.881	31.8 %
RandomForest	+131.0 %	0.666	14.7 %
CNN-LSTM	+129.0 %	0.599	35.6 %
SPY (B&H)	+102.2 %	0.663	25.4 %
UPRO 3x (B&H)	+246.4 %	0.465	64.8 %

Nota: Período de prueba: Oct 2020 a Dic 2025 (1,302 días). Capital inicial: \$10,000. Los modelos en negrita superan a ambos *benchmarks* en Sharpe.

4.2 Análisis por Familia de Modelos

4.2.1 Comparación por Categoría

La Tabla 8 agrupa los 23 modelos por familia metodológica.

Cuadro 8: Rendimiento Promedio por Categoría de Modelo

Categoría	N	Ret. Prom.	Sharpe Prom.	DD Prom.	Mejor Modelo
RNN	4	125.7 %	0.347	42.3 %	LSTM+Attention
ML	5	102.0 %	0.461	22.7 %	Ridge
DeepLearning	5	33.5 %	0.125	37.2 %	DLinear
GradientBoosting	3	29.4 %	0.104	32.8 %	CatBoost
TimeSeries	4	23.2 %	0.216	26.3 %	Theta
Specialized	2	17.4 %	-0.016	16.8 %	GARCH

Nota: N = número de modelos en la categoría. ML = Machine Learning clásico, GradientBoosting = XGBoost/LightGBM/CatBoost, DeepLearning = redes Darts, RNN = LSTM/GRU, TimeSeries = ARIMA/ETS/Theta.

4.2.2 Interpretación por Categoría

Dentro del **ML clásico**, Ridge destaca con un retorno del +263 % y un Sharpe de 0.88, posicionándose como el segundo mejor modelo del estudio. Lasso (+39 %) y ElasticNet (+10 %), en cambio, presentan un rendimiento significativamente inferior, lo que sugiere que la regularización L_1 —que fuerza coeficientes a cero—es demasiado agresiva para este problema, eliminando predictores que contienen señal útil. La penalización L_2 de Ridge, que contrae los coeficientes sin eliminarlos, resulta más adecuada para un espacio de 536 características donde la señal está distribuida entre múltiples predictores.

En la categoría de **gradient boosting**, GradientBoosting lidera con un retorno del +67 % y un Sharpe de 0.62, seguido por CatBoost (+47 %) y XGBoost (+14 %). Ninguno de los tres supera al *benchmark*, lo que indica que los umbrales dinámicos del Meta-KNN resultan menos efectivos para modelos basados en árboles cuyas predicciones presentan baja variabilidad—GradientBoosting, por ejemplo, genera solo 16 predicciones únicas y permanece filtrado el 86 % del tiempo. No obstante, GradientBoosting ofrece el mejor balance riesgo-retorno dentro de esta familia, con el menor *drawdown* máximo del estudio (8.3 %).

Los modelos de **deep learning implementados en Darts** exhiben un rendimiento inferior al esperado dada su complejidad arquitectural. DLinear obtiene el mejor resultado de la subcategoría con +68 %, seguido por NBEATS (+44 %) y NHiTS (+22 %). TFT (+15 %), pese a incorporar atención temporal, no traduce su complejidad arquitectural en rendimiento práctico—un resultado consistente con la observación de [Zeng et al. \(2023\)](#) sobre la superioridad de modelos simples en ciertos contextos de pronóstico.

En contraste, las **arquitecturas híbridas y de atención implementadas en PyTorch** dominan el ranking general. El modelo LSTM+Attention alcanza un retorno del +400 % con un Sharpe de 1.33 y un *drawdown* máximo del 20.5 %, mientras que CNN-LSTM obtiene +129 % con un Sharpe de 0.60 y un *drawdown* del 35.6 %. BiLSTM (+6 %) y BiGRU (−32 %), si bien bidireccionales, logran rendimientos marcadamente inferiores, lo que sugiere que el mecanismo de atención—más que la bidireccionalidad—es el componente arquitectural determinante.

Finalmente, las **series temporales clásicas** presentan un rendimiento modesto en general. Theta (+45 %) y SeasonalNaive (+45 %) lideran la categoría, mientras que Prophet (+8 %) y ExponentialSmoothing (−15 %) cierran el grupo. Este último registra uno de los dos retornos negativos del estudio (junto con BiGRU), confirmando que los modelos univariados carecen de la información necesaria para generar alfa consistente en este contexto.




Figura 2: Curvas de Equity: Top 5 Modelos vs SPY Buy & Hold. Período: Oct 2020 - Dic 2025. Capital inicial: \$10,000.

4.3 Curvas de Equity

La Figura 2 revela patrones diferenciados entre los modelos líderes. El modelo LSTM+Attention muestra el crecimiento más consistente con una trayectoria ascendente suave incluso durante episodios de estrés, alcanzando un *drawdown* máximo del 20.5%. Ridge ocupa la segunda posición con buena estabilidad, seguido por RandomForest (14.7% de *drawdown*, el menor del grupo) y CNN-LSTM. Los cuatro modelos ganadores superan al SPY durante la totalidad del período evaluado.

4.4 Distribución de Posiciones

4.4.1 Patrones de Posicionamiento

La Tabla 9 revela filosofías de inversión radicalmente distintas entre modelos. En un extremo, ExponentialSmoothing (72% del tiempo en posición larga) y TFT (60%) mantienen exposición casi permanente al mercado. En el extremo opuesto, AutoARIMA permanece en efectivo el 100% del tiempo (filtrado por calidad de señal) y GradientBoosting el 92%. El modelo LSTM+Attention, cuya distribución—12.2% en UPRO, 32.7% en SPY y 55.1% en efectivo—refleja una estrategia selectiva que combina exposición apalancada en momentos de alta convicción con posiciones moderadas en SPY. Esto sugiere que el éxito del modelo proviene

Cuadro 9: Distribución de Posiciones por Modelo (Estrategia Long-Only)

Modelo	UPRO (3x)	SPY (1x)	Cash (0)	Total Long	N° Trades
LSTM+Attention	12.2 %	32.7 %	55.1 %	44.9 %	465
Ridge	20.8 %	17.0 %	62.3 %	37.7 %	409
RandomForest	5.2 %	16.9 %	77.9 %	22.1 %	175
CNN-LSTM	12.1 %	28.6 %	59.3 %	40.7 %	633
DLinear	6.6 %	52.2 %	41.2 %	58.8 %	788
GradientBoosting	4.2 %	4.0 %	91.9 %	8.1 %	11
CatBoost	4.0 %	9.1 %	86.9 %	13.1 %	224
Theta	2.3 %	2.2 %	95.5 %	4.5 %	36
SeasonalNaive	20.2 %	39.7 %	40.0 %	60.0 %	1042
NBEATS	13.9 %	10.3 %	75.8 %	24.2 %	507
Lasso	1.4 %	4.8 %	93.9 %	6.1 %	90
GARCH	1.7 %	6.2 %	92.1 %	7.9 %	126
LightGBM	3.7 %	6.3 %	90.0 %	10.0 %	134
NHiTS	7.1 %	52.4 %	40.4 %	59.6 %	805
AutoARIMA	0.0 %	0.0 %	100.0 %	0.0 %	0
TCN	7.7 %	20.7 %	71.6 %	28.4 %	383
TFT	21.4 %	38.7 %	39.9 %	60.1 %	804
XGBoost	29.1 %	3.8 %	67.1 %	32.9 %	42
ElasticNet	3.7 %	9.4 %	86.9 %	13.1 %	175
Prophet	2.3 %	8.8 %	88.9 %	11.1 %	77
BiLSTM	12.1 %	20.1 %	67.8 %	32.2 %	546
ExponentialSmoothing	26.7 %	45.3 %	28.0 %	72.0 %	904
BiGRU	15.7 %	27.5 %	56.8 %	43.2 %	752

Nota: Porcentajes representan la proporción de días en cada posición. UPRO = 3x apalancado largo, SPY = 1x largo, Cash = tasa libre de riesgo. Número de trades = cambios de posición.

no solo de identificar los momentos óptimos para apalancamiento, sino también de mantener exposición parcial al mercado cuando la señal es moderadamente positiva.

4.5 Análisis de Trades

4.5.1 Estadísticas de Trading

La Tabla 10 resume las estadísticas de operación de los cinco modelos líderes.

Cuadro 10: Estadísticas de Trading por Modelo (Top 5)

Modelo	N Trades	Win Rate	Avg Win	Avg Loss	Profit Factor
LSTM+Attention	465	52.9 %	+2.5 %	−1.5 %	1.62
Ridge	409	60.4 %	+2.4 %	−2.1 %	1.11
RandomForest	175	66.1 %	+2.2 %	−2.0 %	1.05
CNN-LSTM	633	54.6 %	+1.7 %	−1.5 %	1.15
DLinear	788	53.6 %	+1.3 %	−1.2 %	1.09

Nota: N Trades = cambios de posición. Win Rate, Avg Win, Avg Loss y Profit Factor calculados sobre trades activos (posición $\neq 0$). Profit Factor = $|Avg Win / Avg Loss|$.




Figura 3: Distribución de retornos diarios en exceso sobre la tasa libre de riesgo: Modelo LSTM+Attention. Histograma calculado sobre los días activos (posición $\neq 0$). Verde = días ganadores, Rojo = días perdedores. Línea vertical en 0 %.

4.5.2 Distribución de P&L Diario

La Figura 3 revela una asimetría positiva, con una cola derecha más extendida que la izquierda. Los días ganadores se concentran en el rango de +0.5 % a +2 %, mientras que las pérdidas presentan un límite natural impuesto por el posicionamiento conservador de la estrategia: al permanecer en efectivo el 55 % del tiempo, la exposición al riesgo se acota automáticamente.

4.6 Comparación con Benchmarks Adicionales

La Tabla 11 compara los cuatro modelos ganadores contra múltiples *benchmarks*.

Cuadro 11: Modelos Ganadores vs Múltiples Benchmarks

Estrategia	Ret. Total	Sharpe	Max DD	Calmar
LSTM+Attention	+400 %	1.33	−20.5 %	1.79
Ridge	+263 %	0.88	−31.8 %	0.89
RandomForest	+131 %	0.67	−14.7 %	1.20
CNN-LSTM	+129 %	0.60	−35.6 %	0.49
SPY Buy & Hold	+102.2 %	0.66	−25.4 %	0.58
UPRO 3x (B&H)	+246.4 %	0.47	−64.8 %	0.42
60/40 Portfolio	+71.1 %	0.68	−21.1 %	0.52

Nota: UPRO 3x B&H incluye expense ratio (0.91 %/año) y bid-ask spread; el volatility decay está implícito en la composición diaria de retornos 3×. 60/40 = 60 % SPY + 40 % LF98TRUU Index (Bloomberg US Aggregate Bond Total Return) con rebalanceo mensual.

La comparación con *benchmarks* alternativos refuerza la solidez de los resultados. La reten-

ción pasiva de UPRO 3x genera un retorno del +246 %, superior al +102 % de SPY gracias al apalancamiento, pero a costa de un *drawdown* máximo del 64.8 % y un *volatility decay* que erosiona 54 puntos porcentuales respecto al retorno teórico de 3× SPY (+300 %). Frente a este *benchmark* apalancado, el modelo LSTM+Attention supera ampliamente en retorno (+400 % vs +246 %) con un *drawdown* tres veces menor (−20.5 % vs −64.8 %) y un Sharpe casi tres veces mayor (1.33 vs 0.47), demostrando que la selección temporal de la exposición apalancada genera un perfil de riesgo-retorno cualitativamente superior a la retención pasiva del ETF 3x. Los cuatro modelos ganadores superan tanto al portafolio conservador 60/40 como a SPY en retorno y en Sharpe, y LSTM+Attention supera incluso a UPRO 3x en ambas métricas.

4.7 Aplicación Interactiva

Se desarrolló una aplicación web interactiva para facilitar la exploración detallada de los resultados, disponible bajo solicitud al autor. La aplicación permite visualizar curvas de *equity* dinámicas, analizar *trades* individuales, comparar múltiples modelos simultáneamente, explorar el rendimiento por régimen de mercado y ajustar parámetros de costo para análisis de sensibilidad.

5. La Paradoja del *Directional Accuracy*

Uno de los hallazgos más llamativos de este estudio es la desconexión entre el *Directional Accuracy* (DA)—la métrica más usada para evaluar predicciones de dirección—y la rentabilidad, dado que el DA resulta ser un predictor poco confiable del rendimiento de una estrategia.

5.1 El Hallazgo Contraintuitivo

5.1.1 Intuición Naïve vs Realidad

Intuitivamente, un modelo que acierta más la dirección del mercado debería generar mayores retornos. Los resultados, sin embargo, contradicen esta expectativa:

$$\rho(\text{DA}, \text{Return}) = -0.37 \quad (6)$$

La correlación entre *Directional Accuracy* y retorno total es **moderadamente negativa**, indicando que modelos con mayor DA no necesariamente generan mejores retornos.

5.1.2 Evidencia Empírica

La Tabla 12 presenta casos ilustrativos de esta paradoja.

Cuadro 12: Paradoja DA vs Retorno: Casos Ilustrativos

Modelo	DA General	Retorno Total	Categoría
GARCH	54.3 %	+27.2 %	Alto DA, Retorno Modesto
Theta	54.6 %	+44.6 %	Alto DA, Retorno Modesto
ExponentialSmoothing	51.3 %	-14.5 %	Alto DA, Retorno Negativo
LSTM+Attention	47.0 %	+400 %	DA Bajo, Mejor Retorno
Ridge	46.8 %	+263 %	DA Bajo, Alto Retorno
CNN-LSTM	45.5 %	+129 %	DA Bajo, Alto Retorno

Nota: DA calculado como porcentaje de días donde la predicción de dirección coincide con el movimiento realizado del mercado.




Figura 4: La Paradoja del *Directional Accuracy*. Panel izquierdo: *Scatter plot* de DA vs Retorno Total mostrando correlación negativa ($\rho = -0.37$). Panel derecho: Comparación de DA General vs DA@3x (*hit rate* en posiciones apalancadas) para modelos seleccionados. Los retornos se indican sobre cada par de barras.

La Figura 4 ilustra gráficamente esta relación inversa entre precisión direccional y rentabilidad.

5.2 Explicación de la Paradoja

5.2.1 El DA Trata Todos los Días como Iguales

El DA asigna el mismo peso a cada predicción, sin distinguir entre la magnitud del movimiento, el tamaño de la posición o el momento del ciclo de mercado.

Ejemplo ilustrativo:

Día	Movimiento	Predicción	Resultado
1	Mercado +0.1 %	Correcta	✓
2	Mercado +0.1 %	Correcta	✓
3	Mercado −3.0 %	Incorrecta	✗

DA = 66.7 % (2/3 aciertos), pero el P&L acumulado es **negativo**: la pérdida del día 3 (−3.0 %) supera las ganancias combinadas de los días 1 y 2 (+0.2 %).

5.2.2 Lo Que Realmente Importa: Asimetría Condicional

La rentabilidad de una estrategia de *trading* depende de tres factores que el DA no captura. En primer lugar, *cuándo* se acierta—acertar en días de movimientos grandes importa más que acertar en días tranquilos, dado que el P&L se determina por la magnitud del movimiento, no por haber acertado la dirección. En segundo lugar, *cuánto* se expone—el tamaño de la posición cuando se acierta frente al tamaño cuando se falla determina la contribución neta de cada predicción al resultado. En tercer lugar, la asimetría entre ganancias y pérdidas—el ratio entre la ganancia promedio y la pérdida promedio por *trade* (*Profit Factor*) puede compensar una tasa de aciertos moderada si las ganancias son sustancialmente mayores que las pérdidas.

5.3 El Indicador DA@3x: Una Métrica Más Relevante

Se propone el indicador **DA@3x** (*Directional Accuracy* en posiciones apalancadas) como una métrica más predictiva de rentabilidad:

$$\text{DA@3x} = \frac{\sum_{t=1}^T \mathbf{1}[\text{pos}_t = 3 \wedge r_t^{\text{mkt}} > 0]}{\sum_{t=1}^T \mathbf{1}[\text{pos}_t = 3]} \quad (7)$$

donde $\mathbf{1}[\cdot]$ es la función indicadora, pos_t es la posición asignada en el día t y r_t^{mkt} es el retorno del mercado en ese día. El numerador cuenta los días en los que el modelo mantiene la posición apalancada máxima (UPRO, 3x) y el mercado efectivamente sube; el denominador cuenta el total de días en posición 3x. Así, el DA@3x mide exclusivamente la precisión del modelo en sus decisiones de mayor convicción—aquellas en las que la exposición y, por tanto, el impacto sobre el portafolio son máximos. La Tabla 13 compara ambas métricas para los modelos más representativos.

Cuadro 13: DA General vs DA@3x: El Predictor de Rentabilidad

Modelo	DA General	DA@3x	% Tiempo 3x	Retorno
LSTM+Attention	47.0 %	62.3 %	12.2 %	+400 %
Ridge	46.8 %	58.5 %	20.8 %	+263 %
RandomForest	45.9 %	51.5 %	5.2 %	+131 %
CNN-LSTM	45.5 %	58.6 %	12.1 %	+129 %
GARCH	54.3 %	63.6 %	1.7 %	+27.2 %
Theta	54.6 %	53.3 %	2.3 %	+44.6 %

Nota: DA@3x = hit rate cuando el modelo está en posición 3x (UPRO). % Tiempo 3x indica qué fracción del período el modelo estuvo en posición apalancada.

Los modelos rentables se distinguen por tres características interrelacionadas. En primer lugar, exhiben un DA@3x superior a su DA general—LSTM+Attention registra un 47.0 % de DA general pero un 62.3 % de DA@3x, lo que significa que acierta con mayor frecuencia precisamente cuando asume mayor exposición. En segundo lugar, son selectivos en el uso del apalancamiento—LSTM+Attention reserva la posición 3x para el 12.2 % del tiempo, activándola ante señales de alta confianza. En tercer lugar, protegen el capital en períodos de incertidumbre, permaneciendo en efectivo cuando la señal no es concluyente—un 55 % del tiempo en el caso de LSTM+Attention. En contraste, GARCH presenta un DA@3x del 63.6 %—el más alto del estudio—pero apenas asigna la posición 3x el 1.7 % del tiempo, limitando severamente su capacidad de generar retornos a pesar de su elevada precisión condicional. Theta (54.6 % DA general vs 53.3 % DA@3x) ejemplifica el caso opuesto, donde su precisión direccional se concentra en movimientos de mercado de pequeña magnitud que no compensan los errores en los días críticos.

5.4 Implicaciones para el Diseño de Estrategias

5.4.1 No Optimizar por DA

Este hallazgo tiene implicaciones importantes para el diseño de estrategias de *trading*.

Implicación Clave

Optimizar un modelo para maximizar *Directional Accuracy* puede ser contraproducente. En su lugar, se debe optimizar por métricas que capturen la asimetría entre ganancias y pérdidas condicionales al tamaño de la posición.

5.4.2 Métricas Alternativas Recomendadas

En lugar de DA, resulta preferible evaluar los modelos de *trading* mediante métricas que capturen la asimetría condicional del rendimiento. El *Sharpe Ratio* captura el *trade-off* riesgo-retorno; el *Profit Factor* mide el ratio entre ganancia promedio y pérdida promedio por *trade*; el DA@3x evalúa el *hit rate* en posiciones de alta convicción; y el retorno neto constituye la métrica final que integra todos los factores anteriores.

5.4.3 El Valor de la Selectividad

El éxito del modelo LSTM+Attention ilustra el valor de la selectividad de manera elocuente. Su DA general del 47.0%—por debajo del azar—lo descalificaría bajo cualquier evaluación convencional basada en precisión direccional. Sin embargo, cuando concentra su exposición en posiciones apalancadas, su DA@3x asciende al 62.3%, significativamente superior. El modelo concentra su exposición en momentos de alta confianza y, lo que es igualmente importante, permanece en efectivo el 55% del tiempo. El resultado neto—un retorno del +400%, el mejor de todos los modelos evaluados—demuestra que la rentabilidad de una estrategia de *trading* depende menos de la frecuencia de aciertos que de su concentración en los momentos de mayor asimetría favorable.

5.5 Conexión con la Literatura

Este hallazgo es consistente con varios resultados fundamentales de la literatura sobre *trading* y gestión de portafolios.

López de Prado (2018) argumenta que las métricas tradicionales de evaluación de modelos predictivos—como R^2 , *accuracy* o, en este caso, el *Directional Accuracy*—son inadecuadas para evaluar estrategias de *trading*, donde lo que importa no es la frecuencia de aciertos sino la rentabilidad ajustada por riesgo. El autor señala específicamente que la minería de datos y el testeo múltiple pueden producir modelos con alta precisión aparente que fracasan en la implementación real, un fenómeno que los resultados de este estudio ilustran de manera inversa, dado que modelos con DA inferior al 50% generan los mejores retornos porque concentran su exposición en los momentos de mayor asimetría favorable.

El criterio de Kelly (Kelly, 1956) formaliza matemáticamente la intuición que subyace a la paradoja del DA. La fracción óptima del capital a exponer en cada operación depende no solo de la probabilidad de ganar, sino también del cociente entre la ganancia esperada y la pérdida esperada. Un agente con una tasa de aciertos del 47 %—como el LSTM+Attention—puede maximizar su riqueza a largo plazo si las ganancias en los días acertados superan sustancialmente las pérdidas en los días erróneos. El sistema de posicionamiento por percentiles implementado en este estudio opera precisamente bajo esta lógica, asignando la máxima exposición (3x) solo cuando la convicción predictiva es elevada y reduciendo la exposición o retirándose a efectivo en los demás casos.

La paradoja de Grossman-Stiglitz (Grossman & Stiglitz, 1980) proporciona el marco teórico más general para interpretar estos hallazgos. Si los mercados fueran perfectamente eficientes, ninguna estrategia—independientemente de su DA—podría generar alfa de forma sistemática. El hecho de que modelos con DA inferior al azar generen rendimientos superiores al mercado sugiere que la ineficiencia explotable no reside en la capacidad de predecir la dirección diaria del mercado, sino en la identificación de momentos donde la relación riesgo-retorno es asimétricamente favorable. La compensación que el mercado otorga por procesar esta información—conforme al equilibrio de Grossman-Stiglitz—se materializa no a través de aciertos frecuentes, sino a través de aciertos concentrados en los momentos de mayor impacto.

Los hallazgos son también consistentes con la evidencia de Gu et al. (2020), quienes muestran que múltiples familias de modelos convergen en las mismas señales predictivas dominantes. En el contexto de la paradoja del DA, esta convergencia adquiere un matiz adicional: tanto Ridge (modelo lineal) como LSTM+Attention (red neuronal profunda) exhiben DA inferior al 50 % y, sin embargo, ambos superan ampliamente al mercado. Esto sugiere que la señal predictiva capturada por ambos modelos—pese a sus arquitecturas radicalmente distintas—no es de naturaleza direccional simple, sino que involucra la identificación de estados de mercado donde la exposición produce retornos asimétricos.

Desde la perspectiva de las finanzas conductuales, Kahneman & Tversky (1979) documentaron que los agentes sistemáticamente sobrevaloran la frecuencia de aciertos frente a la magnitud de los resultados—un sesgo que la *Prospect Theory* atribuye a la aversión a las pérdidas. Esta tendencia cognitiva explica, al menos parcialmente, por qué el DA persiste como métrica dominante en la evaluación de modelos de *trading* pese a su limitada capacidad predictiva: los inversores e investigadores tienden a favorecer estrategias que “aciertan” frecuentemente, aun cuando estrategias con menor frecuencia de aciertos pero mayor asimetría en las magnitudes produzcan resultados superiores.

Finalmente, el concepto de selectividad temporal que emerge de la paradoja del DA se conecta directamente con la filosofía del Triple Screen de Elder (1993), cuya metodología inspira la ingeniería de características de este estudio. Elder argumenta que las señales más fiables surgen cuando múltiples marcos temporales se alinean, y que la disciplina de *no* operar cuando la señal es ambigua es tan importante como la precisión de la señal misma. El LSTM+Attention, al permanecer en efectivo el 55 % del tiempo y reservar la máxima exposición para el 12 % de los días, implementa computacionalmente esta filosofía de selectividad, dado que su ventaja no proviene de predecir mejor la dirección del mercado, sino de identificar con mayor precisión cuándo vale la pena asumir exposición.

5.6 Resumen de la Sección

El análisis presentado en esta sección revela que el *Directional Accuracy* (DA) no constituye un predictor confiable de rentabilidad en estrategias de *trading* basadas en modelos predictivos, como lo evidencia la correlación negativa observada ($\rho = -0.37$) entre la precisión direccional y el retorno total. Los modelos con DA superior al 54 % generaron retornos modestos en relación con su aparente precisión, mientras que los mejores resultados provinieron de modelos con DA en el rango de 45–47 %, lo que contradice la intuición convencional de que mayor frecuencia de aciertos se traduce en mayor rentabilidad. Frente a esta paradoja, el indicador DA@3x—que mide el *hit rate* exclusivamente en los días donde el modelo asigna la máxima exposición apalancada—demuestra ser sustancialmente más predictivo del desempeño real, dado que captura la calidad de las decisiones de alta convicción en lugar de la frecuencia general de aciertos. En conjunto, estos hallazgos sugieren que los modelos rentables se caracterizan por su selectividad temporal y no por la frecuencia con la que predicen correctamente la dirección del mercado, lo que implica que optimizar una estrategia de *trading* maximizando el DA puede resultar contraproducente al favorecer modelos que aciertan frecuentemente pero con exposiciones subóptimas en los momentos de mayor oportunidad.

6. Marco de Gestión de Riesgo

Una estrategia rentable no basta para justificar su implementación, dado que la gestión de riesgo es lo que distingue una estrategia académicamente interesante de una operativamente viable. En esta sección se presenta un marco integral de análisis de riesgo aplicado a los cuatro modelos que superaron al *benchmark* SPY Buy & Hold durante el período de prueba—LSTM+Attention, Ridge, RandomForest y CNN-LSTM—con el objetivo de evaluar si sus retornos superiores compensan adecuadamente los riesgos asumidos. Cada métrica se define for-

malmente y se acompaña de una comparación entre los cuatro modelos y el *benchmark*, lo que permite identificar diferencias sistemáticas en los perfiles de riesgo que subyacen a estrategias con retornos aparentemente comparables.

6.1 Métricas de Riesgo Ajustado

Las métricas de riesgo ajustado permiten comparar estrategias con distintos niveles de volatilidad al normalizar el retorno por alguna medida de riesgo. A continuación se presentan tres ratios ampliamente utilizados en la literatura de gestión de portafolios, cada uno con una perspectiva distinta sobre qué constituye “riesgo”.

6.1.1 Sharpe Ratio

El *Sharpe Ratio* (Sharpe, 1966) mide el exceso de retorno por unidad de volatilidad total:

$$\text{Sharpe} = \frac{E[R_p - R_f]}{\sigma_p} \cdot \sqrt{252} \quad (8)$$

donde R_p es el retorno diario del portafolio, R_f la tasa libre de riesgo, y σ_p la desviación estándar de los retornos. El factor $\sqrt{252}$ anualiza la métrica asumiendo 252 días de *trading*.

Cuadro 14: Sharpe Ratio de los modelos que superan al benchmark

Modelo	Sharpe Ratio
LSTM+Attention	1.327
Ridge	0.881
RandomForest	0.666
CNN-LSTM	0.599
SPY (B&H)	0.663

Como muestra la Tabla 14, el LSTM+Attention alcanza un Sharpe de 1.327, lo que duplica el valor del *benchmark* (0.663) e indica que cada unidad de volatilidad asumida genera el doble de exceso de retorno que una inversión pasiva en el índice. Ridge, con un Sharpe de 0.881, se posiciona como el segundo modelo más eficiente en términos de riesgo ajustado, mientras que RandomForest (0.666) y CNN-LSTM (0.599) se ubican en torno al nivel del *benchmark*, lo que sugiere que su ventaja proviene más de la magnitud absoluta de los retornos que de una eficiencia superior en el uso del riesgo.

6.1.2 Sortino Ratio

El *Sortino Ratio* (Sortino & van der Meer, 1991) mejora sobre el Sharpe al considerar únicamente la volatilidad negativa (*downside risk*), lo que resulta más adecuado para estrategias con

distribuciones de retorno asimétricas:

$$\text{Sortino} = \frac{E[R_p - R_f]}{\sigma_d} \cdot \sqrt{252} \quad (9)$$

donde σ_d es la desviación estándar calculada exclusivamente sobre los retornos que caen por debajo de la tasa libre de riesgo.

Cuadro 15: Sortino Ratio de los modelos que superan al benchmark

Modelo	Sortino Ratio
LSTM+Attention	2.631
RandomForest	1.380
Ridge	1.291
CNN-LSTM	1.161
SPY (B&H)	0.953

La Tabla 15 permite evaluar la relación entre el Sharpe y el Sortino de cada modelo, que revela información importante sobre la asimetría de sus retornos. En el caso del LSTM+Attention, el Sortino (2.631) es prácticamente el doble de su Sharpe (1.327), lo que indica que la volatilidad de este modelo proviene desproporcionadamente del lado positivo de la distribución—es decir, que sus días de ganancia son más dispersos que sus días de pérdida. Este patrón es consistente con una estrategia que permanece en efectivo la mayor parte del tiempo (55.1 %) y genera retornos concentrados en los días donde asume exposición apalancada. RandomForest presenta un fenómeno similar, con un Sortino de 1.380 que supera al de Ridge (1.291) pese a tener un Sharpe inferior, lo que sugiere que RandomForest exhibe un perfil de riesgo a la baja más contenido.

6.1.3 Calmar Ratio

El *Calmar Ratio* relaciona el retorno anualizado con el máximo *drawdown* histórico, capturando la eficiencia de la estrategia en términos del peor escenario observado:

$$\text{Calmar} = \frac{\text{CAGR}}{|\text{Max Drawdown}|} \quad (10)$$

Un Calmar superior a 1.0 indica que el retorno anualizado supera la máxima pérdida experimentada desde un pico, un umbral frecuentemente citado como deseable en contextos de gestión institucional.

Los resultados de la Tabla 16 revelan diferencias sustanciales en la relación retorno-drawdown entre modelos. LSTM+Attention y RandomForest son los únicos que superan el umbral de 1.0, lo que significa que por cada punto porcentual de drawdown máximo sufrido, estos modelos

Cuadro 16: Calmar Ratio de los modelos que superan al benchmark

Modelo	Calmar Ratio
LSTM+Attention	1.788
RandomForest	1.196
Ridge	0.894
CNN-LSTM	0.488
SPY (B&H)	0.576

generan más de un punto de retorno anualizado. El caso de CNN-LSTM es particularmente revelador, dado que pese a superar al *benchmark* en retorno total (+129 %), su Calmar de 0.488 es inferior al del propio SPY B&H (0.576), ya que su *drawdown* máximo (−35.6 %) excede significativamente el del índice (−25.4 %). Este resultado subraya la importancia de evaluar el rendimiento no solo en términos absolutos sino en relación con el riesgo extremo asumido.

6.2 Value at Risk (VaR) y Expected Shortfall

Las métricas de riesgo de cola cuantifican las pérdidas potenciales en escenarios adversos y constituyen un complemento esencial a las métricas de riesgo ajustado, que por su naturaleza promedio pueden subestimar eventos extremos.

El *Value at Risk* (VaR) histórico se calcula mediante percentiles empíricos de la distribución de retornos acumulados sobre ventanas móviles de N días:

$$\text{VaR}_\alpha^{(N)} = -\text{Percentil}_\alpha \left(\prod_{j=0}^{N-1} (1 + R_{t-j}) - 1 \right) \quad (11)$$

Este enfoque, a diferencia de la aproximación paramétrica $\text{VaR}_1 \times \sqrt{N}$ que asume normalidad, captura directamente la no-normalidad y la autocorrelación de los retornos—propiedades especialmente relevantes para estrategias que emplean apalancamiento 3x.

El *Expected Shortfall* o CVaR mide la pérdida promedio condicional en las ventanas que exceden el VaR, capturando con mayor precisión el riesgo de cola:

$$\text{CVaR}_\alpha^{(N)} = -E \left[R_t^{(N)} \mid R_t^{(N)} < -\text{VaR}_\alpha^{(N)} \right] \quad (12)$$

El CVaR es preferido en contextos regulatorios al satisfacer la propiedad de subaditividad que el VaR no cumple, lo que lo convierte en una medida coherente de riesgo (López de Prado, 2018). Se presentan los resultados a dos horizontes complementarios—30 días (mensual) y 90 días (trimestral)—que corresponden a los marcos temporales estándar de reporte en gestión institucional de portafolios.

Los resultados de la Tabla 17 revelan un hallazgo notable, dado que el LSTM+Attention

Cuadro 17: Value at Risk y Expected Shortfall al 95 % por horizonte temporal

Modelo	VaR 95 % (30d)	CVaR 95 % (30d)	VaR 95 % (90d)	CVaR 95 % (90d)
LSTM+Attention	−5.91 %	−10.20 %	−3.33 %	−6.11 %
Ridge	−10.85 %	−19.40 %	−13.36 %	−21.47 %
RandomForest	−3.86 %	−5.61 %	−0.43 %	−2.71 %
CNN-LSTM	−8.93 %	−14.80 %	−15.81 %	−22.60 %
SPY (B&H)	−7.80 %	−10.82 %	−10.77 %	−13.83 %

Nota: VaR y CVaR calculados sobre retornos acumulados en ventanas móviles de 30 y 90 días de operación (1,272 y 1,212 ventanas respectivamente).

presenta un VaR a 30 días (−5.91 %) significativamente inferior al del *benchmark* SPY (−7.80 %), lo que indica que en el 95 % de los meses de operación la estrategia genera pérdidas menores que una inversión pasiva en el índice, pese a producir un retorno total cuatro veces mayor. Esta ventaja se amplifica en el horizonte trimestral, donde el VaR a 90 días del LSTM+Attention (−3.33 %) es menos de un tercio del correspondiente al SPY (−10.77 %), lo que sugiere que la selectividad temporal del modelo—alternar entre efectivo y exposición apalancada según la convicción de la señal—no solo genera retornos superiores sino que además reduce el riesgo de pérdidas sostenidas a horizontes relevantes para la gestión de portafolios.

En contraste, Ridge y CNN-LSTM exhiben riesgo de cola sustancialmente superior al *benchmark* en ambos horizontes. Ridge presenta un CVaR a 90 días de −21.47 %, lo que significa que en el peor 5 % de los trimestres la pérdida promedio supera el 21 %—un nivel que podría resultar inaceptable para mandatos conservadores. CNN-LSTM muestra un patrón aún más severo, con un VaR a 90 días de −15.81 % que supera al del propio SPY, evidenciando que su exposición agresiva durante mercados bajistas prolongados genera un riesgo de cola que no compensa adecuadamente su retorno. RandomForest, por su parte, exhibe el perfil de riesgo de cola más conservador del grupo, con un VaR a 90 días de apenas −0.43 %, consecuencia directa de su alta proporción de días en efectivo y su selectividad extrema.

6.3 Análisis de *Drawdown*

El *drawdown* mide la caída acumulada desde un máximo histórico del portafolio:

$$DD_t = \frac{P_t - \max_{s \leq t}(P_s)}{\max_{s \leq t}(P_s)} \quad (13)$$

donde P_t es el valor del portafolio en el momento t . El tiempo de recuperación se define como el número de días de operación necesarios para alcanzar un nuevo máximo tras el punto más bajo del *drawdown*:

$$T_{\text{recovery}} = \min\{t' > t_{DD} : P_{t'} \geq \max_{s \leq t_{DD}} (P_s)\} \quad (14)$$

Cuadro 18: Análisis de máximo *drawdown* por modelo

Modelo	MaxDD	Pico	Valle	Duración	Recuperación
LSTM+Attention	−20.5 %	2025-02-18	2025-04-07	34 días	1 día
Ridge	−31.8 %	2021-09-14	2022-03-07	120 días	49 días
RandomForest	−14.7 %	2022-04-01	2022-05-19	33 días	23 días
CNN-LSTM	−35.6 %	2022-03-24	2022-07-15	77 días	543 días
SPY (B&H)	−25.4 %	2021-12-31	2022-10-11	195 días	318 días

Nota: Duración = días de operación desde el pico hasta el valle. Recuperación = días desde el valle hasta alcanzar un nuevo máximo.

La Tabla 18 revela diferencias profundas en la dinámica de riesgo de cada modelo. El LSTM+Attention experimenta su máximo *drawdown* (−20.5 %) durante el episodio de volatilidad arancelaria de abril de 2025, un período distinto al mercado bajista de 2022 que afectó a los demás modelos, y se recupera en un único día de operación gracias a que el modelo mantuvo una posición apalancada 3x durante la sesión de rebote posterior al anuncio de pausa arancelaria del 9 de abril de 2025—una de las mayores alzas diarias en la historia del S&P 500. Este resultado, si bien extraordinario en su velocidad, refleja la capacidad del modelo para mantener convicción durante episodios de estrés extremo.

Ridge y CNN-LSTM, en contraste, registran sus *drawdowns* más severos durante el mercado bajista prolongado de 2022 (enero–octubre), con caídas del 31.8 % y 35.6 % respectivamente. La diferencia en tiempos de recuperación es particularmente informativa: Ridge se recupera en 49 días de operación, mientras que CNN-LSTM requiere 543 días—más de dos años de *trading*—lo que sugiere que su posicionamiento agresivo durante la caída de 2022 tuvo consecuencias duraderas sobre la curva de capital. RandomForest exhibe el perfil de *drawdown* más conservador, con una caída máxima de apenas −14.7 % (inferior incluso al *benchmark*) y una recuperación en 23 días, consistente con su alta proporción de días en efectivo y su baja exposición al instrumento apalancado 3x.

El propio SPY B&H requirió 318 días de operación para recuperarse de su *drawdown* máximo del 25.4 % durante 2022, lo que contextualiza la severidad de ese episodio de mercado y pone en perspectiva el desempeño de los modelos que lograron contener sus caídas por debajo de dicho nivel.

6.4 Participación en Movimientos del Mercado

Una pregunta central para evaluar cualquier estrategia activa es en qué medida sus retornos provienen de participar en las subidas del mercado y, de forma complementaria, cuánto de las caídas absorbe. El *Upside/Downside Capture Ratio*, ampliamente utilizado en la evaluación de fondos de inversión, descompone esta relación de manera directa e intuitiva.

El *Upside Capture* mide qué proporción de los retornos del mercado en días alcistas es capturada por la estrategia, mientras que el *Downside Capture* mide la proporción absorbida en días bajistas:

$$\text{Upside Capture} = \frac{\overline{R_p \mid R_m > 0}}{\overline{R_m \mid R_m > 0}} \times 100, \quad \text{Downside Capture} = \frac{\overline{R_p \mid R_m < 0}}{\overline{R_m \mid R_m < 0}} \times 100 \quad (15)$$

donde R_p y R_m son los retornos diarios de la estrategia y del mercado respectivamente. Un inversor pasivo en el SPY exhibe, por definición, un *Upside Capture* y un *Downside Capture* de 100 %, dado que participa plenamente en todos los movimientos del índice. La relación entre ambas métricas se sintetiza en el *Capture Ratio*:

$$\text{Capture Ratio} = \frac{\text{Upside Capture}}{\text{Downside Capture}} \quad (16)$$

Un *Capture Ratio* superior a 1.0 indica que la estrategia captura, en términos proporcionales, más de las subidas del mercado que de sus caídas—una asimetría que constituye la esencia de la gestión activa exitosa. Cuanto mayor sea este ratio, más eficiente es el modelo en participar selectivamente en los movimientos favorables del mercado.

Cuadro 19: *Upside/Downside Capture* de los modelos que superan al benchmark

Modelo	Upside Capture	Downside Capture	Capture Ratio
LSTM+Attention	90.2 %	67.1 %	1.34×
Ridge	99.8 %	84.0 %	1.19×
RandomForest	45.7 %	32.8 %	1.39×
CNN-LSTM	70.4 %	61.4 %	1.15×
SPY (B&H)	100.0 %	100.0 %	1.00×

Nota: Calculado sobre los 1,302 días del período de prueba (710 días alcistas, 589 días bajistas, 3 días neutros). SPY B&H = 100 % por definición.

Como muestra la Tabla 19, el LSTM+Attention exhibe un *Upside Capture* de 90.2 % y un *Downside Capture* de 67.1 %, lo que significa que captura en promedio nueve décimas de cada alza del mercado pero absorbe solo dos tercios de cada caída. Esta brecha de 23.1 puntos porcentuales, aunque puede parecer modesta en términos diarios, se amplifica de manera exponencial a través

del interés compuesto a lo largo de los 1,302 días del período de prueba, dado que capturar sistemáticamente un 90 % de los días alcistas (710 sesiones) mientras se amortigua un tercio del impacto en los días bajistas (589 sesiones) es precisamente el mecanismo que transforma un *Directional Accuracy* inferior al 50 % en un retorno total del +400 %. El modelo logra esta asimetría pese a permanecer en efectivo el 55.1 % del tiempo, lo que indica que la calidad de la selección temporal—cuándo asumir exposición y con qué magnitud—importa sustancialmente más que la cantidad de tiempo invertido en el mercado. Cabe destacar que esta protección parcial frente a las caídas es consistente con las métricas de riesgo de cola presentadas en la Sección 6.2, donde el VaR a 30 días del LSTM+Attention (−5.91 %) resulta inferior al del SPY (−7.80 %) y su VaR a 90 días (−3.33 %) es menos de un tercio del correspondiente al *benchmark* (−10.77 %), dado que el *Downside Capture* de 67.1 % actúa como un amortiguador natural del riesgo de cola al reducir la exposición efectiva durante períodos adversos.

La comparación entre los cuatro modelos revela un espectro de estrategias de participación. Ridge, con el *Upside Capture* más alto (99.8 %), captura prácticamente la totalidad de las alzas pero a costa de absorber el 84.0 % de las caídas, lo que explica su mayor riesgo de cola (CVaR 95 % de −4.37 %, peor día de −17.63 %). En el extremo opuesto, RandomForest exhibe el *Capture Ratio* más alto del grupo (1.39×) gracias a una participación muy selectiva (45.7 % de alzas, 32.8 % de caídas), lo que produce el *drawdown* más contenido (−14.7 %) pero también el retorno más modesto (+131 %). CNN-LSTM presenta la menor asimetría (brecha de apenas 9 puntos, *Capture Ratio* de 1.15×), lo que se traduce en el *drawdown* más profundo (−35.6 %) y el Calmar más bajo (0.488) del grupo.

En síntesis, el análisis del *Capture Ratio* complementa la paradoja del *Directional Accuracy* documentada en la Sección 5, dado que los modelos rentables no se distinguen por predecir correctamente la dirección del mercado con mayor frecuencia, sino por generar una asimetría sistemática entre su participación en alzas y en caídas que, acumulada a lo largo del período de prueba, produce retornos sustancialmente superiores al *benchmark*.

6.5 Control de Riesgo Implícito en la Estrategia

La estrategia *Long-Only* implementada incorpora mecanismos naturales de control de riesgo que emergen del propio diseño del sistema de posicionamiento, sin requerir reglas explícitas de *stop-loss* o límites de exposición predefinidos.

Cuando las predicciones del modelo no superan el umbral q_{1x} determinado por el Meta-KNN, la estrategia asigna el 100 % del capital a efectivo (tasa libre de riesgo), lo que actúa como un mecanismo de protección implícito basado en la confianza del modelo:

$$\text{Position}_t = \begin{cases} 3x & \text{si } \hat{r}_t > P_{100-q_{3x}} \\ 1x & \text{si } P_{100-q_{1x}} < \hat{r}_t \leq P_{100-q_{3x}} \\ 0 & \text{si } \hat{r}_t \leq P_{100-q_{1x}} \end{cases} \quad (17)$$

El LSTM+Attention permanece en efectivo el 55.1 % del tiempo y asigna la máxima exposición apalancada al 12.2 % de los días, mientras que Ridge—pese a generar menor retorno—se mantiene en efectivo el 62.3 % del tiempo. Esta selectividad temporal actúa como un *stop-loss* implícito que protege el capital durante períodos de incertidumbre, dado que si el modelo no detecta una oportunidad de alta convicción la posición por defecto es la preservación de capital. El uso del instrumento apalancado UPRO (3x) se reserva exclusivamente para predicciones en el percentil superior q_{3x} , limitando la exposición a apalancamiento a los momentos donde el modelo exhibe mayor certeza direccional.

7. Validación Estadística

Más allá de la comparación directa de retornos presentada en secciones anteriores, se requiere validación estadística formal para descartar que los resultados observados sean atribuibles al azar muestral. En mercados financieros, donde la señal predictiva es inherentemente débil en relación con el ruido de los retornos diarios, la distinción entre habilidad genuina y suerte se vuelve crítica para cualquier conclusión sobre eficiencia de mercado. A continuación se presentan seis tests estadísticos aplicados a los cuatro modelos ganadores—LSTM+Attention, Ridge, RandomForest y CNN-LSTM—y al *benchmark* SPY *Buy & Hold*, todos computados a partir de los retornos diarios del período de prueba (1,302 días).

7.1 Bootstrap de Sharpe Ratios

El Sharpe Ratio estándar constituye una estimación puntual que no provee información sobre la precisión de la estimación ni permite cuantificar la incertidumbre asociada. Para abordar esta limitación, se emplea *bootstrap* no paramétrico (Efron, 1979), un método de remuestreo que genera $B = 5,000$ muestras con reemplazo de los retornos diarios de cada estrategia, computa el Sharpe Ratio para cada muestra, y construye intervalos de confianza al 95 % a partir de los percentiles 2.5 y 97.5 de la distribución resultante. Adicionalmente, se estima la probabilidad de que el Sharpe sea positivo— $P(\hat{S} > 0)$ —y la probabilidad de que supere al del *benchmark*— $P(\hat{S} > \hat{S}_{\text{SPY}})$ —mediante comparación pareada de las distribuciones *bootstrap*.

Dado que los retornos financieros exhiben autocorrelación de primer orden, el error están-

dar convencional del Sharpe Ratio subestima la incertidumbre verdadera. Se aplica por ello la corrección propuesta por Lo (2002), que ajusta el error estándar incorporando la estructura de dependencia temporal:

$$\text{SE}(\hat{S}) = \sqrt{\frac{1 + \frac{\hat{S}^2}{2} \cdot (1 + \hat{\rho}_1)}{T \cdot (1 - \hat{\rho}_1)}} \quad (18)$$

donde $\hat{\rho}_1$ denota la autocorrelación de primer orden de los retornos y T el número de observaciones.

Cuadro 20: Intervalos de confianza del Sharpe Ratio (*bootstrap* 95 %, $B = 5,000$)

Modelo	Sharpe	IC 95 % Inf	IC 95 % Sup	P(S>0)	P(S>SPY)
LSTM+Attention	1.327	0.369	2.410	99.6 %	82.3 %
Ridge	0.881	-0.099	2.148	95.6 %	62.3 %
RandomForest	0.666	-0.196	1.513	93.4 %	49.6 %
CNN-LSTM	0.599	-0.311	1.505	90.2 %	45.5 %
SPY (B&H)	0.663	-0.248	1.737	91.6 %	-

Nota: $P(S>0)$ = probabilidad de Sharpe positivo. $P(S>SPY)$ = probabilidad de superar el Sharpe del benchmark. Intervalos calculados con 5,000 iteraciones bootstrap, semilla 42.

Los resultados de la Tabla 20 revelan una jerarquía clara en la robustez estadística de los cuatro modelos ganadores. LSTM+Attention es el único modelo cuyo intervalo de confianza se mantiene íntegramente por encima de cero, con un límite inferior de 0.369 que descarta con alta confianza la posibilidad de un Sharpe nulo o negativo. La probabilidad de 99.6 % de Sharpe positivo y de 82.3 % de superar al *benchmark* confiere solidez a la conclusión de que la superioridad de este modelo no obedece al azar muestral. Ridge exhibe un intervalo de confianza que roza el cero por su límite inferior (-0.099), si bien mantiene una probabilidad del 95.6 % de Sharpe positivo y del 62.3 % de superar al SPY, lo que sugiere una ventaja real aunque estadísticamente menos robusta.

En contraste, RandomForest y CNN-LSTM presentan probabilidades cercanas al 50 % de superar al *benchmark* (49.6 % y 45.5 %, respectivamente), lo que indica que, a pesar de sus retornos absolutos positivos, la evidencia estadística de superioridad frente al SPY es débil. Resulta revelador que el propio SPY *Buy & Hold* presente un intervalo de confianza que cruza el cero (-0.248 a 1.737), con solo un 91.6 % de probabilidad de Sharpe positivo, dado que esto contextualiza la dificultad inherente de demostrar significancia estadística en retornos de renta variable sobre períodos de cinco años.

7.2 Test de Diebold-Mariano

El test de [Diebold & Mariano \(1995\)](#) permite evaluar si la diferencia en rendimiento económico entre dos estrategias de inversión es estadísticamente significativa. En su formulación, se define la diferencia de pérdida como $d_t = L(\text{benchmark}_t) - L(\text{estrategia}_t)$, donde la función de pérdida L corresponde al retorno negativo de cada estrategia. El estadístico resultante se construye como:

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \quad (19)$$

donde $\hat{V}(\bar{d})$ es un estimador consistente de la varianza de $\bar{d}$ que incorpora la corrección de [Newey & West \(1987\)](#) con cinco rezagos para ajustar por heterocedasticidad y autocorrelación en las series de retornos. Bajo la hipótesis nula de igual capacidad—es decir, que la estrategia no genera retornos superiores al SPY *Buy & Hold*—el estadístico DM sigue asintóticamente una distribución $N(0, 1)$, y se emplea un contraste de una cola dado que la hipótesis alternativa es unidireccional (la estrategia supera al *benchmark*).

Cuadro 21: Test de Diebold-Mariano (retornos de estrategia vs SPY *Buy & Hold*)

Modelo	Estadístico DM	p-valor (1 cola)	Significativo (5 %)
LSTM+Attention	2.300	0.0107	Sí
Ridge	1.319	0.0937	No (sí al 10 %)
RandomForest	0.387	0.3494	No
CNN-LSTM	0.376	0.3535	No

Nota: $DM > 0$ indica que la estrategia genera retornos superiores al benchmark. Corrección Newey-West con 5 rezagos. Hipótesis alternativa unidireccional (estrategia $>$ benchmark).

La Tabla 21 confirma que LSTM+Attention es el único modelo que alcanza significancia estadística al nivel convencional del 5 % ($DM = 2.300$, $p = 0.011$), lo que permite rechazar la hipótesis nula de que sus retornos diarios sean indistinguibles de los del *benchmark*. Este resultado es particularmente notable porque el test de Diebold-Mariano opera sobre los 1,302 retornos diarios individuales, no sobre la cifra agregada de retorno total, lo que descarta que la superioridad observada se concentre en unos pocos días atípicos. Ridge se sitúa en la zona marginal ($p = 0.094$), alcanzando significancia al 10 % pero no al 5 %, mientras que RandomForest y CNN-LSTM no presentan evidencia estadística de superioridad frente al SPY ($p > 0.34$ en ambos casos), a pesar de que sus retornos totales superan al *benchmark* en términos absolutos.

La asimetría entre significancia económica y estadística observada en RandomForest y CNN-LSTM constituye un fenómeno habitual en la literatura de predicción de retornos, donde la elevada volatilidad diaria de la renta variable dificulta la detección de diferencias genuinas incluso

cuando estas persisten durante cinco años de operación.

7.3 Test de Clark-West

Mientras el test de Diebold-Mariano evalúa la superioridad en retornos de la estrategia, el test de [Clark & West \(2007\)](#) se diseñó específicamente para evaluar la capacidad predictiva de modelos anidados (*nested models*). En este contexto, se compara cada modelo contra el predictor ingenuo de media histórica—que predice el retorno promedio observado en el período de entrenamiento (0.025 % diario)—mediante la siguiente corrección del error cuadrático:

$$CW_t = (e_{1,t}^2 - e_{2,t}^2) + (\hat{y}_{1,t} - \hat{y}_{2,t})^2 \quad (20)$$

donde $e_{1,t}$ y $e_{2,t}$ son los errores de predicción del modelo restringido (media histórica) y del modelo extendido (ML), respectivamente. El término de ajuste $(\hat{y}_{1,t} - \hat{y}_{2,t})^2$ corrige el sesgo que surge cuando el modelo restringido es verdadero, dado que en ese caso el modelo extendido introduce ruido de estimación que infla artificialmente su error cuadrático. El estadístico resultante sigue una distribución $N(0, 1)$ bajo H_0 , y se emplea un contraste de una cola dado que la hipótesis alternativa es que el modelo ML posee capacidad predictiva superior.

Cuadro 22: Test de Clark-West (predicciones vs media histórica del entrenamiento)

Modelo	CW Stat	p-valor (1 cola)	Conclusión
LSTM+Attention	1.901	0.029	Rechaza H_0 (5 %)
Ridge	1.215	0.112	No rechaza
CNN-LSTM	0.641	0.261	No rechaza
RandomForest	-0.336	0.631	No rechaza

Nota: H_0 : el modelo no posee capacidad predictiva superior a la media histórica. Test de una cola. Corrección Newey-West con 5 rezagos.

Los resultados de la Tabla 22 refuerzan el patrón identificado en el test de Diebold-Mariano, dado que LSTM+Attention es nuevamente el único modelo que alcanza significancia estadística ($CW = 1.901$, $p = 0.029$). Este hallazgo es sustantivamente distinto del anterior, puesto que el test de Clark-West evalúa la capacidad predictiva en términos de error cuadrático medio—no de retornos de estrategia—y aun así identifica a LSTM+Attention como el único modelo cuyas predicciones superan significativamente al predictor de media histórica. La convergencia de ambos tests sobre el mismo modelo confiere robustez a la conclusión de que LSTM+Attention posee habilidad predictiva genuina, no meramente rentabilidad estratégica derivada de la suerte en el *timing* de posiciones.

El valor negativo de RandomForest ($CW = -0.336$) indica que, en términos de error cuadrático de predicción, este modelo no mejora respecto a simplemente predecir la media histórica.

No obstante, su retorno total positivo (131 %) demuestra que la rentabilidad de una estrategia no requiere predicciones puntuales precisas, sino únicamente señales direccionales que permitan asignar posiciones de forma asimétrica—un resultado consistente con la literatura de *directional forecasting* (Pesaran & Timmermann, 2002).

7.4 Model Confidence Set

El *Model Confidence Set* (MCS) de Hansen et al. (2011) constituye un procedimiento iterativo que identifica el subconjunto de modelos que contiene al mejor modelo verdadero con una probabilidad dada. El algoritmo parte del conjunto completo de modelos $\mathcal{M}_0$, contrasta la hipótesis de igual capacidad predictiva (EPA) mediante el estadístico $T_{\max}$ con *bootstrap* de bloques estacionarios ($B = 3,000$), y elimina secuencialmente el peor modelo cuando EPA se rechaza, hasta que la hipótesis de igualdad no pueda rechazarse al nivel $\alpha = 0.10$.

En este estudio, se aplica el MCS utilizando los retornos negativos de cada estrategia como función de pérdida—de modo que un retorno más alto corresponde a una pérdida menor—sobre los 23 modelos y el *benchmark* SPY *Buy & Hold* (24 estrategias en total). El resultado es que el procedimiento no logra eliminar ningún modelo del conjunto:

$$\hat{\mathcal{M}}_{0.10}^* = \mathcal{M}_0 \quad (24 \text{ modelos, } 0 \text{ eliminados}) \quad (21)$$

Este resultado, aparentemente contraintuitivo dado que LSTM+Attention genera un retorno cuatro veces superior al del SPY, se explica por la elevada varianza de los retornos diarios de renta variable. La desviación estándar diaria del S&P 500 es aproximadamente 1.1 %, mientras que la diferencia media diaria entre la mejor y la peor estrategia es del orden de 0.05 %, de modo que la relación señal-ruido resulta insuficiente para que el procedimiento MCS discrimine entre estrategias con 1,302 observaciones. Este fenómeno es consistente con la literatura empírica de comparación de estrategias de inversión, donde Hansen et al. (2011) documentan que se requieren frecuentemente más de 5,000 observaciones para que el MCS posea potencia estadística suficiente en activos de alta volatilidad.

La implicación para la tesis de eficiencia de mercado es relevante, dado que el MCS formaliza cuantitativamente una dificultad fundamental de la investigación en finanzas empíricas—la diferencia entre un modelo que genuinamente predice retornos y uno que simplemente captura ruido muestral es tan pequeña, en términos diarios, que resulta estadísticamente indistinguible incluso con cinco años de datos.

7.5 Análisis de *Overfitting*

7.5.1 Degradación de métricas de predicción

Una señal clásica de sobreajuste (*overfitting*) es la degradación significativa de las métricas de predicción entre el período de entrenamiento y el de prueba. Para cuantificar este fenómeno, se comparan la precisión direccional (*directional accuracy*, DA) y la razón de error cuadrático medio (MSE) entre ambos períodos para los cuatro modelos ganadores y XGBoost como ejemplo de sobreajuste severo.

Cuadro 23: Degradación de métricas predictivas entre entrenamiento y prueba

Modelo	DA Train	DA Test	Degradación DA	MSE Test/Train
LSTM+Attention	0.492	0.470	−4.6 %	0.68×
CNN-LSTM	0.501	0.455	−9.3 %	0.87×
Ridge	0.575	0.468	−18.6 %	2.55×
RandomForest	0.580	0.459	−20.9 %	1.86×
XGBoost	0.552	0.543	−1.6 %	0.89×

Nota: DA = *directional accuracy* (proporción de predicciones con signo correcto). MSE Test/Train > 1 indica que el error cuadrático medio aumenta en el período fuera de muestra. XGBoost se incluye como ejemplo de modelo degenerado (Sharpe test = −0.024).

La Tabla 23 revela un patrón que desafía la intuición convencional sobre sobreajuste. LSTM+Attention exhibe la menor degradación en precisión direccional (−4.6 %) y, notablemente, su error cuadrático medio *disminuye* en el período de prueba (0.68× el valor de entrenamiento), lo que sugiere que el mecanismo de atención no memoriza patrones específicos del entrenamiento sino que captura relaciones que se manifiestan con mayor claridad en datos no observados. CNN-LSTM muestra un patrón similar, con degradación moderada (−9.3 %) y ratio de MSE inferior a uno.

Ridge y RandomForest presentan mayor degradación en precisión direccional (−18.6 % y −20.9 %, respectivamente) y ratios de MSE superiores a uno (2.55× y 1.86×), lo que indica un grado de sobreajuste más pronunciado. No obstante, ambos mantienen Sharpe Ratios positivos en el período de prueba, lo que sugiere que el sobreajuste degrada el rendimiento sin anularlo completamente.

El caso de XGBoost resulta instructivo como contraejemplo, dado que presenta la menor degradación en DA (−1.6 %) pero un Sharpe de −0.024 en el período de prueba. Esta aparente paradoja se resuelve al considerar que XGBoost produce predicciones prácticamente constantes (solo 26 valores únicos entre 1,302 días de prueba), de modo que la baja degradación refleja no generalización exitosa sino la ausencia de señal significativa en ambos períodos.

7.5.2 Corrección por comparaciones múltiples

Con 23 modelos evaluados simultáneamente, el riesgo de identificar falsos positivos por comparaciones múltiples es sustancial. Se aplican dos procedimientos de corrección sobre los p-valores del test de Diebold-Mariano.

La corrección de Bonferroni establece un umbral ajustado de $\alpha_{\text{Bonf}} = 0.05/23 \approx 0.0022$. Bajo este criterio conservador, ningún modelo alcanza significancia estadística, dado que el p-valor más bajo corresponde a LSTM+Attention ($p = 0.011$), que excede el umbral ajustado. Este resultado no invalida la evidencia de superioridad de LSTM+Attention, sino que refleja el carácter extremadamente conservador de la corrección de Bonferroni, que controla la probabilidad de *cualquier* falso positivo entre las 23 comparaciones.

Alternativamente, el procedimiento de [Benjamini & Hochberg \(1995\)](#) controla la proporción esperada de falsos positivos entre los rechazos (*False Discovery Rate*, FDR) al nivel $q = 0.10$. Este procedimiento, menos conservador que Bonferroni, ordena los p-valores y rechaza H_0 para los k menores valores que satisfacen $p_{(k)} \leq \frac{k}{m} \cdot q$. Aplicado a los 23 p-valores del test de Diebold-Mariano, el procedimiento BH tampoco identifica modelos significativos al nivel $q = 0.10$, lo que confirma que, bajo cualquier corrección estándar por comparaciones múltiples, la evidencia de superioridad estadística de las estrategias individuales no alcanza los umbrales convencionales.

7.6 Síntesis de la validación estadística

Cuadro 24: Resumen de tests estadísticos por modelo

Modelo	P(S>0)	P(S>SPY)	DM (5 %)	CW (5 %)	Bonferroni
LSTM+Attention	99.6 %	82.3 %	✓	✓	×
Ridge	95.6 %	62.3 %	×	×	×
RandomForest	93.4 %	49.6 %	×	×	×
CNN-LSTM	90.2 %	45.5 %	×	×	×

✓ = significativo al nivel indicado. × = no significativo. El MCS no se incluye porque no logró eliminar ningún modelo del conjunto completo.

La Tabla 24 sintetiza los resultados de todos los tests. La validación estadística proporciona evidencia que, en su conjunto, es consistente con la hipótesis de eficiencia débil de los mercados, matizada por la excepción notable de LSTM+Attention. Este modelo es el único que alcanza significancia estadística en los tests de Diebold-Mariano ($p = 0.011$) y Clark-West ($p = 0.029$) al nivel convencional del 5 %, mantiene un intervalo de confianza *bootstrap* íntegramente positivo, y presenta la menor degradación de métricas predictivas entre entrenamiento y prueba. La convergencia de múltiples tests independientes sobre el mismo modelo—que opera sobre dimensiones distintas del rendimiento (retornos de estrategia, error de predicción, robustez

bootstrap)—confiere credibilidad a la conclusión de que su superioridad no es atribuible al azar.

No obstante, tres resultados atemperan esta conclusión y merecen consideración. Primero, bajo la corrección de Bonferroni por comparaciones múltiples ($\alpha_{\text{adj}} = 0.0022$), incluso LSTM+Attention pierde significancia ($p = 0.011 > 0.0022$), lo que refleja el costo estadístico de evaluar 23 modelos simultáneamente. Segundo, el *Model Confidence Set* no logra distinguir entre ninguna de las 24 estrategias evaluadas, dado que la varianza diaria de los retornos de renta variable genera una relación señal-ruido insuficiente para que el procedimiento iterativo discrimine con 1,302 observaciones. Tercero, Ridge, RandomForest y CNN-LSTM, a pesar de generar retornos totales superiores al *benchmark*, no alcanzan significancia estadística en ninguno de los tests individuales al nivel del 5 %.

Estos hallazgos matizan la conclusión de Gu et al. (2020), quienes encontraron superioridad general de los métodos no lineales complejos sobre los modelos lineales en predicción de retornos. En el contexto específico de este estudio, solo el mecanismo de atención de LSTM+Attention produce una ventaja estadísticamente detectable, lo que sugiere que la complejidad arquitectónica por sí sola no garantiza capacidad predictiva superior. La regularización L_2 de Ridge genera retornos económicamente significativos pero estadísticamente marginales, mientras que los *ensembles* de árboles (RandomForest) y las arquitecturas híbridas (CNN-LSTM) no superan los umbrales convencionales de significancia. Este patrón es consistente con la advertencia de López de Prado (2018) sobre los riesgos inherentes a la evaluación simultánea de múltiples estrategias, donde la corrección por comparaciones múltiples puede erosionar la significancia de rendimientos genuinos.

8. Análisis de Costos de Transacción

8.1 Costos de Transacción en Estrategias Activas

Una crítica recurrente a las estrategias de *trading* activo es que los costos de transacción erosionan—y con frecuencia eliminan—la rentabilidad que muestran en simulaciones históricas. Estudios clásicos como los de Barber & Odean (2000) documentan que los inversores individuales que operan con mayor frecuencia obtienen retornos netos significativamente inferiores, y trabajos más recientes en el ámbito de *machine learning* aplicado a finanzas confirman que modelos con alta capacidad predictiva en entornos sin fricciones pueden volverse no rentables una vez que se incorporan costos realistas de ejecución. Esta evidencia motiva un análisis detallado del impacto de los costos sobre los resultados presentados en las secciones anteriores.

En el caso de este estudio, el modelo de costos incorpora tres componentes—*bid-ask spread*, *expense ratio* y *volatility drag*—calibrados con parámetros que, como se demostrará más adelante,

sobreestiman sistemáticamente las condiciones reales de mercado. A pesar de esta penalización conservadora, cuatro de los 23 modelos evaluados generan retornos netos superiores al *benchmark* SPY *Buy & Hold* (+102%), con LSTM+Attention alcanzando un retorno neto del +400% tras absorber \$12,999 en costos sobre un capital inicial de \$10,000. El costo promedio de los 23 modelos asciende a \$3,545, equivalente al 35.5% del capital inicial, lo que confirma que la incorporación de costos no es trivial y que los modelos que sobreviven a esta carga lo hacen gracias a la calidad de sus señales de entrada y no a una subestimación de fricciones.

Las subsecciones siguientes detallan la estructura del modelo de costos, su validación contra datos de mercado, y una serie de análisis de sensibilidad diseñados para evaluar la robustez de los resultados bajo supuestos de costos más adversos.

8.2 Estructura del Modelo de Costos

El retorno neto diario de cada modelo se calcula a partir de tres componentes de costo que se descuentan del retorno bruto de la posición. El retorno bruto depende de la posición asignada por el sistema de señales y se define como $r_{\text{bruto}} = r_f + p \cdot (r_{\text{mkt}} - r_f)$, donde $p \in \{0, 1, 3\}$ representa la posición (CASH, SPY o UPRO, respectivamente), r_f la tasa libre de riesgo diaria y r_{mkt} el retorno del mercado. El retorno neto se obtiene descontando los tres costos aplicables:

$$r_{\text{neto}} = r_{\text{bruto}} - c_{\text{expense}} - c_{\text{trading}} - c_{\text{drag}} \quad (22)$$

8.2.1 Expense Ratio

Cada ETF cobra un costo operativo anual que se prorratea diariamente. Para UPRO, el *expense ratio* es de 0.91% anual, lo que equivale a $0.91/252 \approx 0.36$ puntos base por día de tenencia. Para SPY, el *expense ratio* es de 0.09% anual (≈ 0.04 bps/día), y para la posición en efectivo no aplica ningún costo. Este componente se acumula de forma lineal con el tiempo de permanencia en cada instrumento.

8.2.2 Bid-Ask Spread

El costo de ejecución por cruzar el *spread* se aplica únicamente cuando se produce un cambio de posición. Al pasar de un instrumento a otro, el modelo cobra el *spread* de salida del instrumento anterior más el *spread* de entrada del nuevo instrumento. La Tabla 25 resume los parámetros por instrumento.

Cuadro 25: Parámetros de Costo por Instrumento

Instrumento	Bid-Ask	Expense Ratio	Round-Trip
UPRO (3x Long)	5 bps	0.91 %/año	10 bps
SPY (1x Long)	2 bps	0.09 %/año	4 bps
Cash	0 bps	0 %	0 bps

Nota: Round-trip = bid-ask de entrada + bid-ask de salida. Expense ratio aplicado diariamente como ratio anual / 252.

8.2.3 Volatility Drag

Los ETFs apalancados que replican un múltiplo diario del índice subyacente están sujetos a una erosión sistemática del valor conocida como *volatility drag* o *beta slippage*. Este fenómeno surge del hecho matemático de que la composición diaria de retornos apalancados no es equivalente al apalancamiento del retorno acumulado, y la divergencia crece con la volatilidad del subyacente. Para un factor de apalancamiento L y una volatilidad diaria σ , la aproximación de primer orden del *drag* diario es

$$c_{\text{drag}} \approx \frac{1}{2}(L^2 - L)\sigma^2 \quad (23)$$

Para UPRO con $L = 3$ y una volatilidad diaria fija de $\sigma = 1\%$, el *drag* diario resulta $\frac{1}{2}(9 - 3)(0.01)^2 = 0.03\%$ por día, lo que equivale a aproximadamente 7.5% anual. Este costo se aplica exclusivamente a los días en que el modelo mantiene posición en UPRO ($p = 3$) y constituye el componente de costo más significativo para los modelos que utilizan la posición apalancada con mayor frecuencia.

Es importante señalar que el *volatility drag* modelado de esta manera representa una penalización conservadora para las estrategias, dado que el UPRO *Buy & Hold* utilizado como *benchmark* en la Sección 4 no incorpora este costo adicional—su *expense ratio* de 0.91% ya cubre internamente los gastos de mantenimiento de la exposición apalancada. Esta asimetría deliberada favorece al *benchmark* y dificulta que las estrategias lo superen, lo que refuerza la significancia de los modelos que logran hacerlo.

8.3 Desglose de Costos por Modelo

La Tabla 26 presenta el desglose completo de costos para los 23 modelos, ordenados por capital final descendente. La columna Tx/P&L indica la proporción de los costos totales respecto al *P&L* bruto generado por cada modelo, lo que permite evaluar la eficiencia con la que cada estrategia convierte rendimiento bruto en rendimiento neto.

Los cuatro modelos que superan al *benchmark* exhiben ratios Tx/P&L que oscilan entre

Cuadro 26: Impacto de Costos de Transacción por Modelo

Modelo	Capital Final	P&L Bruto	Tx Costs	Tx/P&L	Trades
LSTM+Attention	\$49,998	\$52,996	\$12,999	24.5 %	465
Ridge	\$36,317	\$36,983	\$10,666	28.8 %	409
RandomForest	\$23,103	\$15,148	\$2,045	13.5 %	175
CNN-LSTM	\$22,899	\$20,022	\$7,123	35.6 %	633
DLinear	\$16,795	\$11,584	\$4,790	41.3 %	788
GradientBoosting	\$16,683	\$7,061	\$378	5.4 %	11
CatBoost	\$14,743	\$6,169	\$1,426	23.1 %	224
Theta	\$14,462	\$4,954	\$491	9.9 %	36
SeasonalNaive	\$14,446	\$12,816	\$8,370	65.3 %	1042
NBEATS	\$14,444	\$8,824	\$4,381	49.6 %	507
Lasso	\$13,898	\$4,379	\$480	11.0 %	90
GARCH	\$12,725	\$3,337	\$613	18.4 %	126
LightGBM	\$12,712	\$3,588	\$876	24.4 %	134
NHiTS	\$12,212	\$6,043	\$3,831	63.4 %	805
AutoARIMA	\$11,827	\$1,827	\$0	0.0 %	0
TCN	\$11,809	\$3,876	\$2,066	53.3 %	383
TFT	\$11,477	\$7,571	\$6,094	80.5 %	804
XGBoost	\$11,350	\$3,167	\$1,817	57.4 %	42
ElasticNet	\$10,976	\$1,894	\$918	48.5 %	175
Prophet	\$10,765	\$1,221	\$456	37.4 %	77
BiLSTM	\$10,620	\$3,625	\$3,004	82.9 %	546
ExponentialSmoothing	\$8,549	\$4,473	\$5,924	132.4 %	904
BiGRU	\$6,771	\$-436	\$2,793	–	752
<i>Promedio</i>	–	–	\$3,545	–	397

Nota: Capital inicial = \$10,000. Tx Costs incluye bid-ask spreads (UPRO: 10 bps, SPY: 4 bps), expense ratios y volatility drag. Tx/P&L = proporción de costos respecto a ganancias brutas.

13.5 % (RandomForest) y 35.6 % (CNN-LSTM), lo que indica que entre dos tercios y siete octavos de su rendimiento bruto sobrevive a los costos de transacción. En el extremo opuesto, modelos como ExponentialSmoothing presentan un ratio Tx/P&L de 132.4 %, lo que significa que los costos superan al $P\&L$ bruto y destruyen valor neto—este modelo acumula \$5,924 en costos sobre 904 *trades* contra un $P\&L$ bruto de apenas \$4,473, resultando en una pérdida neta del −14.5 %. GradientBoosting representa el caso contrario en términos de eficiencia, ya que con solo 11 operaciones y \$378 en costos logra un retorno del +67 %, aunque su baja actividad se debe al filtro de calidad de señal que lo mantiene en efectivo el 92 % del tiempo.

El modelo promedio incurre \$3,545 en costos de transacción, equivalente al 35.5 % del capital inicial de \$10,000. Esta cifra no es despreciable y subraya la importancia de modelar costos en cualquier evaluación de estrategias activas. Sin embargo, la dispersión entre modelos es amplia—desde \$0 (AutoARIMA, que permanece 100 % en efectivo) hasta \$12,999 (LSTM+Attention)—lo que refleja la diversidad de perfiles de *trading* entre las 23 especificaciones evaluadas.

8.4 Validación Empírica de los Parámetros de Costo

Para verificar que los parámetros del modelo de costos reflejan condiciones de mercado reales, se contrastan los valores empleados con los datos reportados por los emisores de los ETFs correspondientes^{72,73}. La Tabla 27 presenta esta comparación.

Cuadro 27: Validación de Parámetros de Costo: Estudio vs. Mercado Real

Parámetro	Este estudio	Mercado real	Fuente	Ratio
Expense ratio UPRO	0.91 %/año	0.89 %/año	ProShares ^a	1.02×
Expense ratio SPY	0.09 %/año	0.0945 %/año	State Street ^b	0.95×
Bid-ask UPRO	5 bps	2 bps	ProShares ^a (mediana 30d)	2.50×
Bid-ask SPY	2 bps	≈0 bps	State Street ^b (mediana 30d)	>2.5×
σ diaria (vol drag)	1.00 % fijo	0.95–1.26 %	S&P 500 histórico	~1.0×

Nota: ^aProShares reporta un *expense ratio* de 0.89 % bajo un *fee waiver* contractual vigente hasta septiembre 2026. ^bState Street reporta un *gross expense ratio* de 0.0945 % y una mediana de *bid-ask spread* de 0.00 % a 30 días. Datos consultados en marzo 2026 desde las páginas oficiales de los emisores.

Los *expense ratios* empleados resultan prácticamente idénticos a los valores de mercado, con diferencias inferiores a 2 puntos base que no alteran materialmente los resultados. En el caso de UPRO, ProShares reporta un *expense ratio* de 0.89 % bajo un *fee waiver* contractual vigente hasta septiembre de 2026, de modo que el valor de 0.91 % utilizado en este estudio constituye una estimación ligeramente superior al vigente que no depende de exenciones temporales.

⁷²ProShares UPRO: <https://www.proshares.com/our-etfs/leveraged-and-inverse/upro>. Consultado en marzo 2026.

⁷³State Street SPY: <https://www.ssga.com/us/en/intermediary/etfs/spdr-sp-500-etf-trust-spy>. Consultado en marzo 2026.

La comparación resulta particularmente relevante en el caso de los *bid-ask spreads*, donde se evidencia que los valores empleados sobreestiman los costos reales de manera sustancial. La mediana de *spread* a 30 días reportada por ProShares para UPRO es de 2 puntos base, mientras que State Street reporta una mediana de 0 puntos base para SPY—reflejo de la liquidez excepcional del ETF más negociado del mundo. Este estudio utiliza 5 y 2 puntos base respectivamente, aproximadamente 2.5 veces superiores a los valores observados en mercado. Esta sobreestimación implica que los retornos netos reportados incorporan una penalización por costos de ejecución significativamente mayor a la que enfrentaría un operador real, lo que refuerza la robustez de los hallazgos.

En cuanto al *volatility drag*, el modelo emplea una volatilidad diaria fija de 1 %, consistente con la volatilidad anualizada histórica del S&P 500 de aproximadamente 15–20 % ($\sigma_{\text{diaria}} \approx 0.95\text{--}1.26\%$). Si bien una implementación con volatilidad dinámica capturaría con mayor precisión las fluctuaciones intra-período, la aproximación fija representa un valor medio razonable dentro del rango histórico observado.

En conjunto, los parámetros de costo empleados sobreestiman sistemáticamente los costos reales de implementación. Las estrategias que resultan rentables bajo estos supuestos lo serían aún más bajo condiciones de mercado actuales, lo que elimina la posibilidad de que la rentabilidad observada dependa de supuestos optimistas sobre fricciones de ejecución.

8.5 Relación Rentabilidad-Turnover

Un argumento habitual contra las estrategias activas sostiene que una mayor frecuencia de operación se traduce mecánicamente en mayores costos y, por tanto, en menores retornos netos. La Figura 5 evalúa empíricamente esta hipótesis y la evidencia no la respalda en este caso, ya que el coeficiente de determinación entre *turnover* y retorno neto es prácticamente nulo ($R^2 = 0.02$).

LSTM+Attention combina un *turnover* moderado de 465 *trades* con el mayor retorno del estudio (+400 %), mientras que GradientBoosting obtiene +67 % con apenas 11 operaciones. En el otro extremo, SeasonalNaive ejecuta 1,042 *trades* para obtener un modesto +45 %, y ExponentialSmoothing acumula 904 operaciones con un resultado negativo (−14.5 %). Esta dispersión confirma que la calidad de las señales de entrada es considerablemente más determinante que la frecuencia de *trading* en sí misma, dado que un modelo que opera con menor frecuencia pero con precisión condicional elevada puede superar consistentemente a modelos que operan más a menudo con menor capacidad de discriminación.




Figura 5: Relación entre *turnover* (número de *trades*) y retorno neto. Cada punto representa un modelo. Línea punteada: regresión lineal ($R^2 = 0.02$).

8.6 Análisis de Sensibilidad

Para evaluar la robustez de los resultados frente a posibles subestimaciones en el modelo de costos, se recalculan los retornos netos bajo dos escenarios adversos—costos incrementados en un 50 % y en un 100 % respecto al escenario base—y se estima el multiplicador de *break-even*, definido como el factor por el cual deberían multiplicarse los costos totales para que la estrategia pierda dinero. La Tabla 28 resume estos resultados para los cuatro modelos ganadores.

Cuadro 28: Sensibilidad del Retorno a Costos de Transacción

Modelo	Ret. Base	+50 % Costos	+100 % Costos	Break-even	Tx/P&L
LSTM+Attention	+400 %	+335 %	+270 %	4.1×	24.5 %
Ridge	+263 %	+210 %	+157 %	3.5×	28.8 %
RandomForest	+131 %	+121 %	+111 %	7.4×	13.5 %
CNN-LSTM	+129 %	+93 %	+58 %	2.8×	35.6 %

Nota: Aproximación lineal donde el retorno ajustado $\approx (P\&L \text{ bruto} - \text{costos} \times \text{multiplicador}) / \text{capital inicial}$. Break-even = $P\&L \text{ bruto} / \text{costos totales}$, es decir, el multiplicador máximo de costos antes de que la estrategia genere pérdidas. Tx/P&L = costos totales como porcentaje del P&L bruto.

Los cuatro modelos líderes mantienen rentabilidad positiva incluso bajo el escenario de costos duplicados. Con costos al doble del escenario base, LSTM+Attention aún genera un retorno del +270 %—más del doble del *benchmark* SPY (+102 %)—y Ridge mantiene +157 %. El punto de *break-even* de LSTM+Attention se sitúa en $4.1 \times$ los costos actuales, lo que significa que los costos

deberían más que cuadruplicarse antes de que la estrategia deje de ser rentable, proporcionando un colchón sustancial frente a cualquier subestimación en el modelo.

RandomForest exhibe la mayor robustez a costos con un *break-even* de $7.4\times$, resultado directo de su baja proporción Tx/P&L (13.5 %) derivada de un posicionamiento conservador que lo mantiene en efectivo el 78 % del tiempo y concentra la exposición en días de alta convicción. CNN-LSTM, en cambio, resulta más sensible a incrementos de costos dado que con costos duplicados su retorno cae a +58 %, reflejo de su proporción Tx/P&L del 35.6 %—la más alta entre los ganadores. No obstante, incluso en este escenario extremo, CNN-LSTM genera un retorno positivo que supera a la mitad de los modelos en escenario base.

Cabe reiterar que, como se documentó en la Sección 8.4, los parámetros del escenario base ya sobreestiman las condiciones reales de mercado de manera diferenciada según el componente. Los *expense ratios* son prácticamente idénticos a los vigentes (ratio $\approx 1.0\times$), mientras que los *bid-ask spreads*—el componente que se activa en cada cambio de posición—se fijaron en 5 bps para UPRO y 2 bps para SPY, aproximadamente $2.5\times$ superiores a las medianas de mercado reportadas por los emisores (2 bps y ≈ 0 bps, respectivamente). En consecuencia, al duplicar todos los costos en el escenario “+100 %”, los *bid-ask spreads* efectivos alcanzan 10 bps para UPRO—cinco veces el valor observado en mercado—mientras que los *expense ratios* y el *volatility drag* se sitúan en aproximadamente el doble de sus valores reales. Para los modelos con alta frecuencia de operación, donde los *spreads* constituyen la fracción dominante de los costos totales, el escenario “+100 %” representa una penalización cercana a $5\times$ los costos reales de ejecución; para modelos con menor *turnover*, la penalización efectiva es menor pero aún sustancialmente conservadora.

8.7 Costos No Considerados

El modelo de costos implementado captura las fricciones más relevantes para una estrategia *Long-Only* basada en ETFs, pero existen costos adicionales que una implementación real debería contemplar y que no se incluyen en esta simulación.

El *slippage*—la diferencia entre el precio esperado al momento de generar la señal y el precio efectivamente ejecutado—puede incrementar los costos de ejecución, particularmente para órdenes de tamaño institucional. Sin embargo, dado que SPY y UPRO se encuentran entre los ETFs con mayor volumen de negociación en el mundo, con volúmenes diarios promedio de \$35 mil millones y \$800 millones respectivamente, el *market impact*⁷⁴ resulta insignificante para capitales inferiores a varias decenas de millones de dólares.

⁷⁴El *market impact* se refiere al efecto que la propia orden de compra o venta tiene sobre el precio del instrumento. Para instrumentos con alta liquidez como SPY, este efecto es prácticamente imperceptible para órdenes menores a una fracción del volumen diario promedio.

Los impuestos sobre ganancias de capital representan otro costo no modelado cuya magnitud depende de la jurisdicción fiscal del inversor y de la estructura legal utilizada para operar. En Estados Unidos, las ganancias a corto plazo (posiciones mantenidas menos de un año) tributan como ingreso ordinario, lo que puede reducir significativamente el retorno neto después de impuestos. No obstante, este costo afecta de manera simétrica a todas las estrategias activas y al UPRO *Buy & Hold*, por lo que las comparaciones relativas entre modelos y *benchmarks* se mantienen válidas.

Finalmente, los costos de infraestructura—servidores, datos de mercado, desarrollo y mantenimiento del sistema de señales—constituyen costos fijos que no escalan con el tamaño de las posiciones y que resultan amortizables a medida que crece el capital bajo gestión. Estos costos, si bien relevantes para una implementación operativa, no alteran la evaluación comparativa de los modelos presentada en este estudio.

9. Aportes al Debate sobre la Eficiencia de Mercado

9.1 Síntesis de los Hallazgos Empíricos

Los resultados empíricos presentados en las secciones anteriores—retornos ajustados por costos (Sección 4), análisis de riesgo (Sección 6), validación estadística (Sección 7) y costos de transacción (Sección 8)—revelan que cuatro de los 23 modelos evaluados superan de manera consistente al *benchmark* pasivo durante cinco años fuera de muestra, con retornos que incorporan todos los costos transaccionales relevantes. La estrategia opera bajo una restricción estrictamente *Long-Only*—sin posiciones cortas—y el modelo líder permanece en efectivo más de la mitad del período, lo cual sugiere que la capacidad de evitar períodos desfavorables contribuye tanto o más al rendimiento que la selección de períodos alcistas.

Un aspecto metodológicamente crítico es que los umbrales de posicionamiento ($q_{\text{ext}}, q_{\text{mod}}$) fueron determinados mediante Meta-KNN entrenado exclusivamente con datos del período de entrenamiento, sin utilizar información futura del período de prueba. Todos los modelos se alimentan únicamente de datos históricos públicos obtenidos del *Bloomberg Terminal*, y la validación estadística, que incluye *bootstrap* de retornos, pruebas de Diebold & Mariano (1995) y el *Model Confidence Set* de Hansen et al. (2011), confirma que las diferencias de rendimiento observadas no son atribuibles al azar. Estas precauciones metodológicas, junto con la separación temporal estricta entre entrenamiento y evaluación, otorgan mayor credibilidad a los hallazgos reportados.

Lo interesante es que los cuatro modelos ganadores provienen de familias algorítmicas fundamentalmente distintas—un modelo lineal regularizado (Ridge), un *ensemble* de árboles de de-

cisión (RandomForest) y dos arquitecturas de *deep learning* (LSTM+Attention y CNN-LSTM). Esta diversidad estructural reduce sustancialmente la probabilidad de que los resultados sean producto de *overfitting* a un patrón específico de los datos, ya que cada familia captura las señales predictivas a través de mecanismos de aproximación radicalmente diferentes. Dicho de otro modo, si un único tipo de modelo hubiera dominado, cabría sospechar la explotación de un artefacto estadístico particular; la convergencia de enfoques heterogéneos hacia resultados superiores al mercado sugiere, en cambio, la presencia de estructura predictiva genuina en las 536 características derivadas de las 92 variables de Bloomberg.

9.2 La Evidencia contra la Forma Semi-fuerte de la HEM

La definición clásica de eficiencia en su forma semi-fuerte, tal como la formuló Fama (1970), establece que los precios de mercado reflejan en todo momento la totalidad de la información públicamente disponible, de modo que ninguna estrategia basada exclusivamente en datos públicos debería generar retornos anormales sistemáticos de manera sostenida. Los modelos evaluados en este estudio utilizan únicamente información pública—precios, volúmenes, indicadores macroeconómicos, tasas de interés, medidas de volatilidad y variables técnicas extraídas de Bloomberg Terminal—sin emplear información privilegiada ni acceder a datos futuros en la calibración de umbrales. Bajo estas condiciones, cuatro modelos producen *alpha* económicamente significativo durante cinco años fuera de muestra—un resultado que constituye una contradicción empírica directa de la forma semi-fuerte de la hipótesis.

La magnitud de los retornos observados dificulta su explicación mediante compensación por riesgo convencional. El modelo líder genera un retorno acumulado que supera al *benchmark* en aproximadamente 298 puntos porcentuales, y lo hace mientras permanece fuera del mercado más de la mitad del período—es decir, su exposición promedio es sustancialmente inferior a la de una estrategia *Buy & Hold*. Un modelo que participa en el mercado menos de la mitad de los días pero genera aproximadamente cuatro veces el retorno del índice no puede explicarse mediante una simple amplificación de la prima de riesgo por mayor exposición al *beta* del mercado. La fuente del exceso de retorno no es apalancamiento indiscriminado sino capacidad genuina de selección temporal—el modelo identifica cuándo exponerse y cuándo protegerse—, y esta discriminación condicional es precisamente lo que la hipótesis de eficiencia declara imposible a partir de información pública.

La Sección 5 reveló una dimensión adicional que refuerza el argumento. El *alpha* no proviene de predecir la dirección del mercado—los modelos ganadores exhiben *Directional Accuracy* inferior al 50 %—sino de una asimetría condicional, es decir, la capacidad de identificar estados del

mercado donde la relación riesgo-retorno es asimétricamente favorable. Dicho de otro modo, los modelos no aciertan más que una moneda al aire en términos de dirección, pero cuando deciden exponerse, los retornos positivos son sistemáticamente mayores que las pérdidas cuando se equivocan. La HEM en su formulación estándar no contempla esta forma de explotación, porque presupone que toda ventaja informacional se manifiesta como capacidad predictiva direccional. Sin embargo, como documentaron [Kahneman & Tversky \(1979\)](#), los agentes económicos sobrevaloran sistemáticamente la frecuencia de aciertos frente a la magnitud de los resultados—un sesgo cognitivo que genera patrones explotables no en la predicción de precios per se, sino en la estructura condicional de los retornos.

Si la superioridad de un único modelo pudiera descartarse como resultado espurio—una crítica legítima y bien articulada por [López de Prado \(2018\)](#) en su trabajo sobre *backtest overfitting* y el peligro del *data mining* en finanzas cuantitativas—la convergencia de modelos independientes pertenecientes a paradigmas fundamentalmente distintos reduce considerablemente esta posibilidad. Que especificaciones con supuestos funcionales tan diferentes—desde regularización lineal hasta redes neuronales con mecanismos de atención—converjan en la capacidad de generar *alpha* sugiere que la señal predictiva es robusta y no un artefacto de la flexibilidad de una familia particular de estimadores. Este hallazgo es consistente con [Gu et al. \(2020\)](#), quienes demostraron que múltiples familias de modelos convergen sobre las mismas señales predictivas dominantes cuando se aplican a datos financieros de panel. En este contexto, [Dong et al. \(2022\)](#) documentaron más de 100 anomalías en la literatura académica de *asset pricing*; el presente estudio añade evidencia adicional mediante *machine learning* moderno aplicado al índice más líquido y analizado del mundo—precisamente aquel donde la eficiencia debería ser más difícil de refutar.

La explicación más plausible para la existencia de estas señales explotables reside en los sesgos conductuales sistemáticos documentados por [Kahneman & Tversky \(1979\)](#) y en la actividad de *noise traders* modelada por [De Long et al. \(1990\)](#), quienes demostraron teóricamente que agentes irracionales pueden sobrevivir en el mercado e incluso obtener retornos superiores a los de los agentes racionales, generando desviaciones persistentes entre los precios de mercado y los valores fundamentales. Estas desviaciones no son aleatorias sino estructuradas—exhiben patrones temporales y condicionales que los modelos de *machine learning* pueden capturar precisamente porque la maquinaria estadística no está sujeta a los mismos sesgos cognitivos que las generan. La evidencia presentada en este estudio no pretende declarar que los mercados son completamente ineficientes, pero sí documenta que la forma semi-fuerte de la HEM, tal como la formuló [Fama \(1970\)](#), no se sostiene como descripción completa del comportamiento del

S&P 500 durante el período analizado. La eficiencia del mercado es, en todo caso, una cuestión de grado—y los resultados aquí presentados sugieren que el grado es menor de lo que la teoría clásica postula.

9.3 La Paradoja de Grossman-Stiglitz: Del Argumento Teórico a la Verificación Empírica

En la Sección 2, la paradoja de [Grossman & Stiglitz \(1980\)](#) se presentó como un argumento puramente lógico—si los precios reflejan toda la información, nadie tiene incentivos para adquirirla; si nadie la adquiere, los precios no pueden reflejarla—una contradicción interna que los autores resolvieron postulando un “equilibrio de desequilibrio” en el que los mercados se mantienen lo suficientemente ineficientes como para compensar los costos de investigación, pero no tanto como para permitir ganancias triviales. Lo que entonces era una construcción teórica abstracta encuentra ahora, en los resultados de este estudio, una verificación empírica cuantificable. La paradoja deja de ser un argumento sobre lo que *debería* ocurrir y se convierte en una descripción precisa de lo que *efectivamente* ocurre.

El concepto central de [Grossman & Stiglitz \(1980\)](#)—el “costo de adquirir y procesar información”—se formulaba en términos deliberadamente abstractos, sin especificar la naturaleza concreta de ese costo. En el contexto de este estudio, dicha abstracción adquiere una forma tangible y medible, la de una *barrera computacional*. El procesamiento simultáneo de cientos de características—que incluyen estimadores de volatilidad OHLC, indicadores de *momentum* multiescala, estructuras temporales de tasas de interés y medidas de dinámica de mercado—a través de redes neuronales profundas con mecanismos de atención y millones de parámetros entrenables constituye un esfuerzo que la mayoría de los participantes del mercado no puede asumir. No se trata únicamente de una limitación de *hardware* o de tiempo de cómputo, sino de la convergencia de múltiples barreras que se refuerzan mutuamente, a saber, la infraestructura computacional necesaria, la experiencia técnica para diseñar e implementar los modelos, el acceso a datos de calidad institucional y, no menos importante, el conocimiento metodológico para prevenir la filtración de información futura en cada paso del *pipeline*. Desde esta perspectiva, el alfa documentado en las secciones anteriores no constituye una anomalía de mercado ni un defecto en el mecanismo de formación de precios—es la compensación que el mercado otorga a los participantes capaces de superar esta barrera, exactamente como el equilibrio de Grossman-Stiglitz predice.

La estructura de los resultados reproduce con notable fidelidad el equilibrio teórico. El 83 % de las especificaciones evaluadas fracasan en superar al *benchmark* pasivo, lo que constituye evidencia directa de que el mercado es lo suficientemente eficiente como para derrotar a la

mayoría de las estrategias, incluso cuando estas emplean algoritmos sofisticados que abarcan desde *gradient boosting* hasta redes neuronales convolucionales. Pero los modelos ganadores sí lo superan, y lo hacen por márgenes sustanciales. Esta distribución asimétrica—muchos fracasos y pocos pero grandes éxitos—es *exactamente* lo que el equilibrio de Grossman-Stiglitz predice. El mercado mantiene la ineficiencia mínima necesaria para compensar a los participantes capaces de procesarla, pero no la suficiente para que cualquier estrategia la capture. La tasa de fracaso del 83 % no debilita el argumento a favor de la predictibilidad; por el contrario, lo fortalece al demostrar que la eficiencia del mercado es real y formidable—simplemente no es perfecta. El hecho de que los modelos exitosos representen familias metodológicas distintas sugiere además que la ineficiencia residual no es un artefacto capturado por una única estructura funcional, sino una propiedad genuina del proceso generador de datos que múltiples aproximaciones pueden detectar de forma independiente.

Conviene señalar que la eficiencia perfecta no es solo empíricamente falsa—como lo demuestran los modelos que generan alfa—sino que es *lógicamente imposible*, como Grossman & Stiglitz (1980) demostraron hace más de cuatro décadas. Si los precios reflejaran perfectamente toda la información contenida en las variables públicas disponibles, ningún participante tendría incentivos para incurrir en el costo computacional de procesarlas. Pero si nadie las procesa, los precios dejan de incorporar esa información, lo que genera oportunidades de beneficio que a su vez incentivan el procesamiento—un ciclo que solo se estabiliza en el punto donde el beneficio marginal de procesar información adicional iguala su costo marginal. Los resultados de este estudio permiten acotar empíricamente la magnitud de esa “ineficiencia necesaria” que los mercados deben mantener, lo suficientemente grande como para generar un exceso de retorno significativo para el modelo más sofisticado, pero lo suficientemente pequeña como para que la gran mayoría de las especificaciones evaluadas—incluyendo algoritmos tan potentes como XGBoost, GradientBoosting y TFT—no logren capturarla. Dicho de otro modo, el mercado calibra su grado de ineficiencia con una precisión notable, suficiente para que valga la pena investigar, insuficiente para que resulte fácil.

Estas conclusiones requieren, no obstante, una delimitación cuidadosa. Parte del rendimiento superior documentado es atribuible al sesgo alcista del período de prueba, lo que favorece estructuralmente cualquier estrategia con sesgo largo. Los hiperparámetros fueron seleccionados una vez sobre el conjunto de entrenamiento y mantenidos fijos, sin recalibración periódica; en una implementación operacional real, la ausencia de adaptación podría erosionar la ventaja documentada. A su vez, la concentración del análisis en un único mercado limita la generalizabilidad de los hallazgos a otros contextos. Estas salvedades, sin embargo, no invalidan la verificación

empírica del equilibrio de Grossman-Stiglitz; más bien, la enriquecen al subrayar que dicho equilibrio es dinámico y contingente, no estático ni universal. La magnitud precisa de la ineficiencia residual puede variar entre períodos y mercados, pero la lógica subyacente permanece, a saber, los mercados *necesitan* mantener un grado de ineficiencia para funcionar, y la pregunta relevante no es si los mercados son eficientes o ineficientes—una dicotomía falsa que la paradoja de Grossman-Stiglitz resolvió hace décadas—sino cuánta ineficiencia necesitan mantener y qué tipo de esfuerzo se requiere para capturarla.

9.4 La Hipótesis del Mercado Adaptativo y los Fundamentos Teóricos del Estudio

La Sección 2 presentó cinco marcos teóricos que, en conjunto, justificaban la búsqueda de señales predictivas en los retornos del S&P 500 mediante técnicas de aprendizaje automático. Los resultados empíricos acumulados a lo largo de este trabajo permiten ahora evaluar hasta qué punto cada uno de esos fundamentos encuentra confirmación en los datos—no como validación formal de las teorías, que trasciende el alcance de un estudio empírico individual, sino como evidencia de consistencia entre las predicciones teóricas y el comportamiento observado.

La Hipótesis del Mercado Adaptativo, articulada por [Lo \(2019\)](#), propone que la eficiencia no es una propiedad estática del mercado sino una variable dinámica que fluctúa según el entorno competitivo—de forma análoga a un ecosistema biológico donde las especies compiten por recursos finitos. Las estrategias que generan alfa en un período pueden dejar de funcionar cuando suficientes participantes las adoptan, y nuevas oportunidades emergen a medida que las condiciones cambian. Los resultados de este estudio son consistentes con esta dinámica en un sentido preciso, dado que la señal predictiva existe y puede ser capturada por múltiples metodologías, pero su captura requiere una sofisticación computacional que limita el número de participantes capaces de explotarla. El hecho de que las arquitecturas con mecanismos de atención dominen el ranking sugiere que la señal tiene una estructura temporal que los modelos más simples no logran capturar en su totalidad—un hallazgo consistente con un mercado adaptativo donde los patrones “fáciles” han sido arbitrados y solo persisten dependencias no lineales complejas cuya explotación exige herramientas de frontera. A su vez, el éxito de Ridge—un modelo lineal regularizado—indica que una componente de la señal *sí* es accesible mediante métodos más parsimoniosos, lo cual no contradice la HMA sino que confirma su predicción de que las ineficiencias coexisten en múltiples niveles de complejidad.

La Hipótesis del Mercado Fractal de [Peters \(1994\)](#) propone que los mercados exhiben autosimilitud, donde los patrones de precios se repiten a través de diferentes escalas temporales. El *pipeline* de ingeniería de características de este estudio constituye una implementación práctica

de esta idea, al extraer información a múltiples ventanas temporales—5, 21, 63 y 252 días—que capturan dinámicas desde la escala semanal hasta la anual. El éxito de este enfoque multi-temporal proporciona una validación empírica indirecta de la hipótesis fractal, ya que la información contenida en diferentes escalas resulta ser complementaria y no redundante. Los modelos que procesan simultáneamente características de múltiples horizontes superan consistentemente a los modelos univariados de series temporales—que operan en una única escala—por márgenes sustanciales. Si los mercados fueran genuinamente aleatorios en todas las escalas temporales, las características multi-temporales añadirían ruido en lugar de señal, y su inclusión degradaría el rendimiento predictivo en vez de mejorarlo. Que ocurra lo contrario implica la existencia de estructura informativa a través de las escalas, precisamente lo que la hipótesis fractal postula.

Las finanzas conductuales proporcionan una explicación de *por qué* existen los patrones que los modelos explotan. [Kahneman & Tversky \(1979\)](#) documentaron sesgos sistemáticos en la toma de decisiones bajo incertidumbre—en particular, la aversión a la pérdida, por la cual las pérdidas pesan desproporcionadamente más que las ganancias equivalentes—y [De Long et al. \(1990\)](#) formalizaron cómo la participación de agentes irracionales puede causar desviaciones significativas y persistentes respecto a los valores fundamentales. Lo relevante para este estudio es que estos sesgos no son aleatorios sino propiedades recurrentes de la psicología humana, lo que genera patrones explotables que se manifiestan de forma predecible a lo largo del tiempo. [Shefrin & Statman \(1994\)](#) extendieron los modelos tradicionales de valoración incorporando explícitamente factores psicológicos, ofreciendo un marco formal en el cual los precios reflejan no solo información fundamental sino también el sentimiento colectivo de los participantes. La paradoja del *Directional Accuracy* documentada en la Sección 5 es, en sí misma, una manifestación de sesgo conductual, donde el mercado—y los investigadores—sobrevaloran la precisión direccional mientras que el alfa genuino proviene de la asimetría condicional entre ganancias y pérdidas, un fenómeno que la *Prospect Theory* predice con precisión al postular que los agentes ponderan los resultados de forma no lineal.

La teoría de los límites al arbitraje de [Shleifer & Vishny \(1997\)](#) explica, por su parte, por qué las ineficiencias generadas por los sesgos conductuales *persisten* en lugar de ser corregidas instantáneamente por los participantes racionales. Los costos de transacción, el riesgo de posición y las restricciones regulatorias impiden que los arbitrajistas eliminen completamente los errores de valoración. Este estudio opera deliberadamente dentro de dichas restricciones, dado que la estrategia es estrictamente *Long-Only*, emplea instrumentos altamente líquidos (SPY, UPRO) y aplica un modelo de costos que, como se documentó en la Sección 8, sobreestima las fricciones reales de mercado en aproximadamente $2.5\times$ para los *bid-ask spreads*. El hecho de que los modelos

ganadores generen alfa sustancial incluso bajo estos supuestos conservadores sugiere que las ineficiencias son genuinas y no artefactos de una subestimación de costos. Los límites al arbitraje explican, además, por qué estas ineficiencias no han sido eliminadas pese a ser—en principio—detectables, ya que su explotación requiere no solo capacidad computacional de frontera sino también tolerancia al riesgo y capital suficiente para soportar *drawdowns* significativos, una combinación de requisitos que restringe naturalmente el número de participantes capaces de arbitrarlas.

Finalmente, los fundamentos matemáticos discutidos en la Sección 2—la ley del arcoseno (Lévy, 1940; Feller, 1968) y el marco de la martingala (Samuelson, 1965)—encuentran su confirmación práctica en la arquitectura misma de la estrategia. La ley del arcoseno garantiza la existencia de tendencias persistentes como propiedad matemática de cualquier serie temporal, incluyendo las puramente aleatorias; lo que distingue a una estrategia exitosa no es detectar tendencias—que son inevitables—sino identificar cuándo esas tendencias contienen información explotable más allá de lo que la aleatoriedad pura produciría. El marco de la martingala, por su parte, establece que bajo competencia informacional los precios siguen una trayectoria ascendente esperada cuyos movimientos individuales son impredecibles—pero cuyo *posicionamiento relativo* respecto a la tendencia constituye una tarea abordable. Los modelos de este estudio no predicen precios exactos; identifican asimetrías favorables en la relación riesgo-retorno, que es precisamente la tarea que el marco de la martingala valida como legítima. El Triple Screen de Elder (1993), cuya filosofía de alineación multi-temporal inspiró una de las familias de la ingeniería de características, implementa esta lógica al filtrar señales que no están confirmadas en múltiples horizontes—y el éxito del enfoque confirma que la selectividad temporal, saber *cuándo* invertir, importa más que la predicción direccional per se. El modelo líder, al permanecer fuera del mercado la mayor parte del período de prueba y concentrar su exposición en los momentos de mayor convicción, constituye la implementación computacional de esta filosofía.

En conjunto, los cinco pilares teóricos que motivaron este estudio encuentran su correspondencia en los resultados empíricos. La Hipótesis del Mercado Adaptativo explica la coexistencia de señal explotable y dificultad de captura; la Hipótesis del Mercado Fractal justifica y es validada por el enfoque multi-temporal de la ingeniería de características; las finanzas conductuales identifican la fuente psicológica de los patrones que los modelos explotan; los límites al arbitraje explican la persistencia de esos patrones bajo fricciones realistas; y el marco matemático de la martingala y la ley del arcoseno fundamentan la viabilidad teórica de una estrategia basada en posicionamiento relativo más que en predicción puntual. Ninguna de estas teorías, por sí sola, explicaría la totalidad de los hallazgos; pero su convergencia ofrece un marco interpretativo

coherente en el que cada pieza teórica ilumina una dimensión distinta de los resultados—y los resultados, a su vez, proporcionan evidencia empírica que refuerza la pertinencia de cada marco teórico.

9.5 Síntesis: Una Visión Integradora

Los resultados documentados a lo largo de esta sección convergen hacia una conclusión que, si bien no es nueva en la literatura teórica, rara vez se cuantifica con el rigor empírico que este estudio ofrece. La eficiencia de mercado no es una propiedad binaria que se posee o no se posee, sino un continuo dinámico cuyo grado varía en función del horizonte temporal y de la sofisticación de los agentes que participan en el proceso de descubrimiento de precios. La evidencia presentada—cuatro modelos que superan consistentemente al *benchmark* bajo un protocolo estricto de anti-filtración, con *alpha* que persiste tras incorporar costos conservadores de transacción—no describe un mercado ineficiente en el sentido clásico del término, sino un mercado cuyas fricciones residuales exhiben una magnitud económicamente significativa para quien disponga de las herramientas adecuadas para detectarlas.

Es fundamental subrayar que el *alpha* documentado no constituye “dinero fácil” ni contradice la noción fundamental de que los mercados son, en términos generales, notablemente eficientes. La extracción de ese exceso de retorno exige un esfuerzo computacional y metodológico sustancial—arquitecturas de *deep learning* con mecanismos de atención, optimización dinámica de umbrales mediante Meta-KNN y un protocolo de validación diseñado específicamente para eliminar cualquier forma de filtración temporal. Dicho de otro modo, el *alpha* observado es la compensación que el mercado ofrece a quienes invierten recursos significativos en procesar información—precisamente el mecanismo que Grossman & Stiglitz (1980) identificaron como condición necesaria para que los precios sean informativos. Si los mercados fuesen perfectamente eficientes, ningún agente tendría incentivo para analizar información, los precios dejarían de reflejar los fundamentales y la eficiencia misma se destruiría. Lo que este estudio documenta es, en esencia, la magnitud de esa ineficiencia necesaria, el margen mínimo que el mercado debe mantener para que el ecosistema de procesamiento de información continúe funcionando.

En este contexto, la contribución principal de este trabajo no es demostrar que los mercados son “ineficientes” en un sentido absoluto, sino aportar evidencia empírica rigurosa sobre la estructura y dimensión de las ineficiencias residuales que el equilibrio de Grossman-Stiglitz predice como inevitables. Los resultados se posicionan así en un terreno intermedio que ni respalda plenamente la Hipótesis de Eficiencia de Mercado en su formulación clásica ni la refuta de manera categórica, sino que contribuye con datos concretos—retornos, ratios de Sharpe, valida-

ción estadística—a los marcos teóricos contemporáneos que reconocen la naturaleza adaptativa y contingente de la eficiencia, desde la Hipótesis de Mercados Adaptativos de Lo (2019) hasta el equilibrio informacional de Grossman & Stiglitz (1980), ofreciendo una cuantificación del espacio que separa la teoría de la práctica en los mercados financieros del siglo XXI.

10. Conclusión

10.1 Síntesis y Limitaciones

Los hallazgos documentados en la sección anterior—la verificación empírica del equilibrio de Grossman-Stiglitz, la convergencia de familias algorítmicas heterogéneas hacia *alpha* positivo y la reconciliación de la paradoja del *Directional Accuracy* mediante asimetría condicional—configuran una evidencia que, sin pretender resolver el debate sobre eficiencia de mercado, aporta datos concretos a los marcos teóricos contemporáneos que reconocen su naturaleza adaptativa y contingente. Las limitaciones relativas al sesgo alcista del período, la concentración en un único mercado, la ausencia de recalibración y la sobreestimación conservadora de costos fueron discutidas en detalle en la sección precedente; conviene, sin embargo, señalar una restricción adicional que merece atención.

El modelo de costos empleado no incorpora el impacto de mercado que generaría la ejecución de órdenes con capital significativo. Para un portafolio de tamaño modesto, la diferencia entre el precio teórico y el precio efectivo de ejecución es despreciable, pero a medida que el volumen de las órdenes crece, la presión compradora o vendedora deteriora progresivamente los precios obtenidos—un fenómeno particularmente agudo en instrumentos como UPRO, cuya liquidez es considerablemente inferior a la del SPY. Esta limitación de escalabilidad implica que la rentabilidad neta documentada podría reducirse de manera no lineal con el tamaño del capital gestionado, estableciendo un límite práctico a la explotación de las ineficiencias detectadas que es consistente, una vez más, con la lógica del equilibrio de Grossman & Stiglitz (1980).

Estas limitaciones delimitan el alcance de los hallazgos sin invalidar su sustancia, dado que los protocolos de prevención de filtración temporal, la validación estadística rigurosa y la diversidad de los modelos ganadores proporcionan garantías razonables de que la señal documentada es genuina.

10.2 Implicaciones Prácticas

Desde la perspectiva de la inversión cuantitativa, la diversidad de enfoques exitosos—que abarca desde técnicas de regularización lineal hasta arquitecturas de *deep learning* con mecanismos de atención—ofrece a los practicantes la posibilidad de seleccionar modelos en función de

sus restricciones operativas, su tolerancia al riesgo de modelo y su capacidad de infraestructura computacional. Un gestor con recursos limitados puede optar por especificaciones parsimoniosas cuya implementación y mantenimiento exigen menor complejidad, mientras que instituciones con capacidades avanzadas de cómputo pueden explorar arquitecturas neuronales que, según la evidencia presentada, capturan dependencias temporales de mayor orden. La superioridad de los modelos con mecanismos de atención valida la inversión en capacidades de *deep learning* por parte de gestores cuantitativos, dado que estos mecanismos permiten a las redes identificar selectivamente los períodos históricos más informativos para la decisión actual.

La viabilidad de la estrategia tras incorporar costos de transacción conservadores—incluyendo el *volatility drag* inherente a los instrumentos apalancados—demuestra que el *alpha* documentado posee relevancia económica práctica y no es exclusivamente un fenómeno estadístico. Este resultado es particularmente significativo considerando que el modelo de costos fue diseñado deliberadamente para sobreestimar las fricciones reales, lo cual sugiere que una implementación operacional con estimaciones más precisas de los *spreads* podría obtener resultados aún más favorables.

10.3 Direcciones para Investigación Futura

Los resultados de este estudio abren varias líneas de investigación prometedoras. La extensión del análisis a otros índices de renta variable y clases de activos—renta fija, divisas, materias primas—permitiría evaluar si los patrones predictivos documentados son específicos del S&P 500 o reflejan una propiedad más general de los mercados financieros. La incorporación de detección explícita de regímenes de mercado—mediante modelos de cambio de régimen o arquitecturas de mezcla de expertos (*mixture of experts*)—podría mejorar la adaptabilidad de las estrategias a entornos cambiantes, permitiendo que los modelos ajusten dinámicamente sus parámetros de posicionamiento en función del régimen identificado. El desarrollo de formulaciones que optimicen explícitamente el *trade-off* entre señal predictiva y *turnover* constituiría un avance significativo para la implementación práctica, dado que los costos de transacción representan una restricción material sobre la rentabilidad neta que el marco actual aborda de manera ex-post. Finalmente, la integración de fuentes de datos alternativas—sentimiento en redes sociales, imágenes satelitales, datos de transacciones con tarjetas de crédito—podría enriquecer el espacio de características y capturar dimensiones informativas no contenidas en los datos financieros tradicionales, una dirección que Gu et al. (2020) identificaron como particularmente prometedora para la siguiente generación de modelos de *asset pricing*.

10.4 Reflexión Final

Los resultados documentados deben interpretarse con la cautela que impone la naturaleza adaptativa de los mercados financieros. Como advirtió Lo (2019), los mercados son sistemas adaptativos complejos donde las regularidades del pasado pueden desvanecerse cuando suficientes participantes las explotan—y el éxito documentado en este período no garantiza rendimientos futuros equivalentes. El marco metodológico, documentado en detalle en este trabajo y sus apéndices, está diseñado precisamente para facilitar la validación, extensión y eventual refutación de estos hallazgos.

A título personal, el desarrollo de esta investigación ha representado un proceso de aprendizaje que trasciende los resultados numéricos aquí documentados. La construcción del *pipeline* completo—desde la obtención y transformación de datos en Bloomberg Terminal hasta la implementación de arquitecturas de *deep learning* y la simulación de una estrategia de *trading* con costos realistas—ha proporcionado una comprensión integral de las finanzas cuantitativas que complementa de manera sustancial la formación teórica del Magíster de Finanzas. El proceso de depurar meticulosamente cada etapa para prevenir la filtración de información futura, de interpretar resultados que desafían la intuición—como la paradoja del *Directional Accuracy*—y de enfrentar la tensión permanente entre complejidad del modelo y capacidad de generalización, ha forjado una perspectiva crítica sobre las posibilidades y limitaciones del aprendizaje automático aplicado a los mercados financieros. Si este trabajo contribuye, aunque sea modestamente, al debate sobre la eficiencia de mercado y sirve como punto de partida para futuras investigaciones, habrá cumplido su propósito.

Referencias

- Ang, A., Hodrick, R. J., Xing, Y., & Zhang, X. (2006). The Cross-Section of Volatility and Expected Returns. *The Journal of Finance*, 61(1), 259–299.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- De Long, J. B., Shleifer, A., Summers, L. H., & Waldmann, R. J. (1990). Noise Trader Risk in Financial Markets. *Journal of Political Economy*, 98(4), 703–738.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dong, X., Li, Y., Rapach, D., & Zhou, G. (2022). Anomalies and the Expected Market Return. *The Journal of Finance*, 77(1), 639–681.
- Feller, W. (1968). *An Introduction to Probability Theory and Its Applications*, Vol. 1, 3rd ed. New York: John Wiley & Sons.
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.
- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189–1232.
- Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). Learning to Forget: Continual Prediction with LSTM. *Neural Computation*, 12(10), 2451–2471.
- Grossman, S. J., & Stiglitz, J. E. (1980). On the Impossibility of Informationally Efficient Markets. *American Economic Review*, 70(3), 393–408.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The Model Confidence Set. *Econometrica*, 79(2), 453–497.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.

- Hoerl, A. E., & Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Kahneman, D., & Tversky, A. (1979). Prospect Theory: An Analysis of Decision under Risk. *Econometrica*, 47(2), 263–292.
- Lo, A. W. (2019). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press.
- Malkiel, B. G. (1973). *A Random Walk Down Wall Street*. New York: W. W. Norton & Company.
- Mantegna, R. N., & Stanley, H. E. (2000). *An Introduction to Econophysics: Correlations and Complexity in Finance*. Cambridge: Cambridge University Press.
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting. *Proceedings of the 8th International Conference on Learning Representations (ICLR)*.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- Peters, E. E. (1994). *Fractal Market Analysis: Applying Chaos Theory to Investment and Economics*. New York: John Wiley & Sons.
- Samuelson, P. A. (1965). Proof That Properly Anticipated Prices Fluctuate Randomly. *Industrial Management Review*, 6(2), 41–49.
- Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128.
- Benjamini, Y., & Hochberg, Y. (1995). Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- CMT Association. (2020). 1.4 The Opportunity of the Efficient Markets Hypothesis. En *CMT Level I: An Introduction to Technical Analysis*. CMT Association.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- Clark, T. E., & West, K. D. (2007). Approximately Normal Tests for Equal Predictive Accuracy in Nested Models. *Journal of Econometrics*, 138(1), 291–311.

- Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1), 1–26.
- Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, 35(4), 917–926.
- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- Lévy, P. (1940). Sur certains processus stochastiques homogènes. *Compositio Mathematica*, 7, 283–339.
- Lo, A. W. (2002). The Statistics of Sharpe Ratios. *Financial Analysts Journal*, 58(4), 36–52.
- Sharpe, W. F. (1966). Mutual Fund Performance. *The Journal of Business*, 39(1), 119–138.
- Shefrin, H., & Statman, M. (1994). Behavioral Capital Asset Pricing Theory. *Journal of Financial and Quantitative Analysis*, 29(3), 323–349.
- Shleifer, A., & Vishny, R. W. (1997). The Limits of Arbitrage. *The Journal of Finance*, 52(1), 35–55.
- Sortino, F. A., & van der Meer, R. (1991). Downside Risk. *The Journal of Portfolio Management*, 17(4), 27–31.
- Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37–45.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Elder, A. (1993). *Trading for a Living: Psychology, Trading Tactics, Money Management*. John Wiley & Sons.
- Parkinson, M. (1980). The Extreme Value Method for Estimating the Variance of the Rate of Return. *The Journal of Business*, 53(1), 61–65.

- Garman, M. B., & Klass, M. J. (1980). On the Estimation of Security Price Volatilities from Historical Data. *The Journal of Business*, 53(1), 67–78.
- Rogers, L. C. G., & Satchell, S. E. (1991). Estimating Variance from High, Low and Closing Prices. *The Annals of Applied Probability*, 1(4), 504–512.
- Yang, D., & Zhang, Q. (2000). Drift-Independent Volatility Estimation Based on High, Low, Open, and Close Prices. *The Journal of Business*, 73(3), 477–492.
- Vinté, C., Smeureanu, I., Furtună, T.-F., & Ausloos, M. (2019). An Intrinsic Entropy Model for Exchange-Traded Securities. *Entropy*, 21(12), 1173.
- Alizadeh, S., Brandt, M. W., & Diebold, F. X. (2002). Range-Based Estimation of Stochastic Volatility Models. *The Journal of Finance*, 57(3), 1047–1091.
- Chou, R. Y. (2005). Forecasting Financial Volatilities with Extreme Values: The Conditional Autoregressive Range (CARR) Model. *Journal of Money, Credit and Banking*, 37(3), 561–582.
- Fiszeder, P., & Perczak, G. (2016). Low and High Prices Can Improve Volatility Forecasts during the Turmoil Period. *International Journal of Forecasting*, 32(2), 398–410.
- Chen, N.-F., Roll, R., & Ross, S. A. (1986). Economic Forces and the Stock Market. *The Journal of Business*, 59(3), 383–403.
- Harvey, C. R. (1989). Forecasts of Economic Growth from the Bond and Stock Markets. *Financial Analysts Journal*, 45(5), 38–45.
- Fama, E. F., & French, K. R. (1989). Business Conditions and Expected Returns on Stocks and Bonds. *Journal of Financial Economics*, 25(1), 23–49.
- Baker, M., & Wurgler, J. (2006). Investor Sentiment and the Cross-Section of Stock Returns. *The Journal of Finance*, 61(4), 1645–1680.
- Hong, H., & Yogo, M. (2012). What Does Futures Market Interest Tell Us about the Macroeconomy and Asset Prices? *Journal of Financial Economics*, 105(3), 473–490.
- Jegadeesh, N., & Titman, S. (1993). Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. *The Journal of Finance*, 48(1), 65–91.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PLoS ONE*, 13(3), e0194889.

- Kingma, D. P. & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*.
- Barber, B. M., & Odean, T. (2000). Trading Is Hazardous to Your Wealth: The Common Stock Investment Performance of Individual Investors. *The Journal of Finance*, 55(2), 773–806.
- Newey, W. K., & West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, 55(3), 703–708.
- Pesaran, M. H., & Timmermann, A. (2002). Market Timing and Return Prediction under Model Instability. *Journal of Empirical Finance*, 9(5), 495–510.

Apéndices

A. Especificación Completa de Variables

Este apéndice documenta el conjunto completo de 92 variables base empleadas en el análisis. Todos los datos provienen de Bloomberg Terminal.

Las variables se organizan en seis categorías temáticas, más los datos OHLCV del SPY y la tasa libre de riesgo (BIL):

- **Variables de Mercado (M1–M18):** 18 ETFs de renta variable y renta fija
- **Variables Macroeconómicas (E1–E19):** 19 indicadores de actividad económica
- **Variables de Tasas de Interés (I1–I20):** 20 rendimientos y spreads
- **Variables de Commodities (P1–P11):** 11 futuros y ETFs
- **Variables de Volatilidad (V1–V13):** 13 índices VIX y estructura de términos
- **Variables de Sentimiento (S1–S10):** 10 encuestas y ratios

B. Detalles de Ingeniería de Características

Las 536 características se derivan de las 92 variables base mediante:

- Retornos multi-horizonte: $h \in \{1, 5, 21, 63, 126, 252\}$ días
- Indicadores técnicos: RSI, MACD, Bollinger %B, ATR
- Estimadores de volatilidad OHLC: Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang
- Características Triple Screen: Indicadores semanales y diarios
- Estructura de términos de volatilidad: Pendientes y régimen del VIX
- Correlaciones cross-asset: Correlaciones móviles de 21 y 63 días
- Rezagos y estadísticas móviles

C. Hiperparámetros de Modelos

A continuación se detallan los hiperparámetros de cada uno de los 23 modelos evaluados. Para los modelos que emplean *GridSearchCV*, se presenta el *grid* de búsqueda explorado mediante validación cruzada temporal (*TimeSeriesSplit* con 5 *folds*) sobre el conjunto de entrenamiento, junto con los parámetros fijos establecidos en el constructor del modelo. Para los modelos restantes se documentan los parámetros explícitamente configurados en el código.

C.1 Modelos de Regresión Lineal Regularizada (*GridSearchCV*)

Cuadro 29: Ridge — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Grid	alpha	{0.01, 0.1, 1, 10, 100}

Cuadro 30: Lasso — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	max_iter	5,000
Grid	alpha	$\{10^{-7}, 10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}\}$

Cuadro 31: ElasticNet — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	max_iter	50,000
Fijo	tol	10^{-3}
Fijo	selection	'random'
Grid	alpha	$\{10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}\}$
Grid	l1_ratio	{0.3, 0.5, 0.7, 0.9}

C.2 Modelos *Ensemble* (*GridSearchCV*)

Cuadro 32: RandomForest — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	n_jobs	-1 (todos los núcleos)
Grid	n_estimators	{100, 200, 500}
Grid	max_depth	{10, 20, 50, None}

Cuadro 33: GradientBoosting — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Grid	n_estimators	{100, 200, 500}
Grid	learning_rate	{0.01, 0.05, 0.1}
Grid	max_depth	{3, 5, 10, 15}
Grid	subsample	{0.8, 1.0}

C.3 Modelos de *Gradient Boosting* Especializado

Cuadro 34: XGBoost (*GridSearchCV*) — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	n_jobs	-1
Fijo	tree_method	'hist'
<i>Grid</i>	n_estimators	{100, 200}
<i>Grid</i>	learning_rate	{0.01, 0.05}
<i>Grid</i>	max_depth	{3, 5}

Cuadro 35: LightGBM (*GridSearchCV*) — parámetros fijos y *grid* de búsqueda

Tipo	Parámetro	Valor
Fijo	random_state	42
Fijo	n_jobs	-1
Fijo	verbosity	-1
<i>Grid</i>	n_estimators	{100, 200, 500}
<i>Grid</i>	learning_rate	{0.01, 0.05, 0.1}
<i>Grid</i>	num_leaves	{31, 63, 127}

Cuadro 36: CatBoost — parámetros explícitos (sin *GridSearchCV*)

Parámetro	Valor
iterations	200
learning_rate	0.05
depth	6
random_state	42
verbose	0

C.4 Modelos de Series Temporales (Darts Clásicos)

Cuadro 37: Hiperparámetros de modelos de series temporales clásicos

Modelo	Parámetro	Valor
AutoARIMA	—	Parámetros por defecto de Darts (selección automática de p , d , q)
ExponentialSmoothing	seasonal_periods (resto)	None Parámetros por defecto de Darts
Theta	—	Parámetros por defecto de Darts (los valores negativos del <i>target</i> se desplazan hacia valores positivos antes del ajuste)
Prophet	—	Parámetros por defecto de Darts
SeasonalNaive	K	5 (rezago semanal en días hábiles) Modelo sin parámetros entrenables — replica el valor observado K períodos atrás

C.5 GARCH (*arch library*)

Cuadro 38: Hiperparámetros de GARCH

Parámetro	Valor
vol	'Garch'
p	1 (rezagos del término GARCH)
q	1 (rezagos del término ARCH)
mean	'AR' (modelo de media autoregresivo)
lags	1 (rezagos del componente AR)

Los retornos se escalan a porcentaje ($\times 100$) antes del ajuste para estabilidad numérica. Las predicciones de prueba se generan mediante predicción *one-step-ahead* re-estimando el modelo con una ventana móvil de hasta 500 observaciones.

C.6 Modelos de *Deep Learning* (Darts)

Todos los modelos de *deep learning* de Darts comparten la configuración base descrita en la Tabla 39. Los parámetros de arquitectura no listados explícitamente conservan sus valores por defecto según la implementación de Darts 0.41.

Cuadro 39: Configuración común de modelos Darts *Deep Learning*

Parámetro	Valor
input_chunk_length	30
output_chunk_length	21
n_epochs	100 (máximo)
batch_size	32
random_state	42
force_reset	True
<i>Early stopping</i>	PLEarlyStopping(monitor='train_loss', patience=5, mode='min')
gradient_clip_val	1.0

Cuadro 40: Parámetros específicos de cada modelo Darts *Deep Learning*

Modelo	Parámetro específico	Valor
DLinear	—	Solo parámetros comunes (Tabla 39)
N-BEATS	—	Solo parámetros comunes (arquitectura por defecto de Darts)
N-HiTS	—	Solo parámetros comunes (arquitectura por defecto de Darts)
TCN	—	Solo parámetros comunes (arquitectura por defecto de Darts)
TFT	add_relative_index	True

C.7 Modelos *Custom* PyTorch

Los cuatro modelos *custom* de PyTorch comparten la configuración de entrenamiento descrita en la Tabla 41. A continuación se detallan los parámetros de arquitectura específicos de cada modelo.

Cuadro 41: Configuración común de entrenamiento PyTorch *custom*

Parámetro	Valor
sequence_length (<i>lookback</i>)	30
n_epochs	100 (máximo)
batch_size	32
optimizador	Adam
learning_rate	0.0005
weight_decay	10^{-5}
<i>scheduler</i>	ReduceLROnPlateau(patience=5, factor=0.5)
<i>early stopping</i>	patience=10 (sobre pérdida de entrenamiento)
gradient_clip_norm	1.0
función de pérdida	MSELoss
escalado del <i>target</i>	StandardScaler (ajustado solo en <i>train</i>)

Cuadro 42: CNN-LSTM — arquitectura

Componente	Parámetro	Valor
Conv1d (capa 1)	n_filters	128
	kernel_size	3 (padding=1)
Conv1d (capa 2)	n_filters	256 (128×2)
	kernel_size	3 (padding=1)
MaxPool1d	kernel_size	2
Dropout (CNN)	p	0.2
LSTM	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	False
Capa densa	Linear	hidden_dim $\rightarrow$ 1

Cuadro 43: LSTM+Attention (Luong) — arquitectura

Componente	Parámetro	Valor
LSTM	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	True
Atención	tipo	<i>dot-product</i> (Luong)
	dimensión	hidden_dim $\times 2 = 256$
Dropout (salida)	p	0.2
Capa densa	Linear	hidden_dim $\times 2 \rightarrow 1$

Cuadro 44: BiLSTM — arquitectura

Componente	Parámetro	Valor
LSTM	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	True
Dropout (salida)	p	0.1
Capa densa	Linear	hidden_dim $\times$ 2 $\rightarrow$ 1

Cuadro 45: BiGRU — arquitectura

Componente	Parámetro	Valor
GRU	hidden_dim	128
	num_layers	2
	dropout	0.1
	bidirectional	True
Dropout (salida)	p	0.1
Capa densa	Linear	hidden_dim $\times$ 2 $\rightarrow$ 1

C.8 Configuración de Entrenamiento Común

Cuadro 46: Configuración general de entrenamiento

Parámetro	Valor
Período de entrenamiento	Enero 2000 – Septiembre 2020
Período de prueba	Octubre 2020 – Diciembre 2025
División temporal	80/20 sin <i>shuffle</i> , estrictamente cronológica
Validación cruzada	TimeSeriesSplit, 5 <i>folds</i> (modelos con <i>GridSearchCV</i>)
Imputación	SimpleImputer(strategy='median')
Normalización	StandardScaler, ajustado solo en <i>train</i>
<i>Early stopping</i> (Darts DL)	PLEarlyStopping, patience=5
<i>Early stopping</i> (PyTorch <i>custom</i>)	patience=10
Dispositivo de entrenamiento	GPU NVIDIA T4 16 GB (modelos DL, vía CUDA) / CPU (modelos clásicos)
Semilla	42 (NumPy, PyTorch, sklearn)

D. Parámetros Óptimos de Umbral

Los umbrales de posicionamiento (q_{extreme} , q_{moderate}) se determinan dinámicamente para cada modelo y cada día del período de prueba mediante un meta-modelo *K-Nearest Neighbors* (KNN) entrenado exclusivamente con datos del período de entrenamiento. A continuación se detallan los parámetros del procedimiento y las configuraciones resultantes.

D.1 Metodología de Optimización: Meta-KNN

D.1.1 Espacio de Búsqueda

Se evalúan las 26 combinaciones válidas de $(q_{\text{extreme}}, q_{\text{moderate}})$:

- $q_{\text{extreme}} \in \{5, 10, 15, 20, 25, 30\}$ (percentil superior para posición UPRO 3x)
- $q_{\text{moderate}} \in \{20, 30, 40, 50, 60\}$ (percentil superior para posición SPY 1x)
- Restricción: $q_{\text{moderate}} > q_{\text{extreme}}$ (UPRO requiere mayor convicción que SPY)

D.1.2 Función Objetivo

Para cada ventana de evaluación en el meta-dataset de entrenamiento, se calcula el *Sharpe ratio* penalizado:

$$\text{score}(q_{\text{ext}}, q_{\text{mod}}) = \begin{cases} \text{Sharpe}(R_{\text{net}}) - 0,5 & \text{si MaxDD} > 20 \% \\ \text{Sharpe}(R_{\text{net}}) & \text{en caso contrario} \end{cases} \quad (24)$$

La penalización de 0,5 desincentiva combinaciones que generan *drawdowns* excesivos.

D.1.3 Meta-Features

Siete características describen el régimen predictivo de cada ventana de 63 días:

1. $\bar{y}_w$: Media de las predicciones (nivel de optimismo)
2. $\sigma_{\hat{y},w}$: Desviación estándar (variabilidad de señal)
3. $\gamma_{\hat{y},w}$: Asimetría (*skewness* de la distribución)
4. $\rho_{\hat{y},w}$: Autocorrelación de primer orden (persistencia)
5. $\beta_{\hat{y},w}$: Pendiente de tendencia lineal (dirección)
6. $\bar{\sigma}_{m,w}$: Volatilidad promedio del mercado (régimen de vol)
7. $R_{m,w}$: Retorno acumulado del mercado (contexto reciente)

D.1.4 Parámetros del KNN

- $K = 5$ vecinos, ponderados por distancia inversa
- Estandarización de features mediante *StandardScaler*

- Ventanas deslizantes de 63 días con paso de 21 días
- Horizonte de evaluación: 63 días siguientes a cada ventana
- Aproximadamente 242 muestras de entrenamiento por modelo

D.1.5 Filtro de Calidad de Señal

Además del Meta-KNN, se aplica un filtro basado en la desviación estándar *rolling* de las predicciones: si $\sigma_{\text{rolling},63} < \tau = 0,001$, la estrategia se posiciona en efectivo independientemente de los umbrales predichos por el KNN. Este filtro protege contra predicciones cuasi-constantes que generan percentiles aleatorios.

D.2 Tabla de Parámetros Dinámicos

La Tabla 47 presenta los parámetros dinámicos más frecuentes para cada modelo.

Cuadro 47: Parámetros Óptimos de Umbral por Modelo

Modelo	Categoría	q_{3x} (%)	q_{1x} (%)	Interpretación
LSTM+Attention	RNN	5	50	Top 5 % $\rightarrow$ 3x, Top 50 % $\rightarrow$ 1x
Ridge	ML	20	30	Top 20 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
RandomForest	ML	5	40	Top 5 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
CNN-LSTM	RNN	20	40	Top 20 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
DLinear	DeepLearning	5	60	Top 5 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
GradientBoosting	ML	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
CatBoost	GradientBoosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
Theta	TimeSeries	15	60	Top 15 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
SeasonalNaive	TimeSeries	5	60	Top 5 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
NBEATS	DeepLearning	10	20	Top 10 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
Lasso	ML	5	40	Top 5 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x
GARCH	Specialized	5	30	Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
LightGBM	GradientBoosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
NHiTS	DeepLearning	5	60	Top 5 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
AutoARIMA	TimeSeries	10	30	Top 10 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
TCN	DeepLearning	5	30	Top 5 % $\rightarrow$ 3x, Top 30 % $\rightarrow$ 1x
TFT	DeepLearning	20	60	Top 20 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
XGBoost	GradientBoosting	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
ElasticNet	ML	10	60	Top 10 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
Prophet	Specialized	15	60	Top 15 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
BiLSTM	RNN	5	20	Top 5 % $\rightarrow$ 3x, Top 20 % $\rightarrow$ 1x
ExponentialSmoothing	TimeSeries	30	60	Top 30 % $\rightarrow$ 3x, Top 60 % $\rightarrow$ 1x
BiGRU	RNN	30	40	Top 30 % $\rightarrow$ 3x, Top 40 % $\rightarrow$ 1x

Nota: q_{3x} = percentil para posición UPRO (3x). q_{1x} = percentil para posición SPY (1x). Predicciones por debajo del percentil q_{1x} resultan en posición Cash (0). Parámetros predichos dinámicamente mediante Meta-KNN (K=5, ponderado por distancia inversa) entrenado exclusivamente sobre datos históricos. Se muestra la moda de los umbrales predichos para cada modelo.

D.3 Análisis de Parámetros

D.3.1 Diversidad de Umbrales por Modelo

La naturaleza dinámica del Meta-KNN implica que cada modelo utiliza múltiples combinaciones de umbrales a lo largo del período de prueba. Se distinguen tres patrones:

1. **Modelos altamente dinámicos** (>15 combinaciones): LSTM+Attention (22), Ridge (21), CNN-LSTM (18). El KNN adapta activamente los umbrales a las condiciones cambiantes. Predominan las arquitecturas de *deep learning* y modelos lineales con predicciones ricas.
2. **Modelos moderadamente dinámicos** (5–15 combinaciones): CatBoost (10), Theta (9), SeasonalNaive (7), LightGBM (7), GARCH (7). El KNN encuentra un rango limitado de configuraciones útiles.
3. **Modelos estáticos o filtrados** (<5 combinaciones o mayoritariamente en Cash): RandomForest (4), XGBoost (4), NBEATS (2), NHiTS (1), GradientBoosting (1), AutoARIMA (0, 100 % filtrado). Predicciones insuficientemente variables o patrón dominante claro.

D.3.2 Implicaciones

- **Alta diversidad + buen rendimiento:** El modelo captura distintos regímenes de mercado y el KNN adapta los umbrales adecuadamente (LSTM+Attention con 22 combinaciones y +400 %).
- **Baja diversidad + buen rendimiento:** Una configuración robusta funciona consistentemente (RandomForest con 4 combinaciones y +131 %).
- **Filtrado mayoritario:** Predicciones cuasi-constantes impiden la generación de señales— el filtro de calidad protege correctamente (AutoARIMA permanece 100 % en Cash).

D.4 Interpretación de los Umbrales Dinámicos

D.4.1 Significado de los Percentiles

Para LSTM+Attention, cuya combinación más frecuente es ($q_{\text{extreme}}=5$, $q_{\text{moderate}}=50$):

- **Predicción en top 5 %:** Posición UPRO (3x *leverage*)
- **Predicción en top 5–50 %:** Posición SPY (1x)
- **Predicción debajo del top 50 %:** Cash (tasa libre de riesgo)

Sin embargo, estos umbrales varían dinámicamente. En períodos de alta volatilidad, el KNN puede seleccionar (5, 20)—reservando SPY solo para el top 20 %—mientras que en períodos estables puede ampliar a (20, 60), adoptando mayor exposición. El modelo utilizó 22 combinaciones distintas a lo largo del período de prueba, lo que indica una adaptación activa a las condiciones de mercado.

D.4.2 Percentiles vs Valores Absolutos

El uso de percentiles *rolling* en lugar de umbrales fijos tiene ventajas:

1. **Adaptabilidad:** Se ajusta automáticamente a cambios en la distribución de predicciones.
2. **Robustez:** Menos sensible a *drift* en el modelo.
3. **Normalización:** Permite comparar la convicción de modelos con escalas muy distintas.

Combinados con los umbrales dinámicos del Meta-KNN, los percentiles *rolling* proporcionan un sistema de posicionamiento doblemente adaptativo: adaptativo a la escala del modelo (vía percentiles) y adaptativo a las condiciones de mercado (vía KNN).