

DEFENSA DE TESIS • MAGÍSTER EN FINANZAS

Explorando los límites de la eficiencia del mercado

Enfoques clásicos y contemporáneos de modelado cuantitativo para la predicción direccional y generación de alfa en el S&P 500

David González Cañón

Facultad de Economía y Negocios • Universidad de Chile

Profesor guía • David Díaz Solís

Agosto de 2026

MOTIVACIÓN

El debate sobre la eficiencia del mercado sigue abierto y tiene consecuencias prácticas

- La HEM semifuerte (Fama, 1970) sostiene que los precios reflejan toda la información pública.
- La implicación es que ninguna estrategia con datos públicos debería generar alfa sistemático.
- Si es cierta, la gestión activa destruye valor; indexarse sería lo óptimo.
- Anomalías documentadas, más datos y aprendizaje automático reavivan la pregunta.
- En juego hay una industria de hedge funds que cerró 2024 con **\$4.5 billones bajo gestión**, una parte sustancial en estrategias cuantitativas ([HFR, 2024](#)).

PREGUNTA DE INVESTIGACIÓN

¿Puede el aprendizaje automático generar alfa neto de costos en el S&P 500?

La hipótesis es que modelos computacionales suficientemente sofisticados capturan patrones direccionales explotables, generando rentabilidad positiva después de costos de transacción.

HITO 1 • PREDICCIÓN

23 modelos generan predicciones diarias del retorno en exceso del índice.

HITO 2 • IMPLEMENTACIÓN

Las predicciones se traducen en posiciones Cash / SPY / UPRO 3x, netas de costos.

Grossman-Stiglitz y los mercados adaptativos predicen ineficiencias residuales costosas de explotar

Paradoja de Grossman-Stiglitz (1980)

Precios perfectamente informativos son lógicamente imposibles, dado que el mercado mantiene la ineficiencia mínima que compensa el costo de procesar información.

Mercados Adaptativos (Lo, 2019)

La eficiencia es dinámica, las ineficiencias emergen, son explotadas y se disipan en un ciclo continuo, como en un ecosistema.

Martingala y ley del arcoseno

No se predice el nivel del precio sino que se identifica la posición relativa frente a la tendencia (Samuelson, 1965; Lévy, 1940; Feller, 1968).

La implicación verificable es que, si existe alfa, debe ser **escaso y costoso de extraer**, condición que este estudio somete a prueba.

OBJETIVOS DEL ESTUDIO

Separar la predicción de la implementación para aislar la fuente del alfa

01 Marco de dos hitos

¿El alfa proviene del modelo predictivo o de las reglas de posicionamiento? El diseño lo desacopla.

02 Comparación sistemática

23 modelos, las mismas 536 características, el mismo protocolo de evaluación y costos.


03 Evidencia sobre la HEM semifuerte

Prueba fuera de muestra 2020–2025, solo con información pública y costos conservadores.

04 Indicador DA@3x

Precisión condicional en las posiciones apalancadas, que mide el acierto donde la exposición es máxima.

Construcción del conjunto de datos y partición temporal



ETAPA 4

4

Entrenamiento de 23 modelos

>_ train_models.py

2 / 3

536 características · conjunto de entrenamiento

→

se ajustan en 4 familias

ML clásico4

Ridge

Lasso

ElasticNet

RandomForest

Gradient boosting4

GradientBoosting

XGBoost

LightGBM

CatBoost

Series temporales6

AutoARIMA

ExponentialSmoothing

Theta

Prophet

SeasonalNaive · benchmark

GARCH

Deep learning9

DLinear · N-BEATS

N-HiTS · TCN · TFT

CNN-LSTM

LSTM+Attention

BiLSTM · BiGRU

23 predicciones continuas del retorno en exceso · una por modelo, por día

Estrategia Long-Only, backtest y resultados

5

Conversión a posiciones y backtest

>_ optimize_and_backtest.py

a Cada predicción → percentil rolling de 63 días

↓

b

★ META-KNN · UMBRALES DINÁMICOS

Meta-KNN (K=5, ponderado) elige los dos umbrales de compra cada día, aplicando los que mejor funcionaron en los cinco episodios del entrenamiento más parecidos al comportamiento reciente.

↓

c Filtro de señal, si σ rolling < 0.001 → CASH

↓

d

Mapeo a posiciones Long-Only, cuanto más fuerte la señal, mayor exposición al mercado

0

Percentil de la predicción del día frente a los últimos 63 días

100

CASH
percentil < 70
señal débil · fuera del mercado

SPY
percentil ≥ 70
señal alta · invertido 1×

UPRO
percentil ≥ 90
señal muy alta · apalancado 3×

▲ umbral moderado

▲ umbral extremo

Umbrales ilustrativos, el Meta-KNN los reajusta cada día para cada modelo.

↓

e

Backtest neto de tres costos de transacción

Administración de los ETFs (*expense ratio*) · 0.91% anual UPRO, 0.09% SPY
Spread de compraventa en cada cambio de posición · 5 bps UPRO, 2 bps SPY
Desgaste del apalancamiento 3x en días volátiles (*volatility drag*)

Retorno neto = rf + posición × (retorno mercado - rf) - costos

6

Resultados y validación

4 de 23 superan al SPY Buy & Hold (+101.3%)

LSTM+Attention
+395%
Sharpe 1.32

Ridge
+253%
Sharpe 0.86

RandomForest
+128%
Sharpe 0.65

CNN-LSTM
+122%
Sharpe 0.57

SeasonalNaive · benchmark de complejidad mínima +43% · Sharpe 0.14

SPY Buy & Hold · referencia pasiva +101% · Sharpe 0.66

VALIDACIÓN ESTADÍSTICA DE LA ROBUSTEZ

Bootstrap del Sharpe

Diebold-Mariano


Clark-West

Model Confidence Set

Bonferroni · FDR

RESULTADOS

Trayectorias del capital durante el período de prueba



\$49,538
LSTM+Attention

\$20,131
SPY Buy & Hold

Capital inicial de \$10,000, curvas netas de costos · oct 2020 – dic 2025. LSTM+Attention se sitúa sobre el índice el 99.8% de las jornadas y Ridge el 89.5%; la brecha entre ambos se abre en abril de 2025. En las caídas la estrategia tiende a refugiarse en efectivo, y los avances abruptos corresponden a rebotes capturados con exposición 3x.


Figura 2, p. 25; Tabla 4, p. 23

Solo LSTM+Attention sobrevive a los tests al 5%; ninguno a las correcciones múltiples

MODELO	P(S>o)	P(S>SPY)	DIEBOLD-MARIANO	CLARK-WEST	BONFERRONI
LSTM+Attention	99.6%	83.1%	p = 0.011 ✓	p = 0.029 ✓	×
Ridge	94.9%	60.4%	p = 0.101 ×	p = 0.112 ×	×
RandomForest	93.3%	49.9%	p = 0.358 ×	p = 0.631 ×	×
CNN-LSTM	89.3%	44.4%	p = 0.372 ×	p = 0.261 ×	×

- Bootstrap del Sharpe con B = 5,000 remuestreos; P(S>o) y P(S>SPY) son la proporción de remuestreos que cumple cada condición. Solo LSTM+Attention mantiene un intervalo íntegramente positivo [0.375, 2.424].
- Bajo Bonferroni el α ajustado = 0.0022 < p mínimo observado (0.011) → ningún modelo sobrevive; Benjamini-Hochberg tampoco.
- El MCS no elimina ninguna de las 24 estrategias (23 modelos y el SPY), con σ diaria $\approx$ 1.1% frente a diferencias medias $\approx$ 0.05%.

Los resultados se mantienen con un modelo de costos conservador, incluso duplicado




- El modelo asume spreads de 5 bps en UPRO y 2 bps en SPY, unas 2.5 veces los observados en el mercado (2 y ≈0 bps); los costos se sobreestiman a propósito.
- Los costos tendrían que multiplicarse por **3.9×** en LSTM+Att (3.2× Ridge, 6.3× RandomForest, 2.6× CNN-LSTM) antes de que cada estrategia dejara de ser rentable.
- LSTM+Attention acumula \$13,459 en costos sobre los \$10,000 iniciales; el +395% reportado ya descuenta esa fricción.
- **SeasonalNaive** opera 1,042 veces (LSTM+Att, 465) y los costos consumen el 66% de su P&L bruto, frente al 25% de LSTM+Att; su break-even es de solo 1.5×

Tablas 44–46, p. 65; Figura 6, p. 66. Retorno total (%) por escenario de costos, aproximación lineal de la Tabla 46.

RESULTADOS

El alfa no parece provenir de una mayor exposición al riesgo



SPY Buy & Hold = 100% / 100% por definición; con exposición 3x la captura puede superar el 100%. El benchmark ingenuo captura más caída que alza.


Tablas 8–9, pp. 29–30; Tablas 37–38, pp. 62–63

MODELO	SORTINO	CALMAR	MAX DD	VAR 90D
LSTM+Att.	2.61	1.77	−20.5%	−3.77%
Ridge	1.25	0.87	−31.8%	−14.33%
RandomForest	1.34	1.15	−15.0%	−0.67%
CNN-LSTM	1.10	0.47	−35.9%	−16.29%
SeasonalNaive	0.20	0.21	−33.6%	−15.24%
SPY (B&H)	0.94	0.57	−25.4%	−10.80%

VaR al 95% sobre ventanas móviles de 90 días. El efectivo por defecto operaría como un stop-loss implícito.

RESULTADOS

La paradoja del Directional Accuracy, los modelos que más aciertan no son los más rentables



$\rho = -0.37$

Correlación entre DA y retorno total calculada sobre los 23 modelos; el gráfico destaca siete. Ilustrativa por el tamaño muestral.


El DA pondera igual todos los días e ignora la magnitud del movimiento y el tamaño de la posición.

RESULTADOS

DA@3x muestra que los ganadores aciertan donde importa, en sus posiciones apalancadas

DA@3x = tasa de acierto en los días con posición UPRO (Ec. 7, p. 27)

■ DA general ■ DA@3x



Precisión sin selectividad no genera retorno; SeasonalNaive acierta más días que los ganadores, pero su acierto apalancado apenas mejora y Theta casi no se expone.

Tabla 7, p. 27 · línea punteada en 50%

LIMITACIONES

Seis limitaciones delimitan el alcance de los hallazgos

- Período de prueba con sesgo alcista; la estrategia Long-Only no enfrentó un bajista prolongado.
- Un único mercado e instrumento (S&P 500 vía SPY/UPRO); la generalización no está establecida.
- Sin recalibración periódica de hiperparámetros durante los cinco años de prueba.
- Bajo Bonferroni y FDR ningún modelo es significativo; el MCS no discrimina entre las 24 estrategias (23 modelos y el SPY).
- Market impact no modelado; la liquidez de [UPRO](#) ($\approx \$800\text{M}/\text{día}$) limita la escala a capitales moderados.
- Impuestos no modelados; los patrones pueden disiparse al ser explotados (Lo, 2019).

CONCLUSIONES

La evidencia es compatible con mercados adaptativos, no con la eficiencia estricta

- Cuatro de veintitrés modelos parecen generar alfa neto de costos; solo **LSTM+Attention** con significancia individual al 5%.
- La rentabilidad nace de la selectividad temporal (concentrar el apalancamiento donde se acierta), no de acertar más.
- En lectura Grossman-Stiglitz, el alfa compensa el costo computacional de explotar ineficiencias residuales.
- Quedan como líneas futuras otros mercados y clases de activos, detección de regímenes, optimización señal-turnover, datos alternativos.

Gracias.

Referencias

Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.

Feller, W. (1968). *An Introduction to Probability Theory and Its Applications*, Vol. 1, 3rd ed. New York: John Wiley & Sons.

Grossman, S. J., & Stiglitz, J. E. (1980). On the Impossibility of Informationally Efficient Markets. *American Economic Review*, 70(3), 393–408.

HFR (2024). Hedge fund industry reaches \$4.5 trillion in 2024. Hedge Fund Research, vía [Investing.com](https://www.investing.com).

Lévy, P. (1940). Sur certains processus stochastiques homogènes. *Compositio Mathematica*, 7, 283–339.

Lo, A. W. (2019). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press.

Samuelson, P. A. (1965). Proof That Properly Anticipated Prices Fluctuate Randomly. *Industrial Management Review*, 6(2), 41–49.

Bibliografía completa en el documento, pp. 38–42.

Rendimiento de los 23 modelos en el período de prueba

#	MODELO	RET.	SHARPE	MAXDD	#	MODELO	RET.	SHARPE	MAXDD
1	LSTM+Attention	395.4%	1.319	20.5%	13	LightGBM	25.5%	0.088	24.4%
2	Ridge	252.5%	0.856	31.8%	14	N-HiTS	21.4%	0.031	48.3%
3	RandomForest	127.5%	0.651	15.0%	15	AutoARIMA‡	18.3%	0.387	0.0%
4	CNN-LSTM	122.2%	0.572	35.9%	16	TCN	18.0%	0.000	35.0%
5	DLinear	67.7%	0.425	33.4%	17	TFT	13.5%	-0.028	45.2%
6	GradientBoosting	66.3%	0.617	8.3%	18	Prophet	7.8%	-0.230	11.7%
7	CatBoost	46.0%	0.221	31.4%	19	ElasticNet	7.8%	-0.085	40.4%
8	Theta	44.4%	0.560	12.6%	20	XGBoost	7.1%	-0.060	45.7%
9	N-BEATS	43.9%	0.178	25.2%	21	BiLSTM	4.9%	-0.091	55.1%
10	SeasonalNaive†	43.0%	0.142	33.6%	22	ExponentialSmoothing	-15.4%	-0.241	60.3%
11	Lasso	37.7%	0.190	19.5%	23	BiGRU	-33.2%	-0.467	59.0%
12	GARCH	26.6%	0.188	22.1%	—	SPY (B&H)	101.3%	0.657	25.4%

Tabla 3, p. 22. † Benchmark de complejidad mínima. ‡ 100% en efectivo por filtro de calidad de señal.

Configuración del Meta-KNN y perfil operativo de los modelos ganadores

MODELO	(Q_EXT, Q_MOD)*	PARES DE UMBRALES	%UPRO / %SPY / %CASH	TRADES	PROFIT FACTOR
LSTM+Attention	(5, 50)	22	12.2 / 32.7 / 55.1	465	1.52
Ridge	(20, 30)	21	20.8 / 17.0 / 62.3	409	1.35
RandomForest	(5, 40)	4	5.2 / 16.9 / 77.9	175	1.49
CNN-LSTM	(20, 40)	18	12.1 / 28.6 / 59.3	633	1.29

- Meta-KNN · cada día busca los 5 episodios de entrenamiento más parecidos al comportamiento reciente del modelo y adopta los umbrales que resultaron óptimos en ellos, entre 26 combinaciones admisibles y ~242 episodios por modelo; la selección premia el Sharpe y penaliza caídas superiores al 20%.
- Entorno · AWS EC2 g4dn.xlarge (NVIDIA T4) · Python 3.12 · PyTorch 2.6 · Darts 0.41 · scikit-learn 1.7.2 · semilla 42 · dependencias fijadas en requirements.txt.

Tablas 2, 34–35, pp. 21 y 61; Apéndices C–D, pp. 50–60. *Combinación más frecuente; los umbrales varían por día. Profit factor = ganancia bruta sobre pérdida bruta.

Composición de las 536 características por familia de transformación

FAMILIA	CARACT.	FAMILIA	CARACT.
Indicadores técnicos (TA-Lib)	19	Curva de rendimiento y crédito	13
Momentum y retornos históricos	30	Dispersión sectorial	5
Volumen	2	Indicadores macroeconómicos	21
Multitemporal	24	Régimen de mercado e interacciones	7
Volatilidad OHLC clásica†	8	Variables rezagadas (lags)	54
Volatilidad contemporánea	54	Estadísticos móviles (rolling)	24
Microestructura	19	Análisis técnico avanzado‡	60
Correlaciones cross-asset	10	Transformaciones y extensiones	176
VIX y estructura temporal	10	Total	536

Tabla 1, p. 17; Apéndice B, pp. 45–49. † Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang. ‡ Ichimoku, Fibonacci, Donchian, Keltner, flujo de dinero, confluencia estratégica.

La estrategia día a día, cinco jornadas con Ridge y umbrales dinámicos

DÍA	PREDICCIÓN $\hat{Y}$	PERCENTIL	(Q_EXT, Q_MOD)	UMBRALES UPRO / SPY	POSICIÓN
t	-0.005	45	(20, 30)	≥ 80 / ≥ 70	Cash
t+1	+0.002	74	(20, 30)	≥ 80 / ≥ 70	SPY (+1)
t+2	+0.004	91	(20, 30)	≥ 80 / ≥ 70	UPRO (+3)
t+3	+0.003	84	(10, 40)	≥ 90 / ≥ 60	SPY (+1)
t+4	-0.000	53	(10, 40)	≥ 90 / ≥ 60	Cash

El percentil **84** de t+3 habría activado UPRO bajo los umbrales de t+2; el Meta-KNN, al detectar un cambio en las condiciones de mercado, elevó el requisito a percentil ≥ 90 y asignó solo SPY. El sistema adapta la escala (percentil rolling) y la agresividad (umbrales dinámicos) sin usar información futura.