

GUION DE DEFENSA · MAGÍSTER EN FINANZAS

Explorando los límites de la eficiencia del mercado

Guion de presentación con narrativa, tiempos sugeridos y transiciones para las 21 diapositivas, más preguntas probables de la comisión con sus respuestas respaldadas en datos.

David González Cañón · Facultad de Economía y Negocios · Universidad de Chile

Agosto de 2026 · Duración sugerida del cuerpo principal, 25 a 28 minutos (diapositivas 1 a 16; la 17 y los anexos quedan para preguntas)

1 Portada

~30 segundos

Idea clave. Presentarse y encuadrar el tema en una frase, sin promesas.

Buenos días. Mi nombre es David González y hoy presento mi tesis de Magíster en Finanzas, que explora los límites de la eficiencia del mercado. La pregunta de fondo es sencilla de enunciar y difícil de responder, si los precios ya reflejan la información pública, ¿queda algo por capturar para un inversionista sistemático? Para abordarla combiné enfoques clásicos y contemporáneos de modelado cuantitativo sobre el S&P 500.

TRANSICIÓN → "Para entender por qué esta pregunta sigue viva, conviene partir por el debate que la origina."

2 Motivación · El debate sigue abierto

~1,5 minutos

Idea clave. La HEM es una teoría con implicancias prácticas enormes y evidencia mixta.

La Hipótesis de Eficiencia de Mercado, en su forma semifuerte formulada por Fama en 1970, sostiene que los precios incorporan toda la información pública. Si eso es cierto, ninguna estrategia construida con datos públicos debería generar alfa de manera sistemática, y lo racional sería indexarse. Pero el debate no está cerrado, hay anomalías documentadas, cada vez más datos disponibles y técnicas de aprendizaje automático que reabren la pregunta. Y no es una discusión puramente académica, la industria de hedge funds cerró 2024 con 4.5 billones de dólares bajo gestión, una parte sustancial en estrategias cuantitativas.

TRANSICIÓN → "De ese debate general se desprende la pregunta concreta de esta tesis."

3 Pregunta de investigación

~1,5 minutos

Idea clave. Una pregunta medible y una hipótesis falsable, separadas en dos hitos.

La pregunta es, ¿puede el aprendizaje automático generar alfa neto de costos en el S&P 500? La hipótesis de trabajo es que modelos suficientemente sofisticados capturan patrones explotables incluso después de descontar costos de transacción. Para responderla separé el problema en dos hitos. El primero es la predicción, veintitrés modelos generan cada día una

predicción del retorno en exceso del índice. El segundo es la implementación, esas predicciones se traducen en posiciones concretas, efectivo, SPY o UPRO apalancado tres veces, netas de costos. Esta separación permite saber después de dónde proviene el resultado.

TRANSICIÓN → "Antes del método, el marco teórico que hace verificable todo esto."

4 Marco teórico

~2 minutos

Idea clave. La teoría moderna no predice eficiencia perfecta sino ineficiencias residuales costosas de explotar.

Tres marcos sostienen el estudio. Primero, la paradoja de Grossman y Stiglitz de 1980, precios perfectamente informativos son lógicamente imposibles, porque si nadie puede ganar procesando información, nadie paga el costo de procesarla y los precios dejan de ser informativos; el mercado mantiene entonces la ineficiencia mínima que compensa ese costo. Segundo, los mercados adaptativos de Andrew Lo, la eficiencia no es estática, las ineficiencias emergen, se explotan y se disipan como en un ecosistema. Tercero, la representación martingala de Samuelson y la ley del arco seno de Lévy y Feller, que justifican no predecir el nivel del precio sino la posición relativa frente a la tendencia. La implicación verificable es que, si existe alfa, debe ser escaso y costoso de extraer. Eso es exactamente lo que se somete a prueba.

TRANSICIÓN → "Con ese marco, la contribución del trabajo se ordena en cuatro puntos."

5 Objetivos del estudio

~1,5 minutos

Idea clave. Diseño de dos hitos, comparación homogénea, evidencia fuera de muestra y una métrica nueva.

Cuatro objetivos ordenan el estudio. Uno, el marco de dos hitos que desacopla el modelo predictivo de las reglas de posicionamiento, para poder atribuir el resultado. Dos, una comparación sistemática, los veintitrés modelos usan las mismas quinientas treinta y seis características, el mismo protocolo de evaluación y los mismos costos, nada se ajusta a la medida de ningún modelo. Tres, evidencia sobre la HEM semifuerte con una prueba fuera de muestra de dos mil veinte a dos mil veinticinco, solo con información pública y costos deliberadamente conservadores. Y cuatro, el indicador DA@3x, que mide el acierto justo donde la exposición es máxima, sobre el que volveré hacia el final.

TRANSICIÓN → "Veamos ahora el pipeline completo en tres pasos."

6 Pipeline 1 · Datos y partición

~2 minutos

Idea clave. 92 variables → 536 características → partición temporal estricta. Sin filtración.

El punto de partida son noventa y dos variables diarias de Bloomberg, índices, macro, tasas y curva, commodities, volatilidad, sentimiento y la tasa libre de riesgo, con seis mil quinientas siete observaciones entre enero de dos mil y diciembre de dos mil veinticinco. La ingeniería de características las transforma en quinientas treinta y seis, indicadores técnicos, momentum, análisis multitemporal, estimadores de volatilidad OHLC, rezagos y estadísticos móviles. El punto crítico es la prevención de filtración temporal, todas las características usan solo ventanas hacia atrás, y el único desplazamiento hacia adelante del sistema es la variable objetivo, el retorno en exceso del día siguiente. La partición es cronológica y sin aleatorización, ochenta por ciento para entrenamiento hasta septiembre de dos mil veinte y mil trescientos dos días de prueba desde octubre de dos mil veinte.

TRANSICIÓN → "Sobre ese conjunto se entrenan los veintitrés modelos."

7 Pipeline 2 · Entrenamiento de 23 modelos

~1,5 minutos

Idea clave. Cuatro familias, un benchmark ingenuo interno, una predicción por modelo por día.

Los veintitrés modelos cubren cuatro familias, cuatro de aprendizaje automático clásico como Ridge y RandomForest, cuatro de gradient boosting, seis de series temporales y nueve de deep learning, incluida la arquitectura LSTM con mecanismo de atención. Dentro de las series temporales está SeasonalNaive, marcado en dorado, que actúa como benchmark de complejidad mínima, repite el valor de hace cinco días y no aprende ningún parámetro; cualquier modelo que aspire a justificar su complejidad debería al menos superarlo. La salida de esta etapa son veintitrés predicciones continuas del retorno en exceso, una por modelo, por día.

TRANSICIÓN → "Las predicciones por sí solas no son una estrategia; falta convertirlas en posiciones."

8 Pipeline 3 · Estrategia, backtest y resultados

~2,5 minutos

Idea clave. Percentil → umbrales del Meta-KNN → posición. Costos conservadores. 4 de 23 superan al índice.

Cada predicción se convierte primero en un percentil contra los últimos sesenta y tres días del propio modelo, eso normaliza las escalas. Luego un metamodelo KNN elige cada día los dos umbrales de compra, buscando los cinco episodios históricos de entrenamiento más parecidos al comportamiento reciente y aplicando los umbrales que mejor funcionaron en ellos. La regla es simple, cuanto más fuerte la señal, mayor exposición, percentil bajo el umbral moderado, efectivo; sobre el moderado, SPY sin apalancar; sobre el extremo, UPRO tres veces apalancado. El backtest descuenta tres costos, la administración de los ETFs, el spread de cada cambio de posición y el desgaste del apalancamiento en días volátiles. El resultado central, cuatro de veintitrés modelos terminan por encima del SPY Buy and Hold, que hizo más de ciento uno por ciento; LSTM con atención llega a más de trescientos noventa y cinco por ciento con Sharpe uno coma treinta y dos. Abajo están las dos referencias, el benchmark ingenuo con más cuarenta y tres y el índice pasivo.

Nota. Si preguntan por los umbrales 70 y 90 del esquema, son ilustrativos; el Meta-KNN los reajusta cada día y el par mostrado ocurre realmente en los datos.

TRANSICIÓN → "Ese es el resultado agregado; veamos cómo se construyó en el tiempo."

9 Trayectorias del capital

~2 minutos

Idea clave. El orden final se define tarde; en las caídas la estrategia se refugia en efectivo.

Partiendo de diez mil dólares en octubre de dos mil veinte, LSTM con atención termina en cerca de cuarenta y nueve mil quinientos y el SPY en veinte mil ciento treinta. La lectura honesta de esta figura tiene dos partes. Primero, LSTM se mantiene por encima del índice el noventa y nueve coma ocho por ciento de las jornadas y Ridge el ochenta y nueve coma cinco. Segundo, la brecha entre LSTM y Ridge recién se abre con el rebote de abril de dos mil veinticinco, durante buena parte del período van prácticamente empatados. Un detalle importante para leer las curvas, en las caídas la estrategia tiende a refugiarse en efectivo, por eso sus curvas se aplanan en vez de replicar los descensos, y los avances abruptos corresponden a rebotes capturados con exposición apalancada.

Nota. Si preguntan cómo puede subir un modelo mientras el índice cae, la respuesta verificada es que a nivel diario nunca ocurre, un modelo long-only en un día negativo del mercado gana a lo sumo la tasa libre de riesgo; lo que se ve son mesetas en efectivo más rebotes con exposición 3x dentro de la misma ventana.

TRANSICIÓN → "Hasta aquí las buenas noticias; la validación estadística introduce los matices."

10 Validación estadística

~2 minutos

Idea clave. No todos los números son buenas noticias, y decirlo fortalece la tesis.

Quiero ser transparente con esta parte, no todos los números acompañan. Solo LSTM con atención sobrevive a los tests individuales al cinco por ciento, Diebold-Mariano con p cero coma cero once y Clark-West con p cero coma cero veintinueve, y es el único cuyo intervalo bootstrap del Sharpe queda íntegramente en terreno positivo. Los otros tres ganadores no alcanzan significancia individual. Y cuando se corrige por comparaciones múltiples, con Bonferroni el alfa ajustado queda en cero coma cero cero veintidós, por debajo del mejor p observado, de modo que ningún modelo sobrevive; el Model Confidence Set tampoco discrimina entre las veinticuatro estrategias, los veintitrés modelos más el SPY, porque la desviación diaria del índice, cerca del uno coma uno por ciento, es enorme frente a las diferencias medias entre estrategias. La lectura que propongo es prudente, hay una señal interesante en el modelo líder, pero la evidencia no permite descartar del todo el azar.

TRANSICIÓN → "Segunda prueba de estrés, los costos."

11 Costos de transacción

~1,5 minutos

Idea clave. Modelo de costos sobreestimado a propósito; los resultados se sostienen incluso duplicándolo.

El modelo de costos se construyó para jugar en contra, asume spreads de cinco puntos base en UPRO y dos en SPY, unas dos veces y media los observados en el mercado. Aun así, con los costos duplicados los cuatro modelos siguen en terreno positivo, LSTM pasa de trescientos noventa y cinco a doscientos sesenta y uno por ciento. Para dimensionarlo, los costos tendrían que multiplicarse por tres coma nueve en LSTM, y por seis coma tres en RandomForest, antes de que cada estrategia dejara de ser rentable. En dólares, LSTM acumula trece mil cuatrocientos cincuenta y nueve en costos sobre los diez mil iniciales, y el retorno reportado ya descuenta esa fricción.

TRANSICIÓN → "Tercera pregunta de robustez, ¿el retorno es solo compensación por más riesgo?"

12 Gestión de riesgo

~1,5 minutos

Idea clave. Los retornos no se explican por asumir más riesgo; asimetría de capturas y colas más cortas.

Las métricas sugieren que el alfa no proviene de una mayor exposición al riesgo. Las barras muestran la asimetría de capturas, LSTM participa del noventa por ciento de las alzas pero solo del sesenta y siete por ciento de las caídas, un ratio de uno coma treinta y cuatro; los cuatro modelos capturan más subida que bajada. En la tabla, LSTM registra Sortino dos coma sesenta y uno y Calmar uno coma setenta y siete frente a cero coma noventa y cuatro y cero coma cincuenta y siete del índice, con drawdown máximo de veinte y medio por ciento contra veinticinco coma cuatro. Y el VaR a noventa días, menos tres coma setenta y siete por ciento frente a menos diez coma ochenta del SPY. El mecanismo detrás es el efectivo por defecto, que opera como un stop-loss implícito.

TRANSICIÓN → "Estos perfiles llevan a una pregunta incómoda, ¿los que más aciertan son los que más ganan?"

13 La paradoja del Directional Accuracy

~2 minutos

Idea clave. Acertar más días no se asocia con ganar más; la correlación es negativa.

Aquí aparece uno de los hallazgos más llamativos del estudio. Si ordenamos los veintitrés modelos por su tasa de acierto direccional y por su retorno, la correlación es negativa, menos cero coma treinta y siete, ilustrativa por el tamaño muestral pero consistente. Los modelos que más aciertan, como Theta o el propio benchmark ingenuo con tasas sobre el cincuenta y dos por ciento, quedan lejos de los mejores retornos, y los cuatro ganadores aciertan menos del cuarenta y ocho por ciento de los días. La explicación es que el DA pondera igual todos los días, ignora la magnitud del movimiento y el tamaño de la posición, y en estrategias con apalancamiento selectivo eso importa más que la frecuencia.

TRANSICIÓN → "Si el DA no explica la rentabilidad, ¿qué la explica? Eso motiva el DA@3x."

14 DA@3x

~1,5 minutos

Idea clave. Los ganadores aciertan donde importa, en sus días apalancados.

El DA@3x mide la tasa de acierto condicionada a los días en que el modelo tomó la posición apalancada. El contraste es claro, LSTM acierta el cuarenta y siete por ciento de los días en general, pero el sesenta y dos coma tres por ciento de los días en que se jugó el

apalancamiento, que son el doce por ciento del tiempo. Los cuatro ganadores muestran ese salto. Y el contraste con el benchmark es instructivo, SeasonalNaive acierta el cincuenta y dos coma tres por ciento de los días, más que cualquier ganador, pero su acierto apalancado apenas sube a cincuenta y cinco coma uno y termina en más cuarenta y tres por ciento; precisión sin selectividad no genera retorno. La rentabilidad observada se asocia con concentrar los aciertos en los momentos de alta asimetría, no con acertar más veces.

TRANSICIÓN → "Todo lo anterior vale dentro de límites que conviene dejar explícitos."

15 Limitaciones

~1,5 minutos

Idea clave. Seis limitaciones enunciadas sin defensividad; delimitan, no anulan.

Seis limitaciones delimitan el alcance. El período de prueba tiene sesgo alcista y la estrategia long-only no enfrentó un mercado bajista prolongado. Es un único mercado y un único par de instrumentos, la generalización no está establecida. No hubo recalibración periódica de hiperparámetros durante los cinco años. Bajo correcciones múltiples ningún modelo es significativo, como ya mostré. El impacto de mercado no está modelado y la liquidez de UPRO limita la escala a capitales moderados. Y los impuestos tampoco están modelados, además de que, siguiendo a Lo, los patrones pueden disiparse al ser explotados.

TRANSICIÓN → "Con esos límites a la vista, las conclusiones."

16 Conclusiones

~1,5 minutos + cierre

Idea clave. Evidencia compatible con mercados adaptativos; lectura Grossman-Stiglitz del alfa.

Cuatro conclusiones. Cuatro de veintitrés modelos parecen generar alfa neto de costos, y solo LSTM con atención con significancia individual al cinco por ciento. La rentabilidad nace de la selectividad temporal, de concentrar el apalancamiento donde se acierta, no de acertar más. En lectura Grossman-Stiglitz, ese alfa puede interpretarse como la compensación por el costo computacional de explotar ineficiencias residuales. Y quedan líneas futuras, otros mercados y clases de activos, detección de regímenes, optimización señal-rotación y datos alternativos. En conjunto, la evidencia es compatible con mercados adaptativos más que con la eficiencia estricta. Muchas gracias.

TRANSICIÓN → Cierre. La diapositiva 17 (Referencias) y los anexos A a D quedan disponibles para la ronda de preguntas.

17 Referencias • 18–21 Anexos A–D

No se presentan; material de consulta

Idea clave. Saber qué hay en cada anexo para saltar rápido durante las preguntas.

Anexo A, la tabla completa de rendimiento de los veintitrés modelos. Anexo B, la configuración del Meta-KNN y el perfil operativo de los ganadores, umbrales más frecuentes, distribución de posiciones, operaciones y profit factor. Anexo C, la composición de las quinientas treinta y seis características por familia. Anexo D, un ejemplo día a día de cinco jornadas con Ridge que muestra los umbrales dinámicos en acción, útil si piden intuición del Meta-KNN.

Preguntas probables de la comisión

1. ¿Cómo sé que no hay filtración de información futura?

Tres niveles verificados, partición cronológica estricta con hiperparámetros elegidos por validación cruzada temporal dentro del entrenamiento; preprocesamiento ajustado solo en entrenamiento; y características exclusivamente retrospectivas, el único desplazamiento hacia adelante es la variable objetivo. Además el Meta-KNN se entrena únicamente con episodios del período de entrenamiento. La aritmética del backtest se verificó de forma independiente, cada retorno diario cumple la identidad retorno igual a tasa libre más posición por exceso de mercado menos costos.

2. En el gráfico de capital, ¿cómo puede subir un modelo mientras el SPY cae?

A nivel diario no ocurre nunca, en un día negativo del mercado un modelo long-only gana a lo sumo la tasa libre de riesgo, y eso se verificó día por día en los mil trescientos un retornos. Lo que se ve en ventanas de semanas es otra cosa, la estrategia pasó en efectivo los días malos, su curva quedó plana, y capturó con exposición apalancada los días de rebote dentro de la misma ventana. En el cuarto trimestre de dos mil veintitrés, por ejemplo, el SPY hizo más once por ciento y LSTM más diez coma seis, no le ganó al índice en ese tramo.

3. ¿Por qué reportar resultados si no sobreviven a Bonferroni?

Porque el objetivo del estudio es caracterizar la evidencia, no proclamar un descubrimiento. Se reporta el resultado completo, significancia individual del líder en dos tests que miden dimensiones distintas, y pérdida de significancia bajo correcciones múltiples, que es lo esperable al comparar veintitrés estrategias con mil trescientas observaciones y volatilidad diaria del uno por ciento. Esa transparencia es consistente con la advertencia de López de Prado sobre la evaluación de múltiples estrategias.

4. ¿Los retornos no son simplemente compensación por apalancamiento?

La comparación relevante está en la diapositiva de benchmarks del paper, mantener UPRO pasivamente habría rendido cerca de más ciento veintitrés por ciento con un drawdown de sesenta y nueve por ciento y Sharpe cero coma veintiséis. LSTM registra mayor retorno con un drawdown de veinte y medio y Sharpe uno coma treinta y dos, y está apalancado solo el doce por ciento del tiempo. El perfil es cualitativamente distinto al de la retención pasiva del ETF apalancado.

5. ¿Esto escala? ¿Podría gestionarse capital real así?

Con cautela. El modelo no incorpora impacto de mercado, y la liquidez de UPRO limita la escala a capitales moderados; la rentabilidad neta podría reducirse de forma no lineal con el

tamaño gestionado. Es una de las seis limitaciones explícitas, y es coherente con la lógica de Grossman-Stiglitz, las ineficiencias que persisten son las difíciles de escalar.

6. ¿Por qué SeasonalNaive como benchmark interno?

Porque no aprende ningún parámetro, repite el valor de hace cinco días. Cualquier modelo complejo debería superarlo para justificar su costo. De hecho trece de los veintitrés modelos quedan por debajo del ingenuo en retorno, un recordatorio de que la complejidad no garantiza nada, y de que el listón relevante, el índice pasivo con más ciento uno por ciento, es aún más exigente.

Guion generado a partir de la presentación de 21 diapositivas (Defensa_Tesis_FEN_presentacion.html). Cifras verificadas contra los artefactos del pipeline (final_long_only_backtest.json, risk_metrics_detail.json, statistical_validation.json, backtest_detail.pkl) y las tablas del paper compilado.